

Tarea1_EduardRuiz

April 28, 2026

Tarea 1 Data Analysis & Machine Learning
Eduardo Mathias Ruiz Quezada
2022443162
edruiz2022@udec.cl

PREGUNTA 1

R: Inicialmente se leyó la base de datos con la ayuda de pandas, para luego verificar los datos faltantes con el comando `isnull` y la ayuda de la extensión data Wrangler, descubriendo que en todas las variables, menos `id`, faltaban datos, para `drug_use` un 73% y para el resto en promedio un 11.4%. Para la limpieza de datos en primer lugar se eliminó la columna `drug_use`, debido a su crítica falta de datos, luego se eliminaron todas las filas faltantes de `exam_score`, nuestra futura variable dependiente, debido a que no podemos imputar esos datos. Una vez eliminado todo, se dio paso a la estandarización de las variables `academic_level`, `part_time_job` y `exercise_minutes`, debido a que presentaban problemas de formatos. Para las variables restantes se realizó la imputación de datos, debido a que eliminar las filas con datos faltantes conllevaría una importante pérdida de información, se consideraron 3 formas de imputar la data, usando la media para variables que siguieran una distribución cercana a la normal, la moda para variables categóricas y la mediana para variables con distribuciones más asimétricas (REVISAR). Una vez limpio el dataframe, se creó la variable binaria de interés “`rindio_examen`”, separando los valores de la columna “`exam_score`” según lo indicado en el enunciado, las observaciones con un 1.0 se consideran como que no rindieron el examen, quedando con un valor de 0 en la nueva columna “`rindio_examen`” y un 1 para los que tenían una nota superior a 1.0. Finalmente, se transformaron las variables categóricas como “`academic_level`” o “`part_time_job`” en dummies para facilitar su uso en los posteriores análisis.

PREGUNTA 2

R: Para estimar el Modelo de Probabilidad Lineal (MCO) con el objetivo de explicar la probabilidad de que un alumno rinda el examen, inicialmente se definió “`rindio_examen`” como variable dependiente y se seleccionó un modelo ampliado que incluía las variables: “`study_hours`”, “`burnout_level`”, “`mental_health_score`”, “`caffeine_intake_mg`”, “`part_time_job_Yes`”, “`sleep_hours`”, “`social_media_hours`”, “`gaming_hours`”, “`focus_index`” y “`upcoming_deadline`”, al considerar que poseían un potencial explicativo teórico sobre la variable de interés. Se iteró sucesivamente el modelo para descartar aquellas variables que no resultaban estadísticamente significativas ($p\text{-value} > 0.05$).

El modelo final mantuvo una capacidad predictiva intacta ($R^2 = 0.234$) en comparación al modelo saturado, pero logrando reducir los criterios de información (AIC/BIC) y eliminando problemas de multicolinealidad. La decisión de rendir el examen quedó determinada por 4 variables:

1. Horas de estudio(`study_hours`): El tiempo real de dedicación. Cada hora adicional de estudio aumenta la probabilidad de presentarse al examen en 3.03 puntos porcentuales.
2. Índice de concentración(`focus_index`): La calidad del estudio demuestra tener un impacto

positivo, aumentando la probabilidad en 0.63 puntos porcentuales por cada punto adicional.

3. Salud mental(mental_health_score): El bienestar psicológico indica que por cada unidad de mejora en este aspecto, se evidencia un incremento de 1.69 puntos porcentuales en la probabilidad de presentarse.

4. Agotamiento(burnout_level): La única variable con un impacto negativo, disminuyendo en 0.43 puntos porcentuales la probabilidad de asistencia por cada punto adicional en el nivel de estrés crónico.

Esto deja en evidencia que la decisión de asistir a una evaluación es el resultado directo de mantener un equilibrio interno, balanceando el esfuerzo académico puro (horas de estudio y foco) y la resiliencia psicológica (salud mental frente al burnout). A pesar de la solidez de estos hallazgos, se reconoce la limitación teórica intrínseca del Modelo de Probabilidad Lineal (MCO), el cual podría generar predicciones fuera del rango lógico de $[0,1]$, motivando la exploración con modelos de elección discreta.

PREGUNTA 3

R: Se ejecutó un modelo Probit con el mismo objetivo de la pregunta 2, seleccionando las mismas 4 variables independientes que conformaron el modelo final depurado: “study_hours”, “focus_index”, “mental_health_score” y “burnout_level”.

La salida entregó que las 4 variables siguen siendo fuertemente significativas (esta vez alcanzando un $p\text{-value} < 0.01$) y se mantuvo intacta la dirección de sus efectos: impactos positivos para las horas de estudio, la concentración y la salud mental, y un efecto negativo o penalizador para el nivel de agotamiento (“burnout_level”).

Al interpretar el significado y ajuste de este modelo, destacan dos hallazgos fundamentales: 1. El modelo da un salto sustancial en su precisión, alcanzando un Pseudo R^2 de 0.507, lo que indica que logra explicar más del 50% de la varianza en la decisión del alumno de rendir el examen. 2. La estimación arrojó un fenómeno de “quasi-separación completa”, lo que matemáticamente señala que las variables seleccionadas son tan determinantes que el modelo logra predecir con un 100% de exactitud el comportamiento del 29% de la muestra evaluada.

PREGUNTA 4

R: Se ejecutó un modelo Logit con el mismo objetivo de la pregunta 2, seleccionando las mismas 4 variables independientes que conformaron el modelo final depurado: “study_hours”, “focus_index”, “mental_health_score” y “burnout_level”.

La salida entregó que las 4 variables siguen siendo fuertemente significativas (alcanzando un $p\text{-value} < 0.01$) y se mantuvo intacta la dirección de sus efectos: impactos positivos para las horas de estudio, la concentración y la salud mental, y un efecto negativo o penalizador para el nivel de agotamiento (“burnout_level”).

Al interpretar el significado y ajuste de este modelo logístico, destacan dos hallazgos fundamentales: 1. El modelo mantiene su alta precisión, alcanzando un Pseudo R^2 de 0.5089, confirmando que logra explicar casi el 51% de la varianza en la decisión del alumno de rendir la evaluación. 2. La estimación volvió a arrojar un fenómeno de “quasi-separación completa”, lo que indica que el núcleo de variables es tan determinante que el modelo logra predecir con un 100% de exactitud el comportamiento del 11% de la muestra evaluada.

Finalmente, es imperativo señalar que, a diferencia del MCO y del Probit, los coeficientes del modelo Logit asumen una distribución logística y miden el impacto sobre el “Log-Odds” (el logaritmo natural de la razón de probabilidades de rendir el examen frente a no rendirlo). Dado que esta métrica no es intuitivamente interpretable como una probabilidad directa, se hace indispensable

proceder al cálculo de los Efectos Marginales.

PREGUNTA 5

R: Al comparar las estimaciones del MCO (Pregunta 2), Probit (Pregunta 3) y Logit (Pregunta 4), se concluye lo siguiente respecto al análisis de los datos: 1. Diferencias entre los resultados y su justificación: Si bien los tres modelos coinciden exactamente en qué variables importan y si su impacto es positivo o negativo, la magnitud de sus coeficientes difiere bastante. Esto no es un error, sino una diferencia matemática. El modelo MCO asume una relación lineal, por lo que sus coeficientes son cambios directos en la probabilidad. En cambio, Probit y Logit utilizan curvas en forma de “S” y sus coeficientes miden cambios en índices distintos (puntajes Z y Log-Odds). La prueba de que los tres modelos capturan el mismo fenómeno es que, al calcular los “Efectos Marginales” de Probit y Logit para traducirlos a probabilidades reales, los números de los tres modelos convergen casi a la perfección. 2. Modelo más adecuado: Para responder qué determina la probabilidad de rendir el examen, los modelos de elección discreta (Logit o Probit) son categóricamente superiores al MCO. Al ser una decisión de “sí o no” (variable binaria), el modelo lineal falla estructuralmente porque puede llegar a predecir probabilidades imposibles. Logit y Probit corrigen esta falla respetando siempre el límite de 0 a 1. Además, al aplicar estos modelos no lineales, la capacidad predictiva dio un salto gigante, teniendo un $\text{PseudoR}^2 > 0.5$, es decir, logrando explicar más del 50% de la decisión del alumno, frente al 23% que explicaba el MCO. 3. Variables robustas a la especificación: Tras las pruebas, cuatro variables demostraron ser absoluta y transversalmente robustas, manteniendo una significancia máxima ($p\text{-value} < 0.01$) en las tres especificaciones:

Robustas de impacto positivo: Las horas de estudio (“study_hours”), la calidad del enfoque (“focus_index”) y el bienestar emocional (“mental_health_score”). Aumentarlas siempre incrementa la probabilidad de asistencia.

Robusta de impacto negativo: El nivel de agotamiento (“burnout_level”). En los tres modelos, operó como el gran desincentivo para presentarse a la evaluación.

PREGUNTA 6

R: Para explicar la nota obtenida por los alumnos que efectivamente asistieron a la evaluación, se utilizó un modelo de regresión Poisson, debido a que este modelo es el adecuado para analizar variables que representan conteos o puntajes enteros.

Para su correcta ejecución, se realizaron dos ajustes previos: 1. Se excluyó a los alumnos que no rindieron el examen (“rindio_examen” = 0), ya que el objetivo es analizar el desempeño cognitivo real y no la inasistencia. 2. Dado que el modelo requiere matemáticamente números enteros, se procedió a redondear la nota original (“exam_score”) al entero más cercano.

En una primera instancia, se ajustó un modelo ampliado que incluía un espectro completo de posibles determinantes: “study_hours”, “focus_index”, “burnout_level”, “mental_health_score”, “sleep_hours”, “screen_time_hours”, “social_media_hours”, “gaming_hours”, “caffeine_intake_mg” y “part_time_job_Yes”.

Luego de varias iteraciones, se descartaron sistemáticamente aquellas variables que no resultaron estadísticamente significativas ($p\text{-value} > 0.05$). Esto demostró que factores como el sueño, el uso de pantallas, las redes sociales, los videojuegos o el consumo de cafeína no tienen un impacto comprobable en la nota. El modelo definitivo quedó purificado e integrado exclusivamente por 5 variables, cuyos coeficientes se interpretan como cambios porcentuales aproximados en la calificación: 1. Horas de estudio (“study_hours”): Cada hora adicional de estudio incrementa la nota esperada en un 10.67%. Es el factor con mayor peso explicativo. 2. Salud mental (“mental_health_score”): Por cada punto de mejora en el bienestar psicológico, la calificación sube un 6.99%. 3. Índice de foco (“focus_index”): La calidad del estudio aporta un 2.15% extra a la nota por cada punto de con-



centración pura. 4. Trabajo de medio tiempo (“part_time_job_Yes”): A diferencia de la decisión de asistir al examen, al medir el desempeño real la falta de tiempo sí penaliza, reduciendo la calificación en un 1.68%. 5. Nivel de agotamiento (“burnout_level”): Cada unidad de estrés crónico y desgaste resta un 1.51% a la nota final. En conclusión, el modelo demuestra que el rendimiento académico exitoso no se basa en restringir actividades de ocio (como jugar o usar redes sociales), sino, principalmente en la capacidad de aplicar un esfuerzo enfocado y mantener la estabilidad emocional y de tiempo del estudiante.

PREGUNTA 7

R: Para determinar la pertinencia del modelo Poisson estimado en la pregunta anterior, es necesario comprobar si la variable dependiente cumple con el supuesto fundamental de equidispersión, donde la varianza debe ser igual a su media. Para evaluar esto en la distribución de las notas, se aplicó una prueba estadística formal.

Una evaluación inicial de las estadísticas descriptivas reveló un indicio claro y contundente de sobredispersión. La media aritmética de las notas del examen es de 20.59, mientras que su varianza alcanza un valor de 127.25. Dado que la varianza supera con creces a la media (siendo más de 6 veces mayor), se evidencia una violación flagrante del supuesto básico de Poisson en los datos crudos.

Para confirmar esta sobredispersión a nivel condicional (es decir, una vez aplicadas las variables explicativas), se utilizó el Test de Cameron & Trivedi. Este procedimiento matemático extrae los valores predichos () del modelo Poisson depurado y estima una regresión auxiliar por Mínimos Cuadrados Ordinarios (MCO) sin intercepto, buscando explicar la dispersión observada en los errores.

El coeficiente resultante de esta regresión auxiliar representa directamente la medida exacta de la sobredispersión, conocida como el parámetro Alpha (). La estimación arrojó un valor óptimo de $\alpha = 0.0563$, el cual resultó ser estadísticamente hiper-significativo ($p\text{-value} = 0.000$, estadístico $t = 37.17$).

En conclusión, al ser el valor-p estrictamente menor a 0.05, se rechaza la hipótesis nula de equidispersión ($\alpha = 0$). Esto confirma empíricamente la existencia de sobredispersión en los datos, es decir, las calificaciones de los alumnos tienen una variabilidad natural mucho mayor a la que el modelo Poisson es capaz de procesar. En consecuencia, se concluye que el modelo Poisson original presenta una falla estructural que subestima los errores estándar, lo que obliga metodológicamente a realizar la transición hacia una regresión Binomial Negativa calibrada con este valor de dispersión óptimo de $\alpha = 0.0563$.

PREGUNTA 8

R: Usando la información obtenida en la prueba de sobredispersión, se procedió a estimar un modelo de regresión Binomial Negativa para explicar la nota final de los alumnos.

Al ajustar el modelo, el algoritmo confirmó un parámetro de dispersión altamente significativo ($\alpha = 0.0500$, $p\text{-value} = 0.000$), validando la superioridad técnica de esta especificación.

Se incluyeron las variables sobrevivientes del modelo Poisson previo. Sin embargo, al aplicar la corrección de varianza de la Binomial Negativa, se descubrió que el impacto del trabajo de medio tiempo (“part_time_job_Yes”) era un espejismo estadístico: sus errores estándar se ajustaron a la realidad, elevando su $p\text{-value}$ a 0.075. Al superar el nivel de significancia estricto del 5% ($p < 0.05$), esta variable dejó de ser estadísticamente significativa y fue descartada del modelo.

El desempeño académico de los estudiantes queda explicado de forma robusta exclusivamente por cuatro determinantes: 1. Horas de estudio (“study_hours”): Es el pilar del rendimiento, *Ceteris paribus*, cada hora extra dedicada al estudio incrementa la nota final en aproximadamente un 11.56%. 2. Salud mental (“mental_health_score”): El segundo factor más relevante, un aumento

de un punto en el bienestar emocional eleva la calificación esperada en un 7.29%. 3. Índice de foco (“focus_index”): La calidad del estudio ratifica su importancia, aportando un 2.36% extra a la nota por cada punto adicional de concentración pura. 4. Agotamiento (“burnout_level”): Es la única variable que penaliza el rendimiento. Cada incremento en el nivel de estrés crónico o desgaste mental reduce la calificación proyectada en un 1.64%.

Se concluye que el modelo demuestra que el éxito académico en la evaluación depende estrictamente del equilibrio interno del estudiante. La nota obtenida se define maximizando el tiempo de estudio de alta concentración y preservando la salud mental, comprobando que las obligaciones externas (como tener una jornada laboral part-time) no tienen una influencia estadísticamente real en el resultado final.

PREGUNTA 9

R: Al analizar en conjunto las estimaciones del modelo Poisson (Pregunta 6), la prueba empírica (Pregunta 7) y el modelo Binomial Negativa (Pregunta 8), se concluye lo siguiente respecto a los determinantes del desempeño académico: 1. Diferencias entre resultados y su justificación: La diferencia fundamental entre Poisson y Binomial Negativa no radica en la magnitud de los coeficientes (los cuales se mantuvieron casi idénticos), sino en el cálculo de los errores estándar y los valores-p. En el modelo Poisson, el trabajo de medio tiempo aparentaba ser estadísticamente significativo. Sin embargo, en la Binomial Negativa, dejó de serlo. Esto ocurre porque el modelo Poisson asume matemáticamente que la varianza es igual a la media (equidispersión). Al existir sobredispersión en la realidad, Poisson se vuelve un modelo “optimista” que subestima los errores estándar, generando falsos positivos. La Binomial Negativa corrige esta falla ensanchando los errores a su tamaño real, lo que destapa que el efecto del trabajo part-time era solo un espejismo estadístico. 2. Modelo más adecuado: El modelo categórica e indiscutiblemente más adecuado para responder a la pregunta de investigación es la Regresión Binomial Negativa. La elección no responde a una preferencia, sino a la validez matemática. Dado que la prueba de Cameron & Trivedi (Pregunta 7) demostró empíricamente y sin lugar a dudas que los datos tienen una alta sobredispersión ($= 0.0563$), mantener el modelo Poisson implicaría entregar conclusiones inválidas y sesgadas. La Binomial Negativa es el único modelo de conteo capaz de absorber esa variabilidad extra de los alumnos, garantizando inferencias honestas. 3. Variables robustas a la especificación: En este análisis, cuatro variables demostraron ser estructural e innegablemente robustas, manteniendo una significancia estadística máxima ($p < 0.01$) tanto en el entorno optimista de Poisson como bajo el rigor absoluto de la Binomial Negativa: Variables robustas de impacto positivo: Las horas de estudio (“study_hours”), la salud mental (“mental_health_score”) y la calidad de la concentración (“focus_index”).

Variable robusta de impacto negativo: El nivel de estrés crónico (“burnout_level”).

1. Cargar la base de datos en el ambiente. Identifique los tipos de datos que se encuentran en la base, realice estadísticas descriptivas sobre las variables importantes (Hint: Revisar la distribuciones, datos faltantes, outliers, etc.) y limpie las variables cuando sea necesario. Genere una variable binaria para indicar quienes dieron el test. Justifique su proceso.

```
[22]: import pandas as pd
import numpy as np
import statsmodels.formula.api as smf
from statsmodels.iolib.summary2 import summary_col
import statsmodels.api as sm
```

```
[23]: df = pd.read_csv("student_productivity.csv")
```

```
[24]: print(df.isnull().sum())
```

```
student_id      0
age             648
gender          558
academic_level  630
study_hours     574
self_study_hours 667
online_classes_hours 682
social_media_hours 656
gaming_hours    656
sleep_hours     553
screen_time_hours 586
exercise_minutes 599
caffeine_intake_mg 600
part_time_job   703
upcoming_deadline 717
internet_quality 523
mental_health_score 675
drug_use        4103
focus_index    633
burnout_level   716
productivity_score 638
exam_score      709
dtype: int64
```

```
[25]: # Eliminar 'drug_use' y nulos de la dependiente
```

```
df = df.drop(columns=['drug_use'])
df = df.dropna(subset=['exam_score'])
```

```
# Estandarización de categorías
```

```
df['academic_level'] = df['academic_level'].str.strip()
```

```
df['part_time_job'] = df['part_time_job'].str.capitalize()
```

```
df['exercise_minutes'] = pd.to_numeric(df['exercise_minutes'], errors='coerce')
```

```
# Imputaciones según tipo de variable
```

```
vars_media = ['age', 'study_hours', 'self_study_hours', 'online_classes_hours',
              'sleep_hours', 'screen_time_hours', 'focus_index',
              ↪ 'burnout_level', 'productivity_score']
```

```
vars_mediana = ['social_media_hours', 'gaming_hours', 'caffeine_intake_mg',
```

```

        'mental_health_score', 'exercise_minutes']
vars_moda = ['upcoming_deadline', 'gender', 'academic_level', 'part_time_job', 'internet_quality']

for col in vars_media:
    df[col] = df[col].fillna(df[col].mean())
for col in vars_mediana:
    df[col] = df[col].fillna(df[col].median())
for col in vars_moda:
    df[col] = df[col].fillna(df[col].mode()[0])

# Verificación de resultados

print(df.info())

```

```

<class 'pandas.core.frame.DataFrame'>
Index: 4912 entries, 0 to 5620
Data columns (total 21 columns):
#   Column                Non-Null Count  Dtype
---  -
0   student_id            4912 non-null   int64
1   age                   4912 non-null   float64
2   gender                4912 non-null   object
3   academic_level        4912 non-null   object
4   study_hours           4912 non-null   float64
5   self_study_hours      4912 non-null   float64
6   online_classes_hours  4912 non-null   float64
7   social_media_hours    4912 non-null   float64
8   gaming_hours          4912 non-null   float64
9   sleep_hours           4912 non-null   float64
10  screen_time_hours     4912 non-null   float64
11  exercise_minutes      4912 non-null   float64
12  caffeine_intake_mg    4912 non-null   float64
13  part_time_job         4912 non-null   object
14  upcoming_deadline     4912 non-null   float64
15  internet_quality      4912 non-null   object
16  mental_health_score   4912 non-null   float64
17  focus_index           4912 non-null   float64
18  burnout_level         4912 non-null   float64
19  productivity_score     4912 non-null   float64
20  exam_score            4912 non-null   float64
dtypes: float64(16), int64(1), object(4)
memory usage: 844.2+ KB
None

```

[26]: *# Generar la variable binaria dependiente*

```
df['rindio_examen'] = np.where(df['exam_score'] == 1.0, 0, 1)

# Transformación de categóricas a Dummies

df = pd.get_dummies(df, drop_first=True, dtype=float)

# Verificación de resultados

print(df.info())
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 4912 entries, 0 to 5620
Data columns (total 25 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   student_id                            4912 non-null   int64
1   age                                    4912 non-null   float64
2   study_hours                           4912 non-null   float64
3   self_study_hours                       4912 non-null   float64
4   online_classes_hours                   4912 non-null   float64
5   social_media_hours                     4912 non-null   float64
6   gaming_hours                           4912 non-null   float64
7   sleep_hours                            4912 non-null   float64
8   screen_time_hours                      4912 non-null   float64
9   exercise_minutes                       4912 non-null   float64
10  caffeine_intake_mg                     4912 non-null   float64
11  upcoming_deadline                      4912 non-null   float64
12  mental_health_score                    4912 non-null   float64
13  focus_index                            4912 non-null   float64
14  burnout_level                           4912 non-null   float64
15  productivity_score                      4912 non-null   float64
16  exam_score                             4912 non-null   float64
17  rindio_examen                           4912 non-null   int32
18  gender_Male                             4912 non-null   float64
19  gender_Other                             4912 non-null   float64
20  academic_level_Postgraduate             4912 non-null   float64
21  academic_level_Undergraduate            4912 non-null   float64
22  part_time_job_Yes                       4912 non-null   float64
23  internet_quality_Good                    4912 non-null   float64
24  internet_quality_Poor                    4912 non-null   float64
dtypes: float64(23), int32(1), int64(1)
memory usage: 978.6 KB
None
```

```
[27]: df.head()
```



```

[27]: student_id  age  study_hours  self_study_hours  online_classes_hours  \
0          1  20.0          5.37          2.09          1.85
1          2  16.0          5.85          5.04          1.87
2          3  18.0          5.69          2.27          0.00
3          4  24.0          2.32          1.06          2.30
4          5  24.0          3.87          2.63          2.54

      social_media_hours  gaming_hours  sleep_hours  screen_time_hours  \
0          3.66          2.32          7.73          5.68
1          3.60          2.79          6.11          8.96
2          2.93          3.94          7.11          11.02
3          4.34          2.37          8.54          8.73
4          3.71          1.30          7.69          9.60

      exercise_minutes  ...  productivity_score  exam_score  rindio_examen  \
0          54.0  ...          42.59          25.08          1
1          63.0  ...          67.15          37.83          1
2          28.0  ...          37.68          18.66          1
3          55.0  ...          12.83          1.00          0
4          60.0  ...          18.53          7.78          1

      gender_Male  gender_Other  academic_level_Postgraduate  \
0          1.0          0.0          0.0
1          0.0          0.0          0.0
2          0.0          0.0          0.0
3          1.0          0.0          0.0
4          0.0          0.0          1.0

      academic_level_Undergraduate  part_time_job_Yes  internet_quality_Good  \
0          1.0          0.0          1.0
1          0.0          0.0          1.0
2          1.0          0.0          0.0
3          1.0          0.0          0.0
4          0.0          0.0          0.0

      internet_quality_Poor
0          0.0
1          0.0
2          0.0
3          1.0
4          1.0

[5 rows x 25 columns]

```

2. Ejecute un modelo de probabilidad lineal (MCO) que permita explicar la probabilidad de que un alumno rinda el examen, a partir de las informacion disponible. Seleccione las variables dependientes a incluir en el modelo final e interprete su sig-

nificado.

```
[ ]: #Selección de variables y ejecución del modelo

formula_mco = 'rindio_examen ~ study_hours + burnout_level +
↳mental_health_score + caffeine_intake_mg + part_time_job_Yes + sleep_hours +
↳social_media_hours + gaming_hours + focus_index + C(upcoming_deadline)'

modelo_mco = smf.ols(formula=formula_mco, data=df).fit()

# Resultados
print(modelo_mco.summary())
```

OLS Regression Results

=====					
Dep. Variable:	rindio_examen	R-squared:	0.234		
Model:	OLS	Adj. R-squared:	0.233		
Method:	Least Squares	F-statistic:	150.0		
Date:	Sun, 19 Apr 2026	Prob (F-statistic):	3.12e-275		
Time:	17:59:59	Log-Likelihood:	-153.02		
No. Observations:	4912	AIC:	328.0		
Df Residuals:	4901	BIC:	399.5		
Df Model:	10				
Covariance Type:	nonrobust				
=====					
=====					
		coef	std err	t	P> t
[0.025	0.975]				

Intercept		0.6695	0.041	16.237	0.000
0.589	0.750				
C(upcoming_deadline)[T.1.0]		0.0031	0.009	0.339	0.734
-0.015	0.021				
study_hours		0.0295	0.003	11.661	0.000
0.025	0.034				
burnout_level		-0.0041	0.000	-9.660	0.000
-0.005	-0.003				
mental_health_score		0.0163	0.002	9.247	0.000
0.013	0.020				
caffeine_intake_mg		-1.554e-05	2.64e-05	-0.588	0.557
-6.74e-05	3.63e-05				
part_time_job_Yes		-0.0112	0.008	-1.348	0.178
-0.028	0.005				
sleep_hours		0.0012	0.004	0.301	0.764
-0.007	0.009				
social_media_hours		0.0026	0.003	0.931	0.352
-0.003	0.008				
gaming_hours		0.0014	0.003	0.424	0.672

-0.005	0.008				
focus_index		0.0066	0.001	10.423	0.000
0.005	0.008				

```
=====
```

Omnibus:	1697.452	Durbin-Watson:	2.012
Prob(Omnibus):	0.000	Jarque-Bera (JB):	4814.444
Skew:	-1.854	Prob(JB):	0.00
Kurtosis:	6.125	Cond. No.	3.41e+03

```
=====
```

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

[2] The condition number is large, 3.41e+03. This might indicate that there are strong multicollinearity or other numerical problems.

```
[ ]: # Selección de variables y ejecución del modelo (sin sleep_hours ni
      ↪ gaming_hours)

formula_mco = 'rindio_examen ~ study_hours + burnout_level +
      ↪ mental_health_score + caffeine_intake_mg + part_time_job_Yes +
      ↪ social_media_hours + focus_index + C(upcoming_deadline)'

modelo_mco = smf.ols(formula=formula_mco, data=df).fit()

# Resultados
print(modelo_mco.summary())
```

OLS Regression Results

```
=====
```

Dep. Variable:	rindio_examen	R-squared:	0.234
Model:	OLS	Adj. R-squared:	0.233
Method:	Least Squares	F-statistic:	187.5
Date:	Sun, 19 Apr 2026	Prob (F-statistic):	1.91e-277
Time:	17:59:59	Log-Likelihood:	-153.16
No. Observations:	4912	AIC:	324.3
Df Residuals:	4903	BIC:	382.8
Df Model:	8		
Covariance Type:	nonrobust		

```
=====
```

```
=====
```

	coef	std err	t	P> t
--	------	---------	---	------

```
-----
```

[0.025	0.975]			
--------	--------	--	--	--

```
-----
```

Intercept	0.6832	0.021	31.865	0.000
0.641	0.725			
C(upcoming_deadline) [T.1.0]	0.0043	0.008	0.508	0.611

-0.012	0.021				
study_hours		0.0296	0.002	12.022	0.000
0.025	0.034				
burnout_level		-0.0042	0.000	-12.446	0.000
-0.005	-0.004				
mental_health_score		0.0164	0.002	9.540	0.000
0.013	0.020				
caffeine_intake_mg		-1.406e-05	2.6e-05	-0.541	0.589
-6.5e-05	3.69e-05				
part_time_job_Yes		-0.0104	0.008	-1.320	0.187
-0.026	0.005				
social_media_hours		0.0025	0.003	0.919	0.358
-0.003	0.008				
focus_index		0.0065	0.001	11.035	0.000
0.005	0.008				

Omnibus:	1698.146	Durbin-Watson:	2.011
Prob(Omnibus):	0.000	Jarque-Bera (JB):	4819.100
Skew:	-1.855	Prob(JB):	0.00
Kurtosis:	6.128	Cond. No.	1.77e+03

Notes:

- [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
- [2] The condition number is large, 1.77e+03. This might indicate that there are strong multicollinearity or other numerical problems.

```
[ ]: # Selección de variables y ejecución del modelo (sin sleep_hours, gaming_hours,
      ↪ni caffeine_intake_mg)

formula_mco = 'rindio_examen ~ study_hours + burnout_level +
      ↪mental_health_score + part_time_job_Yes + social_media_hours + focus_index'

modelo_mco = smf.ols(formula=formula_mco, data=df).fit()

# Resultados
print(modelo_mco.summary())
```

OLS Regression Results

Dep. Variable:	rindio_examen	R-squared:	0.234
Model:	OLS	Adj. R-squared:	0.233
Method:	Least Squares	F-statistic:	250.0
Date:	Sun, 19 Apr 2026	Prob (F-statistic):	1.05e-279
Time:	17:59:59	Log-Likelihood:	-153.48
No. Observations:	4912	AIC:	321.0

Df Residuals: 4905 BIC: 366.5
 Df Model: 6
 Covariance Type: nonrobust

```
=====
=====
              coef      std err          t      P>|t|      [0.025
0.975]
-----
Intercept          0.6792      0.021     32.591      0.000      0.638
0.720
study_hours         0.0296      0.002     12.032      0.000      0.025
0.034
burnout_level      -0.0041      0.000    -14.872      0.000     -0.005
-0.004
mental_health_score  0.0163      0.002      9.526      0.000      0.013
0.020
part_time_job_Yes   -0.0109      0.008     -1.435      0.151     -0.026
0.004
social_media_hours   0.0026      0.003      0.952      0.341     -0.003
0.008
focus_index         0.0066      0.001     11.130      0.000      0.005
0.008
=====
Omnibus:          1698.871   Durbin-Watson:          2.012
Prob(Omnibus):      0.000   Jarque-Bera (JB):      4823.274
Skew:             -1.856   Prob(JB):              0.00
Kurtosis:          6.129   Cond. No.              330.
=====
```

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

```
[31]: # Selección de variables y ejecución del modelo (sin sleep_hours, gaming_hours,
      ↪caffeine_intake_mg ni part_time_job_Yes)

formula_mco = 'rindio_examen ~ study_hours + burnout_level +
      ↪mental_health_score + focus_index'

modelo_mco = smf.ols(formula=formula_mco, data=df).fit()

print(modelo_mco.summary())
```

OLS Regression Results

```
=====
Dep. Variable:          rindio_examen   R-squared:          0.234
Model:                  OLS            Adj. R-squared:      0.233
```

```

Method:                Least Squares    F-statistic:                374.2
Date:                  Sun, 19 Apr 2026  Prob (F-statistic):        1.17e-281
Time:                  17:59:59          Log-Likelihood:             -154.91
No. Observations:      4912             AIC:                        319.8
Df Residuals:          4907             BIC:                        352.3
Df Model:              4
Covariance Type:       nonrobust

```

```

=====
=====
              coef      std err          t      P>|t|      [0.025
0.975]
-----
-----
Intercept          0.6911      0.018     39.275      0.000      0.657
0.726
study_hours         0.0303      0.002     12.738      0.000      0.026
0.035
burnout_level      -0.0043      0.000    -16.555      0.000     -0.005
-0.004
mental_health_score  0.0169      0.002     10.273      0.000      0.014
0.020
focus_index        0.0063      0.001     11.832      0.000      0.005
0.007
=====
Omnibus:            1701.036    Durbin-Watson:              2.012
Prob(Omnibus):      0.000     Jarque-Bera (JB):           4833.544
Skew:               -1.858     Prob(JB):                   0.00
Kurtosis:           6.132     Cond. No.                   278.
=====

```

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

3. Ejecute un modelo probit para responder a la pregunta 2. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

```

[ ]: # Selección de variables y ejecución del modelo Probit

formula_probit = 'rindio_examen ~ study_hours + burnout_level +
↳mental_health_score + focus_index'

modelo_probit = smf.probit(formula=formula_probit, data=df).fit()

# Resultados
print(modelo_probit.summary())

```

Optimization terminated successfully.

Current function value: 0.148394

Iterations 9

Probit Regression Results

```
=====
Dep. Variable:          rindio_examen    No. Observations:          4912
Model:                  Probit           Df Residuals:             4907
Method:                  MLE             Df Model:                 4
Date:                   Sun, 19 Apr 2026   Pseudo R-squ.:             0.5071
Time:                   17:59:59          Log-Likelihood:            -728.91
converged:               True             LL-Null:                  -1478.9
Covariance Type:         nonrobust        LLR p-value:               0.000
=====
```

```
=====
                                coef      std err          z      P>|z|      [0.025
0.975]
-----
Intercept                   -0.1838      0.175      -1.051      0.293      -0.526
0.159
study_hours                   0.3907      0.028     14.198      0.000      0.337
0.445
burnout_level                -0.0533      0.003    -16.668      0.000      -0.060
-0.047
mental_health_score           0.2464      0.020     12.513      0.000      0.208
0.285
focus_index                  0.0749      0.006     12.940      0.000      0.064
0.086
=====
=====
```

Possibly complete quasi-separation: A fraction 0.29 of observations can be perfectly predicted. This might indicate that there is complete quasi-separation. In this case some parameters will not be identified.

4. Ejecute un modelo logit para responder a la pregunta 2. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

```
[33]: # Selección de variables y ejecución del modelo Logit

formula_logit = 'rindio_examen ~ study_hours + burnout_level +_
↳mental_health_score + focus_index'

modelo_logit = smf.logit(formula=formula_logit, data=df).fit()

print(modelo_logit.summary())
```

Optimization terminated successfully.

Current function value: 0.147874

Iterations 9

```

                                Logit Regression Results
=====
Dep. Variable:                rindio_examen    No. Observations:                4912
Model:                        Logit           Df Residuals:                    4907
Method:                       MLE            Df Model:                        4
Date:                         Sun, 19 Apr 2026  Pseudo R-squ.:                0.5089
Time:                         17:59:59         Log-Likelihood:                 -726.36
converged:                     True            LL-Null:                       -1478.9
Covariance Type:              nonrobust        LLR p-value:                    0.000
=====
=====
                                coef      std err          z      P>|z|      [0.025
0.975]
-----
Intercept                    -0.4683      0.322      -1.455      0.146      -1.099
0.163
study_hours                   0.7420      0.053     14.038      0.000      0.638
0.846
burnout_level                -0.0997      0.006    -16.313      0.000      -0.112
-0.088
mental_health_score          0.4693      0.038     12.410      0.000      0.395
0.543
focus_index                 0.1408      0.011     12.681      0.000      0.119
0.163
=====
=====

```

Possibly complete quasi-separation: A fraction 0.11 of observations can be perfectly predicted. This might indicate that there is complete quasi-separation. In this case some parameters will not be identified.

5. Comente los resultados obtenidos en 2, 3 y 4. ¿Cuáles y por qué existen las diferencias entre los resultados?. En su opinión, ¿Cuál sería el más adecuado para responder la pregunta de investigación y por qué? ¿Qué variables resultaron ser robustas a la especificación?

```

[34]: tabla_comparativa = summary_col(
    [modelo_mco, modelo_probit, modelo_logit],
    model_names=['MCO (Lineal)', 'Probit', 'Logit'],
    stars=True,
    info_dict={'N':lambda x: "{0:d}".format(int(x.nobs)),
               'Pseudo R2':lambda x: "{:.3f}".format(getattr(x, 'prsquared',
    float('nan'))))}
)

print("--- TABLA COMPARATIVA DE ROBUSTEZ ---")
print(tabla_comparativa)

```



```

print("\n--- EFECTOS MARGINALES (Cambio real en probabilidad) ---")

# Calculamos Efectos Marginales (dydx) promedio (overall)
margeff_probit = modelo_probit.get_margeff(at='overall')
margeff_logit = modelo_logit.get_margeff(at='overall')

print("\nEfectos Marginales PROBIT:")
print(margeff_probit.summary())

print("\nEfectos Marginales LOGIT:")
print(margeff_logit.summary())

```

--- TABLA COMPARATIVA DE ROBUSTEZ ---

	MCO (Lineal)	Probit	Logit
Intercept	0.6911*** (0.0176)	-0.1838 (0.1748)	-0.4683 (0.3220)
study_hours	0.0303*** (0.0024)	0.3907*** (0.0275)	0.7420*** (0.0529)
burnout_level	-0.0043*** (0.0003)	-0.0533*** (0.0032)	-0.0997*** (0.0061)
mental_health_score	0.0169*** (0.0016)	0.2464*** (0.0197)	0.4693*** (0.0378)
focus_index	0.0063*** (0.0005)	0.0749*** (0.0058)	0.1408*** (0.0111)
R-squared	0.2337		
R-squared Adj.	0.2331		
N	4912	4912	4912
Pseudo R2	nan	0.507	0.509

Standard errors in parentheses.

* p<.1, ** p<.05, ***p<.01

--- EFECTOS MARGINALES (Cambio real en probabilidad) ---

Efectos Marginales PROBIT:

Probit Marginal Effects

```

=====
Dep. Variable:      rindio_examen
Method:              dydx
At:                  overall
=====

```

```

=====
dy/dx      std err      z      P>|z|      [0.025

```

```

0.975]
-----
-----
study_hours          0.0322      0.002      15.533      0.000      0.028
0.036
burnout_level        -0.0044      0.000     -19.085      0.000     -0.005
-0.004
mental_health_score   0.0203      0.002      13.374      0.000      0.017
0.023
focus_index          0.0062      0.000      13.942      0.000      0.005
0.007
=====
=====

```

Efectos Marginales LOGIT:

Logit Marginal Effects

```

=====
Dep. Variable:          rindio_examen
Method:                  dydx
At:                      overall
=====
=====
              dy/dx      std err          z      P>|z|      [0.025
0.975]
-----
-----
study_hours          0.0327      0.002      15.885      0.000      0.029
0.037
burnout_level        -0.0044      0.000     -19.326      0.000     -0.005
-0.004
mental_health_score   0.0207      0.002      13.576      0.000      0.018
0.024
focus_index          0.0062      0.000      13.941      0.000      0.005
0.007
=====
=====

```

6. Use un modelo Poisson para explicar la nota del examen, entre aquellos alumnos que lo rindieron. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

```

[ ]: # Selección de variables y ejecución del modelo Poisson

df_rindieron = df[df['rindio_examen'] == 1].copy()

df_rindieron['exam_score_int'] = df_rindieron['exam_score'].round().astype(int)

```

```

formula_poisson_inicial = 'exam_score_int ~ study_hours + focus_index +
↳burnout_level + mental_health_score + sleep_hours + screen_time_hours +
↳social_media_hours + gaming_hours + caffeine_intake_mg + part_time_job_Yes'

modelo_poisson_1 = smf.poisson(formula=formula_poisson_inicial,
↳data=df_rindieron).fit()

# Resultados
print(modelo_poisson_1.summary())

```

Optimization terminated successfully.

Current function value: 3.379520

Iterations 6

Poisson Regression Results

```

=====
Dep. Variable:          exam_score_int    No. Observations:          4473
Model:                  Poisson          Df Residuals:              4462
Method:                 MLE              Df Model:                  10
Date:                  Sun, 19 Apr 2026    Pseudo R-squ.:             0.3972
Time:                  18:00:00           Log-Likelihood:            -15117.
converged:              True              LL-Null:                   -25079.
Covariance Type:        nonrobust          LLR p-value:                0.000
=====
=====

```

	coef	std err	z	P> z	[0.025
0.975]					

Intercept	1.9933	0.036	55.381	0.000	1.923
2.064					
study_hours	0.1054	0.002	44.605	0.000	0.101
0.110					
focus_index	0.0220	0.001	37.142	0.000	0.021
0.023					
burnout_level	-0.0149	0.000	-43.766	0.000	-0.016
-0.014					
mental_health_score	0.0688	0.002	41.288	0.000	0.066
0.072					
sleep_hours	0.0025	0.004	0.686	0.493	-0.005
0.010					
screen_time_hours	-0.0012	0.001	-0.781	0.435	-0.004
0.002					
social_media_hours	0.0043	0.003	1.676	0.094	-0.001
0.009					
gaming_hours	0.0049	0.003	1.527	0.127	-0.001
0.011					
caffeine_intake_mg	2.014e-05	2.42e-05	0.831	0.406	-2.73e-05

```
6.76e-05
part_time_job_Yes      -0.0188      0.007      -2.526      0.012      -0.033
-0.004
```

```
=====
=====
```

```
[ ]: # Selección de variables y ejecución del modelo Poisson (sin sleep_hours ni
      ↪screen_time_hours)

formula_poisson_inicial = 'exam_score_int ~ study_hours + focus_index +
      ↪burnout_level + mental_health_score + social_media_hours + gaming_hours +
      ↪caffeine_intake_mg + part_time_job_Yes'

modelo_poisson_2 = smf.poisson(formula=formula_poisson_inicial,
      ↪data=df_rindieron).fit()

# Resultados
print(modelo_poisson_2.summary())
```

Optimization terminated successfully.

Current function value: 3.379619

Iterations 6

Poisson Regression Results

```
=====
Dep. Variable:      exam_score_int      No. Observations:      4473
Model:              Poisson      Df Residuals:      4464
Method:             MLE      Df Model:      8
Date:              Sun, 19 Apr 2026      Pseudo R-squ.:      0.3972
Time:              18:00:00      Log-Likelihood:      -15117.
converged:          True      LL-Null:      -25079.
Covariance Type:    nonrobust      LLR p-value:      0.000
=====
=====
```

```
=====
      coef      std err      z      P>|z|      [0.025
0.975]
```

```
-----
Intercept      2.0083      0.022      92.020      0.000      1.966
2.051
study_hours      0.1051      0.002      45.152      0.000      0.101
0.110
focus_index      0.0221      0.001      38.338      0.000      0.021
0.023
burnout_level     -0.0151      0.000     -56.907      0.000     -0.016
-0.015
mental_health_score  0.0687      0.002      41.746      0.000      0.065
0.072
social_media_hours  0.0045      0.003      1.768      0.077     -0.000
```

```

0.010
gaming_hours          0.0049      0.003      1.559      0.119      -0.001
0.011
caffeine_intake_mg     2.43e-05   2.38e-05      1.021      0.307     -2.24e-05
7.1e-05
part_time_job_Yes      -0.0169     0.007     -2.366      0.018      -0.031
-0.003

```

```

=====
=====

```

```

[ ]: # Selección de variables y ejecución del modelo Poisson (sin sleep_hours,
      ↪screen_time_hours ni gaming_hours)

formula_poisson_inicial = 'exam_score_int ~ study_hours + focus_index +
      ↪burnout_level + mental_health_score + social_media_hours + part_time_job_Yes'

modelo_poisson_3 = smf.poisson(formula=formula_poisson_inicial,
      ↪data=df_rindieron).fit()

# Resultados
print(modelo_poisson_3.summary())

```

Optimization terminated successfully.

Current function value: 3.380009

Iterations 5

Poisson Regression Results

```

=====
Dep. Variable:          exam_score_int    No. Observations:          4473
Model:                  Poisson          Df Residuals:            4466
Method:                 MLE             Df Model:                6
Date:                  Sun, 19 Apr 2026   Pseudo R-squ.:           0.3971
Time:                  18:00:00          Log-Likelihood:          -15119.
converged:              True             LL-Null:                 -25079.
Covariance Type:       nonrobust         LLR p-value:             0.000
=====

```

```

=====
              coef      std err          z      P>|z|      [0.025
0.975]
-----
Intercept          2.0239      0.020    100.418      0.000      1.984
2.063
study_hours         0.1057      0.002     46.215      0.000      0.101
0.110
focus_index        0.0219      0.001     39.468      0.000      0.021
0.023
burnout_level      -0.0151      0.000    -58.100      0.000     -0.016
-0.015

```

mental_health_score	0.0691	0.002	42.809	0.000	0.066
0.072					
social_media_hours	0.0040	0.003	1.573	0.116	-0.001
0.009					
part_time_job_Yes	-0.0173	0.007	-2.438	0.015	-0.031
-0.003					

=====

=====

```
[ ]: # Selección de variables y ejecución del modelo Poisson (sin sleep_hours,
      ↪screen_time_hours, gaming_hours ni social_media_hours)

formula_poisson_inicial = 'exam_score_int ~ study_hours + focus_index +
      ↪burnout_level + mental_health_score + part_time_job_Yes'

modelo_poisson_4 = smf.poisson(formula=formula_poisson_inicial,
      ↪data=df_rindieron).fit()

# Resultados
print(modelo_poisson_4.summary())
```

Optimization terminated successfully.

Current function value: 3.380285

Iterations 5

Poisson Regression Results

Dep. Variable:	exam_score_int	No. Observations:	4473
Model:	Poisson	Df Residuals:	4467
Method:	MLE	Df Model:	5
Date:	Sun, 19 Apr 2026	Pseudo R-squ.:	0.3971
Time:	18:00:00	Log-Likelihood:	-15120.
converged:	True	LL-Null:	-25079.
Covariance Type:	nonrobust	LLR p-value:	0.000

=====

=====

	coef	std err	z	P> z	[0.025
--	------	---------	---	------	--------

0.975]

Intercept	2.0403	0.017	118.519	0.000	2.007
2.074					
study_hours	0.1067	0.002	48.341	0.000	0.102
0.111					
focus_index	0.0215	0.000	43.244	0.000	0.021
0.022					
burnout_level	-0.0151	0.000	-58.464	0.000	-0.016
-0.015					
mental_health_score	0.0699	0.002	45.087	0.000	0.067

```
0.073
part_time_job_Yes      -0.0168      0.007      -2.362      0.018      -0.031
-0.003
```

```
=====
=====
```

7. Determine si existe sobre dispersion en la data y posible valor optimo de alpha para un modelo Binomial Negativa.

```
[39]: media_notas = df_rindieron['exam_score_int'].mean()
varianza_notas = df_rindieron['exam_score_int'].var()
print(f"Media de notas: {media_notas:.2f}")
print(f"Varianza de notas: {varianza_notas:.2f}")
```

```
Media de notas: 20.59
Varianza de notas: 127.25
```

```
[40]: mu = modelo_poisson_4.predict()
aux_y = ((df_rindieron['exam_score_int'] - mu)**2) -
    ↪df_rindieron['exam_score_int']

# Construimos la variable explicativa:  $\mu^2$ 
aux_x = mu**2

# Ajustamos una regresión OLS sin intercepto para hallar el Alpha
test_sobredispersion = sm.OLS(aux_y, aux_x).fit()

print("\n--- 2. TEST DE SOBREDISPERSIÓN Y BÚSQUEDA DE ALPHA ---")
print(test_sobredispersion.summary())
```

```
--- 2. TEST DE SOBREDISPERSIÓN Y BÚSQUEDA DE ALPHA ---
                                OLS Regression Results
```

```
=====
=====
```

Dep. Variable:	exam_score_int	R-squared (uncentered):
0.236		
Model:	OLS	Adj. R-squared (uncentered):
0.236		
Method:	Least Squares	F-statistic:
1382.		
Date:	Sun, 19 Apr 2026	Prob (F-statistic):
7.54e-264		
Time:	18:00:00	Log-Likelihood:
-26321.		
No. Observations:	4473	AIC:
5.264e+04		
Df Residuals:	4472	BIC:
5.265e+04		

```

Df Model: 1
Covariance Type: nonrobust
=====
              coef      std err          t      P>|t|      [0.025      0.975]
-----
x1          0.0563      0.002     37.176      0.000      0.053      0.059
=====
Omnibus: 9516.073 Durbin-Watson: 1.970
Prob(Omnibus): 0.000 Jarque-Bera (JB): 86500521.118
Skew: 18.076 Prob(JB): 0.00
Kurtosis: 683.304 Cond. No. 1.00
=====

```

Notes:

[1] R^2 is computed without centering (uncentered) since the model does not contain a constant.

[2] Standard Errors assume that the covariance matrix of the errors is correctly specified.

8. Usando la informacion anterior, ejecute un modelo Binomial Negativa para responder a la pregunta 6. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

```

[ ]: formula_final_nb = 'exam_score_int ~ study_hours + focus_index + burnout_level_
    ↪+ mental_health_score + part_time_job_Yes'

# Ajustamos el modelo Binomial Negativa

# Usamos el alpha de 0.0563 calculado en el test de sobredispersión
modelo_nb = smf.negativebinomial(formula=formula_final_nb, data=df_rindieron,
    ↪alpha=0.0563).fit()

# Resultados
print(modelo_nb.summary())

```

Optimization terminated successfully.

Current function value: 3.256358

Iterations: 19

Function evaluations: 36

Gradient evaluations: 28

NegativeBinomial Regression Results

```

=====
Dep. Variable: exam_score_int No. Observations: 4473
Model: NegativeBinomial Df Residuals: 4467
Method: MLE Df Model: 5
Date: Sun, 19 Apr 2026 Pseudo R-squ.: 0.1472
Time: 18:00:00 Log-Likelihood: -14566.
converged: True LL-Null: -17081.
Covariance Type: nonrobust LLR p-value: 0.000
=====

```



```
=====
```

	coef	std err	z	P> z	[0.025
0.975]					

Intercept	1.9646	0.025	78.307	0.000	1.915
2.014					
study_hours	0.1156	0.003	35.181	0.000	0.109
0.122					
focus_index	0.0236	0.001	31.957	0.000	0.022
0.025					
burnout_level	-0.0164	0.000	-42.466	0.000	-0.017
-0.016					
mental_health_score	0.0729	0.002	32.576	0.000	0.069
0.077					
part_time_job_Yes	-0.0184	0.010	-1.778	0.075	-0.039
0.002					
alpha	0.0500	0.002	20.497	0.000	0.045
0.055					

```
=====
```

```
=====
```

```
c:\Users\educu\Anaconda\lib\site-packages\statsmodels\base\model.py:130:
ValueWarning: unknown kwargs ['alpha']
  warnings.warn(msg, ValueWarning)
c:\Users\educu\Anaconda\lib\site-
packages\statsmodels\discrete\discrete_model.py:3379: RuntimeWarning: divide by
zero encountered in log
  llf = coeff + size*np.log(prob) + endog*np.log(1-prob)
c:\Users\educu\Anaconda\lib\site-packages\statsmodels\base\model.py:130:
ValueWarning: unknown kwargs ['alpha']
  warnings.warn(msg, ValueWarning)
```

9. Comente los resultados obtenidos en 6, 7 y 8. ¿Cuáles y por qué existen las diferencias entre los resultados?. En su opinión, ¿Cuál sería el más adecuado para responder la pregunta de investigación y por qué? ¿Qué variables resultaron ser robustas a la especificación?