

Tarea1_Vergara_Jofre

April 28, 2026

1 Tarea 1 DAML - Cristóbal Vergara Jofre

#Ejecutada con kernel python 3.11.9

1. Cargar la base de datos en el ambiente. Identifique los tipos de datos que se encuentran en la base, realice estadísticas descriptivas sobre las variables importantes (Hint: Revisar la distribuciones, datos faltantes, outliers, etc.) y limpie las variables cuando sea necesario. Genere una variable binaria para indicar quienes dieron el test. Justifique su proceso.

```
[1]: import missingno as msno
import matplotlib.pyplot as plt
import seaborn as sns
import pandas as pd
import numpy as np
import statsmodels.formula.api as smf
```

```
[2]: df = pd.read_csv("../../data/student_productivity.csv")
initial_count = len(df)
print(f"Filas antes de la limpieza: {initial_count}")
```

Filas antes de la limpieza: 5621

```
[3]: #
#-----Exploracion-----

# 2.1 Resumen de nulos restantes
print("\n--- Nulos Restantes por Columna ---")
null_counts = df.isnull().sum()
if null_counts.sum() > 0:
    # Filtramos solo las columnas que tienen nulos
    nulls = null_counts[null_counts > 0]
    # Calculamos el porcentaje
    nulls_pct = (nulls / len(df)) * 100

    # Creamos un DataFrame para mostrar ambos tabulados y lo ordenamos de mayor
    # a menor
    resume_nulos = pd.DataFrame({
        'Cantidad Nulos': nulls,
```

```

        '% del Total': nulls_pct.round(2)
    }).sort_values(by='Cantidad Nulos', ascending=False)

    # Mostramos la tabla
    print(resume_nulos)

    # Gráfico Visual de Nulos usando missingno
    msno.matrix(df, figsize=(12, 6), sparkline=False, fontsize=10, color=(0.25, 0.45, 0.6))

    plt.show()
else:
    print("    No hay valores nulos en el dataset.")
# 1. Filtramos solo las columnas numéricas para poder calcular la correlación
num_cols = df.select_dtypes(include=[np.number])
# 2. Calculamos la matriz de correlación de Pearson
corr = num_cols.corr()
# 3. Creamos una máscara para el triángulo superior (para no repetir datos y
    que se vea igual a tu foto)
mask = np.triu(np.ones_like(corr, dtype=bool))
# 4. Configuramos el tamaño de la figura
plt.figure(figsize=(14, 10))
# 5. Generamos el Heatmap con Seaborn
sns.heatmap(corr,
            mask=mask,
            cmap='coolwarm',      # Escala de colores (Rojo = Positivo, Azul =
    Negativo)
            vmin=-1, vmax=1,      # Fijar los bordes de la escala de
    correlación
            annot=True,           # Mostrar el número encima
            fmt=".2f",             # 2 decimales, como en tu imagen
            linewidths=.5,        # Margen o separación visual entre los
    cuadritos
            cbar_kws={"shrink": .8}) # Achicar la barra lateral sutilmente
# 6. Agregamos el título y ajustamos los bordes
plt.title('Matriz de Correlación de Variables Numéricas', fontsize=16, pad=20)
plt.tight_layout()
# Mostrar el gráfico
plt.show()
# 2.2 Verificación de rangos lógicos (Sanity Check)
print("\n--- Verificación de Rangos Lógicos ---")
rangos_validos = {
    'age': (10, 80),
    'self_study_hours': (0, 24),
    'sleep_hours': (0, 24),
    'caffeine_intake_mg': (0, 1000),
    'mental_health_score': (1, 10),

```

```

        'exam_score': (1, 100)
    }
    for col, (vmin, vmax) in rangos_validos.items():
        if col in df.columns:
            n_fuera = ((df[col] < vmin) | (df[col] > vmax)).sum()
            if n_fuera > 0:
                print(f"    '{col}': {n_fuera} valores fuera de rango_
↳({vmin}-{vmax}).")
            else:
                print(f"    '{col}': Rangos OK.")
# 2.3 Estadísticas Descriptivas Finales
print("\n--- Estadísticas Descriptivas (Variables Numéricas) ---")
print(df.describe().T.round(2))
print("\n--- Distribución de Variables Categóricas ---")
cat_cols = ['gender', 'academic_level', 'part_time_job', 'internet_quality']
for col in cat_cols:
    if col in df.columns:
        print(f"\n[{col}]")
        print(df[col].value_counts(dropna=False))
# Variables definidas para análisis de outliers y distribuciones
num_cols_for_outliers = [
    'age', 'self_study_hours', 'online_classes_hours', 'social_media_hours',
    'gaming_hours', 'sleep_hours', 'exercise_minutes', 'caffeine_intake_mg',
    'mental_health_score', 'burnout_level', 'exam_score'
]
# 2.4 Visualización de Distribuciones (Boxplots)
print("\n--- Visualización de Distribuciones (Boxplots) ---")
# Creamos una grilla de gráficos de tamaño dinámico
num_plots = len(num_cols_for_outliers)
fig, axes = plt.subplots(nrows=int(np.ceil(num_plots/3)), ncols=3, figsize=(16,
↳14))
axes = axes.flatten()
for i, col in enumerate(num_cols_for_outliers):
    if col in df.columns:
        # Aseguramos formato numérico
        df[col] = pd.to_numeric(df[col], errors='coerce')
        # Dibujamos un Boxplot
        sns.boxplot(y=df[col], ax=axes[i], color='mediumturquoise')
        axes[i].set_title(f"Distribución de {col}", fontsize=12)
        axes[i].set_ylabel('')
# Ocultamos ejes sobrantes si la cantidad de variables no es múltiplo de 3
for j in range(i + 1, len(axes)):
    fig.delaxes(axes[j])
plt.suptitle("Boxplots de Variables Numéricas (Apoyo a decisiones de_
↳Outliers)", fontsize=16, y=1.02)
plt.tight_layout()
plt.show()

```

```

# 2.5 Detección de Outliers (Método de Rango Intercuartílico - IQR)
print("\n--- Detección Numérica de Outliers (Método IQR) ---")
outliers_summary = []
for col in num_cols_for_outliers:
    if col in df.columns:
        df[col] = pd.to_numeric(df[col], errors='coerce')
        Q1 = df[col].quantile(0.25)
        Q3 = df[col].quantile(0.75)
        IQR = Q3 - Q1
        lower_bound = Q1 - 1.5 * IQR
        upper_bound = Q3 + 1.5 * IQR

        # Ojo: No consideramos límite inferior si cae por debajo de 0 y la
        ↪ variable no permite negativos
        outliers_mask = ((df[col] < lower_bound) | (df[col] > upper_bound))
        num_outliers = outliers_mask.sum()
        pct_outliers = (num_outliers / len(df[col].dropna())) * 100


        if num_outliers > 0:
            outliers_summary.append({
                'Variable': col,
                'Outliers': num_outliers,
                '% del Total': round(pct_outliers, 2),
                'Límite Inferior': round(lower_bound, 2),
                'Límite Superior': round(upper_bound, 2)
            })
if outliers_summary:
    df_outliers = pd.DataFrame(outliers_summary).sort_values(by='Outliers',
    ↪ ascending=False)
    print(df_outliers.to_string(index=False))
else:
    print("    No se detectaron outliers bajo el método IQR.")
#-----Exploracion-----
↪
#
↪

```


--- Nulos Restantes por Columna ---

	Cantidad Nulos	% del Total
drug_use	4103	72.99
upcoming_deadline	717	12.76
burnout_level	716	12.74
exam_score	709	12.61
part_time_job	703	12.51
online_classes_hours	682	12.13
mental_health_score	675	12.01

self_study_hours	667	11.87
gaming_hours	656	11.67
social_media_hours	656	11.67
age	648	11.53
productivity_score	638	11.35
focus_index	633	11.26
academic_level	630	11.21
caffeine_intake_mg	600	10.67
exercise_minutes	599	10.66
screen_time_hours	586	10.43
study_hours	574	10.21
gender	558	9.93
sleep_hours	553	9.84
internet_quality	523	9.30



Matriz de Correlación de Variables Numéricas



--- Verificación de Rangos Lógicos ---

'age': Rangos OK.
 'self_study_hours': Rangos OK.
 'sleep_hours': Rangos OK.
 'caffeine_intake_mg': Rangos OK.
 'mental_health_score': Rangos OK.
 'exam_score': Rangos OK.

--- Estadísticas Descriptivas (Variables Numéricas) ---

	count	mean	std	min	25%	50%	\
student_id	5621.0	2811.00	1622.79	1.0	1406.00	2811.00	
age	4973.0	20.51	2.88	16.0	18.00	20.00	
study_hours	5047.0	4.54	1.82	0.0	3.26	4.53	
self_study_hours	4954.0	2.48	1.18	0.0	1.66	2.48	
online_classes_hours	4939.0	2.01	0.98	0.0	1.32	2.01	
social_media_hours	4965.0	3.00	1.47	0.0	2.00	2.99	
gaming_hours	4965.0	1.57	1.11	0.0	0.68	1.50	
sleep_hours	5068.0	7.02	1.16	4.0	6.25	7.02	
screen_time_hours	5035.0	6.98	2.48	1.0	5.28	6.95	

caffeine_intake_mg	5021.0	250.80	143.69	0.0	129.00	251.00
upcoming_deadline	4904.0	0.50	0.50	0.0	0.00	1.00
mental_health_score	4946.0	5.52	2.87	1.0	3.00	5.00
drug_use	1518.0	0.66	0.47	0.0	0.00	1.00
focus_index	4988.0	29.39	10.00	1.0	22.46	29.38
burnout_level	4905.0	45.63	14.26	1.0	35.77	45.65
productivity_score	4983.0	37.31	16.84	1.0	25.33	36.92
exam_score	4912.0	18.84	12.12	1.0	9.41	17.99

	75%	max
student_id	4216.00	5621.00
age	23.00	25.00
study_hours	5.76	11.84
self_study_hours	3.28	7.41
online_classes_hours	2.69	6.00
social_media_hours	4.03	8.28
gaming_hours	2.35	5.64
sleep_hours	7.82	10.00
screen_time_hours	8.70	15.30
caffeine_intake_mg	375.00	499.00
upcoming_deadline	1.00	1.00
mental_health_score	8.00	10.00
drug_use	1.00	1.00
focus_index	36.23	63.48
burnout_level	55.41	97.58
productivity_score	49.20	98.02
exam_score	27.41	64.09

--- Distribución de Variables Categóricas ---

```
[gender]
gender
Male      2213
Female    2181
Other      669
NaN        558
Name: count, dtype: int64
```


```
[academic_level]
academic_level
Postgraduate    1395
Undergraduate   1380
High School     1368
NaN              630
High School      300
Postgraduate     300
Undergraduate    248
Name: count, dtype: int64
```

```
[part_time_job]
part_time_job
No      1838
Yes     1753
NaN     703
yes     696
no      631
Name: count, dtype: int64
```

```
[internet_quality]
internet_quality
Good      1746
Average   1680
Poor      1672
NaN       523
Name: count, dtype: int64
```

--- Visualización de Distribuciones (Boxplots) ---

Boxplots de Variables Numéricas (Apoyo a decisiones de Outliers)



--- Detección Numérica de Outliers (Método IQR) ---

	Variable	Outliers	% del Total	Límite Inferior	Límite Superior
	social_media_hours	23	0.46	-1.05	7.08
	gaming_hours	18	0.36	-1.82	4.86
	burnout_level	16	0.33	6.31	84.87
	online_classes_hours	13	0.26	-0.73	4.74
	self_study_hours	12	0.24	-0.77	5.71
	exam_score	9	0.18	-17.59	54.41

```
[4]: #Limpieza strings quitar " min" y pasar a float exercise minutes
if df['exercise_minutes'].dtype == 'object':
    df['exercise_minutes'] = df['exercise_minutes'].str.replace(' min', '',
    ↪regex=False).astype(float)

# Estandarización de texto (minúsculas, sin espacios extra) para evitar
    ↪duplicados
text_cols = df.select_dtypes(include=['object']).columns
for col in text_cols:
    df[col] = df[col].astype(str).str.strip().str.lower()
    df[col] = df[col].replace('nan', np.nan)

# 1.3 Eliminación de filas basura
# Filas con demasiados nulos (>= 12)
df['null_count_row'] = df.isnull().sum(axis=1)
df.drop(index=df[df['null_count_row'] >= 12].index, inplace=True)
df.drop(columns=['null_count_row'], inplace=True)

# 1.4 Eliminación de variables problemáticas (Multicolinealidad, Endogeneidad y
    ↪Ruido)
cols_to_drop = [
    'drug_use',          # Eliminada por exceso de nulos (>70%)
    'productivity_score', # Endogeneidad severa (es una variable de resultado,
    ↪no predictora) (se observa en heatmap)
    'focus_index'       # Subjetiva y altamente correlacionada con otras
    ↪variables de input (se observa en heatmap)
]
df.drop(columns=[col for col in cols_to_drop if col in df.columns],
    ↪inplace=True)
```

```
[5]: # 1.5 Tratamiento de Nulos
# Numéricas: imputar con mediana
for col in ['age', 'exercise_minutes', 'caffeine_intake_mg']:
    if col in df.columns:
        df[col] = df[col].fillna(df[col].median())
```

```

# Categórica (estructural): imputar con moda
if 'internet_quality' in df.columns:
    df['internet_quality'] = df['internet_quality'].
    ↪ fillna(df['internet_quality'].mode()[0])

# Categóricas (demográficas): Tratamiento específico para evitar dummies basura
if 'gender' in df.columns:
    # Agrupamos los nulos (y futuros 'unknown') directamente en 'other'
    df['gender'] = df['gender'].fillna('other')

# 1.5.2 Variables Part time job y deadline: Método Missing indicator
for col in ['part_time_job', 'upcoming_deadline']:
    if col in df.columns:
        # 1. Crear variable binaria indicadora de nulo
        df[f'{col}_missing'] = np.where(df[col].isnull(), 1, 0)

        # 2. Rellenar los nulos en la columna original con 0
        df[col] = df[col].fillna(0)

        # 3. Estandarizar categóricas a numéricas estrictas (0 y 1) para ↪
        ↪ econometría
        if col == 'part_time_job':
            # Mapeamos 'yes' a 1. 'no' y los 0s recién imputados quedan como 0.
            df[col] = df[col].replace({'yes': 1, 'no': 0}).astype(int)
df['upcoming_deadline'] = df['upcoming_deadline'].astype(int)

```

C:\Users\crist\AppData\Local\Temp\ipykernel_13680\569716481.py:28:
FutureWarning: Downcasting behavior in `replace` is deprecated and will be removed in a future version. To retain the old behavior, explicitly call `result.infer\_objects(copy=False)`. To opt-in to the future behavior, set `pd.set\_option('future.no\_silent\_downcasting', True)`
df[col] = df[col].replace({'yes': 1, 'no': 0}).astype(int)

```

[6]: #Quitamos nulos de variable dependiente
df.dropna(subset=['exam_score'], inplace=True)
# Paso B: Crear la variable binaria rindio_examen
df['rindio_examen'] = np.where(df['exam_score'] == 1.0, 0, 1)

```

```

[7]: df.dropna(inplace=True) #dropna general

final_count = len(df)
print(f"Filas después de la limpieza: {final_count} (Se eliminaron ↪
    ↪ {initial_count - final_count} filas en total)")
print(df.head(2))
print(df.tail(2))

```

Filas después de la limpieza: 4163 (Se eliminaron 1458 filas en total)

```

    student_id  age  gender academic_level  study_hours  self_study_hours  \
0             1  20.0   other undergraduate      5.37           2.09
1             2  16.0  female   high school      5.85           5.04

    online_classes_hours  social_media_hours  gaming_hours  sleep_hours  ...  \
0                   1.85                   3.66           2.32           7.73  ...
1                   1.87                   3.60           2.79           6.11  ...

    caffeine_intake_mg  part_time_job  upcoming_deadline  internet_quality  \
0                   475.0              0                  0              good
1                   362.0              0                  0              good

    mental_health_score  burnout_level  exam_score  part_time_job_missing  \
0                   3.0              31.77      25.08                  0
1                   10.0             45.89      37.83                  0

    upcoming_deadline_missing  rindio_examen
0                          0              1
1                          0              1

[2 rows x 22 columns]

    student_id  age  gender academic_level  study_hours  self_study_hours  \
5616         5617  21.0   male   postgraduate      4.16           0.00
5620         5621  18.0   male   postgraduate      3.96           0.98

    online_classes_hours  social_media_hours  gaming_hours  sleep_hours  \
5616                   1.27                   4.01           3.41           8.07
5620                   1.77                   4.35           2.22           6.57

    ...  caffeine_intake_mg  part_time_job  upcoming_deadline  \
5616  ...                   152.0              0                  1
5620  ...                   154.0              0                  0

    internet_quality  mental_health_score  burnout_level  exam_score  \
5616              poor              7.0          48.07          17.15
5620              poor              3.0          36.62           2.81

    part_time_job_missing  upcoming_deadline_missing  rindio_examen
5616                   0                          0              1
5620                   0                          0              1

[2 rows x 22 columns]

```

R: Resumen Pregunta 1 EDA y limpieza. Se inicio con 5621 filas de registros.

Para analizar nulos se uso la libreria missingno para poder visualizar si existian columnas con muchos nulos o si estuvieran de maneras no aleatorias. Se encontró que drug_use tenia mas del 70% de nulos y que los nulos estaban al parecer aleatoriamente repartidos en la muestra, por lo que se decidió eliminar esta columna.

Se realizo un heatmap de correlaciones donde se encontró que productivity_score y focus_index eran variables con alta colinealidad que realmente son variables de resultado y no predictoras por lo que se decidió no usarlas y eliminarlas.

Se realizaron boxplots para analizar distribuciones de variables numericas para ver si se encontraban outliers problematicos, sin embargo se encontraron todas las variables numericas dentro de rangos logicos. Ademas se hizo el metodo IQR para analizar outliers y encontramos que los porcentajes eran muy bajos siendo el mayor, social_media_hours con el 0.5%.

Se limpió la variable exercise minutes para que sea estrictamente numerica.

Se eliminaron las variables con mas de 12 valores nulos en 1 fila.

Se imputó con la mediana las variables numericas age, exercise_minutes y caffeine intake.

Se imputó con la moda internet_quality.

Para la variable gender se decidió transformar los nulos a la categoria "other".

En el caso de part_time_job y upcoming_deadline se crearon las variables _missing y asi evitar droppear estos datos faltantes y dejarlas con un flag. Ademas se pasaron a binario estricto.

Se borraron los nulos de la variable a explicar exam_score y se creo la variable rindio examen asignando 0 a quienes tenian 1.0 (no rindieron examen) y 1 quien tenia alguna nota en el examen.

Para finalizar se hizo un dropna general para poder tener una muestra de datos fiable quedando con un total de 4163 registros.

2. Ejecute un modelo de probabilidad lineal (*MCO*) que permita explicar la probabilidad de que un alumno rinda el examen, a partir de las informacion disponible. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

```
[8]: ecuacion_mco = """
rindio_examen ~ C(academic_level, Treatment('undergraduate')) +
        social_media_hours + gaming_hours +
        mental_health_score + study_hours +
        burnout_level * sleep_hours
"""

# gender, internet_
quality, age, caffeine_intake_mg, part_time_job_missing, upcoming_deadline_missing, upcoming_dea
modelo_mco_final = smf.ols(formula=ecuacion_mco, data=df).fit(cov_type='HC1')
print(modelo_mco_final.summary())
```

OLS Regression Results

```
=====
Dep. Variable:          rindio_examen    R-squared:                0.232
Model:                  OLS              Adj. R-squared:           0.230
Method:                 Least Squares    F-statistic:              67.39
Date:                  Tue, 21 Apr 2026   Prob (F-statistic):       3.13e-116
Time:                  23:57:23          Log-Likelihood:           -115.07
No. Observations:      4163             AIC:                     250.1
Df Residuals:          4153             BIC:                     313.5
```

```

Df Model:          9
Covariance Type:   HC1
=====
=====
                                coef      std
err      z      P>|z|      [0.025      0.975]
-----
-----
Intercept                                1.1496
0.083    13.927      0.000      0.988      1.311
C(academic_level, Treatment('undergraduate'))[T.high school] -0.0327
0.009    -3.483      0.000      -0.051      -0.014
C(academic_level, Treatment('undergraduate'))[T.postgraduate] -0.0202
0.009    -2.182      0.029      -0.038      -0.002
social_media_hours                                -0.0117
0.003    -4.499      0.000      -0.017      -0.007
gaming_hours                                -0.0102
0.004    -2.874      0.004      -0.017      -0.003
mental_health_score                                0.0285
0.001    19.137      0.000      0.026      0.031
study_hours                                0.0454
0.002    18.229      0.000      0.041      0.050
burnout_level                                -0.0130
0.002    -7.182      0.000      -0.016      -0.009
sleep_hours                                -0.0469
0.010    -4.568      0.000      -0.067      -0.027
burnout_level:sleep_hours                                0.0012
0.000     5.067      0.000      0.001      0.002
=====
Omnibus:          1481.430    Durbin-Watson:          2.009
Prob(Omnibus):      0.000    Jarque-Bera (JB):      4396.376
Skew:              -1.884    Prob(JB):          0.00
Kurtosis:          6.338    Cond. No.          6.87e+03
=====

```

Notes:

[1] Standard Errors are heteroscedasticity robust (HC1)

[2] The condition number is large, 6.87e+03. This might indicate that there are strong multicollinearity or other numerical problems.

R: Se ejecutó este modelo MCO para explicar la probabilidad que un alumno rinda el examen o no. Dado que el MCO presenta por naturaleza problemas de heterocedasticidad, se utilizaron errores estándar robustos (HC1) para garantizar que la inferencia y los p-valores obtenidos fueran válidos. Durante el proceso de selección de variables para el modelo se probó y decidió dejar fuera: age, gender, internet_quality, caffeine_intake_mg, part_time_job (_missing tambien) y upcoming_deadline (_missing tambien) porque sus efectos en el modelo no eran significativos al 95% de confianza.

Las variables escogidas, que serán las mismas de aquí en adelante, y sus respectivos coeficientes

para este modelo MCO son:

- academic_level (High school): -0.0327 (-3.27 pp) | Significativa
- academic_level (Postgraduate): -0.0202 (-2.02 pp) | Significativa
- social_media_hours: -0.0117 (-1.17 pp) | Significativa
- gaming_hours: -0.0102 (-1.02 pp) | Significativa
- mental_health_score: 0.0285 (2.85 pp) | Significativa
- study_hours: 0.0454 (4.54 pp) | Significativa
- burnout_level: -0.0130 (-1.30 pp) | Significativa
- sleep_hours: -0.0469 (-4.69 pp) | Significativa
- burnout_level:sleep_hours (Interacción): 0.0012 (0.12 pp) | Significativa

Al interpretar los coeficientes encontramos varios insights, como que la probabilidad de rendir el examen aumenta en 2.85 pp por cada punto adicional en el índice de salud mental y que por cada hora adicional de estudio (study_hours), la probabilidad de presentarse al examen aumenta en 4.54 pp. Y, por el contrario, una hora extra en redes sociales o videojuegos reduce en 1.17 pp y 1.02 pp respectivamente.

También se encontró que el nivel académico afectaba la probabilidad de rendir el examen o no; se encontró que ser de “High school” o “Postgraduate” reducía su probabilidad en relación a ser “Undergraduate” (grupo base).

Finalmente, se probó la interacción burnout_level * sleep_hours con la tesis de que las horas de sueño iban a tener un efecto distinto en alguien muy agotado mentalmente que en alguien con niveles normales de agotamiento. Al ejecutar el modelo, esta interacción resultó ser positiva y significativa, es decir, que el impacto negativo del nivel de agotamiento sobre la probabilidad de rendir el examen disminuye a medida que el estudiante aumenta sus horas de sueño.

pp = Puntos Porcentuales (usado de aquí en adelante)

3. Ejecute un modelo *probit* para responder a la pregunta 2. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

```
[9]: ecuacion_probit = """
rindio_examen ~ C(academic_level, Treatment('undergraduate')) +
        social_media_hours + gaming_hours +
        mental_health_score + study_hours+
        burnout_level * sleep_hours
"""

modelo_probit = smf.probit(formula=ecuacion_probit, data=df).fit(cov_type='HC1')

# 3. Print the summary
print(modelo_probit.summary())

efectos_marginales = modelo_probit.get_margeff()
print(efectos_marginales.summary())
```

Optimization terminated successfully.

Current function value: 0.150769

Iterations 9

Probit Regression Results

```

=====
Dep. Variable:          rindio_examen    No. Observations:          4163
Model:                  Probit           Df Residuals:              4153
Method:                 MLE             Df Model:                  9
Date:                  Tue, 21 Apr 2026   Pseudo R-squ.:             0.4954
Time:                  23:57:24          Log-Likelihood:            -627.65
converged:              True             LL-Null:                   -1244.0
Covariance Type:        HC1             LLR p-value:                1.091e-259
=====

```

```

=====
                                     coef      std
err          z      P>|z|      [0.025      0.975]
-----
Intercept                                     0.8069
0.974      0.828      0.408      -1.103      2.716
C(academic_level, Treatment('undergraduate'))[T.high school] -0.3184
0.099     -3.213      0.001      -0.513     -0.124
C(academic_level, Treatment('undergraduate'))[T.postgraduate] -0.1791
0.102     -1.763      0.078      -0.378      0.020
social_media_hours                                     -0.1374
0.027     -5.013      0.000      -0.191     -0.084
gaming_hours                                     -0.0798
0.034     -2.363      0.018      -0.146     -0.014
mental_health_score                                     0.4024
0.020     19.634      0.000      0.362      0.443
study_hours                                     0.5759
0.029     19.600      0.000      0.518      0.634
burnout_level                                     -0.0628
0.017     -3.647      0.000      -0.097     -0.029
sleep_hours                                     0.0313
0.134      0.233      0.815      -0.231      0.294
burnout_level:sleep_hours                                     0.0014
0.002      0.566      0.571      -0.003      0.006
=====
=====

```

Possibly complete quasi-separation: A fraction 0.30 of observations can be perfectly predicted. This might indicate that there is complete quasi-separation. In this case some parameters will not be identified.

Probit Marginal Effects

```

=====
Dep. Variable:          rindio_examen
Method:                 dydx
At:                     overall
=====
=====

```

err	z	P> z	[0.025	0.975]	dy/dx	std

C(academic_level, Treatment('undergraduate'))[T.high school]					-0.0263	
0.008	-3.235	0.001	-0.042	-0.010		
C(academic_level, Treatment('undergraduate'))[T.postgraduate]					-0.0148	
0.008	-1.768	0.077	-0.031	0.002		
social_media_hours					-0.0114	
0.002	-5.048	0.000	-0.016	-0.007		
gaming_hours					-0.0066	
0.003	-2.375	0.018	-0.012	-0.001		
mental_health_score					0.0333	
0.001	22.385	0.000	0.030	0.036		
study_hours					0.0476	
0.002	23.222	0.000	0.044	0.052		
burnout_level					-0.0052	
0.001	-3.686	0.000	-0.008	-0.002		
sleep_hours					0.0026	
0.011	0.233	0.816	-0.019	0.024		
burnout_level:sleep_hours					0.0001	
0.000	0.567	0.571	-0.000	0.001		
=====						
=====						

R: Tras el modelo MCO es necesario estimar un modelo Probit, ya que el MCO asume efectos marginales constantes y se podrían generar predicciones/probabilidades irreales. El modelo Probit arregla esto ya que utiliza una CDF normal haciendo que las predicciones estén entre 0 y 1. Se ejecutó el modelo Probit con las mismas variables que el MCO y con corrección HC1, obteniendo un pseudo R-cuadrado de 0.4954. Las variables escogidas y sus respectivos efectos marginales para este modelo Probit son: * academic_level (High school): -0.3184 (-2.63 pp) | Significativa * academic_level (Postgraduate): -0.1791 (-1.48 pp) | No significativa * social_media_hours: -0.1374 (-1.14 pp) | Significativa * gaming_hours: -0.0798 (-0.66 pp) | Significativa * mental_health_score: 0.4024 (3.33 pp) | Significativa * study_hours: 0.5759 (4.76 pp) | Significativa * burnout_level: -0.0628 (-0.52 pp) | Significativa * sleep_hours: 0.0313 (0.26 pp) | No significativa * burnout_level:sleep_hours (Interacción): 0.0014 (0.01 pp) | No significativa

*pp extraídos de tabla de efectos marginales.

Al observar los efectos marginales se observa que la variable que más influye en si un estudiante rindió o no el examen son las horas de estudio; una hora extra aumenta la probabilidad de presentarse en 4.76 pp. Por otro lado, el índice de salud mental suma 3.33 pp por punto adicional, mientras que las horas de redes sociales y gaming siguen teniendo un efecto negativo.

Lo diferente con el modelo MCO fue que ahora la interacción entre burnout_level y sleep_hours ya no es significativa en este modelo Probit. Esto nos demuestra que al usar una CDF normal la interacción de estas variables se hace redundante para explicar la variable.

4. Ejecute un modelo *logit* para responder a la pregunta 2. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.


```
[ ]: ecuacion_logit = """
rindio_examen ~ C(academic_level, Treatment('undergraduate')) +
               social_media_hours + gaming_hours + study_hours +
               mental_health_score +
               burnout_level * sleep_hours
"""

# 2. Ajustar el modelo Logit
modelo_logit = smf.logit(formula=ecuacion_logit, data=df).fit(cov_type='HC1')

# 3. Imprimir el resumen tradicional
print("=== Resumen Tradicional Logit ===")
print(modelo_logit.summary())

# 4. Obtener los Odds Ratios (OR)
print("\n=== Odds Ratios (Para interpretar) ===")
# Elevamos 'e' a los coeficientes estimados
odds_ratios = np.exp(modelo_logit.params)
print(odds_ratios)
```

Optimization terminated successfully.

Current function value: 0.151804

Iterations 9

=== Resumen Tradicional Logit ===

Logit Regression Results

```
=====
Dep. Variable:          rindio_examen    No. Observations:          4163
Model:                  Logit           Df Residuals:             4153
Method:                 MLE            Df Model:                 9
Date:                  Tue, 21 Apr 2026   Pseudo R-squ.:             0.4920
Time:                  23:57:24          Log-Likelihood:            -631.96
converged:              True             LL-Null:                  -1244.0
Covariance Type:        HC1             LLR p-value:              7.935e-258
=====
```

```
=====
                                coef    std
err          z      P>|z|      [0.025    0.975]
-----
Intercept                                1.3037
1.853      0.703      0.482      -2.329      4.936
C(academic_level, Treatment('undergraduate'))[T.high school] -0.5929
0.187     -3.178      0.001      -0.959     -0.227
C(academic_level, Treatment('undergraduate'))[T.postgraduate] -0.3550
0.193     -1.839      0.066      -0.733      0.023
social_media_hours                    -0.2537
0.052     -4.895      0.000      -0.355     -0.152
gaming_hours                          -0.1521
```

0.063	-2.428	0.015	-0.275	-0.029	
study_hours					1.0554
0.055	19.136	0.000	0.947	1.163	
mental_health_score					0.7371
0.039	19.030	0.000	0.661	0.813	
burnout_level					-0.1145
0.033	-3.516	0.000	-0.178	-0.051	
sleep_hours					0.0715
0.256	0.280	0.780	-0.430	0.573	
burnout_level:sleep_hours					0.0027
0.005	0.582	0.560	-0.006	0.012	
=====					
=====					

=== Odds Ratios (Para interpretar) ===

Intercept	3.682973
C(academic_level, Treatment('undergraduate'))[T.hi school]	0.552725
C(academic_level, Treatment('undergraduate'))[T.postgraduate]	0.701163
social_media_hours	0.775941
gaming_hours	0.858869
study_hours	2.872996
mental_health_score	2.089846
burnout_level	0.891779
sleep_hours	1.074126
burnout_level:sleep_hours	1.002721
dtype: float64	

R: Finalmente para contrastar la robustez de resultados del probit se ejecutó un modelo Logit que a diferencia de probit, este asume una distribución logística de errores haciendo “colas mas pesadas” lo que lo hace útil cuando se sospecha de “outliers”, además con logit se pueden calcular “Odds Ratios”.

Las variables escogidas, sus coeficientes, su correspondiente Odds Ratio (OR) y su significancia para este modelo Logit son:

- academic_level (High school): -0.5929 (0.55 OR) | Significativa
- academic_level (Postgraduate): -0.3550 (0.70 OR) | No significativa
- social_media_hours: -0.2537 (0.78 OR) | Significativa
- gaming_hours: -0.1521 (0.86 OR) | Significativa
- mental_health_score: 0.7371 (2.09 OR) | Significativa
- study_hours: 1.0554 (2.87 OR) | Significativa
- burnout_level: -0.1145 (0.89 OR) | Significativa
- sleep_hours: 0.0715 (1.07 OR) | No significativa
- burnout_level:sleep_hours (Interacción): 0.0027 (1.00 OR) | No significativa

Manteniendo las mismas variables de los últimos dos modelos, se observó en primer lugar el log-likelihood (-631.96) que al compararlo rápidamente con probit (-627.65) nos dice que probit tiene un mejor ajuste a los datos.

Pasando a los odds ratios, se observa que por cada hora adicional de estudio la probabilidad relativa

aumenta en 187% (2.87 veces mas probable). En el mismo sentido está el indice de salud mental por cada punto adicional las odds de rendir el examen se duplican (OR de 2.08). Por el contrario horas adicionales de redes sociales tienen un Odd ratio menor a 1, es decir, hora adicional en redes sociales resulta en un 23% menos de probabilidad en presentarse al examen. Además la interacción que resultó significativa en MCO (`sleep_hours * burnout_level`) ya no es significativa.

5. Comente los resultados obtenidos en 2, 3 y 4. ¿Cuáles y por qué existen las diferencias entre los resultados?. En su opinión, ¿Cuál sería el más adecuado para responder la pregunta de investigación y por qué? ¿Qué variables resultaron ser robustas a la especificación?

R: Al comparar los 3 modelos que intentan explicar qué influye en que el estudiante rinda el examen o no, encontramos diferencias en la magnitud de los coeficientes que se puede explicar por los supuestos de cada modelo. El MCO estima efectos constantes, por lo que la mayor diferencia entre este y los modelos que utilizan CDF es que la variable conjunta `sleep_hours * burnout_level` pasa de ser significativa en MCO a no significativa en Probit y Logit. Esto ocurre porque los modelos como probit y logit ya capturan que los efectos marginales no son constantes, haciendo que la interacción explícita sea redundante.


Tras analizar los “outputs” de los modelos, en mi opinión el mas adecuado es el Probit. Este supera al MCO ya que encierra las probabilidades entre 0 y 1, y supera al logit en que se ajusta mejor a los datos (Log-likelihood menos negativo que Logit) y un pseudo R-cuadrado ligeramente mayor.

Finalmente, las variables que resultaron ser robustas a la especificación fueron: `study_hours`, `social_media_hours`, `gaming_hours`, `mental_health_score` y `burnout_level`. Confirmando que las horas de estudio, las horas de ocio y la salud mental son las variables que mas influyen a los estudiantes en si presentarse o no al examen.

6. Use un modelo Poisson para explicar la nota del examen, entre aquellos alumnos que lo rindieron. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

```
[ ]: #Creamos dataframe solo con alumnos que rindieron el examen, es decir, que
      ↪tengan una nota asignada.
df_poisson = df[(df['rindio_examen'] == 1) & (df['exam_score'] > 1.0)].copy()

# 2. Histograma
plt.hist(df_poisson['exam_score'], bins=30, color='steelblue',
      ↪edgecolor='black')
plt.title('Distribución de Notas (Alumnos que rindieron)')
plt.xlabel('Nota del Examen')
plt.ylabel('Frecuencia')
plt.show()
```



Al observar el histograma, se confirma que la distribución no es perfectamente normal y es en su totalidad positiva, como Poisson funciona como un conteo de puntos obtenidos se transforma en buena opción para modelar los datos.

```
[12]: # Definimos la ecuación, ahora con variable Y, la nota del examen.
ecuacion_poisson = """
exam_score ~ C(academic_level, Treatment('undergraduate')) +
              study_hours + social_media_hours + gaming_hours +
              mental_health_score +
              burnout_level * sleep_hours
"""

# Ajustar el modelo
modelo_poisson = smf.poisson(formula=ecuacion_poisson, data=df_poisson).
    ↪ fit(cov_type='HC1')
print(modelo_poisson.summary())

# Predicciones
df_poisson['ppredictions'] = modelo_poisson.predict(df_poisson).astype(float)
```

```
# Mostramos una comparativa rápida de la nota real vs la nota predicha
print("\nComparativa Real vs Predicción:")
print(df_poisson[['exam_score', 'ppredictions']].head())
```

Optimization terminated successfully.

Current function value: 3.433325

Iterations 6

Poisson Regression Results

```
=====
Dep. Variable:          exam_score    No. Observations:          3795
Model:                  Poisson      Df Residuals:              3785
Method:                 MLE          Df Model:                  9
Date:                  Tue, 21 Apr 2026    Pseudo R-squ.:            0.3878
Time:                  23:57:24          Log-Likelihood:           -13029.
converged:              True            LL-Null:                  -21282.
Covariance Type:        HC1            LLR p-value:              0.000
=====
```

```
=====
                                coef      std
err          z      P>|z|      [0.025      0.975]
-----
Intercept                                2.4670
0.105      23.438      0.000      2.261      2.673
C(academic_level, Treatment('undergraduate'))[T.high school]      0.0103
0.012       0.857      0.391      -0.013      0.034
C(academic_level, Treatment('undergraduate'))[T.postgraduate]      0.0002
0.012       0.018      0.985      -0.024      0.024
study_hours                                0.1610
0.003      55.240      0.000      0.155      0.167
social_media_hours                        -0.0418
0.003     -12.371      0.000      -0.048      -0.035
gaming_hours                             -0.0287
0.005      -6.362      0.000      -0.038      -0.020
mental_health_score                        0.1116
0.002      59.258      0.000      0.108      0.115
burnout_level                           -0.0216
0.002      -9.768      0.000      -0.026      -0.017
sleep_hours                             -0.0095
0.013      -0.719      0.472      -0.035      0.016
burnout_level:sleep_hours                  0.0008
0.000       2.690      0.007      0.000      0.001
=====
```

Comparativa Real vs Predicción:

```
exam_score  ppredictions
0          25.08      17.895986
```

1	37.83	32.460688
2	18.66	21.092303
4	7.78	8.804708
6	11.17	11.159283

R: Se ejecutó un modelo Poisson filtrando la muestra exclusivamente para aquellos alumnos que efectivamente rindieron el examen (`rindio_examen == 1`) para observar qué variables influyen más en explicar la nota obtenida en el examen; en el caso de Poisson, los coeficientes representan cambios porcentuales en la variable Y. Las variables escogidas, sus coeficientes, el cambio porcentual esperado en la nota y su significancia para este modelo Poisson son:

- `academic_level` (High school): 0.0103 (+1.0%) | No significativa
- `academic_level` (Postgraduate): 0.0002 (+0.0%) | No significativa
- `social_media_hours`: -0.0418 (-4.1%) | Significativa
- `gaming_hours`: -0.0287 (-2.8%) | Significativa
- `mental_health_score`: 0.1116 (+11.8%) | Significativa
- `study_hours`: 0.1610 (+17.5%) | Significativa
- `burnout_level`: -0.0216 (-2.1%) | Significativa
- `sleep_hours`: -0.0095 (-0.9%) | No significativa
- `burnout_level:sleep_hours` (Interacción): 0.0008 (+0.1%) | Significativa

Al ver los coeficientes vemos que por cada hora más de estudio, la nota aumenta aproximadamente un 17.5% ($\exp(0.1610) - 1$); del mismo modo, por cada punto adicional en el índice de salud mental, la nota aumenta en 11.8%. En el caso de las variables que disminuyen la nota están las horas en redes sociales y videojuegos, con una disminución del 4.1% y 2.8% respectivamente. Vemos además que el nivel académico no influye en la nota obtenida (no es significativa).

Finalmente, vemos que la variable conjunta `burnout_level * sleep_hours` vuelve a ser positiva y significativa al 95% de confianza, lo que nos da a entender que las horas de sueño pueden amortiguar el efecto negativo de la carga mental en la nota que obtienen los estudiantes.

7. Determine si existe sobre dispersión en la data y posible valor óptimo de α para un modelo Binomial Negativa.

```
[ ]: # 1. Obtener la predicción del modelo Poisson (lambda)
df_poisson['lambda_hat'] = modelo_poisson.predict()

# 2. Calcular la variable auxiliar
# [(y - lambda)^2 - lambda] / lambda
df_poisson['aux'] = ((df_poisson['exam_score'] - df_poisson['lambda_hat'])**2 -
                    df_poisson['lambda_hat']) / df_poisson['lambda_hat']

# 3. Regresión auxiliar OLS
test_alpha = smf.ols('aux ~ lambda_hat - 1', data=df_poisson).fit()

# 4. Imprimir resultados
print(test_alpha.summary())
```

OLS Regression Results

=====

```

=====
Dep. Variable:          aux    R-squared (uncentered):
0.073
Model:                  OLS    Adj. R-squared (uncentered):
0.073
Method:                  Least Squares    F-statistic:
299.6
Date:                    Tue, 21 Apr 2026    Prob (F-statistic):
1.14e-64
Time:                    23:57:24    Log-Likelihood:
-9432.0
No. Observations:        3795    AIC:
1.887e+04
Df Residuals:            3794    BIC:
1.887e+04
Df Model:                  1
Covariance Type:          nonrobust
=====

```

	coef	std err	t	P> t	[0.025	0.975]
lambda_hat	0.0357	0.002	17.310	0.000	0.032	0.040

```

=====
Omnibus:                  2107.056    Durbin-Watson:                  1.961
Prob(Omnibus):             0.000    Jarque-Bera (JB):                18590.651
Skew:                      2.530    Prob(JB):                        0.00
Kurtosis:                  12.589    Cond. No.                        1.00
=====

```

Notes:

[1] R^2 is computed without centering (uncentered) since the model does not contain a constant.

[2] Standard Errors assume that the covariance matrix of the errors is correctly specified.

R: Uno de los supuestos fundamentales del modelo de Poisson es la equidispersión, es decir, que la media de la variable dependiente sea igual a su varianza. Si existe sobredispersión (la varianza es mayor que la media), el modelo deja de ser metodológicamente válido.

Para verificar este supuesto, se realizó un test de equidispersión que consiste en estimar una regresión MCO sin constante utilizando una variable auxiliar teórica y las predicciones ajustadas del modelo de Poisson (λ_{hat}). El coeficiente resultante de esta regresión representa el parámetro de dispersión α , cuyo valor estimado es de 0.0357.

Al observar el output, vemos que este coeficiente es altamente significativo ($p = 0.000$), por lo que se rechaza la hipótesis nula de equidispersión. Esto confirma que existe sobredispersión en las notas del examen, concluyendo así que el modelo Poisson es deficiente para estimar estos datos y se debe recurrir a un modelo Binomial Negativo para corregir la varianza inflada.

8. Usando la informacion anterior, ejecute un modelo Binomial Negativa para responder a la pregunta 6. Seleccione las variables dependientes a incluir en el modelo final e interprete su

significado.

```
[14]: df_poisson['burnout_z'] = (df_poisson['burnout_level'] -
    ↪df_poisson['burnout_level'].mean()) / df_poisson['burnout_level'].std()
df_poisson['sleep_z'] = (df_poisson['sleep_hours'] - df_poisson['sleep_hours'].
    ↪mean()) / df_poisson['sleep_hours'].std()

# 2. Usamos las variables estandarizadas solo en la interacción
ecuacion_nb_final = """
exam_score ~ C(academic_level, Treatment('undergraduate')) +
    study_hours + social_media_hours + gaming_hours +
    mental_health_score +
    burnout_z * sleep_z
"""

# 3. Ajustamos el modelo Binomial Negativo
modelo_nb = smf.negativebinomial(formula=ecuacion_nb_final, data=df_poisson).
    ↪fit(method='bfgs', maxiter=2000)

# 4. Imprimir resultados
print("=== Resultados del Modelo Binomial Negativo ===")
print(modelo_nb.summary())
```

Optimization terminated successfully.

Current function value: 3.288973

Iterations: 20

Function evaluations: 29

Gradient evaluations: 29

=== Resultados del Modelo Binomial Negativo ===

NegativeBinomial Regression Results

```
=====
Dep. Variable:          exam_score    No. Observations:          3795
Model:                NegativeBinomial    Df Residuals:          3785
Method:                  MLE    Df Model:              9
Date:                  Tue, 21 Apr 2026    Pseudo R-squ.:          0.1386
Time:                  23:57:24    Log-Likelihood:         -12482.
converged:              True    LL-Null:           -14490.
Covariance Type:        nonrobust    LLR p-value:           0.000
=====
```

```
=====
                                coef    std
err          z      P>|z|      [0.025      0.975]
-----
Intercept                                1.6054
0.026      61.870      0.000      1.555      1.656
C(academic_level, Treatment('undergraduate'))[T.high school]  0.0089
0.013      0.670      0.503      -0.017      0.035
=====
```


C(academic_level, Treatment('undergraduate'))[T.postgraduate]	-0.0030
0.013 -0.224 0.822 -0.029 0.023	
study_hours	0.1729
0.003 54.700 0.000 0.167 0.179	
social_media_hours	-0.0454
0.004 -12.325 0.000 -0.053 -0.038	
gaming_hours	-0.0309
0.005 -6.246 0.000 -0.041 -0.021	
mental_health_score	0.1180
0.002 59.567 0.000 0.114 0.122	
burnout_z	-0.2380
0.006 -37.707 0.000 -0.250 -0.226	
sleep_z	0.0324
0.006 5.201 0.000 0.020 0.045	
burnout_z:sleep_z	0.0120
0.005 2.376 0.017 0.002 0.022	
alpha	0.0574
0.003 19.953 0.000 0.052 0.063	

=====

=====

R: Tras haber realizado el test y demostrado sobredispersión en los datos, se procedió a estimar un modelo Binomial Negativo utilizando las mismas variables del modelo Poisson. Sin embargo, al intentar ejecutarlo, el modelo tuvo problemas para converger debido a la complejidad computacional que conlleva la interacción de variables continuas (como burnout_level con sleep_hours) al mismo tiempo que estima el parámetro α . Para solucionar este problema matemático sin alterar la teoría, se estandarizaron estas dos variables (pasándolas a puntuación Z o z-scores). Esto hace que las variables queden centradas en cero, estabilizando el algoritmo.

Al ejecutarlo nuevamente, el modelo convergió exitosamente. El parámetro de dispersión α se estimó en 0.0574, siendo altamente significativo ($p = 0.000$), lo que ratifica que la Binomial Negativa es la especificación correcta frente a Poisson.

Las variables escogidas, sus coeficientes, el cambio porcentual esperado en la nota y su significancia para este modelo Binomial Negativo son:

- academic_level (High school): 0.0089 (+0.9%) | No significativa
- academic_level (Postgraduate): -0.0030 (-0.3%) | No significativa
- social_media_hours: -0.0454 (-4.4%) | Significativa
- gaming_hours: -0.0309 (-3.0%) | Significativa
- mental_health_score: 0.1180 (+12.5%) | Significativa
- study_hours: 0.1729 (+18.9%) | Significativa
- burnout_z: -0.2380 (-21.2%) | Significativa
- sleep_z: 0.0324 (+3.3%) | Significativa
- burnout_z:sleep_z (Interacción): 0.0120 (+1.2%) | Significativa

Al interpretar los coeficientes vemos que una hora adicional de estudio aumenta la nota esperada en un 18.9% ($\exp(0.1729) - 1$) y, por el contrario, una hora de uso de redes sociales disminuye la nota en un 4.4% ($\exp(-0.0454) - 1$). Otro coeficiente con gran influencia es el índice de salud mental, que suma un 12.5% a la nota esperada por cada aumento en una unidad de este índice.

Finalmente, la interacción propuesta de `burnout_z * sleep_z` mantuvo su significancia al 95% de confianza y su signo positivo. Esto comprueba que el efecto negativo de estar agotado mentalmente se amortigua con las horas de sueño (cuando estas se desvían positivamente del promedio), disminuyendo el impacto severo que el estrés conllevaría en la nota final. Dado que el nivel de agotamiento fue estandarizado, su coeficiente indica que un aumento de una desviación estándar por encima del promedio en el nivel de burnout de un alumno penaliza su nota esperada en 21.2% ($\exp(-0.2380) - 1$).

9. Comente los resultados obtenidos en 6, 7 y 8. ¿Cuáles y por qué existen las diferencias entre los resultados?. En su opinión, ¿Cuál sería el más adecuado para responder la pregunta de investigación y por qué? ¿Qué variables resultaron ser robustas a la especificación?

R: Al comparar los outputs de los modelos Poisson y Binomial Negativo, notamos que sus coeficientes son prácticamente idénticos; sin embargo, los errores estándar son distintos, siendo mayores en el modelo Binomial Negativo. Esto ocurre porque el modelo de Poisson asume que la media y la varianza son iguales, supuesto que comprobamos que no se cumple tras realizar un test de dispersión. Como consecuencia, en el modelo Poisson se inflan los estadísticos z , lo que lleva a pensar erróneamente que ciertas variables son más significativas. En contraste, el modelo Binomial Negativo reconoce que existe una mayor dispersión en los datos, por lo que ajusta y aumenta los errores estándar.

En mi opinión, el modelo más adecuado es el Binomial Negativo. Al corregir la deficiencia del modelo Poisson estimando simultáneamente el parámetro α , asegura que la significancia estadística y los coeficientes de las variables sean válidos y no estén sesgados.

Para finalizar, las variables que resultaron robustas a la especificación son: `study_hours`, `social_media_hours`, `gaming_hours`, `mental_health_score` y la interacción propuesta `burnout_level * sleep_hours`. Esto confirma nuevamente que el ocio, las horas de estudio y el agotamiento mental son los factores que más influyen en el resultado de los estudiantes en el examen.

1.0.1 Conclusion final

R: Considerando el recorrido metodológico y los resultados de ambas etapas (probabilidad de asistir y nota obtenida), las variables de: * Esfuerzo (estudio) * Ocio digital (pantallas) * Bienestar psicológico (salud mental y estrés)

demonstraron ser los determinantes estructurales, causales y estadísticamente robustos del comportamiento académico de esta muestra por lo que para un modelo definitivo a presentar deben incluirse.