



TAREA_1_CONSTANZA_LUARTE

April 28, 2026

Tarea 1 2026

Constanza Luarte Salazar 2022428147

0.0.1 1.1 Librerías y carga de base de datos

```
[1]: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import statsmodels.api as sm
import statsmodels.formula.api as smf
import statsmodels.api as sm
import seaborn as sns
from statsmodels.stats.outliers_influence import variance_inflation_factor
from scipy.stats import poisson as sp_poisson
import warnings
warnings.filterwarnings("ignore")
```

0.0.2 1.1 Cargar base de datos, revisar tipos de datos, inconsistencias y valores faltantes

```
[2]: # Cargar base de datos
df = pd.read_csv('student_productivity.csv', delimiter=",", decimal='.')
# Establecer student_id como índice del DataFrame
df.set_index('student_id', inplace=True)

print(f' Dimensiones del DataFrame ')
print(f' {df.shape}\n')
di=df.shape # Para guardar dimensiones iniciales y compararlo tras limpieza e
↳ imputación

print("\n Tipos de datos ")
print(df.dtypes.to_string())

print("\n Nulos por columna ")
print(df.isnull().sum())

# Revisar unique de las columnas categóricas (object)
for col in df.select_dtypes(include='object').columns:
```

```
print(f"Categorías en {col}: {df[col].unique()}")
```

```
Dimensiones del DataFrame  
(5621, 21)
```

Tipos de datos

age	float64
gender	object
academic_level	object
study_hours	float64
self_study_hours	float64
online_classes_hours	float64
social_media_hours	float64
gaming_hours	float64
sleep_hours	float64
screen_time_hours	float64
exercise_minutes	object
caffeine_intake_mg	float64
part_time_job	object
upcoming_deadline	float64
internet_quality	object
mental_health_score	float64
drug_use	float64
focus_index	float64
burnout_level	float64
productivity_score	float64
exam_score	float64

Nulos por columna

age	648
gender	558
academic_level	630
study_hours	574
self_study_hours	667
online_classes_hours	682
social_media_hours	656
gaming_hours	656
sleep_hours	553
screen_time_hours	586
exercise_minutes	599
caffeine_intake_mg	600
part_time_job	703
upcoming_deadline	717
internet_quality	523
mental_health_score	675
drug_use	4103
focus_index	633

```

burnout_level          716
productivity_score     638
exam_score             709
dtype: int64
Categorias en gender: [nan 'Female' 'Male' 'Other']
Categorias en academic_level: ['Undergraduate' 'High School' 'Undergraduate '
'Postgraduate' nan
'High School ' 'Postgraduate ']
Categorias en exercise_minutes: ['54.0' '63.0' '28.0' '55.0' '60.0' '43.0'
'52.0' '125.0' '26.0' '148.0'
'16.0' '1.0' '102.0' '134.0' '122.0' '121.0 min' '10.0' '79.0' '65.0' nan
'30.0' '14.0' '22.0 min' '41.0' '133.0' '147.0' '62.0' '127.0' '89.0'
'61.0' '10.0 min' '35.0' '6.0' '42.0' '124.0' '136.0' '31.0' '46.0'
'84.0' '29.0' '80.0 min' '106.0' '4.0' '8.0' '71.0' '129.0' '96.0'
'137.0' '123.0' '78.0' '108.0' '19.0' '11.0' '131.0' '111.0' '113.0'
'74.0' '85.0' '39.0' '88.0' '42.0 min' '110.0' '83.0' '126.0' '98.0 min'
'18.0' '92.0' '13.0' '17.0' '27.0' '67.0 min' '23.0' '76.0 min'
'70.0 min' '95.0' '50.0' '119.0' '15.0' '91.0' '90.0 min' '5.0' '76.0'
'32.0' '84.0 min' '101.0' '33.0' '114.0' '132.0' '118.0' '68.0' '25.0'
'100.0' '107.0' '105.0 min' '81.0 min' '120.0' '105.0' '57.0' '88.0 min'
'64.0' '90.0' '94.0' '66.0' '99.0' '77.0' '85.0 min' '52.0 min' '67.0'
'59.0' '104.0' '140.0' '7.0' '75.0' '144.0 min' '38.0' '97.0 min'
'109.0 min' '12.0' '73.0' '109.0' '115.0' '149.0' '56.0' '34.0' '139.0'
'82.0 min' '141.0' '71.0 min' '44.0' '2.0' '51.0' '35.0 min' '112.0'
'74.0 min' '20.0 min' '49.0' '143.0' '20.0' '25.0 min' '108.0 min' '3.0'
'36.0' '70.0' '87.0' '40.0 min' '130.0' '48.0' '83.0 min' '1.0 min'
'53.0' '138.0' '44.0 min' '116.0' '24.0' '126.0 min' '93.0' '116.0 min'
'33.0 min' '21.0' '142.0' '117.0' '22.0' '80.0' '58.0' '41.0 min'
'7.0 min' '145.0' '72.0 min' '146.0' '94.0 min' '103.0 min' '97.0' '69.0'
'121.0' '9.0' '72.0' '124.0 min' '9.0 min' '135.0' '45.0 min' '104.0 min'
'102.0 min' '47.0' '142.0 min' '144.0' '89.0 min' '91.0 min' '135.0 min'
'86.0' '112.0 min' '57.0 min' '81.0' '98.0' '40.0' '0.0' '136.0 min'
'37.0 min' '61.0 min' '73.0 min' '143.0 min' '58.0 min' '2.0 min'
'119.0 min' '49.0 min' '125.0 min' '51.0 min' '133.0 min' '115.0 min'
'47.0 min' '37.0' '93.0 min' '130.0 min' '34.0 min' '48.0 min' '103.0'
'54.0 min' '43.0 min' '78.0 min' '147.0 min' '123.0 min' '132.0 min'
'128.0' '120.0 min' '82.0' '145.0 min' '68.0 min' '141.0 min' '131.0 min'
'8.0 min' '146.0 min' '15.0 min' '99.0 min' '69.0 min' '30.0 min'
'65.0 min' '59.0 min' '29.0 min' '53.0 min' '24.0 min' '45.0' '18.0 min'
'79.0 min' '110.0 min' '149.0 min' '12.0 min' '122.0 min' '62.0 min'
'96.0 min' '66.0 min' '114.0 min' '127.0 min' '137.0 min' '100.0 min'
'0.0 min' '21.0 min' '75.0 min' '56.0 min' '139.0 min' '87.0 min'
'19.0 min' '39.0 min' '77.0 min' '128.0 min' '95.0 min' '113.0 min'
'117.0 min' '134.0 min' '138.0 min' '111.0 min' '36.0 min' '26.0 min'
'50.0 min' '17.0 min' '5.0 min' '118.0 min' '27.0 min' '140.0 min'
'11.0 min' '16.0 min' '63.0 min' '28.0 min' '106.0 min' '6.0 min'
'3.0 min' '46.0 min' '92.0 min' '32.0 min' '86.0 min' '31.0 min'
'14.0 min' '60.0 min' '38.0 min' '4.0 min' '107.0 min' '148.0 min'

```

'23.0 min' '64.0 min']
 Categorías en part_time_job: ['No' 'no' 'Yes' 'yes' nan]
 Categorías en internet_quality: ['Good' 'Average' 'Poor' nan]

0.0.3 1.2 Limpieza y estandarización

Variable	Problema detectado	Decisión
drug_use	72.99 % de faltantes	Eliminar columna
exercise_minutes	Es de tipo object; 602 obs. contienen el sufijo ' min' (ej. '42.0 min')	Limpiar sufijo y convertir a numérico. Se elimina esta columna y en su lugar se usa exercise_hours
exercise_hours	Exercise_minutes no comparte la misma unidad de medida que las demás (horas)	Crear otra columna a partir de Exercise_minutes, convertirla a horas (dividir en 60)
academic_level	Espacios en blanco al final generan 7 pseudo-categorías en lugar de 3	Quitar espacios en blanco
part_time_job	Capitalización inconsistente: 'Yes', 'yes', 'No', 'no'	Normalizar a minúsculas y mapear a binaria {0, 1}
exam_score	Datos faltantes	Al ser la variable binaria, se descartan las filas con valores nulos de exam_score de la base de datos
took_exam	1.0 indica ausencia al examen, no una nota real	Crear la variable binaria took_exam. took_exam = 1 si exam_score > 1.0, 0 en caso contrario
study_hours	Ambigüedad de definición: en ~49 % de observaciones, study_hours < self_study_hours + online_classes_hours	Se decide utilizar solo study_hours en el modelo
part_time_job, upcoming_deadline	Nulos estructurales (~12-13 %)	Se comprobó que imputar nulos introduce sesgo, entonces se decide realizar una eliminación por lista.

```
[3]: df = df.dropna(subset=['exam_score']) # Eliminar nulos de la variable
      ↳ dependiente
df = df.drop_duplicates() # Eliminar filas duplicadas en caso de
      ↳ existir
df = df.drop('drug_use', axis=1) # Eliminar la columna drug_use por su
      ↳ alto porcentaje de nulos (70%)
di2=df.shape
```

```

# Manipulación de variables
df['exercise_minutes'] = df['exercise_minutes'].str.replace(' min', '',
    ↪ regex=False) # Quitar " min" de exercise_minutes
df['exercise_hours'] = pd.to_numeric(df['exercise_minutes'], errors='coerce') /
    ↪ 60 # Convertirlo numerico y a horas
df['academic_level'] = df['academic_level'].str.strip()
    ↪ # Quitar espacios de academic_level
df['part_time_job'] = df['part_time_job'].str.strip().str.lower()
    ↪ # Dejar part_time_job en minúscula

# Creación de variables binarias
df = df.dropna(subset=["exam_score"])
df["took_exam"] = (df["exam_score"] != 1.0).astype(int) # 1.0 en
    ↪ exam_score indica que no rindió (1: rindió examen, 0: no)
print(df["took_exam"].value_counts(normalize=True).round(2))

df['part_time_job'] = df['part_time_job'].map({'yes': 1, 'no': 0}) # (1: tiene
    ↪ trabajo a tiempo parcial, 0: no)
df['gamer'] = np.where(df['gaming_hours'] == 0, 0, 1) # 0 en
    ↪ gaming_hours indica que no es gamer. (1: es gamer, 0: no)
df.loc[df['gaming_hours'].isna(), 'gamer'] = np.nan # Si
    ↪ gaming_hours es nan, gamer también debe ser nan

# Eliminar columnas
df.drop('exercise_minutes', axis=1, inplace=True) # Se usará
    ↪ exercise_hours en su lugar
print(f"\nDimensiones tras limpieza inicial: {df.shape}")

```

```

took_exam
1    0.91
0    0.09
Name: proportion, dtype: float64

```

Dimensiones tras limpieza inicial: (4912, 22)

0.0.4 1.3 Estadísticas descriptivas

```

[4]: print(" Descriptivas de variables numéricas ")
num_cols = df.select_dtypes(include="number").columns.drop(["took_exam",
    ↪ "exam_score"], errors='ignore')
desc = df[num_cols].describe().T
desc['skewness'] = df[num_cols].skew()
desc['kurtosis'] = df[num_cols].kurt()
desc.columns.name = "Estadísticos"
pd.options.display.float_format = '{:.2f}'.format
desc[["count", "mean", "std", "min", "50%", "max", "skewness", "kurtosis"]]

```

Descriptivas de variables numéricas

```
[4]: Estadísticos      count    mean    std    min    50%    max    skewness \
age                4690.00   20.51   2.87  16.00   21.00   25.00    -0.01
study_hours        4742.00    4.53   1.82   0.00    4.53   11.84     0.06
self_study_hours   4700.00    2.48   1.18   0.00    2.48    7.41     0.08
online_classes_hours 4698.00    2.01   0.98   0.00    2.01    6.00     0.12
social_media_hours 4696.00    3.00   1.47   0.00    2.98    8.28     0.12
gaming_hours       4710.00    1.57   1.11   0.00    1.49    5.64     0.43
sleep_hours        4760.00    7.03   1.16   4.00    7.03   10.00    -0.00
screen_time_hours  4774.00    6.98   2.49   1.00    6.96   15.30    -0.00
caffeine_intake_mg 4740.00  250.92 144.04  0.00  251.00 499.00   -0.02
part_time_job      4672.00    0.50   0.50   0.00    0.00    1.00     0.00
upcoming_deadline  4699.00    0.50   0.50   0.00    1.00    1.00    -0.01
mental_health_score 4714.00    5.52   2.88   1.00    5.50   10.00     0.00
focus_index       4711.00   29.47   9.95   1.00   29.47   63.48     0.03
burnout_level      4676.00   45.65  14.22   1.00   45.72   97.58     0.05
productivity_score 4749.00   37.37  16.85   1.00   37.01   98.02     0.09
exercise_hours     4772.00    1.24   0.72   0.00    1.25    2.48     0.00
gamer              4710.00    0.89   0.31   0.00    1.00    1.00    -2.49
```

```
Estadísticos      kurtosis
age                -1.23
study_hours        -0.13
self_study_hours   -0.31
online_classes_hours -0.26
social_media_hours -0.21
gaming_hours       -0.36
sleep_hours        -0.15
screen_time_hours  -0.24
caffeine_intake_mg -1.19
part_time_job      -2.00
upcoming_deadline  -2.00
mental_health_score -1.24
focus_index       -0.17
burnout_level      -0.18
productivity_score -0.38
exercise_hours     -1.19
gamer              4.20
```

0.0.5 1.4 Distribuciones y detección de outliers

```
[5]: # 1. DEFINICIÓN DE LISTAS (Motor del análisis)
vars_plot = ["study_hours", "self_study_hours", "online_classes_hours",
             "social_media_hours", "gaming_hours", "sleep_hours",
             "screen_time_hours", "exercise_hours", "caffeine_intake_mg",
```

```

        "mental_health_score", "focus_index", "burnout_level",
        ↪ "productivity_score"]

cat_cols = ["gender", "academic_level", "internet_quality",
            "upcoming_deadline", "part_time_job", "gamer"]

# Configuración estética global
sns.set_theme(style="whitegrid")
media_global = df["took_exam"].mean()

# =====
# BLOQUE 1: ANÁLISIS DIFERENCIAL DE ASISTENCIA (CATEGÓRICAS)
# =====

fig1, axes1 = plt.subplots(2, 3, figsize=(16, 10))
axes1 = axes1.flatten()

for i, col in enumerate(cat_cols):
    ax = axes1[i]
    # Ordenar por probabilidad para detectar perfiles críticos
    order = df.groupby(col)["took_exam"].mean().sort_values(ascending=False).
    ↪ index

    sns.barplot(data=df, x=col, y="took_exam", order=order, ax=ax,
                palette="Blues_d", ci=95, capsize=0.1)

    ax.set_title(f"Probabilidad por {col}", fontsize=11, fontweight='bold')
    ax.axhline(media_global, color="red", linestyle="--", alpha=0.6,
    ↪ label=f"Media Global: {media_global:.2f}")
    ax.set_ylim(0, 1.05)
    ax.set_ylabel("P(asistencia)")
    ax.set_xlabel("")
    if i == 0: ax.legend(fontsize=9)

fig1.suptitle("Análisis de Perfiles: Probabilidad de Asistencia con IC 95%",
              fontsize=15, fontweight="bold", y=1.02)
plt.tight_layout()
plt.show()

# =====
# BLOQUE 2: CALIDAD DE DATOS Y DISTRIBUCIONES (NUMÉRICAS)
# =====

# Ajustado para usar 'vars_plot' correctamente
fig2, axes2 = plt.subplots(5, 3, figsize=(16, 22))
axes2 = axes2.flatten()

for i, col in enumerate(vars_plot):
    ax = axes2[i]

```

```

data = df[col].dropna()

# Histograma de fondo + KDE suavizado por grupo
ax.hist(data, bins=40, color='skyblue', alpha=0.4, density=True,
↪edgecolor="none")
sns.kdeplot(data=df, x=col, hue='took_exam', ax=ax, fill=True,
            common_norm=False, palette='viridis', alpha=0.3)

# Cálculo de Outliers mediante Método de Tukey (IQR)
q1, q3 = data.quantile([0.25, 0.75])
iqr = q3 - q1
n_out = ((data < q1 - 1.5*iqr) | (data > q3 + 1.5*iqr)).sum()
pct_out = (n_out / len(data)) * 100 if len(data) > 0 else 0

ax.set_title(f"{col}\nOutliers IQR: {pct_out:.1f}%", fontsize=10,
↪fontweight='bold')
ax.set_ylabel("Densidad")

# Apagar subplots vacíos (en la cuadrícula 5x3 sobran 2 espacios para 13
↪variables)
for j in range(len(vars_plot), len(axes2)):
    axes2[j].set_visible(False)


fig2.suptitle("Diagnóstico de Distribuciones y Detección de Outliers",
            fontsize=15, fontweight="bold", y=1.01)
plt.tight_layout()
plt.show()

fig, axes = plt.subplots(5, 3, figsize=(16, 20))
axes = axes.flatten()
for i, col in enumerate(vars_plot):
    ax = axes[i]
    sns.boxplot(data=df, x="took_exam", y=col, ax=ax, palette=["#e17055",
↪"#0984e3"],
                width=0.5, flierprops=dict(marker="o", markersize=2, alpha=0.3))
    ax.set_xticklabels(["No rindió (0)", "Sí rindió (1)"])
    ax.set_title(col, fontsize=10)
    ax.set_xlabel("")


axes[-1].set_visible(False)
fig.suptitle("Distribución por grupo (rindió/no rindió examen)",
            fontsize=13, y=1.01, fontweight="bold")
plt.tight_layout()
plt.show()

```



Análisis de Perfiles: Probabilidad de Asistencia con IC 95%



Diagnóstico de Distribuciones y Detección de Outliers




Distribución por grupo (rindió/no rindió examen)



0.1 1.5 Matriz de correlación

```
[6]: corr_cols = vars_plot + ["part_time_job", "upcoming_deadline", "gamer",  
    ↪ "took_exam"]  
corr = df[corr_cols].corr()  
mask = np.triu(np.ones_like(corr, dtype=bool))  
  
fig, ax = plt.subplots(figsize=(16, 13))  
sns.heatmap(corr, mask=mask, annot=True, fmt=".2f", cmap="RdBu_r", center=0,  
    linewidths=0.4, cbar_kws={"shrink": 0.8}, ax=ax,  
    annot_kws={"size": 12})  
ax.set_title("Matriz de correlación",  
    fontsize=15, fontweight="bold", pad=15)  
plt.tight_layout()  
plt.show()  
  
# Top correlaciones con la VD  
top_corr = corr["took_exam"].drop("took_exam").abs().  
    ↪ sort_values(ascending=False).head(8)  
print("\nTop 8 correlaciones (|r|) con took_exam:")  
print(top_corr.round(4).to_string())
```



Top 8 correlaciones ($|r|$) con took_exam:

```

productivity_score    0.49
focus_index          0.41
mental_health_score   0.29
study_hours           0.28
burnout_level         0.23
sleep_hours           0.13
upcoming_deadline     0.10
part_time_job         0.10

```

0.2 1.6 Diagnóstico de multicolinealidad (VIF)

```

[7]: vif_vars = [c for c in vars_plot if c in df.columns] + ["part_time_job",
    ↪ "upcoming_deadline", "gamer"]
X_vif = df[vif_vars].dropna()
X_vif_c = sm.add_constant(X_vif)

```

```

vif_df = pd.DataFrame({
    "Variable": X_vif_c.columns,
    "VIF": [variance_inflation_factor(X_vif_c.values, i) for i in range(X_vif_c.
↪shape[1])]
}).set_index("Variable").drop("const").sort_values("VIF", ascending=False)

print("  Variance Inflation Factor (Diagnóstico de Multicolinealidad)  ")
print("  Umbral moderado: VIF > 5   |   Umbral crítico: VIF > 10")
print("-" * 65)
print(vif_df.round(2).to_string())
print("-" * 65)

```

Variance Inflation Factor (Diagnóstico de Multicolinealidad)
 Umbral moderado: VIF > 5 | Umbral crítico: VIF > 10

```

-----
                VIF
Variable
productivity_score  11.53
burnout_level       6.20
mental_health_score  5.24
study_hours         5.18
focus_index        4.56
upcoming_deadline   2.46
sleep_hours         2.45
part_time_job       1.75
screen_time_hours   1.66
gaming_hours        1.45
social_media_hours  1.36
gamer               1.34
caffeine_intake_mg   1.22
self_study_hours    1.21
exercise_hours      1.12
online_classes_hours 1.00
-----

```

0.2.1 1.7 Imputación

```

[8]: # LIMPIEZA PREVIA
# Porque se comprobó que al imputar, tienen una variacion de la media >4, crean
↪sesgo
df = df.dropna(subset=["part_time_job", "upcoming_deadline"])

nums = df.select_dtypes(include="number").columns
cats = df.select_dtypes(include=["object", "string"]).columns

# Captura pre-imputación

```

```

stats_pre = df[nums].describe().loc[["mean", "std"]].T
missing_pre = df[nums].isnull().sum()

# Imputación
for col in nums:
    df[col] = df[col].fillna(df[col].median())
for col in cats:
    mode = df[col].mode(dropna=True)
    if not mode.empty:
        df[col] = df[col].fillna(mode[0])

# Control post-imputación
stats_post = df[nums].describe().loc[["mean", "std"]].T
delta_mean = ((stats_post["mean"] - stats_pre["mean"]) / stats_pre["mean"]).
    ↪abs() * 100).abs()

tabla = pd.DataFrame({
    "n_imputados": missing_pre,
    "media_antes": stats_pre["mean"],
    "media_despues": stats_post["mean"],
    "Δmedia_%": delta_mean,
}).loc[lambd d: d["n_imputados"] > 0].sort_values("Δmedia_%", ascending=False)

print(" Impacto de la imputación ")
print(tabla.round(4).to_string())
print("-" * 65)
print("→ Variaciones < 1 % en media confirman estabilidad distribucional.")

# 6. REPORTE DE RETENCIÓN
print(f"\nDimensiones finales: {df.shape}")
print(f"Retención sobre dataset: {df.shape[0]/di2[0]*100:.2f}%")

```

Impacto de la imputación				
	n_imputados	media_antes	media_despues	Δmedia_%
gamer	90	0.89	0.89	0.24
mental_health_score	80	5.51	5.51	0.16
gaming_hours	90	1.57	1.57	0.09
age	108	20.52	20.53	0.06
social_media_hours	104	3.00	3.00	0.02
productivity_score	61	37.31	37.30	0.02
exercise_hours	43	1.24	1.24	0.01
online_classes_hours	96	2.02	2.02	0.01
burnout_level	112	45.66	45.67	0.00
caffeine_intake_mg	68	251.98	251.99	0.00
study_hours	71	4.53	4.53	0.00

screen_time_hours	33	6.99	6.99	0.00
self_study_hours	83	2.47	2.47	0.00
focus_index	82	29.41	29.41	0.00
sleep_hours	63	7.02	7.02	0.00

→ Variaciones < 1 % en media confirman estabilidad distribucional.

Dimensiones finales: (4548, 22)

Retención sobre dataset: 92.59%

0.3 Modelo

$$\begin{aligned}
P(\text{Rindió examen}) = & \beta_0 + \beta_1 \text{Estudio} + \beta_2 \text{Estudio}^2 + \beta_3 \text{Sueño} + \beta_4 (\text{Estudio} \times \text{Sueño}) \\
& + \beta_5 \text{Ejercicio} + \beta_6 \text{Gaming} + \beta_7 \text{Redes_sociales} \\
& + \beta_8 Z(\text{Productividad}) + \beta_9 Z(\text{Salud_mental}) \\
& + \beta_{10} \text{Deadline} + \beta_{11} \text{Trabajo} \\
& C(\text{NivelAcademico}) + \epsilon
\end{aligned}$$

El modelo se diseño a partir de supuestos/hipotesis listadas a continuación. | Hipótesis | Variable(s) |
---	---		La probabilidad de asistir crece a medida que aumentan las horas de sueño	sleep_hours
Las horas de estudio afectan en la asistencia, pero despues de cierta cantidad de horas el beneficio marginal disminuye, sugiriendo punto de saturación	study_hours²			
El efecto positivo de las horas de estudio depende de las horas de sueño (complementariedad)	study_hours × sleep_hours			
+		Las actividades extracurriculares (gaming, exercise y social media) compiten directamente con la decisión de ir a rendir el examen.	gaming_hours, social_media_hours, exercise_hours	
Factores fuera del control del estudiante (presión de fechas y compromisos laborales) reducen la probabilidad de presentarse	part_time_job, upcoming_deadline			
La disposición psicológica es un predictor clave, y al estandarizarlos, busco comparar cuál de los dos “pesa” más en la decisión	focus_index, mental_health_score			

La variable demográfica `academic_level` se incluyen como controles aunque el EDA no mostró separación fuerte entre grupos.

```
[9]: # Ecuación del Modelo
formula_mco = """
    took_exam ~
    study_hours + I(study_hours**2) +
    sleep_hours + study_hours:sleep_hours +
    exercise_hours + gaming_hours + social_media_hours
    + standardize(focus_index)
    + standardize(mental_health_score)
    + upcoming_deadline + part_time_job

    + C(academic_level, Treatment(reference='Undergraduate'))
    """
```


0.3.1 2. Modelo de probabilidad lineal

```
[10]: # Ajuste del Modelo con Errores Estándar Robustos (HC1)
modelo_mco = smf.ols(formula_mco, data=df).fit(cov_type='HC1')
print("RESULTADOS: MODELO DE PROBABILIDAD LINEAL (MCO)")
print(modelo_mco.summary())
```

RESULTADOS: MODELO DE PROBABILIDAD LINEAL (MCO)

```

                                OLS Regression Results
=====
Dep. Variable:                took_exam    R-squared:                0.253
Model:                        OLS          Adj. R-squared:        0.251
Method:                      Least Squares  F-statistic:             57.08
Date:                        Wed, 22 Apr 2026  Prob (F-statistic):    1.20e-138
Time:                        15:26:32       Log-Likelihood:         -93.424
No. Observations:            4548          AIC:                   214.8
Df Residuals:                4534          BIC:                   304.8
Df Model:                    13
Covariance Type:             HC1
=====
=====
coef      std err          z      P>|z|      [0.025      0.975]
-----
Intercept
0.0742      0.089      0.838      0.402      -0.099      0.248
C(academic_level, Treatment(reference='Undergraduate'))[T.High School]
-0.0292      0.009     -3.233      0.001      -0.047     -0.012
C(academic_level, Treatment(reference='Undergraduate'))[T.Postgraduate]
-0.0158      0.009     -1.813      0.070      -0.033      0.001
study_hours
0.2036      0.019     10.995      0.000      0.167      0.240
I(study_hours ** 2)
-0.0092      0.001     -9.967      0.000     -0.011     -0.007
sleep_hours
0.0842      0.011      7.411      0.000      0.062      0.106
study_hours:sleep_hours
-0.0129      0.002     -6.406      0.000     -0.017     -0.009
exercise_hours
0.0034      0.005      0.665      0.506     -0.007      0.013
gaming_hours
-0.0005      0.004     -0.139      0.889     -0.007      0.006
social_media_hours
0.0049      0.003      1.688      0.091     -0.001      0.011
standardize(focus_index)
0.0677      0.007      9.386      0.000      0.054      0.082
standardize(mental_health_score)
0.0431      0.005      8.121      0.000      0.033      0.053

```

```

upcoming_deadline
-0.0547      0.007      -7.455      0.000      -0.069      -0.040
part_time_job
-0.0513      0.007      -7.005      0.000      -0.066      -0.037
=====
Omnibus:                1596.046    Durbin-Watson:                2.028
Prob(Omnibus):           0.000    Jarque-Bera (JB):            4906.430
Skew:                    -1.834    Prob(JB):                     0.00
Kurtosis:                6.527    Cond. No.                    835.
=====

```

Notes:

[1] Standard Errors are heteroscedasticity robust (HC1)

0.3.2 2.1 Interpretación de resultados

El modelo de probabilidad lineal presenta una bondad de ajuste (R^2) de 0.253, es decir, el modelo explica el 25.3% de la decisión de rendir el examen. La significancia global del modelo (F -stat < 0.01) indica que predictores elegidos tienen un impacto real en la probabilidad de rendir el examen.

Cabe destacar que el Intercepto no resultó significativo ($p = 0.402$), lo que sugiere que ante la ausencia total de factores de preparación y bienestar, la probabilidad base de asistencia tiende a cero. Finalmente, el uso de errores robustos HC1 garantiza la validez de las inferencias realizadas frente a posibles problemas de heterocedasticidad

Variable(s)	Interpretación
study_hours	Una hora de estudio adicional aumenta en 20.3 puntos porcentuales la probabilidad de asistir al examen. Este es el motor principal de decision de asistir al examen.
study_hours²	El valor negativo (-0.0092) indica que existen rendimientos decrecientes. Una hora adicional aumenta la probabilidad, pero el beneficio marginal cae a medida que suma horas. Tras un punto de saturación (aprox. 11 hrs) hace que la probabilidad de asistir empiece a disminuir
sleep_hours	Dormir una hora adicional aumenta en 8.4 puntos porcentuales la probabilidad de asistir al examen. Esto confirma la hipótesis de que el descanso es un habilitador crítico, y que no es aconsejable sacrificar horas de sueño.
study_hours × sleep_hours	El signo negativo (-0.0129) indica que las horas de estudio y el sueño actúan como sustitutos, es decir, si ya estudia mucho, el efecto “extra” de dormir más es menor (y viceversa)
gaming_hours, social_media_hours, exercise_hours	No son significativos ($p > 0.05$). Se rechaza la idea de que estas actividades compitan directamente con la asistencia

Variable(s)	Interpretación
part_time_job, upcoming_deadline	Tener un trabajo part-time o una entrega próxima reduce la probabilidad de asistir en un 5.13% y 5.47% respectivamente
focus_index, mental_health_score	focus_index pesa un 57% más (0.067/0.043) que una mejora similar en salud mental, es decir, estar concentrado es mucho más determinante para asistir que la salud mental.

0.4 3. Probit

```
[11]: modelo_probit = smf.probit(formula_mco, data=df).fit(dis= False)
print(" RESULTADOS: MODELO PROBIT ")
print(modelo_probit.summary())
ame_probit = modelo_probit.get_margeff()
print(" Efectos Marginales Promedio (AME) - Probit ")
print(ame_probit.summary())
```

RESULTADOS: MODELO PROBIT

```

Probit Regression Results
=====
Dep. Variable:          took_exam    No. Observations:          4548
Model:                  Probit        Df Residuals:              4534
Method:                 MLE          Df Model:                  13
Date:                  Wed, 22 Apr 2026    Pseudo R-squ.:            0.4773
Time:                  15:26:32          Log-Likelihood:           -717.62
converged:              True            LL-Null:                  -1372.9
Covariance Type:       nonrobust        LLR p-value:              2.847e-272
=====
=====
coef      std err        z    P>|z|    [0.025    0.975]
-----
Intercept
-0.8410    0.606    -1.389    0.165    -2.028    0.346
C(academic_level, Treatment(reference='Undergraduate'))[T.High School]
-0.3048    0.093    -3.275    0.001    -0.487    -0.122
C(academic_level, Treatment(reference='Undergraduate'))[T.Postgraduate]
-0.1673    0.093    -1.801    0.072    -0.349    0.015
study_hours
0.4527    0.184    2.454    0.014    0.091    0.814
I(study_hours ** 2)
-0.0094    0.012    -0.781    0.435    -0.033    0.014
sleep_hours
0.3198    0.082    3.920    0.000    0.160    0.480
study_hours:sleep_hours
-0.0036    0.022    -0.165    0.869    -0.046    0.039

```

exercise_hours	0.0742	0.053	1.405	0.160	-0.029	0.178
gaming_hours	0.0254	0.034	0.739	0.460	-0.042	0.093
social_media_hours	0.0378	0.029	1.317	0.188	-0.018	0.094
standardize(focus_index)	0.7463	0.067	11.218	0.000	0.616	0.877
standardize(mental_health_score)	0.6256	0.060	10.497	0.000	0.509	0.742
upcoming_deadline	-0.6841	0.079	-8.646	0.000	-0.839	-0.529
part_time_job	-0.5817	0.078	-7.500	0.000	-0.734	-0.430

=====

=====

Possibly complete quasi-separation: A fraction 0.25 of observations can be perfectly predicted. This might indicate that there is complete quasi-separation. In this case some parameters will not be identified.

Efectos Marginales Promedio (AME) - Probit

Probit Marginal Effects

=====

Dep. Variable:	took_exam				
Method:	dydx				
At:	overall				

=====

=====

dy/dx	std err	z	P> z	[0.025	0.975]

C(academic_level, Treatment(reference='Undergraduate'))[T.High School]					
-0.0265	0.008	-3.289	0.001	-0.042	-0.011
C(academic_level, Treatment(reference='Undergraduate'))[T.Postgraduate]					
-0.0145	0.008	-1.804	0.071	-0.030	0.001
study_hours					
0.0393	0.016	2.467	0.014	0.008	0.071
I(study_hours ** 2)					
-0.0008	0.001	-0.782	0.434	-0.003	0.001
sleep_hours					
0.0278	0.007	3.955	0.000	0.014	0.042
study_hours:sleep_hours					
-0.0003	0.002	-0.165	0.869	-0.004	0.003
exercise_hours					
0.0064	0.005	1.406	0.160	-0.003	0.015
gaming_hours					
0.0022	0.003	0.740	0.460	-0.004	0.008
social_media_hours					

0.0033	0.002	1.318	0.187	-0.002	0.008
standardize(focus_index)					
0.0648	0.005	11.859	0.000	0.054	0.076
standardize(mental_health_score)					
0.0543	0.005	11.003	0.000	0.045	0.064
upcoming_deadline					
-0.0594	0.007	-8.979	0.000	-0.072	-0.046
part_time_job					
-0.0505	0.007	-7.684	0.000	-0.063	-0.038
=====					
=====					

0.5 3.1 Interpretación de resultados

El modelo presenta una bondad de ajuste (McFadden Pseudo- R^2) de 0.4773, es decir, el modelo explica el 47.73% de la decisión de rendir el examen. La significancia global del modelo (LLR p-value < 0.01) indica que los predictores elegidos tienen un impacto real en la probabilidad de rendir el examen.

Variable(s)	Interpretación efectos marginales
study_hours	Una hora extra de estudio diario eleva la probabilidad de asistir al examen en 3.9 puntos porcentuales.
study_hours²	No resultó estadísticamente significativo ($p = 0.434$), lo que sugiere que, bajo este modelo, la probabilidad de asistencia no presenta una curvatura de saturación tan marcada como se hipotetizó originalmente.
sleep_hours	Dormir una hora adicional aumenta la probabilidad de asistir en 2.7 puntos porcentuales
study_hours × sleep_hours	No significativa ($p = 0.869$). El impacto de estudiar en la asistencia no varía según las horas de sueño del alumno.
gaming_hours, social_media_hours, exercise_hours	Ninguna de estas variables de ocio o actividad física resultó significativa ($p > 0.05$). Se rechaza la hipótesis de que estas actividades compiten o restan probabilidad de asistencia al examen.
part_time_job, upcoming_deadline	Son barreras críticas: tener una entrega próxima reduce la probabilidad de asistir en 5.9 puntos porcentuales, mientras que poseer un empleo parcial la reduce en 5.0 puntos porcentuales.

focus_index, mental_health_score

Son los predictores más potentes: una mejora de una desviación estándar en el foco aumenta la probabilidad en 6.4%, mientras que en salud mental lo hace en 5.4%. Ambos son determinantes psicológicos vitales.

0.5.1 4. Modelo Logit

```
[12]: modelo_logit = smf.logit(formula_mco, data=df).fit(disp=False)
print(" RESULTADOS: MODELO LOGIT ")
print(modelo_logit.summary())

ame_logit = modelo_logit.get_margeff()
print(" Efectos Marginales Promedio (AME) - Logit ")
print(ame_logit.summary())

# Odds Ratios
ci = modelo_logit.conf_int()
or_df = pd.DataFrame({
    "OR": np.exp(modelo_logit.params),
    "IC 2.5 %": np.exp(ci[0]),
    "IC 97.5 %": np.exp(ci[1]),
    "p-value": modelo_logit.pvalues,
    "Sig": modelo_logit.pvalues.map(lambda p: "****" if p<0.01 else "***" if
    p<0.05 else "*" if p<0.1 else ""),
}).drop("Intercept")

print("\n Odds Ratios ")
print(or_df.round(4).to_string())
print(f"\nMcFadden Pseudo-R²: {1 - modelo_logit.llf/modelo_logit.llnull:.4f}")
```

RESULTADOS: MODELO LOGIT

Logit Regression Results

```
=====
Dep. Variable:          took_exam    No. Observations:          4548
Model:                  Logit         Df Residuals:              4534
Method:                 MLE          Df Model:                  13
Date:                   Wed, 22 Apr 2026    Pseudo R-squ.:           0.4754
Time:                   15:26:32          Log-Likelihood:          -720.18
converged:              True            LL-Null:                -1372.9
Covariance Type:        nonrobust        LLR p-value:             3.623e-271
=====
=====
coef    std err          z      P>|z|    [0.025    0.975]
-----
Intercept
```

```

-1.2990      1.109      -1.172      0.241      -3.472      0.874
C(academic_level, Treatment(reference='Undergraduate'))[T.High School]
-0.5756      0.172      -3.356      0.001      -0.912      -0.239
C(academic_level, Treatment(reference='Undergraduate'))[T.Postgraduate]
-0.3082      0.173      -1.782      0.075      -0.647      0.031
study_hours
0.7005      0.350      2.002      0.045      0.015      1.386
I(study_hours ** 2)
-0.0089      0.023      -0.387      0.699      -0.054      0.036
sleep_hours
0.5572      0.149      3.727      0.000      0.264      0.850
study_hours:sleep_hours
0.0049      0.041      0.122      0.903      -0.075      0.085
exercise_hours
0.1483      0.098      1.514      0.130      -0.044      0.340
gaming_hours
0.0384      0.063      0.609      0.542      -0.085      0.162
social_media_hours
0.0689      0.053      1.289      0.198      -0.036      0.174
standardize(focus_index)
1.3794      0.126      10.911      0.000      1.132      1.627
standardize(mental_health_score)
1.1531      0.113      10.173      0.000      0.931      1.375
upcoming_deadline
-1.2154      0.146      -8.316      0.000      -1.502      -0.929
part_time_job
-1.0721      0.144      -7.439      0.000      -1.355      -0.790
=====
=====
Efectos Marginales Promedio (AME) - Logit
Logit Marginal Effects
=====
Dep. Variable:      took_exam
Method:      dydx
At:      overall
=====
=====
dy/dx      std err      z      P>|z|      [0.025      0.975]
-----
-----
C(academic_level, Treatment(reference='Undergraduate'))[T.High School]
-0.0270      0.008      -3.380      0.001      -0.043      -0.011
C(academic_level, Treatment(reference='Undergraduate'))[T.Postgraduate]
-0.0145      0.008      -1.786      0.074      -0.030      0.001
study_hours
0.0329      0.016      2.013      0.044      0.001      0.065
I(study_hours ** 2)
-0.0004      0.001      -0.387      0.699      -0.003      0.002

```

sleep_hours					
0.0262	0.007	3.769	0.000	0.013	0.040
study_hours:sleep_hours					
0.0002	0.002	0.122	0.903	-0.004	0.004
exercise_hours					
0.0070	0.005	1.516	0.130	-0.002	0.016
gaming_hours					
0.0018	0.003	0.610	0.542	-0.004	0.008
social_media_hours					
0.0032	0.003	1.290	0.197	-0.002	0.008
standardize(focus_index)					
0.0648	0.006	11.687	0.000	0.054	0.076
standardize(mental_health_score)					
0.0542	0.005	10.718	0.000	0.044	0.064
upcoming_deadline					
-0.0571	0.007	-8.632	0.000	-0.070	-0.044
part_time_job					
-0.0503	0.007	-7.677	0.000	-0.063	-0.037
=====					
=====					

Odds Ratios

					OR	IC
2.5 %	IC	97.5 %	p-value	Sig		
C(academic_level,	Treatment(reference='Undergraduate'))[T.High School]				0.56	
0.40	0.79	0.00	***			
C(academic_level,	Treatment(reference='Undergraduate'))[T.Postgraduate]				0.73	
0.52	1.03	0.07	*			
study_hours					2.01	
1.01	4.00	0.05	**			
I(study_hours ** 2)					0.99	
0.95	1.04	0.70				
sleep_hours					1.75	
1.30	2.34	0.00	***			
study_hours:sleep_hours					1.00	
0.93	1.09	0.90				
exercise_hours					1.16	
0.96	1.41	0.13				
gaming_hours					1.04	
0.92	1.18	0.54				
social_media_hours					1.07	
0.96	1.19	0.20				
standardize(focus_index)					3.97	
3.10	5.09	0.00	***			
standardize(mental_health_score)					3.17	
2.54	3.96	0.00	***			
upcoming_deadline					0.30	
0.22	0.40	0.00	***			

part_time_job				0.34
0.26	0.45	0.00	***	

McFadden Pseudo- R^2 : 0.4754

0.5.2 4.1 Interpretación de resultados

El modelo Logit presenta una bondad de ajuste (McFadden Pseudo- R^2) de 0.4754, lo que indica que el modelo explica el 47.54% de la decisión de rendir el examen. La alta significancia global (LLR p-value < 0.01) confirma que los predictores son robustos para explicar el fenómeno.

Variable(s)	Interpretación efectos marginales
study_hours	Un aumento de una hora de estudio diario incrementa la probabilidad de asistir en 3.29 puntos porcentuales. Su Odds Ratio de 2.01 indica que, por cada hora extra, las chances (odds) de asistir se duplican.
study_hours ²	no resulta significativo ($p = 0.699$), sugiriendo que el efecto es lineal, al contrario de la hipótesis planteada
sleep_hours	Una hora extra de sueño aumenta la probabilidad de asistir en 2.62 puntos porcentuales. El OR de 1.75 indica que las chances de asistir aumentan un 75% por cada hora adicional de sueño
study_hours $\times$ sleep_hours	La interacción no es significativa ($p = 0.903$), reforzando que ambos factores operan de manera independiente en la decisión del estudiante.
gaming_hours, social_media_hours, exercise_hours	El gaming, las redes sociales y el ejercicio no tienen impacto significativo ($p > 0.05$). Se descarta que estas actividades compitan con la intención de asistir.
part_time_job, upcoming_deadline	El OR de 0.30 (deadline) y 0.34 (trabajo) significan que estas variables reducen las chances de asistir en un 70% y 66% respectivamente
focus_index, mental_health_score	Son los determinantes más críticos. El focus tiene un OR de 3.97 y la salud mental de 3.17. Esto significa que mejorar el focus triplica las posibilidades de asistencia

```
[13]: # Ver resúmenes
print("--- RESUMEN MCO ---")
print(modelo_mco.summary())
print("\n--- RESUMEN PROBIT ---")
print(modelo_probit.summary())
```

```
print("\n--- RESUMEN LOGIT ---")
print(modelo_logit.summary())
```

--- RESUMEN MCO ---

OLS Regression Results

```
=====
Dep. Variable:          took_exam    R-squared:                0.253
Model:                  OLS          Adj. R-squared:           0.251
Method:                 Least Squares  F-statistic:              57.08
Date:                   Wed, 22 Apr 2026  Prob (F-statistic):       1.20e-138
Time:                   15:26:32      Log-Likelihood:           -93.424
No. Observations:       4548          AIC:                     214.8
Df Residuals:           4534          BIC:                     304.8
Df Model:                13
Covariance Type:        HC1
=====
```

```
=====
coef      std err          z      P>|z|      [0.025      0.975]
-----
Intercept
0.0742      0.089      0.838      0.402      -0.099      0.248
C(academic_level, Treatment(reference='Undergraduate'))[T.High School]
-0.0292      0.009     -3.233      0.001      -0.047     -0.012
C(academic_level, Treatment(reference='Undergraduate'))[T.Postgraduate]
-0.0158      0.009     -1.813      0.070      -0.033      0.001
study_hours
0.2036      0.019     10.995      0.000      0.167      0.240
I(study_hours ** 2)
-0.0092      0.001     -9.967      0.000     -0.011     -0.007
sleep_hours
0.0842      0.011      7.411      0.000      0.062      0.106
study_hours:sleep_hours
-0.0129      0.002     -6.406      0.000     -0.017     -0.009
exercise_hours
0.0034      0.005      0.665      0.506     -0.007      0.013
gaming_hours
-0.0005      0.004     -0.139      0.889     -0.007      0.006
social_media_hours
0.0049      0.003      1.688      0.091     -0.001      0.011
standardize(focus_index)
0.0677      0.007      9.386      0.000      0.054      0.082
standardize(mental_health_score)
0.0431      0.005      8.121      0.000      0.033      0.053
upcoming_deadline
-0.0547      0.007     -7.455      0.000     -0.069     -0.040
part_time_job
-0.0513      0.007     -7.005      0.000     -0.066     -0.037
=====
```

```

=====
Omnibus:                1596.046    Durbin-Watson:                2.028
Prob(Omnibus):          0.000    Jarque-Bera (JB):            4906.430
Skew:                   -1.834    Prob(JB):                     0.00
Kurtosis:               6.527    Cond. No.                     835.
=====

```

Notes:

[1] Standard Errors are heteroscedasticity robust (HC1)

--- RESUMEN PROBIT ---

Probit Regression Results

```

=====
Dep. Variable:          took_exam    No. Observations:          4548
Model:                  Probit        Df Residuals:              4534
Method:                  MLE          Df Model:                  13
Date:                   Wed, 22 Apr 2026    Pseudo R-squ.:            0.4773
Time:                   15:26:32          Log-Likelihood:           -717.62
converged:              True            LL-Null:                  -1372.9
Covariance Type:        nonrobust        LLR p-value:              2.847e-272
=====

```

```

=====
coef      std err        z    P>|z|    [0.025    0.975]
-----
Intercept
-0.8410    0.606    -1.389    0.165    -2.028    0.346
C(academic_level, Treatment(reference='Undergraduate'))[T.High School]
-0.3048    0.093    -3.275    0.001    -0.487    -0.122
C(academic_level, Treatment(reference='Undergraduate'))[T.Postgraduate]
-0.1673    0.093    -1.801    0.072    -0.349    0.015
study_hours
0.4527    0.184    2.454    0.014    0.091    0.814
I(study_hours ** 2)
-0.0094    0.012    -0.781    0.435    -0.033    0.014
sleep_hours
0.3198    0.082    3.920    0.000    0.160    0.480
study_hours:sleep_hours
-0.0036    0.022    -0.165    0.869    -0.046    0.039
exercise_hours
0.0742    0.053    1.405    0.160    -0.029    0.178
gaming_hours
0.0254    0.034    0.739    0.460    -0.042    0.093
social_media_hours
0.0378    0.029    1.317    0.188    -0.018    0.094
standardize(focus_index)
0.7463    0.067    11.218    0.000    0.616    0.877
standardize(mental_health_score)

```

0.6256	0.060	10.497	0.000	0.509	0.742
upcoming_deadline					
-0.6841	0.079	-8.646	0.000	-0.839	-0.529
part_time_job					
-0.5817	0.078	-7.500	0.000	-0.734	-0.430

=====

=====

Possibly complete quasi-separation: A fraction 0.25 of observations can be perfectly predicted. This might indicate that there is complete quasi-separation. In this case some parameters will not be identified.

--- RESUMEN LOGIT ---

Logit Regression Results

Dep. Variable:	took_exam	No. Observations:	4548
Model:	Logit	Df Residuals:	4534
Method:	MLE	Df Model:	13
Date:	Wed, 22 Apr 2026	Pseudo R-squ.:	0.4754
Time:	15:26:32	Log-Likelihood:	-720.18
converged:	True	LL-Null:	-1372.9
Covariance Type:	nonrobust	LLR p-value:	3.623e-271

=====

=====

coef	std err	z	P> z	[0.025	0.975]
------	---------	---	------	--------	--------

Intercept					
-1.2990	1.109	-1.172	0.241	-3.472	0.874
C(academic_level, Treatment(reference='Undergraduate'))[T.High School]					
-0.5756	0.172	-3.356	0.001	-0.912	-0.239
C(academic_level, Treatment(reference='Undergraduate'))[T.Postgraduate]					
-0.3082	0.173	-1.782	0.075	-0.647	0.031
study_hours					
0.7005	0.350	2.002	0.045	0.015	1.386
I(study_hours ** 2)					
-0.0089	0.023	-0.387	0.699	-0.054	0.036
sleep_hours					
0.5572	0.149	3.727	0.000	0.264	0.850
study_hours:sleep_hours					
0.0049	0.041	0.122	0.903	-0.075	0.085
exercise_hours					
0.1483	0.098	1.514	0.130	-0.044	0.340
gaming_hours					
0.0384	0.063	0.609	0.542	-0.085	0.162
social_media_hours					
0.0689	0.053	1.289	0.198	-0.036	0.174
standardize(focus_index)					

1.3794	0.126	10.911	0.000	1.132	1.627
standardize(mental_health_score)					
1.1531	0.113	10.173	0.000	0.931	1.375
upcoming_deadline					
-1.2154	0.146	-8.316	0.000	-1.502	-0.929
part_time_job					
-1.0721	0.144	-7.439	0.000	-1.355	-0.790

=====

=====

0.5.3 5. Comparación MPL, Probit y Logit

¿Cuáles y por qué existen las diferencias entre los resultados?

La bondad de ajuste de R^2 del MCO es 0.25, mientras que el Pseudo- R^2 de Probit/Logit sube a 0.47, es decir, los modelos no lineales explican mucho mejor el comportamiento, con casi el doble de mejora.

El MPL es poco realista, ya que a veces predice cosas imposibles (como probabilidades negativas) al tratar de ajustar todo a una línea recta. En cambio, Logit y Probit son mucho más precisos porque reconocen que el impacto de las variables no es siempre el mismo ni lineal, y encierran los resultados entre 0 y 1

En su opinión, ¿Cuál sería el más adecuado para responder la pregunta de investigación y por qué?

Logit, porque es el que mejor se adapta a la realidad, asegurando que las probabilidades siempre tengan sentido (entre 0 y 1). Además, permite hablar de “chances” de éxito; por ejemplo, nos deja decir que un buen focus_index casi cuadruplica las posibilidades de que un alumno asista. Es el modelo que mejor explica qué pasa sin complicar las cosas de más, cumpliendo con los estándares técnicos más altos.

¿Qué variables resultaron ser robustas a la especificación?

Study_hours, sleep_hours, focus_index y mental_health_score siempre ayudan a que el alumno se presente. Por el contrario, tener un trabajo o entregas de otras materias siempre actúan como frenos. Un gran hallazgo es que jugar o usar redes sociales no tienen significancia estadística.

0.6 6. Modelo Poisson para la nota del examen

```
[14]: df_2 = df[df['took_exam'] == 1].copy() # hago una copia del df solo con los que
      ↪dieron el examen

# Ecuación del Modelo
formula_notas = """
    exam_score ~
    study_hours + I(study_hours**2) +
    sleep_hours + study_hours:sleep_hours +
    exercise_hours + gaming_hours + social_media_hours
    + standardize(focus_index)
    + standardize(mental_health_score)
```

```

+ upcoming_deadline + part_time_job
+ C(academic_level, Treatment(reference='Undergraduate'))
"""

modelo_poisson = smf.poisson(formula_notas, data=df_2).fit(dis= False)
print(" RESULTADOS: MODELO POISSON ")
print(modelo_poisson.summary())

```

RESULTADOS: MODELO POISSON

```

Poisson Regression Results
=====
Dep. Variable:          exam_score    No. Observations:          4140
Model:                  Poisson      Df Residuals:              4126
Method:                  MLE         Df Model:                  13
Date:                   Wed, 22 Apr 2026    Pseudo R-squ.:            0.3843
Time:                   15:26:33          Log-Likelihood:           -14317.
converged:              True            LL-Null:                 -23252.
Covariance Type:        nonrobust        LLR p-value:              0.000
=====
=====
coef      std err          z      P>|z|      [0.025      0.975]
-----
Intercept
1.1304      0.074      15.258      0.000      0.985      1.276
C(academic_level, Treatment(reference='Undergraduate'))[T.High School]
0.0006      0.008       0.067      0.947     -0.016      0.017
C(academic_level, Treatment(reference='Undergraduate'))[T.Postgraduate]
0.0058      0.008       0.690      0.490     -0.011      0.022
study_hours
0.3075      0.016      19.608      0.000      0.277      0.338
I(study_hours ** 2)
-0.0090      0.001     -11.455      0.000     -0.011     -0.007
sleep_hours
0.1690      0.009      17.991      0.000      0.151      0.187
study_hours:sleep_hours
-0.0153      0.002      -8.940      0.000     -0.019     -0.012
exercise_hours
0.0388      0.005       8.105      0.000      0.029      0.048
gaming_hours
0.0052      0.003       1.582      0.114     -0.001      0.012
social_media_hours
0.0072      0.003       2.709      0.007      0.002      0.012
standardize(focus_index)
0.2045      0.006      36.211      0.000      0.193      0.216
standardize(mental_health_score)
0.1880      0.005      38.905      0.000      0.179      0.197
upcoming_deadline

```



```

-0.2320      0.007    -33.479      0.000      -0.246      -0.218
part_time_job
-0.1691      0.007    -24.536      0.000      -0.183      -0.156
=====
=====

```

```

[15]: # El modelo Poisson es ideal para variables de respuesta que son razones o
      ↪ conteos positivos
modelo_poisson = smf.poisson(formula_notas, data=df_2).fit(cov_type='HC1')

print("--- RESULTADOS MODELO POISSON (NOTAS) ---")
print(modelo_poisson.summary())

# 4. Cálculo de efectos marginales para interpretar en "puntos de nota"
mfx_notas = modelo_poisson.get_margeff()
print("\n--- EFECTOS MARGINALES (Cambio en puntos de nota) ---")
print(mfx_notas.summary())

```

Optimization terminated successfully.

Current function value: 3.458249

Iterations 6

--- RESULTADOS MODELO POISSON (NOTAS) ---

Poisson Regression Results

```

=====
Dep. Variable:          exam_score  No. Observations:          4140
Model:                Poisson      Df Residuals:              4126
Method:                MLE          Df Model:                  13
Date:                  Wed, 22 Apr 2026  Pseudo R-squ.:            0.3843
Time:                  15:26:33        Log-Likelihood:           -14317.
converged:              True          LL-Null:                  -23252.
Covariance Type:        HC1          LLR p-value:              0.000
=====

```

```

=====
coef      std err          z      P>|z|      [0.025      0.975]
-----
Intercept
1.1304      0.102      11.114      0.000      0.931      1.330
C(academic_level, Treatment(reference='Undergraduate'))[T.High School]
0.0006      0.012       0.048      0.962     -0.023      0.024
C(academic_level, Treatment(reference='Undergraduate'))[T.Postgraduate]
0.0058      0.012       0.494      0.622     -0.017      0.029
study_hours
0.3075      0.022      14.104      0.000      0.265      0.350
I(study_hours ** 2)
-0.0090      0.001      -7.388      0.000     -0.011     -0.007
sleep_hours
0.1690      0.013      13.274      0.000      0.144      0.194

```

```

study_hours:sleep_hours
-0.0153      0.002      -6.736      0.000      -0.020      -0.011
exercise_hours
0.0388      0.007      5.794      0.000      0.026      0.052
gaming_hours
0.0052      0.005      1.129      0.259      -0.004      0.014
social_media_hours
0.0072      0.004      1.879      0.060      -0.000      0.015
standardize(focus_index)
0.2045      0.008      25.086      0.000      0.189      0.221
standardize(mental_health_score)
0.1880      0.007      27.202      0.000      0.174      0.202
upcoming_deadline
-0.2320      0.010      -23.801      0.000      -0.251      -0.213
part_time_job
-0.1691      0.010      -17.500      0.000      -0.188      -0.150
=====
=====

```

--- EFECTOS MARGINALES (Cambio en puntos de nota) ---

Poisson Marginal Effects

```

=====
Dep. Variable:          exam_score
Method:                dydx
At:                    overall
=====
=====

```

```

dy/dx      std err          z      P>|z|      [0.025      0.975]
-----
-----

```

```

C(academic_level, Treatment(reference='Undergraduate'))[T.High School]
0.0117      0.243      0.048      0.962      -0.464      0.488
C(academic_level, Treatment(reference='Undergraduate'))[T.Postgraduate]
0.1188      0.241      0.494      0.622      -0.353      0.591
study_hours
6.3284      0.448      14.126      0.000      5.450      7.207
I(study_hours ** 2)
-0.1853      0.025      -7.392      0.000      -0.234      -0.136
sleep_hours
3.4777      0.262      13.289      0.000      2.965      3.991
study_hours:sleep_hours
-0.3154      0.047      -6.741      0.000      -0.407      -0.224
exercise_hours
0.7986      0.138      5.796      0.000      0.529      1.069
gaming_hours
0.1062      0.094      1.129      0.259      -0.078      0.291
social_media_hours
0.1475      0.079      1.879      0.060      -0.006      0.301

```



```

standardize(focus_index)
4.2099      0.169      24.960      0.000      3.879      4.540
standardize(mental_health_score)
3.8698      0.142      27.237      0.000      3.591      4.148
upcoming_deadline
-4.7745      0.201      -23.752      0.000      -5.168      -4.380
part_time_job
-3.4816      0.199      -17.469      0.000      -3.872      -3.091
=====
=====

```

0.6.1 6.1 Interpretación de resultados

El modelo presenta un ajuste (Pseudo- R^2) de 0.3843, lo que indica una buena capacidad para explicar la variabilidad de las notas. Sin embargo, el Ratio Varianza/Media de 6.20 advierte que los resultados de significancia (p-values) podrían estar inflados por la sobredispersión.

Variable(s)	Interpretación efectos marginales
study_hours	Una hora extra de estudio aumenta la nota en 6,33 puntos, siendo el factor con mayor impacto directo.
study_hours ²	El signo negativo (-0.18) confirma rendimientos decrecientes: estudiar demasiado satura y aporta cada vez menos.
sleep_hours	Dormir una hora adicional sube la nota en 3,48 puntos. El descanso es una inversión directa en el rendimiento.
study_hours × sleep_hours	El efecto negativo (-0.31) indica que el beneficio del sueño disminuye si el estudio es excesivo (y viceversa)
gaming_hours, social_media_hours, exercise_hours	El ejercicio físico sí aporta positivamente (0.8 pts), mientras que el gaming y redes sociales no tienen un impacto significativo
part_time_job, upcoming_deadline	Tener entregas próximas resta 4,77 puntos y tener trabajo resta 3,48 puntos
focus_index, mental_health_score	Influye más el foco (4.21 pts) que el bienestar emocional (3.87 pts) en la nota

0.7 7. Diagnóstico de sobredispersión y estimación del parámetro α

```

[16]: mean_y = df_2['exam_score'].mean()
      var_y = df_2['exam_score'].var()

      print(f"Media de la nota: {mean_y:.2f}")
      print(f"Varianza de la nota: {var_y:.2f}")

```

```

print(f"Ratio Varianza/Media: {var_y/mean_y:.2f}")

# Usamos la misma fórmula pero en el formato de la librería 'statsmodels.api'
↳ para NB
# El modelo NegBinomial en statsmodels usa por defecto el parámetro 'alpha'
modelo_nb = smf.negativebinomial(formula_notas, data=df_2).fit()

print(modelo_nb.summary())

# El valor de alpha estimado
alpha_optim = modelo_nb.params['alpha']
print(f"\nEl valor óptimo de alpha estimado es: {alpha_optim:.4f}")

```

Media de la nota: 20.58

Varianza de la nota: 127.52

Ratio Varianza/Media: 6.20

Optimization terminated successfully.

Current function value: 3.299607

Iterations: 29

Function evaluations: 39

Gradient evaluations: 39

NegativeBinomial Regression Results

```

=====
Dep. Variable:          exam_score    No. Observations:          4140
Model:                  NegativeBinomial    Df Residuals:          4126
Method:                  MLE    Df Model:          13
Date:                    Wed, 22 Apr 2026    Pseudo R-squ.:          0.1361
Time:                    15:26:33    Log-Likelihood:        -13660.
converged:                True    LL-Null:          -15812.
Covariance Type:          nonrobust    LLR p-value:          0.000
=====

```

```

=====
coef      std err          z      P>|z|      [0.025      0.975]
-----
Intercept
1.1006      0.110      10.048      0.000      0.886      1.315
C(academic_level, Treatment(reference='Undergraduate'))[T.High School]
0.0008      0.013       0.065      0.948     -0.025      0.026
C(academic_level, Treatment(reference='Undergraduate'))[T.Postgraduate]
0.0032      0.013       0.250      0.803     -0.022      0.028
study_hours
0.3074      0.024      12.796      0.000      0.260      0.355
I(study_hours ** 2)
-0.0085      0.001      -6.769      0.000     -0.011     -0.006
sleep_hours
0.1738      0.014      12.367      0.000      0.146      0.201
study_hours:sleep_hours

```

-0.0156	0.003	-5.830	0.000	-0.021	-0.010
exercise_hours					
0.0397	0.007	5.390	0.000	0.025	0.054
gaming_hours					
0.0056	0.005	1.117	0.264	-0.004	0.015
social_media_hours					
0.0074	0.004	1.815	0.069	-0.001	0.015
standardize(focus_index)					
0.2226	0.009	25.433	0.000	0.205	0.240
standardize(mental_health_score)					
0.1956	0.007	26.674	0.000	0.181	0.210
upcoming_deadline					
-0.2536	0.011	-23.880	0.000	-0.274	-0.233
part_time_job					
-0.1816	0.011	-17.129	0.000	-0.202	-0.161
alpha					
0.0606	0.003	21.510	0.000	0.055	0.066

=====

=====

El valor óptimo de alpha estimado es: 0.0606

```
[17]: mu_y = df_2["exam_score"].mean()
var_y = df_2["exam_score"].var()

# 1. Ratio Var/Media

print(f"Ratio Var/Media = {var_y/mu_y:.4f}")
print(f"→ El Poisson asume ratio = 1.0. Un ratio de {var_y/mu_y:.2f} implica
→ sobredispersión severa.\n")

# 2. Test de Cameron-Trivedi
mu_hat = modelo_poisson.fittedvalues
y_obs = df_2["exam_score"].values
aux_y = (y_obs - mu_hat)**2 - y_obs
aux_X = sm.add_constant(mu_hat**2)

ct = sm.OLS(aux_y, aux_X).fit()
alpha_ct = ct.params.iloc[1]
t_ct = ct.tvalues.iloc[1]
p_ct = ct.pvalues.iloc[1]

print(" Test de Cameron-Trivedi (1990) ")
print(f" H: = 0 (Poisson / equidispersión)")
print(f" estimado: {alpha_ct:.6f}")
print(f" t-estadístico: {t_ct:.4f}")
print(f" p-value: {p_ct:.3e}")
```

```

if p_ct < 0.05:
    print(" → RECHAZA H → sobredispersión estadísticamente significativa")
else:
    print(" → No rechaza H ")

# 3. Visualización residuos de Pearson
pearson_res = (y_obs - mu_hat) / np.sqrt(mu_hat)

fig, axes = plt.subplots(1, 2, figsize=(14, 4))
axes[0].scatter(mu_hat, pearson_res, alpha=0.15, s=8, color="#0984e3")
axes[0].axhline(0, color="red", lw=1)
axes[0].set_xlabel("Valores ajustados ( $\hat{\mu}$ )")
axes[0].set_ylabel("Residuos de Pearson")
axes[0].set_title("Residuos Pearson vs.  $\hat{\mu}$  - Poisson\n(fan shape confirma sobredispersión)")

axes[1].hist(pearson_res, bins=60, color="#74b9ff", edgecolor="none", alpha=0.7)
axes[1].set_xlabel("Residuo de Pearson")
axes[1].set_title("Distribución de residuos de Pearson")
plt.tight_layout(); plt.show()

```

Ratio Var/Media = 6.1956

→ El Poisson asume ratio = 1.0. Un ratio de 6.20 implica sobredispersión severa.

Test de Cameron-Trivedi (1990)


H: = 0 (Poisson / equidispersión)

estimado: 133.286425

t-estadístico: 84.4361

p-value: 0.000e+00

→ RECHAZA H → sobredispersión estadísticamente significativa



Análisis	Resultados	Conclusión
Relación entre media y varianza	Media 20.49. Varianza de la nota: 126.84. Ratio Varianza/Media: 6.19	En Poisson deberían ser iguales. La varianza es 6 veces mayor, lo que indica que las notas varían mucho más, entonces Poisson subestima los errores, dando resultados poco confiables.
Test de Cameron Trivedi	$p\text{-value} = 0.000e + 00$	Se rechaza la hipótesis nula (H_0) de equidispersión.
α estimado	$\alpha = 0.0311$	El parámetro α captura la heterogeneidad no observada entre estudiantes, indicando que hay factores que el modelo no está viendo que causan la variación.

0.8 8. Modelo Binomial Negativa (NB2)

```
[20]: # 1. Ajustar el modelo primero
modelo_nb = smf.negativebinomial(formula_notas, data=df_2).fit(dis=False)

# 2. Extraer métricas de Alpha (directamente del modelo ya ajustado)
alpha_nb = modelo_nb.params["alpha"]
ci_nb     = modelo_nb.conf_int()

print(" RESULTADOS: MODELO BINOMIAL NEGATIVA (NB2) ")
print(modelo_nb.summary())

print(f" estimado (NB2): {alpha_nb:.6f}")
# Nota: Para alpha no se usa np.exp en el IC, se muestra el valor directo
print(f"IC 95 % alpha: [{ci_nb.loc['alpha', 0]:.6f}, {ci_nb.loc['alpha', 1]:.6f}]")
print(f"p-value : {modelo_nb.pvalues['alpha']:.4e}")
print("→ significativamente distinto de cero confirma que NB2 > Poisson.\n")

# 3. IRR y efectos marginales NB2

# Extraemos los efectos marginales (que no incluyen Intercept ni Alpha)
marg_eff = modelo_nb.get_margeff().margeff

# Filtramos los parámetros para que coincidan con el largo de marg_eff (13 variables)
# Quitamos el Intercepto y el Alpha de los vectores de parámetros
params_filtered = modelo_nb.params.drop(["Intercept", "alpha"])
pvalues_filtered = modelo_nb.pvalues.drop(["Intercept", "alpha"])
```

```

ci_filtered = modelo_nb.conf_int().drop(["Intercept", "alpha"])

irr_nb = pd.DataFrame({
    " (NB2)":      params_filtered,
    "IRR (NB2)":   np.exp(params_filtered),
    "IC 2.5 %":    np.exp(ci_filtered[0]),
    "IC 97.5 %":   np.exp(ci_filtered[1]),
    "EM (puntos)": marg_eff,
    "p-value":     pvalues_filtered,
    "Sig":         pvalues_filtered.map(lambda p: "***" if p<0.01 else "**" if
    ↪ p<0.05 else "*" if p<0.1 else ""),
})

print("  IRR y Efectos Marginales - NB2                ")
print(irr_nb.round(5).to_string())

```

RESULTADOS: MODELO BINOMIAL NEGATIVA (NB2)

NegativeBinomial Regression Results

```

=====
Dep. Variable:          exam_score    No. Observations:          4140
Model:                  NegativeBinomial    Df Residuals:              4126
Method:                  MLE    Df Model:              13
Date:                    mié, 22 abr. 2026    Pseudo R-squ.:            0.1361
Time:                    15:29:51    Log-Likelihood:          -13660.
converged:                True    LL-Null:                -15812.
Covariance Type:          nonrobust    LLR p-value:              0.000
=====
coef      std err          z      P>|z|      [0.025      0.975]
-----
Intercept
1.1006      0.110      10.048      0.000      0.886      1.315
C(academic_level, Treatment(reference='Undergraduate'))[T.High School]
0.0008      0.013       0.065      0.948     -0.025      0.026
C(academic_level, Treatment(reference='Undergraduate'))[T.Postgraduate]
0.0032      0.013       0.250      0.803     -0.022      0.028
study_hours
0.3074      0.024      12.796      0.000      0.260      0.355
I(study_hours ** 2)
-0.0085      0.001     -6.769      0.000     -0.011     -0.006
sleep_hours
0.1738      0.014      12.367      0.000      0.146      0.201
study_hours:sleep_hours
-0.0156      0.003     -5.830      0.000     -0.021     -0.010
exercise_hours
0.0397      0.007       5.390      0.000      0.025      0.054
gaming_hours

```

0.0056	0.005	1.117	0.264	-0.004	0.015
social_media_hours					
0.0074	0.004	1.815	0.069	-0.001	0.015
standardize(focus_index)					
0.2226	0.009	25.433	0.000	0.205	0.240
standardize(mental_health_score)					
0.1956	0.007	26.674	0.000	0.181	0.210
upcoming_deadline					
-0.2536	0.011	-23.880	0.000	-0.274	-0.233
part_time_job					
-0.1816	0.011	-17.129	0.000	-0.202	-0.161
alpha					
0.0606	0.003	21.510	0.000	0.055	0.066
=====					
=====					

estimado (NB2): 0.060621
 IC 95 % alpha: [0.055097, 0.066145]
 p-value : 1.2564e-102
 → significativamente distinto de cero confirma que NB2 > Poisson.

IRR y Efectos Marginales - NB2

IRR (NB2)	IC 2.5 %	IC 97.5 %	EM (puntos)	p-value	Sig	(NB2)
C(academic_level, Treatment(reference='Undergraduate'))[T.High School]						0.00
1.00	0.98	1.03	0.02	0.95		
C(academic_level, Treatment(reference='Undergraduate'))[T.Postgraduate]						0.00
1.00	0.98	1.03	0.07	0.80		
study_hours						0.31
1.36	1.30	1.43	6.37	0.00 ***		
I(study_hours ** 2)						-0.01
0.99	0.99	0.99	-0.18	0.00 ***		
sleep_hours						0.17
1.19	1.16	1.22	3.60	0.00 ***		
study_hours:sleep_hours						-0.02
0.98	0.98	0.99	-0.32	0.00 ***		
exercise_hours						0.04
1.04	1.03	1.06	0.82	0.00 ***		
gaming_hours						0.01
1.01	1.00	1.02	0.12	0.26		
social_media_hours						0.01
1.01	1.00	1.02	0.15	0.07 *		
standardize(focus_index)						0.22
1.25	1.23	1.27	4.61	0.00 ***		
standardize(mental_health_score)						0.20
1.22	1.20	1.23	4.05	0.00 ***		
upcoming_deadline						-0.25
0.78	0.76	0.79	-5.25	0.00 ***		
part_time_job						-0.18

0.83 0.82 0.85 -3.76 0.00 ***

0.8.1 8.1 Interpretación de resultados

El parámetro α resultó ser 0.0606 con un p -value cercano a cero, lo que valida que este modelo es superior al Poisson para explicar las notas.

Variable	Interpretación
study_hours	Cada hora extra de estudio sube la nota directamente. Es el predictor de mayor impacto en el rendimiento académico.
study_hours ²	Los rendimientos son decrecientes: las primeras horas son muy productivas, pero pasadas 11 horas decrece
sleep_hours	Dormir una hora más sube la nota en 3.6 puntos. El sueño no es un lujo — es una inversión directa en el puntaje.
study_hours:sleep_hours	Estudiar y dormir mucho simultáneamente se neutralizan parcialmente cuando se llega a niveles extremos
gaming_hours, social_media_hours, exercise_hours	El impacto no es robusto. El ejercicio ayuda levemente, mientras que el gaming y las redes sociales no afectan significativamente la nota.
focus_index, mental_health_score	1 más de concentración sube la nota en 4.6 puntos. Una sesión de 2 horas con foco total supera a 5 horas con distracciones.
upcoming_deadline, part_time_job	Tener una entrega próxima resta 5.3 y trabajar medio tiempo resta 3.8 puntos

```
[19]: # Comparación de IRR lado a lado
irr_cmp = pd.DataFrame({
    "IRR Poisson": np.exp(modelo_poisson.params),
    "p Poisson": modelo_poisson.pvalues,
    "IRR NB2": np.exp(modelo_nb.params),
    "p NB2": modelo_nb.pvalues,
}).drop(["Intercept"], errors="ignore").drop(["alpha"], errors="ignore")
print(" Comparación IRR: Poisson vs. NB2 ")
print(irr_cmp.round(5).to_string())

# Variables robustas al supuesto distribucional
sig_p = set(modelo_poisson.pvalues[modelo_poisson.pvalues < 0.05].index) ->
->{"Intercept"}
sig_nb = set(modelo_nb.pvalues[modelo_nb.pvalues < 0.05].index) ->
->{"Intercept", "alpha"}
robust_count = sig_p & sig_nb
print(f"\n Variables robustas (p<0.05 en ambos modelos) ")
for v in sorted(robust_count): print(f" {v}")
```


Comparación IRR: Poisson vs. NB2

IRR

Poisson	p Poisson	IRR NB2	p NB2
C(academic_level, Treatment(reference='Undergraduate'))[T.High School]			
1.00	0.96	1.00	0.95
C(academic_level, Treatment(reference='Undergraduate'))[T.Postgraduate]			
1.01	0.62	1.00	0.80
I(study_hours ** 2)			
0.99	0.00	0.99	0.00
exercise_hours			
1.04	0.00	1.04	0.00
gaming_hours			
1.01	0.26	1.01	0.26
part_time_job			
0.84	0.00	0.83	0.00
sleep_hours			
1.18	0.00	1.19	0.00
social_media_hours			
1.01	0.06	1.01	0.07
standardize(focus_index)			
1.23	0.00	1.25	0.00
standardize(mental_health_score)			
1.21	0.00	1.22	0.00
study_hours			
1.36	0.00	1.36	0.00
study_hours:sleep_hours			
0.98	0.00	0.98	0.00
upcoming_deadline			
0.79	0.00	0.78	0.00

Variables robustas (p<0.05 en ambos modelos)

```

I(study_hours ** 2)
exercise_hours
part_time_job
sleep_hours
standardize(focus_index)
standardize(mental_health_score)
study_hours
study_hours:sleep_hours
upcoming_deadline

```

0.8.2 9.1 Comentarios y conclusiones

¿Cuáles y por qué existen las diferencias entre los resultados?

Al comparar el modelo Poisson y el Binomial Negativo (NB2), la diferencia fundamental está en la precisión de la inferencia. El modelo Poisson asume que la varianza es igual a la media, pero como en este caso la varianza es 6.2 veces mayor a la media, Poisson subestima los errores estándar. Por

ejemplo, en el modelo Poisson, la variable `social_media_hours` estaba al borde de la significancia ($p = 0.06$), pero en el NB2 sube a **0.07**. NB2 es, por tanto, el to modelo válido para evitar conclusiones erróneas.

Variables robustas al supuesto distribucional

Las variables que no resultaron robustas fueron nivel academico, horas de gaming y horas de social media, las demás resultaron totalmente robustas, manteniendo su significancia ($p < 0.01$) y magnitudes de IRR casi iguales en ambos modelos. Esto sugiere que el impacto de factores como el **estudio (IRR 1.36)**, el **foco (IRR 1.25)** y el **sueño (IRR 1.19)** es tan real que no depende del modelo elegido.

0.8.3 9.2 Conclusiones Estratégicas y Recomendaciones

El foco o concentración (`focus_index`) incrementa la nota en **4.6 puntos** por cada desviación estándar, superando incluso a la Salud Mental (**4.0 puntos**). Es preferible una sesión de estudio de 2 horas con foco máximo que una de 5 horas con distracciones.

El coeficiente de `study_hours` es positivo (+6.3 pts/hr), pero su término cuadrático es negativo (-0.18) indicando un punto de saturación aproximadamente después de la hora 11, donde la nota a caer.

El efecto interacción `study_hours:sleep_hours` es negativo (-0.32). Esto rompe con la hipótesis inicial e indica que si ya se estudia mucho, el beneficio de dormir una hora extra disminuye en términos marginales. Esto indica que no es recomendable sacrificar sueño por horas de estudio de baja calidad.

Los deadlines y el trabajo restan en promedio **5.2** y **3.7 puntos** respectivamente, entonces es importante balancearlos correctamente.