

# Tarea\_1\_PSE



April 28, 2026

## 0.1 Tarea 1 - Patricio Sepúlveda Ewert



## 0.2 Pregunta 1 — Carga, Exploración y Limpieza

**Estructura inicial.** El dataset tiene **5.621 observaciones y 22 variables**, con 16 numéricas (`float64`), 1 entera (`student_id`) y 5 categóricas (`object`). `exercise_minutes` aparece como `object` debido a la presencia del sufijo ' min' en 602 observaciones.

**Valores faltantes.** Todas las variables (excepto `student_id`) presentan entre un 9 % y un 13 % de datos faltantes, con la excepción crítica de `drug_use`, que tiene un **72.99 %** de ausencias. La similitud en las tasas de missingness en el resto de variables es compatible con un mecanismo **MCAR (Missing Completely At Random)**, supuesto bajo el cual la eliminación listwise produce estimadores insesgados y consistentes (solo se pierde eficiencia).

### Decisiones de limpieza:

1. `drug_use` eliminada: con 73 % de faltantes, ningún método de imputación es confiable.
2. `student_id` eliminada: no aporta información estructural.
3. `exercise_minutes` → `exercise_hours`: se elimina el sufijo ' min', se convierte a numérico y se divide entre 60 para homogeneizar unidades con el resto de variables temporales.
4. `academic_level`: se corrigen espacios (`.strip()`) que generaban categorías duplicadas, quedando **3 niveles limpios**: High\_School, Undergraduate, Postgraduate.
5. `part_time_job`: se normaliza capitalización y se codifica como binaria (1 = sí, 0 = no).
6. `study_hours` y `screen_time_hours`: aunque la descripción sugiere que son sumas de sus componentes, el 48.5 % y 45.1 % de las observaciones respectivamente violan esta relación. Se documenta la inconsistencia y se **retienen** ambas; los modelos determinarán empíricamente su aporte.

**Variable binaria `took_exam`** (clave para P2–P4):

| Condición                        | <code>took_exam</code> | n              |
|----------------------------------|------------------------|----------------|
| <code>exam_score &gt; 1.0</code> | 1 (rindió)             | 4.473 (91.1 %) |
| <code>exam_score = 1.0</code>    | 0 (no rindió)          | 439 (8.9 %)    |
| <code>exam_score = NaN</code>    | NaN (excluido)         | 709            |

Los NaN se interpretan como datos genuinamente faltantes (examen realizado pero no registrado) y se excluyen — no se imputan porque eso sesgaría directamente la variable dependiente. Existe un **desbalance de clases de ~91/9 %** que afectará la capacidad predictiva sobre la clase minoritaria.

**Eliminación listwise.** Tras eliminar observaciones con al menos un NaN en predictores, se retienen **3.996 casos completos (71.1 %)**. Bajo MCAR esto no introduce sesgo.



**Codificación categórica.** Se crean dummies con categorías de referencia explícitas: `gender` → Male, `academic_level` → High\_School, `internet_quality` → Good.

**Descriptivas y diagnósticos.** Todas las variables numéricas presentan distribuciones razonables y rangos fisiológicamente plausibles. Los outliers por IQR son inferiores al 0.6 % en todas las variables, por lo que se **mantienen** para evitar sesgo de selección. La matriz de correlación y el VIF muestran que `productivity_score` presenta  $VIF = 11.54$  (multicolinealidad moderada-alta), lo cual se documenta como limitación; los demás predictores están por debajo del umbral crítico.

### 0.3 Pregunta 2 — Modelo de Probabilidad Lineal (MPL / MCO)

**Especificación:**  $P(\text{took\_exam}_i = 1) = \beta_0 + \sum_k \beta_k X_{ki} + \varepsilon_i$ , estimado por MCO con errores estándar **HC3** (robustos a la heterocedasticidad estructural del MPL, donde  $\text{Var}(\varepsilon_i) = p_i(1 - p_i)$ ). Selección de variables por **eliminación hacia atrás** con umbral  $p < 0.05$  partiendo de los 22 predictores.

**Modelo final (4 variables,  $R^2 = 0.2458$ ):**

| Variable                            |            | Interpretación (puntos porcentuales) |
|-------------------------------------|------------|--------------------------------------|
| <code>focus_index</code>            | +0.0039*** | +0.39 p.p. por unidad adicional      |
| <code>burnout_level</code>          | -0.0025*** | -0.25 p.p. por unidad adicional      |
| <code>productivity_score</code>     | +0.0056*** | +0.56 p.p. por unidad adicional      |
| <code>academic_Undergraduate</code> | +0.0264*** | +2.64 p.p. vs categoría High_School  |

**Significados económicos:** mayor concentración, mayor productividad autorreportada y ser *Undergraduate* (respecto a *High School*) aumentan la probabilidad de rendir el examen; mayor agotamiento (burnout) la reduce. Todos los coeficientes son significativos al 1 %.

**Limitación estructural del MPL.** El **27.82 %** de las probabilidades predichas cae fuera del intervalo  $[0, 1]$ , lo que confirma la necesidad de modelos no lineales acotados. Además, el MPL tiende a predecir siempre la clase mayoritaria (0 % de recall sobre “no rindió”), reflejando tanto el desbalance de clases como la rigidez del efecto marginal constante.

### 0.4 Pregunta 3 — Modelo Probit

**Especificación:**  $P(\text{took\_exam}_i = 1) = \Phi(X_i' \beta)$ , donde  $\Phi$  es la CDF normal estándar. Estimación por Máxima Verosimilitud. Interpretación mediante **AME** (Average Marginal Effects): cambio promedio en la probabilidad evaluado en los valores observados de cada individuo.

**Modelo final (4 variables, Pseudo- $R^2 = 0.5878$ ):**

| Variable               | AME        | p.p.       |
|------------------------|------------|------------|
| focus_index            | +0.0034*** | +0.34 p.p. |
| burnout_level          | -0.0025*** | -0.25 p.p. |
| productivity_score     | +0.0067*** | +0.67 p.p. |
| academic_Undergraduate | +0.0176*** | +1.76 p.p. |

La selección backward arroja exactamente el **mismo conjunto de variables** que el MPL. Los signos coinciden y la magnitud de los efectos marginales promedio es comparable. El Probit soluciona la limitación del MPL: todas las probabilidades predichas se encuentran en  $[0, 1]$ .

## 0.5 Pregunta 4 — Modelo Logit

**Especificación:**  $P(\text{took\_exam}_i = 1) = \frac{e^{X_i'\beta}}{1+e^{X_i'\beta}}$ . Permite dos interpretaciones complementarias: **AME** (cambio en p.p.) y **Odds Ratios** ( $e^{\beta}$ , factor multiplicativo sobre las odds).

**Modelo final (5 variables, Pseudo-R<sup>2</sup> = 0.5883):**

| Variable               | AME (p.p.)     | OR   | Interpretación Odds   |
|------------------------|----------------|------|-----------------------|
| upcoming_deadline      | +1.56 p.p. **  | 1.53 | odds aumentan 53.4 %  |
| focus_index            | +0.34 p.p. *** | 1.10 | odds aumentan 9.7 %   |
| burnout_level          | -0.27 p.p. *** | 0.93 | odds disminuyen 7.2 % |
| productivity_score     | +0.68 p.p. *** | 1.20 | odds aumentan 20.4 %  |
| academic_Undergraduate | +1.73 p.p. *** | 1.61 | odds aumentan 60.7 %  |

El Logit recupera `upcoming_deadline` como significativa (al 5 %), que no sobrevivía en MPL ni Probit. Aporta, además, la interpretación en *odds ratios*, estándar en economía y ciencias sociales. La matriz de confusión mejora sustancialmente frente al MPL: recall de 59 % sobre la clase minoritaria vs 0 % del MPL.

## 0.6 Pregunta 5 — Comparación MPL, Probit y Logit

**1. Diferencias estructurales.** El MPL supone efectos marginales constantes sobre toda la distribución de  $X$ , lo que genera predicciones fuera de  $[0, 1]$  (27.8 % de los casos) y heterocedasticidad intrínseca. Probit y Logit usan funciones de enlace  $S$  que acotan la probabilidad en  $[0, 1]$  y capturan no linealidades.

**2. Probit vs Logit.** Difieren en el supuesto distribucional de los errores latentes (normal estándar vs. logística). Con  $n \approx 3.975$ , los AME convergen numéricamente y las diferencias son prácticamente irrelevantes en magnitud.

**3. Modelo más adecuado.** El **Logit** es la mejor opción para responder la pregunta de investigación por tres razones: (i) garantiza probabilidades en  $[0, 1]$ ; (ii) sus coeficientes tienen

interpretación directa como log-odds y permiten reportar OR, métrica estándar en la literatura; (iii) logró el mejor desempeño sobre la clase minoritaria (recall 59 % vs 0 % del MPL).

**4. Variables robustas a la especificación** (significativas al 5 % o más en los tres modelos): - **focus\_index** (+) — concentración - **burnout\_level** (-) — agotamiento - **productivity\_score** (+) — productividad - **academic\_Undergraduate** (+) — nivel Undergraduate vs High\_School

Estas cuatro variables constituyen el **núcleo causal robusto** de la probabilidad de rendir el examen. La variable **upcoming\_deadline** es significativa únicamente en Logit y podría interpretarse como marginalmente relevante.

**5. Limitación compartida.** El desbalance de clases (~91/9 %) limita estructuralmente la capacidad predictiva sobre estudiantes que no rindieron.

## 0.7 Pregunta 6 — Modelo Poisson para la Nota del Examen

**Muestra:** 3.630 estudiantes que rindieron (**took\_exam** = 1). **Variable dependiente:** **exam\_score\_int** = **exam\_score** redondeado al entero más cercano. **Limitación documentada:** **exam\_score** es una variable continua, no un conteo natural. El redondeo es la transformación mínima para cumplir con el requisito formal del Poisson (soporte en enteros no negativos).

**Estadística descriptiva clave:** Media = 20.52, Varianza = 127.65 → **ratio Var/Media** = **6.22**. Esta primera señal indica que el supuesto Poisson (equidispersión, Var = Media) es violado severamente.

**Modelo final (5 variables):**

| Variable                              | IRR   | EM (pts) | Interpretación           |
|---------------------------------------|-------|----------|--------------------------|
| <b>upcoming_deadline</b> -0.0266***   | 0.974 | -0.55    | -2.63 % en nota esperada |
| <b>mental_health_score</b> -0.0070*** | 1.007 | +0.14    | +0.71 %                  |
| <b>focus_index</b> +0.0135***         | 1.014 | +0.28    | +1.36 %                  |
| <b>burnout_level</b> -0.0088***       | 0.991 | -0.18    | -0.87 %                  |
| <b>productivity_score</b> +0.0211***  | 1.021 | +0.43    | +2.14 %                  |

**Advertencia explícita:** la devianza/gl = 1.75 y el ratio Var/Media = 6.22 sugieren sobredispersión. Por tanto los **errores estándar están subestimados** y los p-values son artificialmente pequeños. Esto motiva los análisis de las Preguntas 7 y 8.

## 0.8 Pregunta 7 — Diagnóstico de Sobredispersión y Óptimo

Se aplican **tres pruebas convergentes**:

1. **Descriptivo:** Var/Media = 6.22 (si Poisson fuera correcto, debería ser 1).
2. **Test de Cameron–Trivedi (1990):** regresión auxiliar  $(y - \hat{\mu})^2 - y = \alpha \hat{\mu}^2 + u$ . Resultado:  $\hat{\alpha} = 0.0299$ ,  $t = 28.13$ ,  $p < 10^{-8}$  → **rechaza H (equidispersión)**.
3. **Estimación directa por NB2:**  $\hat{\alpha} = 0.0284$ , IC 95 %: [0.0242, 0.0325], significativo al 1 %.

**Conclusión:** los tres métodos convergen. La sobredispersión es estadísticamente significativa y cuantitativamente relevante. El **valor óptimo de  $\alpha$  es aproximadamente 0.0284**, que implica una estructura de varianza  $\text{Var}(Y) = \mu + 0.0284 \cdot \mu^2$ . El modelo Poisson no es apropiado; la Binomial Negativa es necesaria.

## 0.9 Pregunta 8 — Modelo Binomial Negativa (NB2)

**Especificación:**  $E[Y_i|X_i] = \mu_i$ ,  $\text{Var}[Y_i] = \mu_i + \alpha\mu_i^2$ , con  $\alpha > 0$  capturando heterogeneidad no observada entre estudiantes.

**Nota técnica:** al estimar con los 22 predictores, la Hessiana resulta casi singular (p-values NaN), señal de sobreparametrización. Se recurre al conjunto de variables seleccionadas por Poisson, que converge sin problemas.

**Modelo final (5 variables,  $\alpha = 0.0284$ ):**

| Variable            | IRR        | EM (pts) | Interpretación           |
|---------------------|------------|----------|--------------------------|
| upcoming_deadline   | -0.0293*** | 0.971    | -2.89 % en nota esperada |
| mental_health_score | -0.0057*** | 1.006    | +0.57 %                  |
| focus_index         | +0.0146*** | 1.015    | +1.47 %                  |
| burnout_level       | -0.0094*** | 0.991    | -0.94 %                  |
| productivity_score  | +0.0224*** | 1.023    | +2.26 %                  |

Todas las variables permanecen significativas al 1 %. La interpretación económica es idéntica al Poisson: concentración, salud mental y productividad elevan la nota esperada; próxima entrega y agotamiento la reducen.

## 0.10 Pregunta 9 — Comparación Poisson vs Binomial Negativa

**1. Coeficientes similares, errores estándar distintos.** La sobredispersión **no sesga** los coeficientes del Poisson (pseudo-ML sigue siendo consistente), pero **subestima** los errores estándar en un factor aproximado de  $\sqrt{1 + \alpha\mu}$ . Esto infla los t-estadísticos y produce p-values artificialmente pequeños.

**2. Test de Razón de Verosimilitud (LRT).**  $H_0 : \alpha = 0$  vs  $H_1 : \alpha > 0$  (test de frontera, p-value dividido por 2). Resultado:  $\text{LRT} = 361.82$ ,  $p < 10^{-8} \rightarrow$  **rechaza Poisson con contundencia.**

**3. Indicadores de ajuste.**

| Modelo           | Log-Lik    | AIC       | BIC       |        |
|------------------|------------|-----------|-----------|--------|
| Poisson (final)  | -11.632.41 | 23.276.82 | 23.314.00 | —      |
| Binomial         | -11.451.50 | 22.917.00 | 22.960.38 | 0.0284 |
| Negativa (final) |            |           |           |        |

La NB gana en los tres criterios (Log-Lik más alto, AIC y BIC menores).

**4. Origen de la sobredispersión.** Heterogeneidad no observada entre estudiantes (motivación, contexto familiar, estado de salud el día del examen, etc.) que genera varianza adicional no capturada por los regresores.

**5. Modelo más adecuado.** La **Binomial Negativa** es el modelo correcto para esta pregunta de investigación: (a) el ratio Var/Media  $> 1$ , (b) Cameron–Trivedi rechaza  $H_0$  con  $p \approx 0$ , (c) LRT rechaza Poisson con  $p \approx 0$ , y (d) presenta menores AIC y BIC. Sus errores estándar son los válidos.

**6. Variables robustas al supuesto distribucional** (significativas al 1 % en ambos modelos): - focus\_index (+) - burnout\_level (-) - mental\_health\_score (+) - productivity\_score (+) - upcoming\_deadline (-)

Estas cinco variables tienen efectos **genuinos y robustos** sobre la nota esperada, independientes del supuesto de dispersión. Constituyen el conjunto explicativo más confiable para el desempeño académico en esta muestra.

---

## 0.11 Síntesis Global

A través de los dos bloques de modelos (binarios para asistencia y de conteo para nota), emergen consistentemente **tres variables centrales** que operan sobre el desempeño académico:

- **productivity\_score** y **focus\_index**: efecto positivo y robusto tanto sobre rendir el examen como sobre la nota obtenida.
- **burnout\_level**: efecto negativo robusto en ambos bloques.

Estos hallazgos son coherentes con la literatura sobre rendimiento académico: la productividad, la concentración y la ausencia de agotamiento constituyen los determinantes proximales más consistentes, por encima de factores demográficos, de estilo de vida o socioeconómicos observables en este dataset.

## 0.12 Importación de Librerías

```
[1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import statsmodels.api as sm
from statsmodels.stats.outliers_influence import variance_inflation_factor
from sklearn.metrics import confusion_matrix, classification_report
from scipy import stats
import warnings
warnings.filterwarnings('ignore')

plt.rcParams['figure.figsize'] = (14, 5)
plt.rcParams['figure.dpi'] = 100
sns.set_theme(style='whitegrid', palette='muted')
pd.set_option('display.max_columns', None)
```

```
pd.set_option('display.float_format', '{:.4f}'.format)
```

## 0.13 Pregunta 1 - Carga, Exploración y Limpieza de Datos

### 0.13.1 1.A Carga y Exploración Inicial

```
[2]: df = pd.read_csv("../data/student_productivity.csv")
n_orig = len(df)
n_vars_orig = df.shape[1]
print(f'Dimensiones originales: {df.shape[0]} × {df.shape[1]}')
df.head()
```

Dimensiones originales: 5621 × 22

```
[2]:
```

|   | student_id | age     | gender | academic_level | study_hours | self_study_hours | \ |
|---|------------|---------|--------|----------------|-------------|------------------|---|
| 0 | 1          | 20.0000 | NaN    | Undergraduate  | 5.3700      | 2.0900           |   |
| 1 | 2          | 16.0000 | Female | High School    | 5.8500      | 5.0400           |   |
| 2 | 3          | 18.0000 | Female | Undergraduate  | 5.6900      | 2.2700           |   |
| 3 | 4          | 24.0000 | Male   | Undergraduate  | 2.3200      | 1.0600           |   |
| 4 | 5          | 24.0000 | Female | Postgraduate   | 3.8700      | 2.6300           |   |

|   | online_classes_hours | social_media_hours | gaming_hours | sleep_hours | \ |
|---|----------------------|--------------------|--------------|-------------|---|
| 0 | 1.8500               | 3.6600             | 2.3200       | 7.7300      |   |
| 1 | 1.8700               | 3.6000             | 2.7900       | 6.1100      |   |
| 2 | 0.0000               | 2.9300             | 3.9400       | 7.1100      |   |
| 3 | 2.3000               | 4.3400             | 2.3700       | 8.5400      |   |
| 4 | 2.5400               | 3.7100             | 1.3000       | 7.6900      |   |

|   | screen_time_hours | exercise_minutes | caffeine_intake_mg | part_time_job | \ |
|---|-------------------|------------------|--------------------|---------------|---|
| 0 | 5.6800            | 54.0             | 475.0000           | No            |   |
| 1 | 8.9600            | 63.0             | 362.0000           | no            |   |
| 2 | 11.0200           | 28.0             | 200.0000           | No            |   |
| 3 | 8.7300            | 55.0             | 233.0000           | No            |   |
| 4 | 9.6000            | 60.0             | 159.0000           | No            |   |

|   | upcoming_deadline | internet_quality | mental_health_score | drug_use | \ |
|---|-------------------|------------------|---------------------|----------|---|
| 0 | 0.0000            | Good             | 3.0000              | NaN      |   |
| 1 | 0.0000            | Good             | 10.0000             | NaN      |   |
| 2 | 0.0000            | Average          | 5.0000              | NaN      |   |
| 3 | 1.0000            | Poor             | 3.0000              | 1.0000   |   |
| 4 | 1.0000            | Poor             | 2.0000              | NaN      |   |

|   | focus_index | burnout_level | productivity_score | exam_score |
|---|-------------|---------------|--------------------|------------|
| 0 | 19.0100     | 31.7700       | 42.5900            | 25.0800    |
| 1 | 42.1000     | 45.8900       | 67.1500            | 37.8300    |
| 2 | 21.9300     | 37.0700       | 37.6800            | 18.6600    |

|   |         |         |         |        |
|---|---------|---------|---------|--------|
| 3 | 13.4700 | 43.6300 | 12.8300 | 1.0000 |
| 4 | 19.9500 | 56.6200 | 18.5300 | 7.7800 |

```
[3]: print('Tipos de Datos:')
      print(df.dtypes)
      print()
      df.info()
```

Tipos de Datos:

```
student_id      int64
age             float64
gender          object
academic_level  object
study_hours     float64
self_study_hours float64
online_classes_hours float64
social_media_hours float64
gaming_hours    float64
sleep_hours     float64
screen_time_hours float64
exercise_minutes object
caffeine_intake_mg float64
part_time_job   object
upcoming_deadline float64
internet_quality object
mental_health_score float64
drug_use        float64
focus_index    float64
burnout_level   float64
productivity_score float64
exam_score      float64
dtype: object
```

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 5621 entries, 0 to 5620

Data columns (total 22 columns):

| # | Column               | Non-Null Count | Dtype   |
|---|----------------------|----------------|---------|
| 0 | student_id           | 5621 non-null  | int64   |
| 1 | age                  | 4973 non-null  | float64 |
| 2 | gender               | 5063 non-null  | object  |
| 3 | academic_level       | 4991 non-null  | object  |
| 4 | study_hours          | 5047 non-null  | float64 |
| 5 | self_study_hours     | 4954 non-null  | float64 |
| 6 | online_classes_hours | 4939 non-null  | float64 |
| 7 | social_media_hours   | 4965 non-null  | float64 |
| 8 | gaming_hours         | 4965 non-null  | float64 |
| 9 | sleep_hours          | 5068 non-null  | float64 |

```

10 screen_time_hours      5035 non-null    float64
11 exercise_minutes      5022 non-null    object
12 caffeine_intake_mg     5021 non-null    float64
13 part_time_job          4918 non-null    object
14 upcoming_deadline      4904 non-null    float64
15 internet_quality       5098 non-null    object
16 mental_health_score    4946 non-null    float64
17 drug_use               1518 non-null    float64
18 focus_index            4988 non-null    float64
19 burnout_level          4905 non-null    float64
20 productivity_score     4983 non-null    float64
21 exam_score             4912 non-null    float64
dtypes: float64(16), int64(1), object(5)
memory usage: 966.2+ KB

```

```

[4]: missing = df.isnull().sum()
missing_pct = (missing / len(df) * 100).round(2)
m_df = pd.DataFrame({'Faltantes': missing, 'Porcentaje (%)': missing_pct})
m_df = m_df[m_df['Faltantes'] > 0].sort_values('Porcentaje (%)',
↪ascending=False)
print('Valores Faltantes por Variable:')
print(m_df.to_string())

```

Valores Faltantes por Variable:

|                      | Faltantes | Porcentaje (%) |
|----------------------|-----------|----------------|
| drug_use             | 4103      | 72.9900        |
| upcoming_deadline    | 717       | 12.7600        |
| burnout_level        | 716       | 12.7400        |
| exam_score           | 709       | 12.6100        |
| part_time_job        | 703       | 12.5100        |
| online_classes_hours | 682       | 12.1300        |
| mental_health_score  | 675       | 12.0100        |
| self_study_hours     | 667       | 11.8700        |
| gaming_hours         | 656       | 11.6700        |
| social_media_hours   | 656       | 11.6700        |
| age                  | 648       | 11.5300        |
| productivity_score   | 638       | 11.3500        |
| focus_index          | 633       | 11.2600        |
| academic_level       | 630       | 11.2100        |
| caffeine_intake_mg   | 600       | 10.6700        |
| exercise_minutes     | 599       | 10.6600        |
| screen_time_hours    | 586       | 10.4300        |
| study_hours          | 574       | 10.2100        |
| gender               | 558       | 9.9300         |
| sleep_hours          | 553       | 9.8400         |
| internet_quality     | 523       | 9.3000         |

### 0.13.2 1.B Limpieza y Estandarización de Datos

**Eliminación de drug\_use** Se elimina `drug_use` porque el **72.99 %** de sus valores son ausentes (4.103 de 5.621 observaciones). Con más de dos tercios de los datos faltantes, ningún método de tratamiento es válido.

```
[5]: df = df.drop(columns=['drug_use'])
```

**Eliminación de student\_id** Ya que el identificador único no posee contenido informativo para los modelos econométricos.

```
[6]: df = df.drop(columns=['student_id'])
```

**Limpieza y conversión de exercise\_minutes → exercise\_hours** Problema detectado: 602 observaciones contienen el sufijo ' min' (ej. '28.0 min'), lo que fuerza el tipo *string* e impide operaciones numéricas.

Por ello, se elimina el sufijo, se convierte a numérico y se divide entre 60 para obtener `exercise_hours`. La conversión a horas es necesaria para **homogeneizar las unidades** de todas las variables de tiempo (el resto está en horas), facilitando la interpretación y comparación directa de coeficientes en los modelos. El rango resultante [0 – 2.48 h/día] es fisiológicamente plausible.

```
[7]: df['exercise_minutes'] = (
    df['exercise_minutes'].astype(str)
    .str.replace(' min', '', regex=False).str.strip()
)
df['exercise_minutes'] = pd.to_numeric(df['exercise_minutes'], errors='coerce')
df['exercise_hours'] = df['exercise_minutes'] / 60
df = df.drop(columns=['exercise_minutes'])
print('exercise_hours creada.')
print(df['exercise_hours'].describe())
```

```
exercise_hours creada.
count    5022.0000
mean         1.2444
std          0.7162
min          0.0000
25%          0.6167
50%          1.2500
75%          1.8667
max          2.4833
Name: exercise_hours, dtype: float64
```

**Estandarización de academic\_level** Problema detectado: Espacios en blanco al final del string generan 7 categorías aparentes en lugar de 3 ('High School' vs 'High School '). Una codificación dummy sin corregir esto generaría columnas redundantes e incorrectas.

Por tal motivo, se aplica `.str.strip()` y se reemplaza el espacio interno por `_`.

```
[8]: df['academic_level'] = df['academic_level'].str.strip().str.replace(' ', '_')
print(df['academic_level'].value_counts(dropna=False))
```

```
academic_level
Postgraduate      1695
High_School       1668
Undergraduate     1628
NaN                630
Name: count, dtype: int64
```

**Estandarización y binarización de part\_time\_job** Problema detectado: Capitalización inconsistente genera 4 valores distintos ('Yes'/'yes', 'No'/'no').

Debido a lo anterior, se normaliza a minúsculas y se codifica como binario entero (1 = tiene trabajo part-time, 0 = no tiene).

```
[9]: df['part_time_job'] = df['part_time_job'].str.lower().map({'yes': 1, 'no': 0})
print(df['part_time_job'].value_counts(dropna=False))
```

```
part_time_job
0.0000      2469
1.0000      2449
NaN          703
Name: count, dtype: int64
```

**study\_hours y screen\_time\_hours — Documentación de inconsistencia y retención** Aunque la descripción define `study_hours` como total de `self_study_hours` + `online_classes_hours`, y `screen_time_hours` como total de tiempo frente a pantallas, el análisis empírico muestra inconsistencia interna: en el **48.5 %** de los casos `study_hours < self_study + online_classes`, y en el **45.1 %**, `screen_time < gaming + social + online`. Esto indica que los encuestados reportaron cada variable de forma independiente.

**Decisión:** Se **retienen** ambas variables. Podrían capturar información adicional no recogida por sus componentes (ej. clases presenciales en `study_hours`). Se documenta la inconsistencia como limitación y se deja que los modelos determinen empíricamente si aportan poder explicativo adicional.

```
[10]: df_chk = df[['self_study_hours', 'online_classes_hours', 'study_hours']].dropna()
diff1 = df_chk['study_hours'] - df_chk['self_study_hours'] -
    ↪ df_chk['online_classes_hours']
n1_men = (diff1 < -0.01).sum()
print('study_hours vs self_study + online_classes')
print(f' Casos con study < self+online: {n1_men} ({100*n1_men/len(df_chk):.
    ↪ 1f}%) → RETENIDA\n')

df_chk2 =
    ↪ df[['screen_time_hours', 'gaming_hours', 'social_media_hours', 'online_classes_hours']].
    ↪ dropna()
diff2 = (df_chk2['screen_time_hours'] - df_chk2['gaming_hours']
```

```

        -df_chk2['social_media_hours']-df_chk2['online_classes_hours'])
n2_men = (diff2 < -0.01).sum()
print('screen_time_hours vs gaming + social + online')
print(f' Casos con screen < suma: {n2_men} ({100*n2_men/len(df_chk2):.1f}%) →
↳RETENIDA')

```

```

study_hours vs self_study + online_classes
Casos con study < self+online: 2250 (48.5%) → RETENIDA

```

```

screen_time_hours vs gaming + social + online
Casos con screen < suma: 2054 (45.1%) → RETENIDA

```

**Creación de la variable binaria took\_exam** Según la descripción, exam\_score = 1.0 identifica a los estudiantes que **no rindieron** el examen. Se asume que este es un valor centinela artificial y no una nota real, basándose en que: (a) la escala de notas llega hasta 64 puntos, por lo que una nota de exactamente 1.0 sería extremadamente inusual como resultado, y (b) la descripción lo define explícitamente como indicador de no-rendición.

**Supuesto sobre los NaN en exam\_score (709 obs.):** Se interpretan como **datos genuinamente faltantes** (el examen existió pero la nota no fue registrada), y se excluyen de los modelos 2-4. No se imputan porque took\_exam es la variable dependiente: asignar 0 o 1 artificialmente sesgaría directamente los coeficientes estimados.

| Condición        | took_exam      | n     |
|------------------|----------------|-------|
| exam_score > 1.0 | 1 (rindió)     | 4.473 |
| exam_score = 1.0 | 0 (no rindió)  | 439   |
| exam_score = NaN | NaN (excluido) | 709   |

```

[11]: df['took_exam'] = np.where(df['exam_score']>1.0,1,
                                np.where(df['exam_score']==1.0,0,np.nan))
print('Distribución de took_exam:')
n1_all = (df['took_exam']==1).sum()
n0_all = (df['took_exam']==0).sum()
nna_all = df['took_exam'].isna().sum()
nobs_all= n1_all + n0_all
print(f' Rindió (1): {n1_all} ({n1_all/nobs_all*100:.1f}%)')
print(f' No rindió (0): {n0_all} ({n0_all/nobs_all*100:.1f}%)')
print(f' Desconocido (NaN): {nna_all} (excluidos de P2-4, independiente del
↳listwise)')
print(f'\n Tasa asistencia (sobre observados): {n1_all/nobs_all*100:.2f}%)')
print(f' Clase minoritaria (no rindió): {n0_all/nobs_all*100:.2f}%)')
print('\n Notese que existe desbalance de clases (~91% vs ~9%).')
print(' Esto puede afectar la precisión de los modelos sobre la clase
↳minoritaria.')

```

```

Distribución de took_exam:
Rindió (1): 4473 (91.1%)

```

No rindió (0): 439 (8.9%)

Desconocido (NaN): 709 (excluidos de P2-4, independiente del listwise)

Tasa asistencia (sobre observados): 91.06%

Clase minoritaria (no rindió): 8.94%

Notese que existe desbalance de clases (~91% vs ~9%).

Esto puede afectar la precisión de los modelos sobre la clase minoritaria.

### 0.13.3 1.C Tratamiento de Valores Faltantes: Eliminación Listwise (*Complete Case Analysis*)

**Mecanismo de datos faltantes:** Se ha establecido que el mecanismo de ausencia es **MCAR** (**Missing Completely At Random**): la probabilidad de que un valor falte no depende ni del propio valor faltante ni de ninguna otra variable del dataset. Bajo MCAR, la eliminación listwise produce **estimadores insesgados y consistentes** — los casos completos son una muestra aleatoria del dataset original. El único costo es una pérdida de eficiencia (mayor varianza en los estimadores por tener menos observaciones), pero no existe sesgo sistemático.

**Procedimiento:** Se eliminan todas las observaciones que tengan al menos un valor faltante en cualquiera de los predictores. Las variables dependientes (`exam_score`, `took_exam`) conservan sus NaN originales, que se manejan separadamente en cada modelo.

```
[12]: feature_cols = [
    'age', 'study_hours', 'self_study_hours', 'online_classes_hours',
    'social_media_hours', 'gaming_hours', 'screen_time_hours',
    'sleep_hours', 'exercise_hours', 'caffeine_intake_mg',
    'part_time_job', 'upcoming_deadline', 'mental_health_score',
    'focus_index', 'burnout_level', 'productivity_score',
    'gender', 'academic_level', 'internet_quality'
]

# Identificar observaciones con NaN en predictores
has_nan_pred = df[feature_cols].isnull().any(axis=1)
n_nan_obs    = has_nan_pred.sum()
pct_nan_obs  = 100 * has_nan_pred.mean()
n_completas  = (~has_nan_pred).sum()
pct_completas = 100 * (~has_nan_pred).mean()

print('Impacto de la Eliminación Listwise')
print(f' Dataset post-limpieza básica:           {len(df):>5} observaciones')
print(f' Obs con al menos 1 NaN en predictores: {n_nan_obs:>5} ({pct_nan_obs:.1f}%)')
print(f' Obs completas retenidas:                 {n_completas:>5} ({pct_completas:.1f}%)')
print(f' Pérdida de observaciones:                {n_nan_obs:>5} ({pct_nan_obs:.1f}%)')
print()
```

```
print(' NaN por variable (motivo de eliminación):')
nan_per_var = df[feature_cols].isnull().sum().sort_values(ascending=False)
for col, n in nan_per_var[nan_per_var>0].items():
    print(f' {col:<25}: {n:>4} NaN ({100*n/len(df):.1f}%)')
```

Impacto de la Eliminación Listwise

|                                        |                    |
|----------------------------------------|--------------------|
| Dataset post-limpieza básica:          | 5621 observaciones |
| Obs con al menos 1 NaN en predictores: | 1625 (28.9%)       |
| Obs completas retenidas:               | 3996 (71.1%)       |
| Pérdida de observaciones:              | 1625 (28.9%)       |

NaN por variable (motivo de eliminación):

|                      |                   |
|----------------------|-------------------|
| upcoming_deadline    | : 717 NaN (12.8%) |
| burnout_level        | : 716 NaN (12.7%) |
| part_time_job        | : 703 NaN (12.5%) |
| online_classes_hours | : 682 NaN (12.1%) |
| mental_health_score  | : 675 NaN (12.0%) |
| self_study_hours     | : 667 NaN (11.9%) |
| gaming_hours         | : 656 NaN (11.7%) |
| social_media_hours   | : 656 NaN (11.7%) |
| age                  | : 648 NaN (11.5%) |
| productivity_score   | : 638 NaN (11.4%) |
| focus_index          | : 633 NaN (11.3%) |
| academic_level       | : 630 NaN (11.2%) |
| caffeine_intake_mg   | : 600 NaN (10.7%) |
| exercise_hours       | : 599 NaN (10.7%) |
| screen_time_hours    | : 586 NaN (10.4%) |
| study_hours          | : 574 NaN (10.2%) |
| gender               | : 558 NaN (9.9%)  |
| sleep_hours          | : 553 NaN (9.8%)  |
| internet_quality     | : 523 NaN (9.3%)  |

```
[13]: # Aplicamos listwise deletion
df_clean = df[~has_nan_pred].copy()
print(f'Dataset final (casos completos): {len(df_clean)} observaciones')
print(f'Variables: {df_clean.shape[1]}')
```

Dataset final (casos completos): 3996 observaciones  
Variables: 21

#### 0.13.4 1.D Codificación de Variables Categóricas

Se crean dummies omitiendo la categoría de referencia: - **gender**: referencia = **Male** -  
**academic\_level**: referencia = **High\_School** - **internet\_quality**: referencia = **Good**

```
[14]:
```

```

gen_d = pd.get_dummies(df_clean['gender'], prefix='gender',
    ↳drop_first=False, dtype=int).drop(columns=['gender_Male'])
acad_d = pd.get_dummies(df_clean['academic_level'],
    ↳prefix='academic', drop_first=False, dtype=int).
    ↳drop(columns=['academic_High_School'])
inet_d = pd.get_dummies(df_clean['internet_quality'],
    ↳prefix='internet', drop_first=False, dtype=int).drop(columns=['internet_Good'])

df_clean = pd.concat([df_clean, gen_d, acad_d, inet_d], axis=1)
df_clean = df_clean.drop(columns=['gender', 'academic_level', 'internet_quality'])

feature_cols = [
    'age', 'study_hours', 'self_study_hours', 'online_classes_hours',
    'social_media_hours', 'gaming_hours', 'screen_time_hours',
    'sleep_hours', 'exercise_hours', 'caffeine_intake_mg',
    'part_time_job', 'upcoming_deadline', 'mental_health_score',
    'focus_index', 'burnout_level', 'productivity_score',
    'gender_Female', 'gender_Other',
    'academic_Undergraduate', 'academic_Postgraduate',
    'internet_Average', 'internet_Poor'
]
print(f'Predictores finales: {len(feature_cols)}')
print(feature_cols)

```

Predictores finales: 22

```

['age', 'study_hours', 'self_study_hours', 'online_classes_hours',
'social_media_hours', 'gaming_hours', 'screen_time_hours', 'sleep_hours',
'exercise_hours', 'caffeine_intake_mg', 'part_time_job', 'upcoming_deadline',
'mental_health_score', 'focus_index', 'burnout_level', 'productivity_score',
'gender_Female', 'gender_Other', 'academic_Undergraduate',
'academic_Postgraduate', 'internet_Average', 'internet_Poor']

```

### 0.13.5 1.E Estadísticas Descriptivas (sobre casos completos)

```

[15]: numeric_cols = [
    'age', 'study_hours', 'self_study_hours', 'online_classes_hours',
    'social_media_hours', 'gaming_hours', 'screen_time_hours',
    'sleep_hours', 'exercise_hours', 'caffeine_intake_mg',
    'mental_health_score', 'focus_index', 'burnout_level',
    'productivity_score', 'exam_score'
]
print('Estadísticas Descriptivas - Variables Numéricas (n = casos completos)')
print(df_clean[numeric_cols].describe().round(3).to_string())

```

Estadísticas Descriptivas - Variables Numéricas (n = casos completos)


```

    age  study_hours  self_study_hours  online_classes_hours
social_media_hours  gaming_hours  screen_time_hours  sleep_hours  exercise_hours
caffeine_intake_mg  mental_health_score  focus_index  burnout_level

```


|           | productivity_score | exam_score |           |           |           |
|-----------|--------------------|------------|-----------|-----------|-----------|
| count     | 3996.0000          | 3996.0000  | 3996.0000 | 3996.0000 | 3996.0000 |
| 3996.0000 | 3996.0000          |            | 3996.0000 | 3996.0000 | 3996.0000 |
| 3996.0000 |                    | 3996.0000  | 3996.0000 | 3996.0000 | 3996.0000 |
| 3975.0000 |                    |            |           |           |           |
| mean      | 20.5260            | 4.5390     | 2.4720    |           | 2.0190    |
| 2.9920    | 1.5670             |            | 6.9950    | 7.0190    | 1.2400    |
| 252.3340  |                    | 5.5200     | 29.4970   | 45.6700   | 37.3600   |
| 18.8270   |                    |            |           |           |           |
| std       | 2.8630             | 1.8220     | 1.1740    |           | 0.9890    |
| 1.4790    | 1.1120             |            | 2.4840    | 1.1680    | 0.7180    |
| 144.6030  |                    | 2.8810     | 9.9050    | 14.1850   | 16.8730   |
| 12.1060   |                    |            |           |           |           |
| min       | 16.0000            | 0.0000     | 0.0000    |           | 0.0000    |
| 0.0000    | 0.0000             |            | 1.0000    | 4.0000    | 0.0000    |
| 0.0000    |                    | 1.0000     | 1.0000    | 1.0000    | 1.0000    |
| 1.0000    |                    |            |           |           |           |
| 25%       | 18.0000            | 3.2700     | 1.6500    |           | 1.3200    |
| 1.9700    | 0.6700             |            | 5.2900    | 6.2300    | 0.6170    |
| 130.0000  |                    | 3.0000     | 22.6750   | 35.8500   | 25.2650   |
| 9.3250    |                    |            |           |           |           |
| 50%       | 21.0000            | 4.5300     | 2.4800    |           | 2.0100    |
| 2.9700    | 1.4900             |            | 6.9900    | 7.0100    | 1.2500    |
| 252.0000  |                    | 5.0000     | 29.4150   | 45.7100   | 36.8850   |
| 17.9800   |                    |            |           |           |           |
| 75%       | 23.0000            | 5.7600     | 3.2800    |           | 2.6820    |
| 4.0300    | 2.3500             |            | 8.7100    | 7.8200    | 1.8540    |
| 378.0000  |                    | 8.0000     | 36.2500   | 55.3520   | 49.3420   |
| 27.4750   |                    |            |           |           |           |
| max       | 25.0000            | 10.8000    | 6.5200    |           | 6.0000    |
| 8.2100    | 5.6400             |            | 15.3000   | 10.0000   | 2.4830    |
| 499.0000  |                    | 10.0000    | 61.8900   | 97.5800   | 91.5200   |
| 64.0900   |                    |            |           |           |           |

```
[16]: n_nc = len(numeric_cols)
n_rows = (n_nc + 4) // 5
fig, axes = plt.subplots(n_rows, 5, figsize=(22, n_rows*4))
axes = axes.flatten()
for i, col in enumerate(numeric_cols):
    axes[i].hist(df_clean[col].dropna(), bins=30, color='steelblue',
edgecolor='white', alpha=0.85)
    axes[i].set_title(col, fontsize=9, fontweight='bold')
for j in range(n_nc, len(axes)): axes[j].set_visible(False)
plt.suptitle('Distribución de Variables Numéricas (casos completos)',
fontsize=14, fontweight='bold', y=1.01)
plt.tight_layout(); plt.show()
```



```
[17]: fig, axes = plt.subplots(n_rows, 5, figsize=(22, n_rows*4))
axes = axes.flatten()
for i, col in enumerate(numeric_cols):
    axes[i].boxplot(df_clean[col].dropna(), patch_artist=True,
                    boxprops=dict(facecolor='steelblue',alpha=0.6),
                    medianprops=dict(color='red',linewidth=2))
    axes[i].set_title(col, fontsize=9, fontweight='bold')
for j in range(n_nc, len(axes)): axes[j].set_visible(False)
plt.suptitle('Boxplots (casos completos)', fontsize=14, fontweight='bold', y=1.01)
plt.tight_layout(); plt.show()

print('Outliers (IQR)')
for col in numeric_cols:
    d = df_clean[col].dropna()
    Q1,Q3 = d.quantile(0.25), d.quantile(0.75)
    IQR = Q3 - Q1
    n_out = ((d<Q1-1.5*IQR)|(d>Q3+1.5*IQR)).sum()
    print(f' {col:<25}: {n_out:>4} ({100*n_out/len(d):.1f}%)')
```



#### Outliers (IQR)

|                      |   |           |
|----------------------|---|-----------|
| age                  | : | 0 (0.0%)  |
| study_hours          | : | 15 (0.4%) |
| self_study_hours     | : | 7 (0.2%)  |
| online_classes_hours | : | 14 (0.4%) |
| social_media_hours   | : | 18 (0.5%) |
| gaming_hours         | : | 14 (0.4%) |
| screen_time_hours    | : | 13 (0.3%) |
| sleep_hours          | : | 0 (0.0%)  |
| exercise_hours       | : | 0 (0.0%)  |
| caffeine_intake_mg   | : | 0 (0.0%)  |
| mental_health_score  | : | 0 (0.0%)  |
| focus_index          | : | 22 (0.6%) |
| burnout_level        | : | 14 (0.4%) |
| productivity_score   | : | 6 (0.2%)  |
| exam_score           | : | 6 (0.2%)  |

Dado que el porcentaje de outliers es inferior al 0.6 % en todas las variables y los valores extremos son plausibles, se **decide mantenerlos** para evitar sesgo de selección

```
[18]: # Figura 1: Variables categóricas (reconstruidas desde dummies)
# gender, academic_level e internet_quality fueron eliminadas al crear dummies,
# por lo que se reconstruyen sus distribuciones a partir de las columnas dummy.

gender_counts = pd.Series({
    'Male': int(((df_clean['gender_Female']==0) &
    ↪(df_clean['gender_Other']==0)).sum()),
```

```

    'Female':      int(df_clean['gender_Female'].sum()),
    'Other':       int(df_clean['gender_Other'].sum())
})
acad_counts = pd.Series({
    'High_School':  int(((df_clean['academic_Undergraduate']==0) &
↪(df_clean['academic_Postgraduate']==0)).sum()),
    'Undergraduate': int(df_clean['academic_Undergraduate'].sum()),
    'Postgraduate': int(df_clean['academic_Postgraduate'].sum())
})
inet_counts = pd.Series({
    'Good':        int(((df_clean['internet_Average']==0) &
↪(df_clean['internet_Poor']==0)).sum()),
    'Average':     int(df_clean['internet_Average'].sum()),
    'Poor':        int(df_clean['internet_Poor'].sum())
})

fig, axes = plt.subplots(1, 3, figsize=(15, 5))
palette = ['#4878CF', '#D65F5F', '#6ACC65']

for ax, counts, title in zip(
    axes,
    [gender_counts, acad_counts, inet_counts],
    ['Género', 'Nivel Académico', 'Calidad de Internet']
):
    bars = ax.bar(counts.index, counts.values,
                  color=palette[:len(counts)], edgecolor='white', linewidth=1.2)
    ax.set_title(title, fontsize=12, fontweight='bold')
    ax.set_ylabel('Frecuencia')
    for bar in bars:
        ax.annotate(f'{int(bar.get_height())}',
                    (bar.get_x() + bar.get_width()/2, bar.get_height()),
                    ha='center', va='bottom', fontsize=10)

plt.suptitle('Distribución de Variables Categóricas (casos completos)',
            fontsize=13, fontweight='bold')
plt.tight_layout(); plt.show()

# Figura 2: Variables binarias clave
fig, axes = plt.subplots(1, 3, figsize=(15, 5))
for ax, col, title in zip(
    axes,
    ['part_time_job', 'upcoming_deadline', 'gender_Female'],
    ['Part-time Job (1=Sí)', 'Upcoming Deadline (1=Sí)', 'Gender Female (1=Sí)']
):
    counts = df_clean[col].value_counts().sort_index()
    bars = ax.bar(counts.index.astype(str), counts.values,
                  color=['#4878CF', '#D65F5F'], edgecolor='white')


```

```

ax.set_title(title, fontsize=11, fontweight='bold')
ax.set_ylabel('Frecuencia')
for bar in bars:
    ax.annotate(f'{int(bar.get_height())}',
                (bar.get_x() + bar.get_width()/2, bar.get_height()),
                ha='center', va='bottom', fontsize=10)

plt.suptitle('Variables Binarias Clave (casos completos)', fontsize=13,
             fontweight='bold')
plt.tight_layout(); plt.show()

```



### 0.13.6 1.F Análisis de Correlación y VIF

```

[19]: df_obs_corr = df_clean[df_clean['took_exam'].notna()]
corr_bin = (df_obs_corr[feature_cols+['took_exam']].corr()['took_exam']
            .drop('took_exam').sort_values(key=abs,ascending=False))
print('Correlación con took_exam')
print(corr_bin.round(4).to_string())
print()
df_cnt_c = df_clean[df_clean['took_exam']==1]

```

```

corr_cnt = (df_cnt_c[feature_cols+['exam_score']].corr()['exam_score']
            .drop('exam_score').sort_values(key=abs,ascending=False))
print('Correlación con exam_score')
print(corr_cnt.round(4).to_string())

```

Correlación con took\_exam


|                        |         |
|------------------------|---------|
| productivity_score     | 0.4755  |
| focus_index            | 0.4084  |
| mental_health_score    | 0.2841  |
| study_hours            | 0.2782  |
| burnout_level          | -0.2295 |
| sleep_hours            | 0.1451  |
| upcoming_deadline      | -0.0951 |
| part_time_job          | -0.0896 |
| screen_time_hours      | -0.0892 |
| gaming_hours           | -0.0505 |
| social_media_hours     | -0.0503 |
| self_study_hours       | 0.0479  |
| academic_Undergraduate | 0.0446  |
| caffeine_intake_mg     | -0.0388 |
| age                    | -0.0190 |
| exercise_hours         | 0.0158  |
| academic_Postgraduate  | -0.0105 |
| internet_Average       | 0.0099  |
| gender_Other           | 0.0087  |
| internet_Poor          | -0.0086 |
| gender_Female          | -0.0084 |
| online_classes_hours   | -0.0071 |

Correlación con exam\_score

|                        |         |
|------------------------|---------|
| productivity_score     | 0.8639  |
| focus_index            | 0.7118  |
| mental_health_score    | 0.5064  |
| study_hours            | 0.4599  |
| burnout_level          | -0.3703 |
| sleep_hours            | 0.2176  |
| upcoming_deadline      | -0.1925 |
| part_time_job          | -0.1225 |
| screen_time_hours      | -0.1063 |
| social_media_hours     | -0.0932 |
| caffeine_intake_mg     | -0.0663 |
| self_study_hours       | 0.0639  |
| exercise_hours         | 0.0441  |
| gaming_hours           | -0.0392 |
| gender_Female          | 0.0196  |
| online_classes_hours   | 0.0165  |
| academic_Undergraduate | -0.0162 |
| gender_Other           | -0.0136 |

```
internet_Poor          0.0130
internet_Average       0.0100
age                   -0.0071
academic_Postgraduate  -0.0004
```

```
[20]: corr_m = df_clean[feature_cols].corr()
plt.figure(figsize=(18,15))
mask = np.triu(np.ones_like(corr_m, dtype=bool))
sns.heatmap(corr_m,mask=mask,annot=True,fmt='.2f',cmap='RdBu_r',center=0,
            linewidths=0.3,cbar_kws={'shrink':0.8},annot_kws={'size':6})
plt.title('Matriz de Correlación entre Predictores', fontsize=13,
         fontweight='bold')
plt.xticks(rotation=45, ha='right', fontsize=7); plt.yticks(fontsize=7)
plt.tight_layout(); plt.show()
```



```
[21]: X_vif = sm.add_constant(df_clean[feature_cols].dropna())
vif_df = pd.DataFrame({
    'Variable': X_vif.columns,
    'VIF': [variance_inflation_factor(X_vif.values,i) for i in range(X_vif.
↳shape[1])]
})
vif_df = vif_df[vif_df['Variable']!='const'].sort_values('VIF',ascending=False)
print(vif_df.to_string(index=False))
print('\nVIF<5: sin problema | 5-10: moderado | >10: grave')
```

| Variable               | VIF     |
|------------------------|---------|
| productivity_score     | 11.5419 |
| burnout_level          | 6.1918  |
| mental_health_score    | 5.2560  |
| study_hours            | 5.1784  |
| focus_index            | 4.5624  |
| sleep_hours            | 2.4617  |
| upcoming_deadline      | 2.4548  |
| part_time_job          | 1.7509  |
| screen_time_hours      | 1.6625  |
| social_media_hours     | 1.3647  |
| academic_Postgraduate  | 1.3389  |
| academic_Undergraduate | 1.3378  |
| internet_Poor          | 1.3131  |
| internet_Average       | 1.3108  |
| caffeine_intake_mg     | 1.2199  |
| self_study_hours       | 1.2085  |
| gender_Female          | 1.1293  |
| gender_Other           | 1.1260  |
| exercise_hours         | 1.1179  |
| gaming_hours           | 1.1142  |
| online_classes_hours   | 1.0060  |
| age                    | 1.0048  |

VIF<5: sin problema | 5-10: moderado | >10: grave

---

## 0.14 Funciones Auxiliares

```
[22]: def backward_ols(X, y, thr=0.05):
    feats = list(X.columns)
    while feats:
        res = sm.OLS(y, sm.add_constant(X[feats])).fit(cov_type='HC3')
        pv = res.pvalues.drop('const', errors='ignore')
        if pv.max() > thr: feats.remove(pv.idxmax())
        else: break
    return res, feats
```

```

def backward_mle(X, y, Cls, thr=0.05):
    feats = list(X.columns)
    while feats:
        try: res = Cls(y, sm.add_constant(X[feats])).fit(disp=0, maxiter=500)
        except: res = Cls(y, sm.add_constant(X[feats])).
    fit(method='bfgs', maxiter=1000, disp=0)
    pv = res.pvalues.drop(['const', 'alpha'], errors='ignore')
    if len(pv)==0: break
    if pv.max()>thr: feats.remove(pv.idxmax())
    else: break
    return res, feats

def irr_table(model):
    ci = model.conf_int()
    return pd.DataFrame({
        'IRR': np.exp(model.params),
        'IC 2.5%': np.exp(ci.iloc[:,0]),
        'IC 97.5%': np.exp(ci.iloc[:,1]),
        'p-value': model.pvalues
    }).drop(index=['const', 'alpha'], errors='ignore')

def marginal_effect_cnt(model, X):
    mu_bar = model.predict(sm.add_constant(X)).mean()
    return model.params.drop(['const', 'alpha'], errors='ignore') * mu_bar

def poisson_deviance(model, y):
    mu = model.predict()
    with np.errstate(divide='ignore', invalid='ignore'):
        term = np.where(y > 0, y * np.log(y / mu), 0)
    return 2 * np.sum(term - (y - mu))

def stars(p): return '***' if p<0.01 else ('**' if p<0.05 else ('*' if p<0.10
    else ''))

def sig_txt(p):
    if p<0.01: return 'estadísticamente significativo al 1%'
    if p<0.05: return 'estadísticamente significativo al 5%'
    if p<0.10: return 'estadísticamente significativo al 10%'
    return 'NO estadísticamente significativo al 10%'

```

```
def robustness_table(models_dict, all_vars):
    rows = []
    for v in sorted(all_vars):
        row = {'Variable': v}
        for name, (model, sel_vars) in models_dict.items():
            if v not in sel_vars: row[name] = '-'
            else:
                p = model.pvalues.get(v, 1.0)
                row[name] = stars(p) if p < 0.10 else 'ns'
        rows.append(row)
    return pd.DataFrame(rows).set_index('Variable')

print('Funciones cargadas.')
```

Funciones cargadas.

## 0.15 Pregunta 2 — Modelo de Probabilidad Lineal (MPL / MCO)

$$P(\text{took\_exam}_i = 1) = \beta_0 + \sum_k \beta_k X_{ki} + \varepsilon_i$$

**Muestra:** casos completos con `took_exam` conocido.

**Errores estándar HC3:** robustos a heterocedasticidad estructural del MPL ( $\text{Var}(\varepsilon_i) = p_i(1-p_i)$ ).

**Selección:** eliminación hacia atrás, umbral  $p > 0.05$ .

```
[23]: df_bin = df_clean[df_clean['took_exam'].notna()].copy()
y_bin = df_bin['took_exam'].astype(float)
X_bin = df_bin[feature_cols]
n_bin = len(df_bin)
n1_bin = int(y_bin.sum()); n0_bin = int((y_bin==0).sum())
nobs_bin= n1_bin + n0_bin
print(f'Muestra: {n_bin} obs | took_exam=1: {n1_bin} ({100*n1_bin/nobs_bin:.1f}%) '
      f'| took_exam=0: {n0_bin} ({100*n0_bin/nobs_bin:.1f}%)')
print(f'(vs. 4.912 con imputación - se pierden {4912-n_bin} obs por listwise_
      deletion)')
```

Muestra: 3975 obs | took\_exam=1: 3630 (91.3%) | took\_exam=0: 345 (8.7%)  
(vs. 4.912 con imputación - se pierden 937 obs por listwise deletion)

```
[24]: ols_full = sm.OLS(y_bin, sm.add_constant(X_bin)).fit(cov_type='HC3')
print('MPL - Modelo Completo')
print(ols_full.summary2().tables[1].round(4))
print(f'\nR²={ols_full.rsquared:.4f} | AIC={ols_full.aic:.2f} | BIC={ols_full.
      bic:.2f}')
```

### MPL - Modelo Completo

|                        | Coef.   | Std.Err. | z       | P> z   | [0.025  | 0.975]  |
|------------------------|---------|----------|---------|--------|---------|---------|
| const                  | 0.7365  | 0.0607   | 12.1404 | 0.0000 | 0.6176  | 0.8554  |
| age                    | -0.0014 | 0.0014   | -1.0049 | 0.3150 | -0.0040 | 0.0013  |
| study_hours            | 0.0008  | 0.0048   | 0.1625  | 0.8709 | -0.0087 | 0.0102  |
| self_study_hours       | -0.0000 | 0.0036   | -0.0079 | 0.9937 | -0.0071 | 0.0070  |
| online_classes_hours   | -0.0041 | 0.0039   | -1.0412 | 0.2978 | -0.0117 | 0.0036  |
| social_media_hours     | 0.0024  | 0.0031   | 0.7850  | 0.4325 | -0.0037 | 0.0086  |
| gaming_hours           | -0.0032 | 0.0038   | -0.8461 | 0.3975 | -0.0106 | 0.0042  |
| screen_time_hours      | -0.0017 | 0.0020   | -0.8218 | 0.4112 | -0.0056 | 0.0023  |
| sleep_hours            | 0.0005  | 0.0052   | 0.0952  | 0.9242 | -0.0097 | 0.0107  |
| exercise_hours         | -0.0041 | 0.0057   | -0.7098 | 0.4779 | -0.0153 | 0.0072  |
| caffeine_intake_mg     | 0.0000  | 0.0000   | 0.3718  | 0.7100 | -0.0000 | 0.0001  |
| part_time_job          | -0.0029 | 0.0104   | -0.2785 | 0.7806 | -0.0232 | 0.0174  |
| upcoming_deadline      | 0.0068  | 0.0118   | 0.5753  | 0.5651 | -0.0164 | 0.0300  |
| mental_health_score    | -0.0006 | 0.0030   | -0.1950 | 0.8454 | -0.0064 | 0.0052  |
| focus_index            | 0.0040  | 0.0009   | 4.5872  | 0.0000 | 0.0023  | 0.0058  |
| burnout_level          | -0.0026 | 0.0007   | -3.7404 | 0.0002 | -0.0039 | -0.0012 |
| productivity_score     | 0.0055  | 0.0008   | 6.7533  | 0.0000 | 0.0039  | 0.0071  |
| gender_Female          | -0.0033 | 0.0084   | -0.3877 | 0.6983 | -0.0197 | 0.0132  |
| gender_Other           | 0.0093  | 0.0123   | 0.7534  | 0.4512 | -0.0149 | 0.0334  |
| academic_Undergraduate | 0.0314  | 0.0095   | 3.3062  | 0.0009 | 0.0128  | 0.0499  |
| academic_Postgraduate  | 0.0088  | 0.0099   | 0.8958  | 0.3704 | -0.0105 | 0.0282  |
| internet_Average       | 0.0005  | 0.0094   | 0.0555  | 0.9557 | -0.0178 | 0.0189  |
| internet_Poor          | -0.0065 | 0.0097   | -0.6728 | 0.5011 | -0.0256 | 0.0125  |

R<sup>2</sup>=0.2476 | AIC=118.92 | BIC=263.54

```
[25]: ols_fin, ols_vars = backward_ols(X_bin, y_bin)
print(f'MPL - Modelo Final ({len(ols_vars)} variables)')
print(f'Variables: {ols_vars}\n')
print(ols_fin.summary2().tables[1].round(4))
print(f'\nR²={ols_fin.rsquared:.4f} | R²_adj={ols_fin.rsquared_adj:.4f}')
print(f'AIC={ols_fin.aic:.2f} | BIC={ols_fin.bic:.2f}')
```

### MPL - Modelo Final (4 variables)

Variables: ['focus\_index', 'burnout\_level', 'productivity\_score', 'academic\_Undergraduate']

|                        | Coef.   | Std.Err. | z       | P> z   | [0.025  | 0.975]  |
|------------------------|---------|----------|---------|--------|---------|---------|
| const                  | 0.6972  | 0.0211   | 33.0559 | 0.0000 | 0.6558  | 0.7385  |
| focus_index            | 0.0039  | 0.0007   | 5.7135  | 0.0000 | 0.0026  | 0.0053  |
| burnout_level          | -0.0025 | 0.0003   | -8.5079 | 0.0000 | -0.0031 | -0.0020 |
| productivity_score     | 0.0056  | 0.0004   | 12.7618 | 0.0000 | 0.0047  | 0.0064  |
| academic_Undergraduate | 0.0264  | 0.0080   | 3.3094  | 0.0009 | 0.0108  | 0.0421  |

R<sup>2</sup>=0.2458 | R<sup>2</sup>\_adj=0.2451

AIC=92.38 | BIC=123.82


```
[26]: pred_ols = ols_fin.predict()
n_out_ols = int((pred_ols<0).sum() + (pred_ols>1).sum())
print(f'Predicciones fuera [0,1]: {n_out_ols} ({100*n_out_ols/len(pred_ols):.
↪2f}%)')
print('↪ Limitación estructural del MPL.\n')

plt.figure(figsize=(8,4))
plt.hist(pred_ols, bins=40, color='steelblue', edgecolor='white', alpha=0.8)
plt.axvline(0, color='red', ls='--', label='P=0')
plt.axvline(1, color='red', ls='--', label='P=1')
plt.xlabel('Probabilidad predicha'); plt.ylabel('Frecuencia')
plt.title('MPL - Distribución de Probabilidades Predichas')
plt.legend(); plt.tight_layout(); plt.show()

pred_ols_bin = (pred_ols>=0.5).astype(int)
print('Matriz de Confusión - MPL')
cm_ols = confusion_matrix(y_bin.astype(int), pred_ols_bin)
print(pd.DataFrame(cm_ols,index=['Real: No rindió','Real: Rindió'],
                    columns=['Pred: No rindió','Pred: Rindió']))
print(classification_report(y_bin.astype(int), pred_ols_bin,
                            target_names=['No rindió','Rindió']))
```

Predicciones fuera [0,1]: 1106 (27.82%)

↪ Limitación estructural del MPL.



Matriz de Confusión - MPL

|                 | Pred: No rindió | Pred: Rindió |
|-----------------|-----------------|--------------|
| Real: No rindió | 0               | 345          |
| Real: Rindió    | 0               | 3630         |

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| No rindió    | 0.00      | 0.00   | 0.00     | 345     |
| Rindió       | 0.91      | 1.00   | 0.95     | 3630    |
| accuracy     |           |        | 0.91     | 3975    |
| macro avg    | 0.46      | 0.50   | 0.48     | 3975    |
| weighted avg | 0.83      | 0.91   | 0.87     | 3975    |

### 0.15.1 Interpretación del MPL

Cada coeficiente  $\hat{\beta}_k$  mide el cambio en **puntos porcentuales (p.p.)** en la probabilidad de rendir el examen ante un aumento de una unidad en  $X_k$ , manteniendo constantes todas las demás variables (*ceteris paribus*). El efecto es constante a lo largo de toda la distribución de  $X_k$ .

```
[27]: print('INTERPRETACIÓN COMPLETA - MPL')
coef_ols = ols_fin.params.drop('const')
pval_ols = ols_fin.pvalues.drop('const')
ci_ols = ols_fin.conf_int().drop('const')

for v in ols_vars:
    b=coef_ols[v]; p=pval_ols[v]; lo=ci_ols.loc[v,0]; hi=ci_ols.loc[v,1]
    dir_='incrementa' if b>0 else 'reduce'
    print(f'\n    {v}')
    print(f'    =[{b:.4f}] {stars(p)} | p=[p:.4f] | IC95%: [{lo:.4f},{hi:.4f}]')
    print(f'    Manteniendo constantes las demás variables, un aumento de 1_
↪unidad en')
    print(f'    "{v}" {dir_} la probabilidad de rendir el examen en {abs(b)*100:
↪.2f} p.p.')
    print(f'    ({sig_txt(p)}.)')
```

INTERPRETACIÓN COMPLETA - MPL

```
focus_index
=0.0039 *** | p=0.0000 | IC95%: [0.0026,0.0053]
Manteniendo constantes las demás variables, un aumento de 1 unidad en
"focus_index" incrementa la probabilidad de rendir el examen en 0.39 p.p.
(estadísticamente significativo al 1%).
```

```
burnout_level
=-0.0025 *** | p=0.0000 | IC95%: [-0.0031,-0.0020]
Manteniendo constantes las demás variables, un aumento de 1 unidad en
"burnout_level" reduce la probabilidad de rendir el examen en 0.25 p.p.
(estadísticamente significativo al 1%).
```

```
productivity_score
=0.0056 *** | p=0.0000 | IC95%: [0.0047,0.0064]
```

Manteniendo constantes las demás variables, un aumento de 1 unidad en "productivity\_score" incrementa la probabilidad de rendir el examen en 0.56 p.p.  
(estadísticamente significativo al 1%.)

academic\_Undergraduate  
=0.0264 \*\*\* | p=0.0009 | IC95%: [0.0108,0.0421]  
Manteniendo constantes las demás variables, un aumento de 1 unidad en "academic\_Undergraduate" incrementa la probabilidad de rendir el examen en 2.64 p.p.  
(estadísticamente significativo al 1%.)

## 0.16 Pregunta 3 — Modelo Probit

$$P(\text{took\_exam}_i = 1) = \Phi(X_i' \beta)$$

Estimado por Máxima Verosimilitud. Interpretación mediante **AME** (Efectos Marginales Promedio): cambio promedio en la probabilidad ante un aumento unitario en  $X_k$ , evaluado en los valores observados de cada individuo y promediado sobre la muestra.

```
[28]: probit_full = sm.Probit(y_bin, sm.add_constant(X_bin)).fit(dis=0, maxiter=300)
print('Probit - Modelo Completo')
print(probit_full.summary2().tables[1].round(4))
print(f'\nPseudo-R²={probit_full.prsquared:.4f} | AIC={probit_full.aic:.2f}')
```

Probit - Modelo Completo

|                        | Coef.   | Std.Err. | z       | P> z   | [0.025  | 0.975]  |
|------------------------|---------|----------|---------|--------|---------|---------|
| const                  | -0.5296 | 0.6901   | -0.7674 | 0.4428 | -1.8821 | 0.8230  |
| age                    | 0.0053  | 0.0160   | 0.3309  | 0.7407 | -0.0261 | 0.0367  |
| study_hours            | -0.0528 | 0.0589   | -0.8965 | 0.3700 | -0.1682 | 0.0626  |
| self_study_hours       | -0.0187 | 0.0445   | -0.4212 | 0.6736 | -0.1060 | 0.0685  |
| online_classes_hours   | -0.0238 | 0.0479   | -0.4959 | 0.6199 | -0.1177 | 0.0701  |
| social_media_hours     | 0.0384  | 0.0367   | 1.0471  | 0.2951 | -0.0335 | 0.1103  |
| gaming_hours           | 0.0293  | 0.0419   | 0.6979  | 0.4853 | -0.0529 | 0.1115  |
| screen_time_hours      | -0.0391 | 0.0238   | -1.6425 | 0.1005 | -0.0857 | 0.0076  |
| sleep_hours            | 0.0192  | 0.0601   | 0.3190  | 0.7497 | -0.0986 | 0.1370  |
| exercise_hours         | -0.0024 | 0.0683   | -0.0352 | 0.9719 | -0.1363 | 0.1315  |
| caffeine_intake_mg     | -0.0000 | 0.0003   | -0.0567 | 0.9548 | -0.0007 | 0.0007  |
| part_time_job          | -0.0606 | 0.1198   | -0.5058 | 0.6130 | -0.2953 | 0.1741  |
| upcoming_deadline      | 0.1031  | 0.1469   | 0.7018  | 0.4828 | -0.1849 | 0.3911  |
| mental_health_score    | 0.0075  | 0.0382   | 0.1957  | 0.8448 | -0.0675 | 0.0824  |
| focus_index            | 0.0547  | 0.0101   | 5.4014  | 0.0000 | 0.0349  | 0.0746  |
| burnout_level          | -0.0353 | 0.0079   | -4.4506 | 0.0000 | -0.0508 | -0.0198 |
| productivity_score     | 0.1051  | 0.0104   | 10.1513 | 0.0000 | 0.0848  | 0.1254  |
| gender_Female          | 0.1538  | 0.0992   | 1.5507  | 0.1210 | -0.0406 | 0.3482  |
| gender_Other           | 0.0921  | 0.1484   | 0.6204  | 0.5350 | -0.1987 | 0.3828  |
| academic_Undergraduate | 0.3278  | 0.1134   | 2.8900  | 0.0039 | 0.1055  | 0.5501  |

|                       |        |        |        |        |         |        |
|-----------------------|--------|--------|--------|--------|---------|--------|
| academic_Postgraduate | 0.1306 | 0.1107 | 1.1800 | 0.2380 | -0.0863 | 0.3476 |
| internet_Average      | 0.0542 | 0.1119 | 0.4842 | 0.6283 | -0.1651 | 0.2735 |
| internet_Poor         | 0.0279 | 0.1133 | 0.2463 | 0.8054 | -0.1942 | 0.2500 |

Pseudo-R<sup>2</sup>=0.5942 | AIC=997.93

```
[29]: probit_fin, probit_vars = backward_mle(X_bin, y_bin, sm.Probit)
print(f'Probit - Modelo Final ({len(probit_vars)} variables)')
print(f'Variables: {probit_vars}\n')
print(probit_fin.summary2().tables[1].round(4))
print(f'\nPseudo-R²={probit_fin.prsquared:.4f} | AIC={probit_fin.aic:.2f} | BIC={probit_fin.bic:.2f}')
```

Probit - Modelo Final (4 variables)

Variables: ['focus\_index', 'burnout\_level', 'productivity\_score', 'academic\_Undergraduate']

|                        | Coef.   | Std.Err. | z       | P> z   | [0.025  | 0.975]  |
|------------------------|---------|----------|---------|--------|---------|---------|
| const                  | -0.2221 | 0.2100   | -1.0575 | 0.2903 | -0.6336 | 0.1895  |
| focus_index            | 0.0504  | 0.0076   | 6.6328  | 0.0000 | 0.0355  | 0.0653  |
| burnout_level          | -0.0367 | 0.0037   | -9.8648 | 0.0000 | -0.0440 | -0.0294 |
| productivity_score     | 0.1001  | 0.0062   | 16.0222 | 0.0000 | 0.0878  | 0.1123  |
| academic_Undergraduate | 0.2623  | 0.0986   | 2.6604  | 0.0078 | 0.0691  | 0.4556  |

Pseudo-R<sup>2</sup>=0.5878 | AIC=976.86 | BIC=1008.30

```
[30]: probit_ame = probit_fin.get_margeff(at='overall')
print('AME - Probit'); print(probit_ame.summary())

pred_probit = (probit_fin.predict()>=0.5).astype(int)
print('\nMatriz de Confusión - Probit')
cm_p = confusion_matrix(y_bin.astype(int), pred_probit)
print(pd.DataFrame(cm_p, index=['Real: No rindió', 'Real: Rindió'],
                    columns=['Pred: No rindió', 'Pred: Rindió']))
rep_p = classification_report(y_bin.astype(int), pred_probit,
                              target_names=['No rindió', 'Rindió'], output_dict=True)
print(classification_report(y_bin.astype(int), pred_probit,
                              target_names=['No rindió', 'Rindió']))
print(f'Recall minoritaria: {rep_p["No rindió"]["recall"]:.2f} | Accuracy: {rep_p["accuracy"]:.2f}')
```

AME - Probit

Probit Marginal Effects

```
=====
Dep. Variable:      took_exam
Method:             dydx
At:                 overall
=====
```

|                        | dy/dx   | std err | z       | P> z  | [0.025 |
|------------------------|---------|---------|---------|-------|--------|
| 0.975]                 |         |         |         |       |        |
| -----                  |         |         |         |       |        |
| focus_index            | 0.0034  | 0.000   | 6.838   | 0.000 | 0.002  |
| 0.004                  |         |         |         |       |        |
| burnout_level          | -0.0025 | 0.000   | -10.673 | 0.000 | -0.003 |
| -0.002                 |         |         |         |       |        |
| productivity_score     | 0.0067  | 0.000   | 20.369  | 0.000 | 0.006  |
| 0.007                  |         |         |         |       |        |
| academic_Undergraduate | 0.0176  | 0.007   | 2.678   | 0.007 | 0.005  |
| 0.031                  |         |         |         |       |        |
| =====                  |         |         |         |       |        |
| =====                  |         |         |         |       |        |

#### Matriz de Confusión - Probit

|                 | Pred: No rindió | Pred: Rindió |          |         |
|-----------------|-----------------|--------------|----------|---------|
| Real: No rindió | 198             | 147          |          |         |
| Real: Rindió    | 61              | 3569         |          |         |
|                 | precision       | recall       | f1-score | support |
| No rindió       | 0.76            | 0.57         | 0.66     | 345     |
| Rindió          | 0.96            | 0.98         | 0.97     | 3630    |
| accuracy        |                 |              | 0.95     | 3975    |
| macro avg       | 0.86            | 0.78         | 0.81     | 3975    |
| weighted avg    | 0.94            | 0.95         | 0.94     | 3975    |

Recall minoritaria: 0.57 | Accuracy: 94.77%

### 0.16.1 Interpretación del Probit

Los **AME** expresan el cambio promedio en la probabilidad de rendir el examen ante un aumento de una unidad en el regresor, capturando la no-linealidad del modelo (efectos menores en los extremos, mayores en el centro de la distribución).

```
[31]: print('INTERPRETACIÓN COMPLETA - PROBIT (AME)')

ame_pf = probit_ame.summary_frame()
for v in probit_vars:
    if v not in ame_pf.index: continue
    ame=ame_pf.loc[v,'dy/dx']; p=ame_pf.loc[v,'Pr(>|z|)']; se=ame_pf.loc[v,'Std.
    Err.'].
    dir_='incrementa' if ame>0 else 'reduce'
    print(f'\n    {v}')
    print(f'    AME={ame:.4f} {stars(p)} | SE={se:.4f} | p={p:.4f}')
    print(f'    En promedio sobre la muestra, un aumento de 1 unidad en "{v}"')
```

```

print(f'      {dir_} la probabilidad promedio de rendir en {abs(ame)*100:.2f} p.p.')
print(f'      ({sig_txt(p)}, evaluado en los valores observados de cada individuo.)')

```

#### INTERPRETACIÓN COMPLETA - PROBIT (AME)

**focus\_index**  
 AME=0.0034 \*\*\* | SE=0.0005 | p=0.0000  
 En promedio sobre la muestra, un aumento de 1 unidad en "focus\_index" incrementa la probabilidad promedio de rendir en 0.34 p.p.  
 (estadísticamente significativo al 1%, evaluado en los valores observados de cada individuo.)

**burnout\_level**  
 AME=-0.0025 \*\*\* | SE=0.0002 | p=0.0000  
 En promedio sobre la muestra, un aumento de 1 unidad en "burnout\_level" reduce la probabilidad promedio de rendir en 0.25 p.p.  
 (estadísticamente significativo al 1%, evaluado en los valores observados de cada individuo.)

**productivity\_score**  
 AME=0.0067 \*\*\* | SE=0.0003 | p=0.0000  
 En promedio sobre la muestra, un aumento de 1 unidad en "productivity\_score" incrementa la probabilidad promedio de rendir en 0.67 p.p.  
 (estadísticamente significativo al 1%, evaluado en los valores observados de cada individuo.)

**academic\_Undergraduate**  
 AME=0.0176 \*\*\* | SE=0.0066 | p=0.0074  
 En promedio sobre la muestra, un aumento de 1 unidad en "academic\_Undergraduate" incrementa la probabilidad promedio de rendir en 1.76 p.p.  
 (estadísticamente significativo al 1%, evaluado en los valores observados de cada individuo.)

---

### 0.17 Pregunta 4 — Modelo Logit

$$P(\text{took\_exam}_i = 1) = \frac{e^{X'_i\beta}}{1 + e^{X'_i\beta}}$$

Dos métricas complementarias: **AME** (cambio en p.p.) y **Odds Ratio** ( $e^{\hat{\beta}}$ : factor multiplicativo sobre las *odds*).

```

[32]: logit_full = sm.Logit(y_bin, sm.add_constant(X_bin)).fit(dis=0, maxiter=300)
print('Logit - Modelo Completo')

```

```
print(logit_full.summary2().tables[1].round(4))
print(f'\nPseudo-R²={logit_full.prsquared:.4f} | AIC={logit_full.aic:.2f}')
```

Logit - Modelo Completo

|                        | Coef.   | Std.Err. | z       | P> z   | [0.025  | 0.975]  |
|------------------------|---------|----------|---------|--------|---------|---------|
| const                  | -1.1494 | 1.2626   | -0.9104 | 0.3626 | -3.6241 | 1.3252  |
| age                    | 0.0115  | 0.0295   | 0.3920  | 0.6951 | -0.0462 | 0.0693  |
| study_hours            | -0.1131 | 0.1076   | -1.0510 | 0.2933 | -0.3240 | 0.0978  |
| self_study_hours       | -0.0294 | 0.0810   | -0.3634 | 0.7163 | -0.1881 | 0.1292  |
| online_classes_hours   | -0.0186 | 0.0884   | -0.2107 | 0.8331 | -0.1920 | 0.1547  |
| social_media_hours     | 0.0659  | 0.0669   | 0.9852  | 0.3245 | -0.0652 | 0.1969  |
| gaming_hours           | 0.0550  | 0.0764   | 0.7209  | 0.4710 | -0.0946 | 0.2047  |
| screen_time_hours      | -0.0641 | 0.0435   | -1.4735 | 0.1406 | -0.1493 | 0.0211  |
| sleep_hours            | 0.0427  | 0.1110   | 0.3843  | 0.7008 | -0.1749 | 0.2603  |
| exercise_hours         | -0.0154 | 0.1256   | -0.1224 | 0.9026 | -0.2616 | 0.2309  |
| caffeine_intake_mg     | 0.0001  | 0.0006   | 0.0966  | 0.9230 | -0.0012 | 0.0013  |
| part_time_job          | -0.0932 | 0.2206   | -0.4225 | 0.6727 | -0.5255 | 0.3391  |
| upcoming_deadline      | 0.2970  | 0.2692   | 1.1033  | 0.2699 | -0.2306 | 0.8245  |
| mental_health_score    | 0.0029  | 0.0699   | 0.0410  | 0.9673 | -0.1342 | 0.1399  |
| focus_index            | 0.1001  | 0.0185   | 5.4027  | 0.0000 | 0.0638  | 0.1364  |
| burnout_level          | -0.0658 | 0.0147   | -4.4868 | 0.0000 | -0.0945 | -0.0370 |
| productivity_score     | 0.1959  | 0.0195   | 10.0400 | 0.0000 | 0.1576  | 0.2341  |
| gender_Female          | 0.2702  | 0.1815   | 1.4889  | 0.1365 | -0.0855 | 0.6259  |
| gender_Other           | 0.1428  | 0.2718   | 0.5256  | 0.5992 | -0.3898 | 0.6755  |
| academic_Undergraduate | 0.5880  | 0.2082   | 2.8247  | 0.0047 | 0.1800  | 0.9960  |
| academic_Postgraduate  | 0.2439  | 0.2027   | 1.2032  | 0.2289 | -0.1534 | 0.6412  |
| internet_Average       | 0.0660  | 0.2034   | 0.3243  | 0.7457 | -0.3327 | 0.4646  |
| internet_Poor          | 0.0557  | 0.2089   | 0.2666  | 0.7898 | -0.3537 | 0.4651  |

Pseudo-R²=0.5930 | AIC=1000.63

```
[33]: logit_fin, logit_vars = backward_mle(X_bin, y_bin, sm.Logit)
print(f'Logit - Modelo Final ({len(logit_vars)} variables)')
print(f'Variables: {logit_vars}\n')
print(logit_fin.summary2().tables[1].round(4))
print(f'\nPseudo-R²={logit_fin.prsquared:.4f} | AIC={logit_fin.aic:.2f} | BIC={logit_fin.bic:.2f}')
```

Logit - Modelo Final (5 variables)

Variables: ['upcoming\_deadline', 'focus\_index', 'burnout\_level', 'productivity\_score', 'academic\_Undergraduate']

|                    | Coef.   | Std.Err. | z       | P> z   | [0.025  | 0.975]  |
|--------------------|---------|----------|---------|--------|---------|---------|
| const              | -0.3311 | 0.3879   | -0.8537 | 0.3933 | -1.0914 | 0.4291  |
| upcoming_deadline  | 0.4279  | 0.1997   | 2.1429  | 0.0321 | 0.0365  | 0.8193  |
| focus_index        | 0.0922  | 0.0142   | 6.5095  | 0.0000 | 0.0644  | 0.1199  |
| burnout_level      | -0.0746 | 0.0079   | -9.4111 | 0.0000 | -0.0901 | -0.0590 |
| productivity_score | 0.1858  | 0.0120   | 15.5359 | 0.0000 | 0.1624  | 0.2092  |

academic\_Undergraduate 0.4741 0.1809 2.6206 0.0088 0.1195 0.8287

Pseudo-R<sup>2</sup>=0.5883 | AIC=977.67 | BIC=1015.40

```
[34]: logit_ame = logit_fin.get_margeff(at='overall')
print('AME - Logit'); print(logit_ame.summary())
print()
print('Odds Ratios - Logit')
print(irr_table(logit_fin).round(4))

pred_logit = (logit_fin.predict())>=0.5).astype(int)
print('\n Matriz de Confusión - Logit')
cm_l = confusion_matrix(y_bin.astype(int), pred_logit)
print(pd.DataFrame(cm_l,index=['Real: No rindió','Real: Rindió'],
                    columns=['Pred: No rindió','Pred: Rindió']))
print(classification_report(y_bin.astype(int), pred_logit,
                             target_names=['No rindió','Rindió']))
```

AME - Logit

Logit Marginal Effects

```
=====
Dep. Variable:      took_exam
Method:            dydx
At:                overall
=====
```

```
=====
              dy/dx      std err          z      P>|z|      [0.025
-----
```

```
upcoming_deadline      0.0156      0.007      2.149      0.032      0.001
0.030
focus_index            0.0034      0.000      6.768      0.000      0.002
0.004
burnout_level          -0.0027      0.000     -10.208      0.000     -0.003
-0.002
productivity_score      0.0068      0.000     20.713      0.000      0.006
0.007
academic_Undergraduate  0.0173      0.007      2.643      0.008      0.004
0.030
=====
```

Odds Ratios - Logit

|                   | IRR    | IC 2.5% | IC 97.5% | p-value |
|-------------------|--------|---------|----------|---------|
| upcoming_deadline | 1.5341 | 1.0372  | 2.2690   | 0.0321  |
| focus_index       | 1.0965 | 1.0665  | 1.1274   | 0.0000  |
| burnout_level     | 0.9281 | 0.9138  | 0.9427   | 0.0000  |

|                        |        |        |        |        |
|------------------------|--------|--------|--------|--------|
| productivity_score     | 1.2042 | 1.1763 | 1.2327 | 0.0000 |
| academic_Undergraduate | 1.6066 | 1.1270 | 2.2904 | 0.0088 |

#### Matriz de Confusión - Logit

|                 |           |                 |              |         |
|-----------------|-----------|-----------------|--------------|---------|
|                 |           | Pred: No rindió | Pred: Rindió |         |
| Real: No rindió |           | 205             | 140          |         |
| Real: Rindió    |           | 65              | 3565         |         |
|                 | precision | recall          | f1-score     | support |
| No rindió       | 0.76      | 0.59            | 0.67         | 345     |
| Rindió          | 0.96      | 0.98            | 0.97         | 3630    |
| accuracy        |           |                 | 0.95         | 3975    |
| macro avg       | 0.86      | 0.79            | 0.82         | 3975    |
| weighted avg    | 0.94      | 0.95            | 0.95         | 3975    |

### 0.17.1 Interpretación del Logit

**AME:** idéntica interpretación al Probit (cambio en p.p.).

**OR:** si  $OR = 1.10$ , las *odds* de rendir aumentan un 10% por unidad adicional; si  $OR = 0.85$ , disminuyen un 15%.

```
[35]: print('INTERPRETACIÓN COMPLETA - LOGIT (AME y Odds Ratios)')

ame_lf = logit_ame.summary_frame()
or_s = np.exp(logit_fin.params.drop('const'))

for v in logit_vars:
    if v not in ame_lf.index: continue
    ame=ame_lf.loc[v,'dy/dx']; p=ame_lf.loc[v,'Pr(>|z|)']
    OR=or_s[v]; pct=(OR-1)*100
    dir_p='incrementa' if ame>0 else 'reduce'
    dir_o='incrementan' if OR>1 else 'disminuyen'
    print(f'\n {v}')
    print(f'    AME={ame:.4f} {stars(p)} | OR={OR:.4f} | p={p:.4f}')
    print(f'    - Probabilidad: 1 unidad adicional en "{v}" {dir_p}')
    print(f'    la prob. promedio de rendir en {abs(ame)*100:.2f} p.p., □
    ↪ceteris paribus.')
    print(f'    - Odds: las odds de rendir el examen {dir_o} en un {abs(pct):.
    ↪1f}%.')
    print(f'    ({sig_txt(p)}.)')
```

INTERPRETACIÓN COMPLETA - LOGIT (AME y Odds Ratios)

```
upcoming_deadline
AME=0.0156 ** | OR=1.5341 | p=0.0316
- Probabilidad: 1 unidad adicional en "upcoming_deadline" incrementa
```

la prob. promedio de rendir en 1.56 p.p., ceteris paribus.  
 - Odds: las odds de rendir el examen incrementan en un 53.4%.  
 (estadísticamente significativo al 5%).

focus\_index

AME=0.0034 \*\*\* | OR=1.0965 | p=0.0000  
 - Probabilidad: 1 unidad adicional en "focus\_index" incrementa la prob. promedio de rendir en 0.34 p.p., ceteris paribus.  
 - Odds: las odds de rendir el examen incrementan en un 9.7%.  
 (estadísticamente significativo al 1%).

burnout\_level

AME=-0.0027 \*\*\* | OR=0.9281 | p=0.0000  
 - Probabilidad: 1 unidad adicional en "burnout\_level" reduce la prob. promedio de rendir en 0.27 p.p., ceteris paribus.  
 - Odds: las odds de rendir el examen disminuyen en un 7.2%.  
 (estadísticamente significativo al 1%).

productivity\_score

AME=0.0068 \*\*\* | OR=1.2042 | p=0.0000  
 - Probabilidad: 1 unidad adicional en "productivity\_score" incrementa la prob. promedio de rendir en 0.68 p.p., ceteris paribus.  
 - Odds: las odds de rendir el examen incrementan en un 20.4%.  
 (estadísticamente significativo al 1%).

academic\_Undergraduate

AME=0.0173 \*\*\* | OR=1.6066 | p=0.0082  
 - Probabilidad: 1 unidad adicional en "academic\_Undergraduate" incrementa la prob. promedio de rendir en 1.73 p.p., ceteris paribus.  
 - Odds: las odds de rendir el examen incrementan en un 60.7%.  
 (estadísticamente significativo al 1%).

## 0.18 Pregunta 5 — Comparación MPL, Probit y Logit

### 0.18.1 5.A Tabla de Efectos Marginales Comparados

```
[36]: ame_pb = probit_fin.get_margeff(at='overall').summary_frame()['dy/dx']
ame_lg = logit_fin.get_margeff(at='overall').summary_frame()['dy/dx']
c_ols = ols_fin.params.drop('const')
all_v = sorted(set(ols_vars)|set(probit_vars)|set(logit_vars))
rows = [{'Variable':v, 'MPL ( )':c_ols.get(v,np.nan),
        'Probit (AME)':ame_pb.get(v,np.nan),
        'Logit (AME)':ame_lg.get(v,np.nan)} for v in all_v]
comp = pd.DataFrame(rows).set_index('Variable')
print('Efectos Marginales Comparados (p.p.)')
print(comp.round(4).to_string())
```

## Efectos Marginales Comparados (p.p.)

|                        | MPL ( ) | Probit (AME) | Logit (AME) |
|------------------------|---------|--------------|-------------|
| Variable               |         |              |             |
| academic_Undergraduate | 0.0264  | 0.0176       | 0.0173      |
| burnout_level          | -0.0025 | -0.0025      | -0.0027     |
| focus_index            | 0.0039  | 0.0034       | 0.0034      |
| productivity_score     | 0.0056  | 0.0067       | 0.0068      |
| upcoming_deadline      | NaN     | NaN          | 0.0156      |

```
[37]: print(f'{"Modelo":<12} {"R²/Pseudo-R²":>15} {"Log-Lik":>12} {"AIC":>10} {"BIC":>10}')
print('-'*62)
for name, mdl, r2 in [('MPL',ols_fin,ols_fin.rsquared),
                      ('Probit',probit_fin,probit_fin.prsquared),
                      ('Logit',logit_fin,logit_fin.prsquared)]:
    print(f'{name:<12} {r2:>15.4f} {mdl.llf:>12.2f} {mdl.aic:>10.2f} {mdl.bic:>10.2f}')
```

| Modelo | R²/Pseudo-R² | Log-Lik | AIC    | BIC     |
|--------|--------------|---------|--------|---------|
| MPL    | 0.2458       | -41.19  | 92.38  | 123.82  |
| Probit | 0.5878       | -483.43 | 976.86 | 1008.30 |
| Logit  | 0.5883       | -482.84 | 977.67 | 1015.40 |

## 0.18.2 5.B Variables Robustas

```
[38]: models_bin = {'MPL':(ols_fin,ols_vars),'Probit':
    ↪(probit_fin,probit_vars),'Logit':(logit_fin,logit_vars)}
rob_bin = robustness_table(models_bin,
    ↪set(ols_vars)|set(probit_vars)|set(logit_vars))
print('Tabla de Robustez - Modelos Binarios')
print('(** p<0.01 ** p<0.05 * p<0.10 ns=no sig. -=no incluida)')
print(rob_bin.to_string()); print()
robust_vars_bin=[v for v in rob_bin.index
    ↪if all(rob_bin.loc[v,c] not in ['-','ns'] for c in rob_bin.
    ↪columns)]
print(f'Variables robustas (sig. en los 3): {robust_vars_bin}')
```

## Tabla de Robustez - Modelos Binarios

(\*\* p<0.01 \*\* p<0.05 \* p<0.10 ns=no sig. -=no incluida)

|                        | MPL | Probit | Logit |
|------------------------|-----|--------|-------|
| Variable               |     |        |       |
| academic_Undergraduate | *** | ***    | ***   |
| burnout_level          | *** | ***    | ***   |
| focus_index            | *** | ***    | ***   |
| productivity_score     | *** | ***    | ***   |
| upcoming_deadline      | -   | -      | **    |

Variables robustas (sig. en los 3): ['academic\_undergraduate', 'burnout\_level', 'focus\_index', 'productivity\_score']

### 0.18.3 5.C Discusión

- 1. MPL vs Probit/Logit:** El MPL impone efectos marginales constantes para todos los niveles de  $X$ , generando predicciones fuera de  $[0, 1]$  y violando sistemáticamente la homocedasticidad. Probit y Logit garantizan predicciones en  $[0, 1]$  mediante funciones  $S$ .
- 2. Probit vs Logit:** Difieren en el supuesto distribucional (normal estándar vs. logística). Con  $n = 3.975$ , los AME convergen y las diferencias son numéricamente irrelevantes.
- 3. Modelo recomendado: Logit** — coeficientes con interpretación directa como log-odds, estándar en la literatura económica, y garantiza  $P \in [0, 1]$ .
- 4. Desbalance de clases (~91/9%):** los tres modelos predicen casi siempre la clase mayoritaria. Limitación estructural del dataset.
- 5. Variables robustas:** las listadas arriba son las más confiables — su efecto es independiente del modelo elegido.

---

## 0.19 Pregunta 6 — Modelo Poisson para la Nota del Examen

**Muestra:** casos completos que rindieron el examen (`took_exam = 1`).

**Variable dependiente:** `exam_score_int` = `exam_score` redondeado.

**Limitación:** `exam_score` es continua, no un conteo natural. El redondeo es la transformación mínima para cumplir el requisito formal.

```
[39]: df_cnt = df_clean[df_clean['took_exam']==1].copy()
df_cnt['exam_score_int'] = df_cnt['exam_score'].round().astype(int)
y_cnt = df_cnt['exam_score_int']
X_cnt = df_cnt[feature_cols]
n_cnt = len(df_cnt)
media_y = y_cnt.mean(); var_y = y_cnt.var()
ratio_var_med = var_y / media_y


print(f'Muestra: {n_cnt} obs')
print(y_cnt.describe())
print(f'\nMedia={media_y:.4f} | Varianza={var_y:.4f} | Var/Media={ratio_var_med:.4f}')
print('→ Var/Media >> 1: sobredispersión evidente\n')

fig, axes = plt.subplots(1, 2, figsize=(14, 5))
axes[0].hist(y_cnt, bins=40, color='steelblue', edgecolor='white', alpha=0.8)
axes[0].set_title('exam_score_int', fontweight='bold')
axes[0].set_xlabel('Nota'); axes[0].set_ylabel('Frecuencia')
lam = y_cnt.mean(); x_r = np.arange(0, y_cnt.max()+1)
axes[1].bar(x_r, stats.poisson.pmf(x_r, lam)*len(y_cnt), alpha=0.5, color='orange', label='Poisson teórico')
```

```
axes[1].hist(y_cnt,bins=40,alpha=0.6,color='steelblue',label='Datos reales')
axes[1].set_title('Datos vs Poisson teórico',fontweight='bold'); axes[1].
    ↪ legend()
plt.tight_layout(); plt.show()
```

```
Muestra: 3630 obs
count    3630.0000
mean      20.5204
std       11.2980
min        1.0000
25%       12.0000
50%       19.0000
75%       28.0000
max       64.0000
Name: exam_score_int, dtype: float64
```

Media=20.5204 | Varianza=127.6456 | Var/Media=6.2204  
 → Var/Media >> 1: sobredispersión evidente



```
[40]: pois_full = sm.Poisson(y_cnt, sm.add_constant(X_cnt)).fit(dis=0, maxiter=300)
print('Poisson - Modelo Completo')
print(pois_full.summary2().tables[1].round(4))
dev_full_p=poisson_deviance(pois_full,y_cnt); gl_full_p=len(y_cnt)-pois_full.
    ↪ df_model-1
print(f'\nLog-Lik={pois_full.llf:.4f} | Devianza/gl={dev_full_p/gl_full_p:.4f}')
print('(Devianza/gl>>1 → sobredispersión)')
```

Poisson - Modelo Completo

|                  | Coef.   | Std.Err. | z       | P> z   | [0.025  | 0.975] |
|------------------|---------|----------|---------|--------|---------|--------|
| const            | 2.0711  | 0.0573   | 36.1476 | 0.0000 | 1.9588  | 2.1834 |
| age              | -0.0003 | 0.0013   | -0.2435 | 0.8076 | -0.0028 | 0.0022 |
| study_hours      | 0.0064  | 0.0046   | 1.3930  | 0.1636 | -0.0026 | 0.0154 |
| self_study_hours | -0.0045 | 0.0034   | -1.3031 | 0.1925 | -0.0112 | 0.0022 |

|                        |         |        |          |        |         |         |
|------------------------|---------|--------|----------|--------|---------|---------|
| online_classes_hours   | -0.0041 | 0.0037 | -1.1204  | 0.2625 | -0.0114 | 0.0031  |
| social_media_hours     | 0.0019  | 0.0029 | 0.6677   | 0.5043 | -0.0037 | 0.0076  |
| gaming_hours           | 0.0028  | 0.0035 | 0.7848   | 0.4326 | -0.0041 | 0.0097  |
| screen_time_hours      | 0.0019  | 0.0019 | 0.9894   | 0.3225 | -0.0019 | 0.0057  |
| sleep_hours            | -0.0065 | 0.0050 | -1.3154  | 0.1884 | -0.0162 | 0.0032  |
| exercise_hours         | -0.0075 | 0.0054 | -1.3819  | 0.1670 | -0.0181 | 0.0031  |
| caffeine_intake_mg     | 0.0000  | 0.0000 | 1.2581   | 0.2084 | -0.0000 | 0.0001  |
| part_time_job          | 0.0110  | 0.0098 | 1.1192   | 0.2631 | -0.0082 | 0.0302  |
| upcoming_deadline      | -0.0134 | 0.0115 | -1.1677  | 0.2429 | -0.0359 | 0.0091  |
| mental_health_score    | 0.0096  | 0.0029 | 3.2698   | 0.0011 | 0.0038  | 0.0153  |
| focus_index            | 0.0143  | 0.0008 | 17.9415  | 0.0000 | 0.0127  | 0.0158  |
| burnout_level          | -0.0100 | 0.0007 | -15.2827 | 0.0000 | -0.0112 | -0.0087 |
| productivity_score     | 0.0201  | 0.0007 | 27.1348  | 0.0000 | 0.0186  | 0.0215  |
| gender_Female          | 0.0086  | 0.0079 | 1.0924   | 0.2747 | -0.0068 | 0.0240  |
| gender_Other           | 0.0109  | 0.0118 | 0.9185   | 0.3583 | -0.0123 | 0.0341  |
| academic_Undergraduate | 0.0030  | 0.0090 | 0.3288   | 0.7423 | -0.0147 | 0.0206  |
| academic_Postgraduate  | -0.0086 | 0.0090 | -0.9537  | 0.3402 | -0.0263 | 0.0091  |
| internet_Average       | 0.0072  | 0.0089 | 0.8170   | 0.4139 | -0.0101 | 0.0246  |
| internet_Poor          | 0.0003  | 0.0091 | 0.0343   | 0.9726 | -0.0175 | 0.0181  |

Log-Lik=-11625.4338 | Devianza/gl=1.7533  
(Devianza/gl>>1 → sobredispersión)

```
[41]: pois_fin, pois_vars = backward_mle(X_cnt, y_cnt, sm.Poisson)
print(f'Poisson - Modelo Final ({len(pois_vars)} variables)')
print(f'Variables: {pois_vars}\n')
print(pois_fin.summary2().tables[1].round(4))
dev_fin_p=poisson_deviance(pois_fin,y_cnt); gl_fin_p=len(y_cnt)-pois_fin.
    ↪df_model-1
dev_fin_gl = dev_fin_p/gl_fin_p
print(f'\nLog-Lik={pois_fin.llf:.4f} | AIC={pois_fin.aic:.2f} | BIC={pois_fin.
    ↪bic:.2f}')
print(f'Devianza={dev_fin_p:.2f} | gl={gl_fin_p} | Devianza/gl={dev_fin_gl:.
    ↪4f}')
print()
print('IRR - Poisson')
print(irr_table(pois_fin).round(4))
```

Poisson - Modelo Final (5 variables)

Variables: ['upcoming\_deadline', 'mental\_health\_score', 'focus\_index',  
'burnout\_level', 'productivity\_score']

|                     | Coef.   | Std.Err. | z        | P> z   | [0.025  | 0.975]  |
|---------------------|---------|----------|----------|--------|---------|---------|
| const               | 2.0114  | 0.0190   | 105.9875 | 0.0000 | 1.9742  | 2.0486  |
| upcoming_deadline   | -0.0266 | 0.0085   | -3.1464  | 0.0017 | -0.0432 | -0.0100 |
| mental_health_score | 0.0070  | 0.0017   | 4.0602   | 0.0000 | 0.0036  | 0.0104  |
| focus_index         | 0.0135  | 0.0006   | 21.6608  | 0.0000 | 0.0123  | 0.0147  |
| burnout_level       | -0.0088 | 0.0003   | -27.5908 | 0.0000 | -0.0094 | -0.0081 |

```
productivity_score    0.0211    0.0004  52.0113 0.0000  0.0203  0.0219
```

Log-Lik=-11632.4080 | AIC=23276.82 | BIC=23314.00

Devianza=6337.94 | gl=3624.0 | Devianza/gl=1.7489

IRR - Poisson

|                     | IRR    | IC 2.5% | IC 97.5% | p-value |
|---------------------|--------|---------|----------|---------|
| upcoming_deadline   | 0.9737 | 0.9577  | 0.9900   | 0.0017  |
| mental_health_score | 1.0071 | 1.0036  | 1.0105   | 0.0000  |
| focus_index         | 1.0136 | 1.0124  | 1.0148   | 0.0000  |
| burnout_level       | 0.9913 | 0.9907  | 0.9919   | 0.0000  |
| productivity_score  | 1.0214 | 1.0206  | 1.0222   | 0.0000  |

### 0.19.1 Interpretación del Modelo Poisson

**IRR** ( $e^{\hat{\beta}_k}$ ): factor multiplicativo sobre la nota esperada.

**EM en niveles** ( $\hat{\beta}_k \cdot \bar{\mu}$ ): cambio en puntos de nota.

**Advertencia:** errores estándar subestimados por sobredispersión. Los p-values son artificialmente pequeños. La NB (Q8) corrige esto.

```
[42]: irr_p = irr_table(pois_fin)
me_p = marginal_effect_cnt(pois_fin, X_cnt[pois_vars])
mu_med = pois_fin.predict().mean()

print('INTERPRETACIÓN COMPLETA - POISSON')

print(f'Nota media predicha: {mu_med:.2f} pts')
print('ADVERTENCIA: errores estándar subestimados. Ver P7 y P8.\n')

for v in pois_vars:
    if v not in irr_p.index: continue
    irr = irr_p.loc[v, 'IRR']; p = irr_p.loc[v, 'p-value']
    me = me_p.get(v, np.nan); pct = (irr - 1) * 100
    dir_ = 'aumenta' if irr > 1 else 'reduce'
    print(f'    {v}')
    print(f'    IRR={irr:.4f} {stars(p)} | EM={me:+.4f} pts | p={p:.4f}')
    print(f'    - IRR: 1 unidad adicional en "{v}" {dir_} la nota esperada')
    print(f'    en {abs(pct):.2f}%, ceteris paribus.')
    print(f'    - En niveles: {me:+.4f} pts sobre la nota media de {mu_med:.2f}.'
          '\n')
    print(f'    ({sig_txt(p)} - sujeto a sobredispersión.)')
    print()
```

INTERPRETACIÓN COMPLETA - POISSON

Nota media predicha: 20.52 pts

ADVERTENCIA: errores estándar subestimados. Ver P7 y P8.

upcoming\_deadline

IRR=0.9737 \*\*\* | EM=-0.5463 pts | p=0.0017

- IRR: 1 unidad adicional en "upcoming\_deadline" reduce la nota esperada en 2.63%, ceteris paribus.

- En niveles: -0.5463 pts sobre la nota media de 20.52.

(estadísticamente significativo al 1% - sujeto a sobredispersión.)

mental\_health\_score

IRR=1.0071 \*\*\* | EM=+0.1442 pts | p=0.0000

- IRR: 1 unidad adicional en "mental\_health\_score" aumenta la nota esperada en 0.71%, ceteris paribus.

- En niveles: +0.1442 pts sobre la nota media de 20.52.

(estadísticamente significativo al 1% - sujeto a sobredispersión.)

focus\_index

IRR=1.0136 \*\*\* | EM=+0.2772 pts | p=0.0000

- IRR: 1 unidad adicional en "focus\_index" aumenta la nota esperada en 1.36%, ceteris paribus.

- En niveles: +0.2772 pts sobre la nota media de 20.52.

(estadísticamente significativo al 1% - sujeto a sobredispersión.)

burnout\_level

IRR=0.9913 \*\*\* | EM=-0.1798 pts | p=0.0000

- IRR: 1 unidad adicional en "burnout\_level" reduce la nota esperada en 0.87%, ceteris paribus.

- En niveles: -0.1798 pts sobre la nota media de 20.52.

(estadísticamente significativo al 1% - sujeto a sobredispersión.)

productivity\_score

IRR=1.0214 \*\*\* | EM=+0.4338 pts | p=0.0000

- IRR: 1 unidad adicional en "productivity\_score" aumenta la nota esperada en 2.14%, ceteris paribus.

- En niveles: +0.4338 pts sobre la nota media de 20.52.

(estadísticamente significativo al 1% - sujeto a sobredispersión.)

---

## 0.20 Pregunta 7 — Análisis de Sobredispersión y Alpha Óptimo

Tres métodos complementarios para diagnosticar y cuantificar la sobredispersión.

```
[43]: print('1. Descriptivo')
      print(f' Media={media_y:.4f} | Varianza={var_y:.4f} | Ratio={ratio_var_med:.4f}')
      print(f' Varianza es {ratio_var_med:.1f}× la media → sobredispersión evidente')
```

1. Descriptivo

Media=20.5204 | Varianza=127.6456 | Ratio=6.2204

Varianza es 6.2× la media → sobredispersión evidente

```
[44]: mu_hat=pois_fin.predict()
z_aux=(y_cnt-mu_hat)**2 - y_cnt
x_aux=mu_hat**2
ct=sm.OLS(z_aux,x_aux).fit()
alpha_ct=ct.params.iloc[0]; t_ct=ct.tvalues.iloc[0]
p_ct=ct.pvalues.iloc[0]/2
```

```
print('2. Test Cameron-Trivedi (1990)')
print(f' H0: alpha=0 (Poisson) | H1: alpha>0 (NB2)')
print(f' Alpha={alpha_ct:.6f} | t={t_ct:.4f} | p={p_ct:.8f}')
if p_ct<0.05: print(' → RECHAZA H0: sobredispersión significativa')
```


```
2. Test Cameron-Trivedi (1990)
H0: alpha=0 (Poisson) | H1: alpha>0 (NB2)
Alpha=0.029907 | t=28.1332 | p=0.00000000
→ RECHAZA H0: sobredispersión significativa
```

```
[45]: nb_temp =sm.NegativeBinomial(y_cnt,sm.add_constant(X_cnt[pois_vars])).
↳fit(dis=0,maxiter=500)
alpha_nb=nb_temp.params['alpha']; p_alpha=nb_temp.pvalues['alpha']
ci_alpha=nb_temp.conf_int().loc['alpha']

print('3. Alpha Óptimo - NB2')
print(f' Alpha={alpha_nb:.6f} | p={p_alpha:.8f}')
print(f' IC95%: [{ci_alpha[0]:.6f}, {ci_alpha[1]:.6f}']')
if p_alpha<0.05:
    print(f' → Alpha>0 significativamente: Var(Y)=mu+{alpha_nb:.4f}·mu²')
    print(f' → Valor óptimo de alpha: {alpha_nb:.4f}')
```

```
3. Alpha Óptimo - NB2
Alpha=0.028366 | p=0.00000000
IC95%: [0.024230, 0.032502]
→ Alpha>0 significativamente: Var(Y)=mu+0.0284·mu²
→ Valor óptimo de alpha: 0.0284
```

```
[46]: mu_p=pois_fin.predict(); resid2=(y_cnt-mu_p)**2/mu_p
plt.figure(figsize=(8,5))
plt.scatter(mu_p,resid2,alpha=0.2,s=10,color='steelblue')
plt.axhline(1,color='red',ls='--',label='E[r²/mu]=1 (Poisson)')
plt.xlabel('Valores ajustados'); plt.ylabel('Residuos Pearson²/mu')
plt.title('Diagnóstico de Sobredispersión',fontweight='bold')
plt.legend(); plt.tight_layout(); plt.show()
print(f'Media residuos Pearson²/mu: {resid2.mean():.4f} (>>1 →
↳sobredispersión)')
```



Media residuos  $\text{Pearson}^2/\mu$ : 1.6074 ( $>1 \rightarrow$  sobredispersión)

**Conclusión:** los tres métodos convergen. Existe sobredispersión significativa. El Poisson subestima errores estándar. La Binomial Negativa es necesaria.

## 0.21 Pregunta 8 — Modelo Binomial Negativa (NB2)

$$E[Y_i|X_i] = \mu_i \quad \text{Var}[Y_i] = \mu_i + \alpha \mu_i^2$$

**Estrategia:** se intenta primero con todos los predictores. Si aparecen NaN en errores estándar (Hessiana casi singular), se usa el subconjunto `pois_vars`.

```
[47]: print(' Intento con todos los predictores ')
nb_all = sm.NegativeBinomial(y_cnt, sm.add_constant(X_cnt)).
    fit(dis=0, maxiter=500)
n_nan_all = int(nb_all.pvalues.isna().sum())
print(f'NaN en p-values: {n_nan_all} de {len(nb_all.pvalues)}')
print(f'Alpha estimado: {nb_all.params["alpha"]:.4f}')

if n_nan_all==0:
    print('→ Convergencia OK con todos los predictores.')
    nb_fin=nb_all; nb_vars=feature_cols.copy()
else:
    print(f'→ {n_nan_all} NaN: Hessiana casi singular. Usando pois_vars.\n')
```

```

    nb_fin=sm.NegativeBinomial(y_cnt,sm.add_constant(X_cnt[pois_vars])).
    ↪fit(dis=0,maxiter=500)
    nb_vars=list(pois_vars)
    if int(nb_fin.pvalues.isna().sum())>0:
        print(' Reintentando con bfgs...')
        nb_fin=sm.NegativeBinomial(y_cnt,sm.add_constant(X_cnt[pois_vars])).
    ↪fit(method='bfgs',maxiter=1000,disp=0)

print('\n Binomial Negativa - Modelo Final')
print(nb_fin.summary2().tables[1].round(4))
print(f'\nLog-Lik={nb_fin.llf:.4f} | AIC={nb_fin.aic:.2f} | BIC={nb_fin.bic:.
    ↪2f}')
print(f'Alpha={nb_fin.params["alpha"]:.4f} | NaN={int(nb_fin.pvalues.isna().
    ↪sum())}')

```

Intento con todos los predictores  
NaN en p-values: 24 de 24  
Alpha estimado: 1.0513  
→ 24 NaN: Hessiana casi singular. Usando pois\_vars.

Binomial Negativa - Modelo Final

|                     | Coef.   | Std.Err. | z        | P> z   | [0.025  | 0.975]  |
|---------------------|---------|----------|----------|--------|---------|---------|
| const               | 1.9614  | 0.0244   | 80.4516  | 0.0000 | 1.9136  | 2.0092  |
| upcoming_deadline   | -0.0293 | 0.0109   | -2.6885  | 0.0072 | -0.0507 | -0.0079 |
| mental_health_score | 0.0057  | 0.0022   | 2.5774   | 0.0100 | 0.0014  | 0.0100  |
| focus_index         | 0.0146  | 0.0008   | 17.9988  | 0.0000 | 0.0130  | 0.0161  |
| burnout_level       | -0.0094 | 0.0004   | -22.7514 | 0.0000 | -0.0102 | -0.0086 |
| productivity_score  | 0.0224  | 0.0005   | 41.9727  | 0.0000 | 0.0213  | 0.0234  |
| alpha               | 0.0284  | 0.0021   | 13.4407  | 0.0000 | 0.0242  | 0.0325  |

Log-Lik=-11451.4984 | AIC=22917.00 | BIC=22960.38  
Alpha=0.0284 | NaN=0

```

[48]: print('IRR - Binomial Negativa')
      print(irr_table(nb_fin).round(4))

```

IRR - Binomial Negativa

|                     | IRR    | IC 2.5% | IC 97.5% | p-value |
|---------------------|--------|---------|----------|---------|
| upcoming_deadline   | 0.9711 | 0.9506  | 0.9921   | 0.0072  |
| mental_health_score | 1.0057 | 1.0014  | 1.0100   | 0.0100  |
| focus_index         | 1.0147 | 1.0131  | 1.0163   | 0.0000  |
| burnout_level       | 0.9906 | 0.9898  | 0.9914   | 0.0000  |
| productivity_score  | 1.0226 | 1.0216  | 1.0237   | 0.0000  |

### 0.21.1 Interpretación del Modelo Binomial Negativa

Los **IRR** tienen la misma interpretación que en Poisson, pero con errores estándar **correctamente ajustados por sobredispersión**: los p-values son confiables. El parámetro  $\hat{\alpha}$  cuantifica la heterogeneidad no observada entre estudiantes no capturada por los regresores.

```
[49]: irr_n=irr_table(nb_fin)
me_n =marginal_effect_cnt(nb_fin,X_cnt[nb_vars])
mu_nb=nb_fin.predict().mean()
alpha=nb_fin.params['alpha']

print('INTERPRETACIÓN COMPLETA - BINOMIAL NEGATIVA')

print(f'Nota media predicha: {mu_nb:.2f} pts')
print(f'Alpha (dispersión): {alpha:.4f}')
print(f'  Var(Y)=mu+{alpha:.4f}·mu²: heterogeneidad no observada entre_
↪estudiantes.\n')

for v in nb_vars:
    if v not in irr_n.index: continue
    irr=irr_n.loc[v,'IRR']; p=irr_n.loc[v,'p-value']
    lo=irr_n.loc[v,'IC 2.5%']; hi=irr_n.loc[v,'IC 97.5%']
    me=me_n.get(v,np.nan); pct=(irr-1)*100
    dir_='aumenta' if irr>1 else 'reduce'
    print(f'    {v}')
    print(f'    IRR={irr:.4f} {stars(p)} | IC95%:[{lo:.4f},{hi:.4f}] | p={p:.
↪4f}')
    print(f'    EM={me:+.4f} pts')
    print(f'    - IRR: 1 unidad adicional en "{v}" {dir_} la nota esperada')
    print(f'    en {abs(pct):.2f}%, manteniendo constantes las demás_
↪variables.')
    print(f'    - En niveles: {me:+.4f} pts sobre la nota media de {mu_nb:.2f}.
↪')
    print(f'    ({sig_txt(p)}.)')
    print()
```

INTERPRETACIÓN COMPLETA - BINOMIAL NEGATIVA

Nota media predicha: 20.67 pts

Alpha (dispersión): 0.0284

Var(Y)=mu+0.0284·mu²: heterogeneidad no observada entre estudiantes.

upcoming\_deadline

IRR=0.9711 \*\*\* | IC95%:[0.9506,0.9921] | p=0.0072

EM=-0.6061 pts

- IRR: 1 unidad adicional en "upcoming\_deadline" reduce la nota esperada en 2.89%, manteniendo constantes las demás variables.

- En niveles: -0.6061 pts sobre la nota media de 20.67.

(estadísticamente significativo al 1%.)

```

mental_health_score
IRR=1.0057 *** | IC95%:[1.0014,1.0100] | p=0.0100
EM=+0.1171 pts
- IRR: 1 unidad adicional en "mental_health_score" aumenta la nota esperada
  en 0.57%, manteniendo constantes las demás variables.
- En niveles: +0.1171 pts sobre la nota media de 20.67.
  (estadísticamente significativo al 1%.)

focus_index
IRR=1.0147 *** | IC95%:[1.0131,1.0163] | p=0.0000
EM=+0.3008 pts
- IRR: 1 unidad adicional en "focus_index" aumenta la nota esperada
  en 1.47%, manteniendo constantes las demás variables.
- En niveles: +0.3008 pts sobre la nota media de 20.67.
  (estadísticamente significativo al 1%.)

burnout_level
IRR=0.9906 *** | IC95%:[0.9898,0.9914] | p=0.0000
EM=-0.1944 pts
- IRR: 1 unidad adicional en "burnout_level" reduce la nota esperada
  en 0.94%, manteniendo constantes las demás variables.
- En niveles: -0.1944 pts sobre la nota media de 20.67.
  (estadísticamente significativo al 1%.)

productivity_score
IRR=1.0226 *** | IC95%:[1.0216,1.0237] | p=0.0000
EM=+0.4622 pts
- IRR: 1 unidad adicional en "productivity_score" aumenta la nota esperada
  en 2.26%, manteniendo constantes las demás variables.
- En niveles: +0.4622 pts sobre la nota media de 20.67.
  (estadísticamente significativo al 1%.)

```

---

## 0.22 Pregunta 9 — Comparación Poisson vs Binomial Negativa

### 0.22.1 9.A Test de Razón de Verosimilitud (LRT)

Contrasta  $H_0 : \alpha = 0$  vs  $H_1 : \alpha > 0$ . Test de frontera: p-value dividido por 2. Ambos modelos usan el mismo conjunto de variables.

```

[50]: pois_lrt=sm.Poisson(y_cnt,sm.add_constant(X_cnt[nb_vars])).
      ↪fit(dis=0,maxiter=300)
nb_lrt =sm.NegativeBinomial(y_cnt,sm.add_constant(X_cnt[nb_vars])).
      ↪fit(dis=0,maxiter=500)

lrt_stat=-2*(pois_lrt.llf-nb_lrt.llf)

```

```

p_lr      =stats.chi2.sf(lrt_stat,df=1)/2

print('LRT: Poisson vs Binomial Negativa')
print(f' Variables: {nb_vars}')
print(f' LL Poisson: {pois_lrt.llf:.4f} | LL NB: {nb_lrt.llf:.4f}')
print(f' LRT stat:   {lrt_stat:.4f} | p-value: {p_lr:.8f}')
if p_lr<0.05: print(' → RECHAZA H0: NB supera significativamente al Poisson')

```

LRT: Poisson vs Binomial Negativa

Variables: ['upcoming\_deadline', 'mental\_health\_score', 'focus\_index',  
'burnout\_level', 'productivity\_score']  
LL Poisson: -11632.4080 | LL NB: -11451.4984  
LRT stat: 361.8191 | p-value: 0.00000000  
→ RECHAZA H0: NB supera significativamente al Poisson

```

[51]: print(f'{"Modelo":<25} {"Log-Lik":>12} {"AIC":>10} {"BIC":>10} {"Alpha":>10}')
print('-'*70)
print(f'{"Poisson (final)":<25} {pois_fin.llf:>12.4f} {pois_fin.aic:>10.2f}└─
    ↳{pois_fin.bic:>10.2f} {"N/A":>10}')
print(f'{"Binomial Neg. (final)":<25} {nb_fin.llf:>12.4f} {nb_fin.aic:>10.2f}└─
    ↳{nb_fin.bic:>10.2f} {nb_fin.params["alpha"]:>10.4f}')
print('\nAmbos modelos usan el mismo conjunto de variables.')

```

| Modelo                | Log-Lik     | AIC      | BIC      | Alpha  |
|-----------------------|-------------|----------|----------|--------|
| Poisson (final)       | -11632.4080 | 23276.82 | 23314.00 | N/A    |
| Binomial Neg. (final) | -11451.4984 | 22917.00 | 22960.38 | 0.0284 |

Ambos modelos usan el mismo conjunto de variables.

### 0.22.2 9.B Variables Robustas

```

[52]: models_cnt={ 'Poisson':(pois_fin,pois_vars), 'NegBin':(nb_fin,nb_vars)}
rob_cnt  =robustness_table(models_cnt,set(pois_vars)|set(nb_vars))
print('Tabla de Robustez - Modelos de Conteo')
print('(** p<0.01 ** p<0.05 * p<0.10 ns=no sig. -=no incluida)')
print(rob_cnt.to_string()); print()
robust_vars_cnt=[v for v in rob_cnt.index
                  if all(rob_cnt.loc[v,c] not in ['-','ns'] for c in rob_cnt.
↳columns)]
print(f'Variables robustas: {robust_vars_cnt}')

```

Tabla de Robustez - Modelos de Conteo

(\*\* p<0.01 \*\* p<0.05 \* p<0.10 ns=no sig. -=no incluida)

Poisson NegBin

Variable

|                     |     |     |
|---------------------|-----|-----|
| burnout_level       | *** | *** |
| focus_index         | *** | *** |
| mental_health_score | *** | *** |

```
productivity_score      ***      ***
upcoming_deadline      ***      ***
```

Variables robustas: ['burnout\_level', 'focus\_index', 'mental\_health\_score', 'productivity\_score', 'upcoming\_deadline']

```
[53]: irr_pf=irr_table(pois_fin); irr_nf=irr_table(nb_fin)
common=sorted(set(pois_vars)&set(nb_vars))
print(f'{"Variable":<25} {"IRR Poisson":>13} {"p(Pois.):>10} {"IRR NB":>10} {"p(NB)":>10}')
print('-'*72)
for v in common:
    ip=irr_pf.loc[v,'IRR'] if v in irr_pf.index else np.nan
    nb=irr_nf.loc[v,'IRR'] if v in irr_nf.index else np.nan
    pp=irr_pf.loc[v,'p-value'] if v in irr_pf.index else np.nan
    pn=irr_nf.loc[v,'p-value'] if v in irr_nf.index else np.nan
    print(f' {v:<23} {ip:>13.4f} {pp:>10.4f} {nb:>10.4f} {pn:>10.4f}')
```

| Variable            | IRR Poisson | p(Pois.) | IRR NB | p(NB)  |
|---------------------|-------------|----------|--------|--------|
| burnout_level       | 0.9913      | 0.0000   | 0.9906 | 0.0000 |
| focus_index         | 1.0136      | 0.0000   | 1.0147 | 0.0000 |
| mental_health_score | 1.0071      | 0.0000   | 1.0057 | 0.0100 |
| productivity_score  | 1.0214      | 0.0000   | 1.0226 | 0.0000 |
| upcoming_deadline   | 0.9737      | 0.0017   | 0.9711 | 0.0072 |

### 0.22.3 9.C Discusión

**1. Coeficientes similares, errores estándar distintos:** La sobredispersión no sesga los coeficientes del Poisson (sigue siendo consistente), pero subestima sus errores estándar en un factor  $\approx \sqrt{1 + \alpha\bar{\mu}}$ . Esto infla los t-estadísticos y produce p-values artificialmente pequeños, declarando significativos efectos que no lo son al nivel de confianza correcto.

**2. Origen de la sobredispersión:** Heterogeneidad no observada entre estudiantes — diferencias en motivación, contexto familiar, estado de salud el día del examen, etc. — que genera variación adicional más allá de lo que capturan los regresores.

**3. Modelo más adecuado:** La **Binomial Negativa** es el modelo correcto: (a) ratio Var/Media  $\gg 1$ , (b) Cameron-Trivedi rechaza  $H_0$  con  $p = 0$ , (c) LRT rechaza Poisson con  $p = 0$ , (d) NB tiene AIC y BIC menores.

**4. Comparabilidad:** Ambos modelos usan el mismo conjunto de variables, garantizando que la única diferencia sea el supuesto distribucional.

**5. Variables robustas:** las listadas en 9.B tienen efectos genuinos sobre la nota del examen, robustos al supuesto distribucional elegido.