

Tarea_1_Sonez_Vicente

April 28, 2026

1. Cargar la base de datos en el ambiente. Identifique los tipos de datos que se encuentran en la base, realice estadísticas descriptivas sobre las variables importantes (Hint: Revisar la distribuciones, datos faltantes, outliers, etc.) y limpie las variables cuando sea necesario. Genere una variable binaria para indicar quienes dieron el test. Justifique su proceso.

```
[2]: # 1. Cargar la base de datos en el ambiente
#!pip install pandas
#!pip install seaborn
#!pip install matplotlib
#!pip install missingno
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import missingno as msno
import matplotlib.pyplot as plt
data_path = '../data/student_productivity.csv'
df = pd.read_csv(data_path)

# Identificar los tipos de datos
print('--- Tipos de datos en la base ---')
display(df.dtypes)

# Analizar valores faltantes
print('\n--- Valores faltantes por columna ---')
display(df.isnull().sum())

# Estadísticas descriptivas preliminares
print('\n--- Estadísticas Descriptivas Preliminares ---')
display(df.describe(include='all'))

# Transformar variables de horas a minutos
hour_columns = [col for col in df.columns if 'hours' in col]
for col in hour_columns:
    df[col] = df[col] * 60
    df.rename(columns={col: col.replace('hours', 'minutes')}, inplace=True)

# Matriz de correlación entre las variables
```

```

print('\n--- Matriz de Correlación ---')
corr_matrix = df.corr(numeric_only=True)
display(corr_matrix)

plt.figure(figsize=(12, 8))
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm', fmt='.2f')
plt.title('Matriz de Correlación')
plt.show()
df

```

--- Tipos de datos en la base ---

```

student_id      int64
age             float64
gender          str
academic_level  str
study_hours     float64
self_study_hours float64
online_classes_hours float64
social_media_hours float64
gaming_hours    float64
sleep_hours     float64
screen_time_hours float64
exercise_minutes str
caffeine_intake_mg float64
part_time_job   str
upcoming_deadline float64
internet_quality str
mental_health_score float64
drug_use        float64
focus_index    float64
burnout_level   float64
productivity_score float64
exam_score      float64
dtype: object

```

--- Valores faltantes por columna ---

```

student_id      0
age             648
gender          558
academic_level  630
study_hours     574
self_study_hours 667
online_classes_hours 682
social_media_hours 656
gaming_hours    656
sleep_hours     553

```

```

screen_time_hours      586
exercise_minutes       599
caffeine_intake_mg     600
part_time_job          703
upcoming_deadline      717
internet_quality       523
mental_health_score    675
drug_use               4103
focus_index           633
burnout_level          716
productivity_score     638
exam_score             709
dtype: int64

```

--- Estadísticas Descriptivas Preliminares ---

	student_id	age	gender	academic_level	study_hours \
count	5621.000000	4973.000000	5063	4991	5047.000000
unique	NaN	NaN	3	6	NaN
top	NaN	NaN	Male	Postgraduate	NaN
freq	NaN	NaN	2213	1395	NaN
mean	2811.000000	20.510557	NaN	NaN	4.538708
std	1622.787263	2.876399	NaN	NaN	1.819412
min	1.000000	16.000000	NaN	NaN	0.000000
25%	1406.000000	18.000000	NaN	NaN	3.260000
50%	2811.000000	20.000000	NaN	NaN	4.530000
75%	4216.000000	23.000000	NaN	NaN	5.760000
max	5621.000000	25.000000	NaN	NaN	11.840000

	self_study_hours	online_classes_hours	social_media_hours \
count	4954.000000	4939.000000	4965.000000
unique	NaN	NaN	NaN
top	NaN	NaN	NaN
freq	NaN	NaN	NaN
mean	2.480454	2.012296	3.002872
std	1.178094	0.983104	1.472740
min	0.000000	0.000000	0.000000
25%	1.660000	1.320000	2.000000
50%	2.480000	2.010000	2.990000
75%	3.280000	2.690000	4.030000
max	7.410000	6.000000	8.280000

	gaming_hours	sleep_hours	...	caffeine_intake_mg	part_time_job \
count	4965.000000	5068.000000	...	5021.000000	4918
unique	NaN	NaN	...	NaN	4
top	NaN	NaN	...	NaN	No
freq	NaN	NaN	...	NaN	1838
mean	1.571458	7.023301	...	250.804820	NaN

std	1.112557	1.159948	...	143.685652	NaN
min	0.000000	4.000000	...	0.000000	NaN
25%	0.680000	6.250000	...	129.000000	NaN
50%	1.500000	7.015000	...	251.000000	NaN
75%	2.350000	7.820000	...	375.000000	NaN
max	5.640000	10.000000	...	499.000000	NaN

	upcoming_deadline	internet_quality	mental_health_score	drug_use	\
count	4904.000000	5098	4946.000000	1518.000000	
unique	NaN	3	NaN	NaN	
top	NaN	Good	NaN	NaN	
freq	NaN	1746	NaN	NaN	
mean	0.501223	NaN	5.516983	0.661397	
std	0.500049	NaN	2.873859	0.473391	
min	0.000000	NaN	1.000000	0.000000	
25%	0.000000	NaN	3.000000	0.000000	
50%	1.000000	NaN	5.000000	1.000000	
75%	1.000000	NaN	8.000000	1.000000	
max	1.000000	NaN	10.000000	1.000000	

	focus_index	burnout_level	productivity_score	exam_score
count	4988.000000	4905.000000	4983.000000	4912.000000
unique	NaN	NaN	NaN	NaN
top	NaN	NaN	NaN	NaN
freq	NaN	NaN	NaN	NaN
mean	29.388119	45.633156	37.313526	18.840542
std	9.996024	14.257283	16.841997	12.119456
min	1.000000	1.000000	1.000000	1.000000
25%	22.460000	35.770000	25.330000	9.410000
50%	29.380000	45.650000	36.920000	17.990000
75%	36.232500	55.410000	49.200000	27.410000
max	63.480000	97.580000	98.020000	64.090000

[11 rows x 22 columns]

--- Matriz de Correlación ---

	student_id	age	study_minutes	\
student_id	1.000000	0.005831	-0.013664	
age	0.005831	1.000000	0.004276	
study_minutes	-0.013664	0.004276	1.000000	
self_study_minutes	0.004844	0.004512	-0.003068	
online_classes_minutes	-0.004560	0.000504	0.014348	
social_media_minutes	0.002965	-0.003212	-0.001865	
gaming_minutes	-0.006432	0.006558	0.020275	
sleep_minutes	0.011184	-0.001735	-0.032438	
screen_time_minutes	0.007503	0.008363	-0.023094	
caffeine_intake_mg	0.005359	-0.003085	-0.012690	

upcoming_deadline	0.010479	-0.001858	-0.009466
mental_health_score	0.015920	-0.029391	-0.015430
drug_use	-0.009957	-0.001124	0.019056
focus_index	0.014801	-0.018056	0.450743
burnout_level	0.015888	-0.008295	0.001070
productivity_score	-0.000822	-0.013137	0.636863
exam_score	-0.005589	-0.008330	0.509619

	self_study_minutes	online_classes_minutes	\
student_id	0.004844	-0.004560	
age	0.004512	0.000504	
study_minutes	-0.003068	0.014348	
self_study_minutes	1.000000	-0.012307	
online_classes_minutes	-0.012307	1.000000	
social_media_minutes	-0.012857	-0.007456	
gaming_minutes	0.001632	-0.008978	
sleep_minutes	-0.007006	-0.009254	
screen_time_minutes	-0.023549	-0.024113	
caffeine_intake_mg	0.002061	0.007108	
upcoming_deadline	0.009935	-0.001534	
mental_health_score	0.008090	-0.014262	
drug_use	-0.000973	-0.004190	
focus_index	0.234834	0.005031	
burnout_level	-0.000379	-0.021918	
productivity_score	0.059270	0.003524	
exam_score	0.083280	0.006132	

	social_media_minutes	gaming_minutes	sleep_minutes	\
student_id	0.002965	-0.006432	0.011184	
age	-0.003212	0.006558	-0.001735	
study_minutes	-0.001865	0.020275	-0.032438	
self_study_minutes	-0.012857	0.001632	-0.007006	
online_classes_minutes	-0.007456	-0.008978	-0.009254	
social_media_minutes	1.000000	0.012579	0.002585	
gaming_minutes	0.012579	1.000000	-0.022191	
sleep_minutes	0.002585	-0.022191	1.000000	
screen_time_minutes	-0.020346	-0.006432	-0.009586	
caffeine_intake_mg	-0.025638	0.001844	-0.007337	
upcoming_deadline	-0.005094	0.012808	0.007289	
mental_health_score	-0.003405	-0.008235	0.003565	
drug_use	0.024713	0.038816	-0.028664	
focus_index	-0.306228	-0.174848	0.160955	
burnout_level	-0.018375	0.017326	-0.491554	
productivity_score	-0.065768	-0.027111	0.150011	
exam_score	-0.102402	-0.051127	0.234670	

	screen_time_minutes	caffeine_intake_mg	\
student_id	0.007503	0.005359	


age	0.008363	-0.003085
study_minutes	-0.023094	-0.012690
self_study_minutes	-0.023549	0.002061
online_classes_minutes	-0.024113	0.007108
social_media_minutes	-0.020346	-0.025638
gaming_minutes	-0.006432	0.001844
sleep_minutes	-0.009586	-0.007337
screen_time_minutes	1.000000	-0.024991
caffeine_intake_mg	-0.024991	1.000000
upcoming_deadline	-0.023451	-0.003461
mental_health_score	0.020431	0.013591
drug_use	-0.005769	0.215888
focus_index	-0.008492	-0.006038
burnout_level	0.338036	0.193833
productivity_score	-0.089084	-0.050819
exam_score	-0.132770	-0.076370

	upcoming_deadline	mental_health_score	drug_use	\
student_id	0.010479	0.015920	-0.009957	
age	-0.001858	-0.029391	-0.001124	
study_minutes	-0.009466	-0.015430	0.019056	
self_study_minutes	0.009935	0.008090	-0.000973	
online_classes_minutes	-0.001534	-0.014262	-0.004190	
social_media_minutes	-0.005094	-0.003405	0.024713	
gaming_minutes	0.012808	-0.008235	0.038816	
sleep_minutes	0.007289	0.003565	-0.028664	
screen_time_minutes	-0.023451	0.020431	-0.005769	
caffeine_intake_mg	-0.003461	0.013591	0.215888	
upcoming_deadline	1.000000	-0.009534	0.034999	
mental_health_score	-0.009534	1.000000	-0.096911	
drug_use	0.034999	-0.096911	1.000000	
focus_index	-0.010659	0.578187	-0.056196	
burnout_level	0.507658	0.012557	-0.048045	
productivity_score	-0.137298	0.630824	-0.017908	
exam_score	-0.212570	0.547794	-0.011825	

	focus_index	burnout_level	productivity_score	\
student_id	0.014801	0.015888	-0.000822	
age	-0.018056	-0.008295	-0.013137	
study_minutes	0.450743	0.001070	0.636863	
self_study_minutes	0.234834	-0.000379	0.059270	
online_classes_minutes	0.005031	-0.021918	0.003524	
social_media_minutes	-0.306228	-0.018375	-0.065768	
gaming_minutes	-0.174848	0.017326	-0.027111	
sleep_minutes	0.160955	-0.491554	0.150011	
screen_time_minutes	-0.008492	0.338036	-0.089084	
caffeine_intake_mg	-0.006038	0.193833	-0.050819	
upcoming_deadline	-0.010659	0.507658	-0.137298	

mental_health_score	0.578187	0.012557	0.630824
drug_use	-0.056196	-0.048045	-0.017908
focus_index	1.000000	-0.078021	0.786384
burnout_level	-0.078021	1.000000	-0.264197
productivity_score	0.786384	-0.264197	1.000000
exam_score	0.750577	-0.407376	0.886618

	exam_score
student_id	-0.005589
age	-0.008330
study_minutes	0.509619
self_study_minutes	0.083280
online_classes_minutes	0.006132
social_media_minutes	-0.102402
gaming_minutes	-0.051127
sleep_minutes	0.234670
screen_time_minutes	-0.132770
caffeine_intake_mg	-0.076370
upcoming_deadline	-0.212570
mental_health_score	0.547794
drug_use	-0.011825
focus_index	0.750577
burnout_level	-0.407376
productivity_score	0.886618
exam_score	1.000000



```
[2]: student_id  age  gender  academic_level  study_minutes  \
0          1   20.0    NaN    Undergraduate      322.2
1          2   16.0  Female    High School      351.0
2          3   18.0  Female    Undergraduate      341.4
3          4   24.0    Male    Undergraduate      139.2
4          5   24.0  Female    Postgraduate      232.2
...      ...   ...   ...      ...      ...
5616      5617  21.0    Male    Postgraduate      249.6
5617      5618  25.0  Female           NaN           NaN
5618      5619   NaN    NaN           NaN           NaN
5619      5620   NaN    NaN           NaN           NaN
5620      5621  18.0    Male    Postgraduate      237.6

      self_study_minutes  online_classes_minutes  social_media_minutes  \
0          125.4          111.0          219.6
1          302.4          112.2          216.0
2          136.2           0.0          175.8
3           63.6          138.0          260.4
4          157.8          152.4          222.6
```


...	...	...	...
5616	0.0	76.2	240.6
5617	NaN	NaN	310.8
5618	NaN	NaN	NaN
5619	NaN	NaN	211.2
5620	58.8	106.2	261.0

	gaming_minutes	sleep_minutes	...	caffeine_intake_mg	part_time_job	\
0	139.2	463.8	...	475.0	No	
1	167.4	366.6	...	362.0	no	
2	236.4	426.6	...	200.0	No	
3	142.2	512.4	...	233.0	No	
4	78.0	461.4	...	159.0	No	
...	...	...	...	...	...	
5616	204.6	484.2	...	152.0	no	
5617	NaN	NaN	...	NaN	NaN	
5618	NaN	NaN	...	NaN	Yes	
5619	NaN	NaN	...	NaN	NaN	
5620	133.2	394.2	...	154.0	No	

	upcoming_deadline	internet_quality	mental_health_score	drug_use	\
0	0.0	Good	3.0	NaN	
1	0.0	Good	10.0	NaN	
2	0.0	Average	5.0	NaN	
3	1.0	Poor	3.0	1.0	
4	1.0	Poor	2.0	NaN	
...	...	...	...	...	
5616	1.0	Poor	7.0	NaN	
5617	NaN	NaN	8.0	NaN	
5618	NaN	NaN	NaN	NaN	
5619	NaN	NaN	NaN	NaN	
5620	0.0	Poor	3.0	1.0	

	focus_index	burnout_level	productivity_score	exam_score
0	19.01	31.77	42.59	25.08
1	42.10	45.89	67.15	37.83
2	21.93	37.07	37.68	18.66
3	13.47	43.63	12.83	1.00
4	19.95	56.62	18.53	7.78
...	...	...	...	...
5616	21.78	48.07	43.06	17.15
5617	NaN	NaN	42.52	21.06
5618	NaN	NaN	NaN	NaN
5619	NaN	NaN	NaN	NaN
5620	16.28	36.62	21.36	2.81

[5621 rows x 22 columns]

```
[3]: # 2. Limpieza de las variables y manejo de datos problemáticos

# Eliminamos filas con NaN en el target antes de cualquier operación
df = df.dropna(subset=['exam_score'])

# Crear 'took_test': 0 si es 1.0 (ausente/mínimo), 1 si es distinto
df['took_test'] = (df['exam_score'] != 1.0).astype(int)

# Eliminar columna 'drug_use' si existe
if 'drug_use' in df.columns:
    df.drop('drug_use', axis=1, inplace=True)

# Mantener filas con MENOS de 4 NaN (borra las que tienen 4, 5, etc.)
df = df[df.isna().sum(axis=1) < 4]

# Transformar variables de horas a minutos y renombrar
hour_columns = [col for col in df.columns if 'hours' in col]
for col in hour_columns:
    df[col] = df[col] * 60
    df.rename(columns={col: col.replace('hours', 'minutes')}, inplace=True)

# Estandarizar academic_level (solo si es string)
if 'academic_level' in df.columns and df['academic_level'].dtype == 'object':
    df['academic_level'] = df['academic_level'].str.strip().str.capitalize()

# Corregir exercise_minutes a formato numérico
if 'exercise_minutes' in df.columns:
    df['exercise_minutes'] = df['exercise_minutes'].astype(str).str.replace('_',
    ↪min', '', regex=False)
    df['exercise_minutes'] = pd.to_numeric(df['exercise_minutes'],
    ↪errors='coerce')

if df['part_time_job'].dtype == "object":
    df['part_time_job'].str.lower().str.strip().map({'no': 0, 'yes': 1})

# --- BLOQUE DE IMPUTACIÓN ---

# 1. Identificar columnas numéricas (float e int) -> Mediana
cols_numericas = df.select_dtypes(include=['float64', 'int64']).columns
for col in cols_numericas:
    df[col] = df[col].fillna(df[col].median())

# 2. Identificar columnas categóricas (object) o binarias -> Moda
# Nota: La moda devuelve una Serie, por eso usamos [0]
cols_categoricas = df.select_dtypes(include=['object', 'category', 'bool']).
    ↪columns
for col in cols_categoricas:
```

```

if df[col].isnull().any():
    df[col] = df[col].fillna(df[col].mode()[0])
# Visualización de matriz de nulos final
msno.matrix(df)
plt.show()
df


```

C:\Users\56965\AppData\Local\Temp\ipykernel_14320\316399662.py:43:
Pandas4Warning: For backward compatibility, 'str' dtypes are included by
select_dtypes when 'object' dtype is specified. This behavior is deprecated and
will be removed in a future version. Explicitly pass 'str' to `include` to
select them, or to `exclude` to remove them and silence this warning.
See [https://pandas.pydata.org/docs/user_guide/migration-3-strings.html#string-](https://pandas.pydata.org/docs/user_guide/migration-3-strings.html#string-migration-select-dtypes)
migration-select-dtypes for details on how to write code that works with pandas
2 and 3.

```

cols_categoricas = df.select_dtypes(include=['object', 'category',
'bool']).columns

```



```

[3]:
      student_id  age  gender  academic_level  study_minutes  \
0              1  20.0   Male   Undergraduate           322.2
1              2  16.0  Female    High School           351.0
2              3  18.0  Female   Undergraduate           341.4
3              4  24.0   Male   Undergraduate           139.2
4              5  24.0  Female   Postgraduate           232.2
...           ...  ...   ...              ...           ...
5609          5610  22.0   Male   Postgraduate            95.4
5612          5613  18.0  Other   Postgraduate           258.0
5614          5615  25.0  Female   Undergraduate           231.0
5616          5617  21.0   Male   Postgraduate           249.6

```

5620	5621	18.0	Male	Postgraduate	237.6
------	------	------	------	--------------	-------

	self_study_minutes	online_classes_minutes	social_media_minutes	\
0	125.4	111.0	219.6	
1	302.4	112.2	216.0	
2	136.2	0.0	175.8	
3	63.6	138.0	260.4	
4	157.8	152.4	222.6	
...	...	...	...	
5609	212.4	49.2	309.6	
5612	140.4	42.0	25.8	
5614	157.8	120.6	153.0	
5616	0.0	76.2	240.6	
5620	58.8	106.2	261.0	

	gaming_minutes	sleep_minutes	...	caffeine_intake_mg	part_time_job	\
0	139.2	463.8	...	475.0	No	
1	167.4	366.6	...	362.0	no	
2	236.4	426.6	...	200.0	No	
3	142.2	512.4	...	233.0	No	
4	78.0	461.4	...	159.0	No	
...	...	...	...	...	...	
5609	231.6	403.2	...	420.0	Yes	
5612	242.4	443.4	...	87.0	no	
5614	147.6	489.0	...	453.0	Yes	
5616	204.6	484.2	...	152.0	no	
5620	133.2	394.2	...	154.0	No	

	upcoming_deadline	internet_quality	mental_health_score	focus_index	\
0	0.0	Good	3.0	19.01	
1	0.0	Good	10.0	42.10	
2	0.0	Average	5.0	21.93	
3	1.0	Poor	3.0	13.47	
4	1.0	Poor	2.0	19.95	
...	...	...	...	...	
5609	0.0	Poor	6.0	17.36	
5612	1.0	Poor	2.0	36.18	
5614	1.0	Good	10.0	38.26	
5616	1.0	Poor	7.0	21.78	
5620	0.0	Poor	3.0	16.28	

	burnout_level	productivity_score	exam_score	took_test
0	31.77	42.59	25.08	1
1	45.89	67.15	37.83	1
2	37.07	37.68	18.66	1
3	43.63	12.83	1.00	0
4	56.62	18.53	7.78	1

...	...	...	...	...
5609	49.19	14.12	4.51	1
5612	40.42	31.42	10.57	1
5614	57.39	45.30	23.77	1
5616	48.07	43.06	17.15	1
5620	36.62	21.36	2.81	1

[4655 rows x 22 columns]

-
2. Ejecute un modelo de probabilidad lineal (*MCO*) que permita explicar la probabilidad de que un alumno rinda el examen, a partir de las informacion disponible. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

Para estimar la probabilidad de que un alumno rinda el examen (`took_test`), ejecutaremos un Modelo de Probabilidad Lineal empleando Mínimos Cuadrados Ordinarios (MCO).

Selección de Variables Explicativas: Seleccionamos variables que de forma teórica y lógica afectan la decisión o probabilidad de rendir el test: - `study_minutes`: Representa el tiempo de preparación. Siguiendo la logica de que estudiar mas horas genera mayor confianza a la hora de presentarse para un examen. - `mental_health_score` y `burnout_level`: Factores psicológicos críticos. Un mayor burnout disminuye la probabilidad de rendir debido al agotamiento, ademas el estado de la salud mental es clave a la hora presentarse a un examen. - `social_media_minutes` y `gaming_minutes`: Indicadores de distracciones y procrastinación. - `sleep_minutes`: El descanso impacta la productividad y asistencia. - `upcoming_deadline`: Indica si hay o no una fecha límite cercana.

```
[4]: import statsmodels.api as sm

# Definición de variables independientes (X) y dependiente (y)
indep_vars = [
    'study_minutes', 'social_media_minutes', 'gaming_minutes',
    'sleep_minutes', 'mental_health_score', 'burnout_level',
    'upcoming_deadline'
]

X = df[indep_vars]
X = sm.add_constant(X)
y = df['took_test']

# Ajustamos el modelo de MCO (MPL)
model = sm.OLS(y, X).fit()

# Mostrar los resultados del modelo
model.summary()
```

[4]:

Dep. Variable:	took_test	R-squared:	0.221
Model:	OLS	Adj. R-squared:	0.220
Method:	Least Squares	F-statistic:	188.5
Date:	Tue, 21 Apr 2026	Prob (F-statistic):	9.79e-247
Time:	16:23:35	Log-Likelihood:	-209.52
No. Observations:	4655	AIC:	435.0
Df Residuals:	4647	BIC:	486.6
Df Model:	7		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
const	0.7353	0.040	18.190	0.000	0.656	0.815
study_minutes	0.0008	3.43e-05	22.402	0.000	0.001	0.001
social_media_minutes	-0.0002	4.23e-05	-4.074	0.000	-0.000	-8.95e-05
gaming_minutes	-0.0002	5.61e-05	-2.703	0.007	-0.000	-4.16e-05
sleep_minutes	0.0001	6.46e-05	1.757	0.079	-1.31e-05	0.000
mental_health_score	0.0295	0.001	22.731	0.000	0.027	0.032
burnout_level	-0.0045	0.000	-12.268	0.000	-0.005	-0.004
upcoming_deadline	0.0104	0.009	1.151	0.250	-0.007	0.028

Omnibus:	1645.129	Durbin-Watson:	2.003
Prob(Omnibus):	0.000	Jarque-Bera (JB):	4757.936
Skew:	-1.889	Prob(JB):	0.00
Kurtosis:	6.202	Cond. No.	6.00e+03

Notes:

- [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 6e+03. This might indicate that there are strong multicollinearity or other numerical problems.

1

1. El Ajuste Global del Modelo (R^2 y Prueba F) R-squared (0.221) y Adj. R-squared (0.220): Tienen un valor del 22.1%. Esto significa que las variables que seleccionaste son capaces de explicar un 22.1% de los motivos por los que un estudiante decide (o logra) dar el examen. Dado que modelar comportamiento humano suele ser difícil y un MPL siempre arroja R^2 bajos por su ajuste lineal sobre puntos discretos, este es un valor poco practico en la realidad, ya que existen modelos como probit y logit que se ajustan mejor.

Prob (F-statistic) (9.79e-247): Este valor es brutalmente cercano a 0. Nos indica que el modelo, en su conjunto, es altamente significativo. Es decir, las variables que introdujiste realmente sirven juntas para explicar la asistencia al examen.

2. Interpretación de las Variables y significancia Para interpretar si una variable importa de verdad, miramos el P-valor ($P>|t|$). Usaremos un nivel de significancia de 0.05 (5%).

Variables Positivas:

study_minutes (Coef: 0.0008, P-valor: 0.000): Un impacto positivo y estadísticamente significativo. Cada minuto adicional que el estudiante pasa estudiando aumenta su probabilidad de rendir en

un 0.08. Puesto de una forma más intuitiva: Por cada hora extra de estudio (60 minutos), la probabilidad de presentarse al examen aumenta casi en un 5 (4.8), manteniendo todo lo demás constante.

mental_health_score (Coef: 0.0295, P-valor: 0.000): Un impacto positivo y muy significativo. Por cada punto que sube el marcador de la salud mental del estudiante, la probabilidad de presentarse a rendir aumenta en casi un 3 (2.95). Una mejor salud mental impulsa fuertemente la participación.

Variables negativas:

burnout_level (Coef: -0.0045, P-valor: 0.000): Un impacto negativo y significativo. Su incremento penaliza al alumno. Cada punto extra en el nivel de burnout reduce la probabilidad de rendir en un 0.45. social_media_minutes (Coef: -0.0002, P-valor: 0.000): Negativo y significativo. Cada hora invertida en redes sociales (60 min) disminuye la probabilidad de rendir en un 1.2.

gaming_minutes (Coef: -0.0002, P-valor: 0.007): Negativo y significativo al igual que el caso anterior. Cada hora dedicada a jugar videojuegos reduce la probabilidad de realizar el test en un 1.2.

Variables no significativas

sleep_minutes (Coef: 0.0001, P-valor: 0.079): Es levemente positivo, pero no posee significancia con un 5 de significancia. En la práctica, esto indica evidencia débil de que el total de sueño influya de forma dura y directa en la probabilidad de dar el examen en este modelo.

upcoming_deadline (Coef: 0.0104, P-valor: 0.250): No es estadísticamente significativo. Como su P-valor es mucho mayor a 0.05, estadísticamente no podemos asegurar que tener una entrega inminente afecte de algún modo la probabilidad de que el alumno rinda el examen.

3. Ejecute un modelo *probit* para responder a la pregunta 2. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

Selección de Variables: Nuestra variable dependiente es **took_test** (binaria: 1 si rindió el examen, 0 si no). Se ocupa el mismo modelo que en OLS pero quitando las variables que resultaron ser no significativas.

```
[5]: import statsmodels.api as sm

# Selección de variables independientes finales
indep_vars_probit = [
    'study_minutes', 'mental_health_score', 'burnout_level',
    'social_media_minutes', 'gaming_minutes'
]

X_probit = df[indep_vars_probit]
X_probit = sm.add_constant(X_probit)
y_probit = df['took_test']

# Estimar el Modelo Probit
probit_model = sm.Probit(y_probit, X_probit).fit()

# Mostrar los resultados
```

```

print(probit_model.summary())

# Calculamos los efectos marginales promedio (dy/dx) para poder
# interpretar el impacto real de cada variable en la probabilidad.
marginal_effects = probit_model.get_margeff()
print("\n--- Efectos Marginales Promedio ---")
print(marginal_effects.summary())

```

Optimization terminated successfully.

Current function value: 0.160666

Iterations 8

Probit Regression Results

```

=====
Dep. Variable:          took_test    No. Observations:          4655
Model:                  Probit       Df Residuals:              4649
Method:                 MLE         Df Model:                  5
Date:                   Tue, 21 Apr 2026    Pseudo R-squ.:           0.4707
Time:                   16:23:35          Log-Likelihood:          -747.90
converged:              True           LL-Null:                 -1413.1
Covariance Type:        nonrobust        LLR p-value:             1.737e-285
=====

```

```

=====
                                coef    std err          z      P>|z|      [0.025
0.975]
-----
const                0.9344      0.186      5.021      0.000      0.570
1.299
study_minutes        0.0090      0.000     19.746      0.000      0.008
0.010
mental_health_score   0.3828      0.020     19.492      0.000      0.344
0.421
burnout_level        -0.0534      0.003    -17.039      0.000     -0.060
-0.047
social_media_minutes  -0.0021      0.000     -4.848      0.000     -0.003
-0.001
gaming_minutes       -0.0012      0.001     -2.305      0.021     -0.002
-0.000
=====
=====

```

Possibly complete quasi-separation: A fraction 0.26 of observations can be perfectly predicted. This might indicate that there is complete quasi-separation. In this case some parameters will not be identified.

--- Efectos Marginales Promedio ---

Probit Marginal Effects

=====

Dep. Variable:	took_test				
Method:	dydx				
At:	overall				
=====					
=====					
	dy/dx	std err	z	P> z	[0.025
0.975]					

study_minutes	0.0008	3.38e-05	23.704	0.000	0.001
0.001					
mental_health_score	0.0339	0.001	23.231	0.000	0.031
0.037					
burnout_level	-0.0047	0.000	-19.539	0.000	-0.005
-0.004					
social_media_minutes	-0.0002	3.75e-05	-4.895	0.000	-0.000
-0.000					
gaming_minutes	-0.0001	4.73e-05	-2.311	0.021	-0.000
-1.66e-05					
=====					
=====					

1.0.1 Interpretación del Modelo Probit

1. Ajuste y Significancia Global:

- El **Pseudo R^2 (McFadden)** es aproximadamente **0.471**. Para modelos no lineales como el Probit, un Pseudo R-cuadrado entre 0.2 y 0.4 se considera un ajuste excelente (similar a un R-cuadrado de 0.70 - 0.90 en MCO). Esto ratifica que la combinación de estas variables explica bien si un estudiante asiste y rinde o no.
- El **LLR p-value** es prácticamente 0, validando robustamente que el modelo no es aleatorio y en conjunto las variables independientes son altamente significativas para predecir la asistencia al examen.

2. Interpretación de los Efectos Marginales (Impactos Cuantitativos sobre la Probabilidad):

Al analizar la tabla de “*Efectos Marginales Promedio*”, comprobamos que todas las variables retenidas son concluyentemente estadísticamente significativas al 5% , lo que justifica correctamente su selección.

- **Variables positivas:**

- **mental_health_score** (dy/dx = **0.0339**): Tiene el impacto de mayor magnitud. Por cada incremento de un punto en bienestar psicológico, la probabilidad de presentarse a dar el examen aumenta en un **3.4%** aproximadamente.
- **study_minutes** (dy/dx = **0.0008**): Es consistente con el MCO, ratificando su efectividad y estabilidad algorítmica a pesar de la restricción del modelo Probit. Cada minuto adicional de estudio eleva marginalmente dicha probabilidad en un 0.08% (o **4.8% por cada hora adicional**).

- **Variables negativas:**

- **burnout_level** (dy/dx = **-0.0047**): Manteniendo las demás aisladas constantes, el

aumento unitario del burnout baja de forma concluyente la probabilidad predecida de presentarse al examen en un **0.47%** de probabilidad unitaria.

- **social_media_minutes** ($dy/dx = -0.0002$) y **gaming_minutes** ($dy/dx = -0.0001$): Reafirmación completa sobre el rol nocivo de ambas adicciones sobre la acción. Por cada hora empleada en redes sociales o videojuegos la probabilidad de terminar el examen se reduce en alrededor del **1.2%** y **0.6%** respectivamente.

1.0.2 Modelo Logit

Estimaremos un modelo **Logit** utilizando las mismas variables seleccionadas.

Las variables independientes seleccionadas seran homologas al modelo Probit

Variable Dependiente: `took_test`

```
[6]: import statsmodels.api as sm

# Las variables ya fueron definidas en el paso anterior de la misma manera
indep_vars_logit = [
    'study_minutes', 'mental_health_score', 'burnout_level',
    'social_media_minutes', 'gaming_minutes'
]

X_logit = df[indep_vars_logit]
X_logit = sm.add_constant(X_logit)
y_logit = df['took_test']

# Estimar el Modelo Logit
logit_model = sm.Logit(y_logit, X_logit).fit()

# Mostrar los resultados
print(logit_model.summary())

# Calculamos los efectos marginales del Logit
marginal_effects_logit = logit_model.get_margeff()
print("\n--- Efectos Marginales Promedio (Logit) ---")
print(marginal_effects_logit.summary())
```

Optimization terminated successfully.

Current function value: 0.160947

Iterations 9

Logit Regression Results

```
=====
Dep. Variable:          took_test    No. Observations:          4655
Model:                  Logit        Df Residuals:              4649
Method:                  MLE         Df Model:                  5
Date:                    Tue, 21 Apr 2026    Pseudo R-squ.:            0.4698
Time:                    16:23:35          Log-Likelihood:           -749.21
converged:                True          LL-Null:                 -1413.1
```

```

Covariance Type:          nonrobust    LLR p-value:          6.426e-285
=====
=====
              coef      std err          z      P>|z|      [0.025
0.975]
-----
const          1.6285      0.345      4.724      0.000      0.953
2.304
study_minutes    0.0169      0.001     19.094      0.000      0.015
0.019
mental_health_score  0.7138      0.038     18.913      0.000      0.640
0.788
burnout_level   -0.0988      0.006    -16.617      0.000     -0.111
-0.087
social_media_minutes -0.0038      0.001     -4.811      0.000     -0.005
-0.002
gaming_minutes  -0.0023      0.001     -2.344      0.019     -0.004
-0.000
=====
=====

```

--- Efectos Marginales Promedio (Logit) ---

Logit Marginal Effects

```

=====
Dep. Variable:          took_test
Method:                dydx
At:                    overall
=====
=====
              dy/dx      std err          z      P>|z|      [0.025
0.975]
-----
study_minutes    0.0008    3.36e-05     24.094      0.000      0.001
0.001
mental_health_score  0.0342      0.001     23.424      0.000      0.031
0.037
burnout_level   -0.0047      0.000    -19.646      0.000     -0.005
-0.004
social_media_minutes -0.0002    3.76e-05     -4.862      0.000     -0.000
-0.000
gaming_minutes  -0.0001    4.67e-05     -2.352      0.019     -0.000
-1.83e-05
=====
=====

```

1.0.3 Interpretación del Modelo Logit

1. Ajuste Computacional:

- El **Pseudo R^2** es de **0.4698**, de la misma forma que en el Probit, evidenciando un ajuste excepcional para detectar o pronosticar la probabilidad de que un alumno abandone antes de hacer la prueba.
- La significancia conjunta mediante el LLR p-value vuelve a certificar que este set de variables son correctas y potentes.

2. Interpretación y Comparación de Efectos Marginales:

- Como suele ocurrir estadísticamente, ambos modelos (Probit y Logit) convergen a estimaciones marginales casi idénticas.
- **mental_health_score** ($dy/dx = 0.0342$): cada unidad superior predice un 3.4% extra de probabilidad de rendir.
- **study_minutes** ($dy/dx = 0.0008$): Resultados virtuales equivalentes (4.8% extra por cada 60 minutos o 1 hora de estudio).
- **burnout_level** ($dy/dx = -0.0047$): Al igual que en el Probit, castiga con exactitud en -0.47% la probabilidad de asistencia por cada punto de estrés.
- **social_media_minutes** y **gaming_minutes**: Siguen reduciendo en promedios equivalentes (-0.0002 y -0.0001 por minuto gastado correspondientemente).

Conclusión: Tanto el análisis por Modelo de Probabilidad Lineal, Probit, o Logit confirman de manera indudable los mismos catalizadores empíricos en los estudiantes. Mantener una buena salud mental y la aplicación teórica de horas de estudio guían de manera directa hacia la conclusión del curso, mientras que la exposición digital a plataformas de ocio incide inversamente sobre su éxito final.

-
5. Comente los resultados obtenidos en 2, 3 y 4. ¿Cuáles y por qué existen las diferencias entre los resultados?. En su opinión, ¿Cuál sería el más adecuado para responder la pregunta de investigación y por qué? ¿Qué variables resultaron ser robustas a la especificación?

Diferencias entre los Resultados y su Razonamiento Si analizamos los tres modelos, observamos que los coeficientes crudos son muy distintos en escala. Esto ocurre porque matemáticamente evalúan la variable dependiente de forma distinta: - El **MCO** asume que la relación es lineal. Por tanto, asume que el efecto marginal es constante sin importar los valores iniciales. Esto arrastra problemas teóricos fundamentales, permitiendo probabilidades predichas menores a 0 o mayores a 1. - Los modelos **Probit y Logit** asumen funciones de densidad acumulada no lineales (Normal Estándar y Logística). Estos modelos *aplastan* las probabilidades para que encajen lógicamente en el rango [0, 1]. Sus coeficientes originales no miden directamente probabilidad, sino un *índice latente* (z-score) o los *log-odds*.

Sin embargo, al pedir en statsmodels los **Efectos Marginales Promedio (dy/dx)** para Probit y Logit, observamos que las diferencias *efectivas* sobre la probabilidad son empíricamente nulas entre los tres enfoques (ej. **study_minutes** fue 0.0008 constante en MCO, Probit y Logit). Las diferencias subyacentes se suavizan al evaluar a los individuos promedio.

1.0.4 El Modelo Más Adecuado

Para responder a una pregunta de investigación con una variable dependiente de naturaleza dual / **binaria** (“Rindió” vs “No Rindió”), **el modelo Logit (o el Probit) son más adecuados que el MCO**. El comportamiento humano frente al estudio sigue rendimientos marginales decrecientes (pasar de estudiar 0 horas a 1 hora impacta mucho más en tu decisión de asistir al examen, que pasar de estudiar 15 horas a 16 horas sintiéndote agotado). El MCO ignora esto, pero la curvatura natural en forma de “S” de los modelos Probit/Logit modelan exquisitamente bien esta realidad.

1.0.5 Variables Robustas a la Especificación

Las variables demostraron ser **extremadamente robustas** a la especificación, puesto que su significancia, peso numérico, e interpretaciones lógicas sobrevivieron de manera inalterable y sin sesgos de sobreestimación al cambio desde estimadores lineales a funciones de Máxima Verosimilitud (MLE) no lineales. Estas son:

1. **study_minutes** y **mental_health_score** (Robustas Positivas): Actuando sinérgicamente para empujar la asistencia al examen.
2. **burnout_level**, **social_media_minutes** y **gaming_minutes** (Robustas Negativas): Actuando como destructores directos sobre la asistencia.

-
6. Use un modelo Poisson para explicar la nota del examen, entre aquellos alumnos que lo rindieron. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

El requerimiento nos solicita explicar el **puntaje del examen (exam_score)**, asumiendo a esta como variable dependiente, delimitando la muestra **únicamente a los estudiantes que sí rindieron el test**. Puesto que la calificación es una variable discreta o de conteo (puntajes definidos típicamente enteros y en rangos pre-determinados mayores a 0), un Modelo de Probabilidad no es apto. En estos casos, el **Modelo de Regresión Poisson** es el estimador teórico de máxima verosimilitud preferido para datos de conteo no negativos.

Selección de Variables Explicativas: - Restringiremos los datos según la condición exigida: `df[df['took_test'] == 1]`. - Incluiremos un set amplio de las determinantes probadas anteriormente, y rescataremos variables como el **sueño** y el **estudio autónomo** (`sleep_minutes` y `self_study_minutes`) para ver si, ahora que tratamos de prever *rendimiento* y no mera *asistencia*, estas toman mayor significancia estadística.

```
[7]: import statsmodels.api as sm

# Filtramos el DataFrame para que incluya exclusivamente a los alumnos que
# rindieron
df_tested = df[df['took_test'] == 1].copy()

# Definimos determinantes (rescatando variables que hipotéticamente impactan en
# la atención y nota)
indep_vars_poisson = [
    'study_minutes', 'self_study_minutes', 'mental_health_score',
    'burnout_level', 'social_media_minutes', 'gaming_minutes',
```

```

    'sleep_minutes'
]

X_poisson = df_tested[indep_vars_poisson]
X_poisson = sm.add_constant(X_poisson)
y_poisson = df_tested['exam_score'] # Variable observada es ahora la nota
↳discreta

# Estimación Poisson
poisson_model = sm.Poisson(y_poisson, X_poisson).fit()
print(poisson_model.summary())

# Extraemos Efectos Marginales para entender cambios exactos en # de puntaje
margeff_poisson = poisson_model.get_margeff()
print("\n--- Efectos Marginales Promedio sobre Nota del Examen ---")
print(margeff_poisson.summary())

```

Optimization terminated successfully.

Current function value: 3.468993

Iterations 7

Poisson Regression Results

```

=====
Dep. Variable:          exam_score  No. Observations:          4234
Model:                  Poisson    Df Residuals:              4226
Method:                 MLE        Df Model:                  7
Date:                  Tue, 21 Apr 2026  Pseudo R-squ.:          0.3834
Time:                  16:23:35    Log-Likelihood:         -14688.
converged:              True        LL-Null:                 -23821.
Covariance Type:        nonrobust    LLR p-value:             0.000
=====
=====

```

	coef	std err	z	P> z	[0.025
0.975]					

const	2.0840	0.036	57.241	0.000	2.013
2.155					
study_minutes	0.0027	3.15e-05	84.805	0.000	0.003
0.003					
self_study_minutes	0.0006	4.86e-05	12.024	0.000	0.000
0.001					
mental_health_score	0.1109	0.001	89.064	0.000	0.108
0.113					
burnout_level	-0.0154	0.000	-54.962	0.000	-0.016
-0.015					
social_media_minutes	-0.0007	3.85e-05	-17.146	0.000	-0.001
-0.001					
gaming_minutes	-0.0005	5.17e-05	-9.369	0.000	-0.001

```

-0.000
sleep_minutes          0.0005    5.6e-05    8.881    0.000    0.000
0.001
=====
=====

--- Efectos Marginales Promedio sobre Nota del Examen ---
      Poisson Marginal Effects
=====
Dep. Variable:          exam_score
Method:                dydx
At:                    overall
=====
=====
                        dy/dx    std err      z      P>|z|      [0.025
0.975]
-----
-----
study_minutes          0.0550    0.001    81.511    0.000    0.054
0.056
self_study_minutes     0.0120    0.001    12.014    0.000    0.010
0.014
mental_health_score    2.2845    0.027    85.272    0.000    2.232
2.337
burnout_level          -0.3170    0.006   -54.035    0.000   -0.328
-0.305
social_media_minutes   -0.0136    0.001   -17.117    0.000   -0.015
-0.012
gaming_minutes         -0.0100    0.001    -9.364    0.000   -0.012
-0.008
sleep_minutes          0.0103    0.001     8.877    0.000    0.008
0.013
=====
=====

```

1.0.6 Interpretación del Modelo Poisson en exam_score

1. Justificación Geométrica y Significancia:

- El Pseudo R^2 roza el **0.385**, lo cual es un desempeño extraordinario para predecir puntuales exactos de estudiantes reales.
- Lo más sorpresivo es la **significancia unánime**. Absolutamente todas las variables incorporadas arrojaron un P-valor de 0.000 (o cercas de ello), probando que aunque ciertas métricas (como el sueño o el auto-estudio extra) no eran cruciales para decidir asistir, resultan determinantes para su puntaje final del examen.

2. Impactos Marginales Directos sobre la Nota (Puntos Brutos de la Evaluación):

Nota: Dado que la variable dependiente directa esta vez es el puntaje en sí (y no una probabilidad), el efecto marginal dy/dx se lee como “el aumento promedio de puntaje en el examen

por cada aumento de 1 unidad base en la variable independiente”.

- **study_minutes** ($dy/dx = 0.055$): Cada minuto estudiado incrementa el puntaje. Por cada **1 hora base de estudio (60 min)**, la calificación sube **3.3 puntos** nominales.
- **mental_health_score** ($dy/dx = 2.29$): Cada estatus o puntaje extra de bienestar mental del estudiante se traduce en sumar **2.3 puntos firmes** al puntaje del examen del sujeto.
- **sleep_minutes** ($dy/dx = 0.010$): Sorprendentemente significativa para rendimiento cognitivo frente a simple asistencia. Cada unidad (1 min) de reposo extrae 0.01 puntos. Por ende, **descansar una hora de sueño adicional incrementaba el puntaje promedial en 0.6 puntos**.
- **burnout_level** ($dy/dx = -0.317$): Repercute agresivamente, restando casi **0.32 puntos** nominales por cada unidad de burnout .
- **social_media_minutes** ($dy/dx = -0.0136$) y **gaming_minutes** ($dy/dx = -0.0100$): Cada hora derrochada (60 min) en estas dispersiones le robaban al alumno **-0.81** y **-0.6** puntos de su nota final correspondiente.

-
7. Determine si existe sobre dispersion en la data y posible valor optimo de alpha para un modelo Binomial Negativa.

Para justificar un modelo Binomial Negativo, verificamos empíricamente si existe sobredispersión (Varianza > Media) y realizamos la prueba auxiliar de Cameron & Trivedi para hallar el valor óptimo de α .

```
[8]: # 1. Comparación empírica: Media vs Varianza
mean_y = df_tested['exam_score'].mean()
var_y = df_tested['exam_score'].var()
print(f"Media: {mean_y:.2f}, Varianza: {var_y:.2f}")
print("Existe una sobredispersión severa ya que la Varianza supera ampliamente
↳a la Media.\n")

# 2. Prueba auxiliar de Cameron & Trivedi para estimar alpha óptimo
df_tested['fitted_poisson'] = poisson_model.fittedvalues
df_tested['aux_dep'] = ((df_tested['exam_score'] -
↳df_tested['fitted_poisson'])**2 - df_tested['exam_score']) /
↳df_tested['fitted_poisson']

# Regresión de OLS sin intercepto para hallar el factor alpha óptimo
aux_model = sm.OLS(df_tested['aux_dep'], df_tested['fitted_poisson']).fit()
alpha_opt = aux_model.params.iloc[0]
p_val = aux_model.pvalues.iloc[0]

print(f"Valor óptimo estimado de alpha: {alpha_opt:.4f} (p-valor: {p_val:.4f})")
print("Al ser alpha positivo y significativo, se ratifica el Modelo Binomial
↳Negativo.")
```

Media: 20.60, Varianza: 128.08

Existe una sobredispersión severa ya que la Varianza supera ampliamente a la

Media.

Valor óptimo estimado de alpha: 47.0810 (p-valor: 0.0000)

Al ser alpha positivo y significativo, se ratifica el Modelo Binomial Negativo.

-
8. Usando la informacion anterior, ejecute un modelo Binomial Negativa para responder a la pregunta 6. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

Ejecutamos el modelo Binomial Negativo sobre la nota del examen (`exam_score`) utilizando las mismas variables explicativas seleccionadas en el modelo Poisson.

```
[11]: # Las matrices de regresión X_poisson y y_poisson se calcularon en el punto 6.
# Ajustamos el modelo Binomial Negativo (parametrización clásica)
negbin_model = sm.NegativeBinomial(y_poisson, X_poisson).fit(method="nm",
    ↪maxiter=5000, disp=0)
print(negbin_model.summary())

# Obtenemos los Efectos Marginales (dy/dx)
# Esto reflejará el cambio estimado absoluto en la nota final del test.
margeff_negbin = negbin_model.get_margeff()
print("\n--- Efectos Marginales Promedio (Binomial Negativo) ---")
print(margeff_negbin.summary())
```

NegativeBinomial Regression Results

```
=====
Dep. Variable:          exam_score    No. Observations:          4234
Model:                NegativeBinomial    Df Residuals:              4226
Method:                  MLE    Df Model:                7
Date:                  Tue, 21 Apr 2026    Pseudo R-squ.:           0.1355
Time:                  16:30:07    Log-Likelihood:          -13986.
converged:              True    LL-Null:              -16178.
Covariance Type:        nonrobust    LLR p-value:             0.000
=====
```

```
=====
                                coef    std err          z      P>|z|      [0.025
0.975]
-----
const                2.0095      0.056    36.001      0.000      1.900
2.119
study_minutes        0.0029     5.1e-05    56.799      0.000      0.003
0.003
self_study_minutes   0.0007     7.52e-05     8.896      0.000      0.001
0.001
mental_health_score   0.1180      0.002    61.329      0.000      0.114
0.122
=====
```

```

burnout_level          -0.0167      0.000    -38.262      0.000      -0.018
-0.016
social_media_minutes   -0.0007    5.97e-05   -12.188      0.000      -0.001
-0.001
gaming_minutes         -0.0005    7.98e-05    -6.657      0.000      -0.001
-0.000
sleep_minutes          0.0006    8.65e-05     6.402      0.000      0.000
0.001
alpha                  0.0614      0.003     21.900      0.000      0.056
0.067
=====
=====

--- Efectos Marginales Promedio (Binomial Negativo) ---
    NegativeBinomial Marginal Effects
=====
Dep. Variable:          exam_score
Method:                 dydx
At:                     overall
=====
=====
                                dy/dx      std err      z      P>|z|      [0.025
0.975]
-----
-----
study_minutes           0.0602      0.001     51.362      0.000      0.058
0.063
self_study_minutes      0.0139      0.002      8.870      0.000      0.011
0.017
mental_health_score     2.4515      0.045     54.891      0.000      2.364
2.539
burnout_level          -0.3470      0.010    -36.476      0.000     -0.366
-0.328
social_media_minutes    -0.0151      0.001    -12.125      0.000     -0.018
-0.013
gaming_minutes         -0.0110      0.002     -6.647      0.000     -0.014
-0.008
sleep_minutes           0.0115      0.002      6.392      0.000      0.008
0.015
=====
=====

```

1.0.7 Interpretación del Modelo Binomial Negativo

Como se podía prever, usar un Binomial Negativo en lugar del Poisson original **preservó los signos y la dirección teórica de los efectos**, pero corrigió y robusteció eficientemente los errores estándar estimando además internamente un parámetro de sobredispersión, dando como resultados un ajuste excelente.

La significancia y magnitud de los predictores se comportó fielmente:

- **mental_health_score** ($dy/dx = \sim 2.45$): Subir de estrato en salud emocional garantiza rendimientos dramáticamente superiores (añadiendo alrededor de 2.45 puntos promedio a la nota final por cada grado de sanidad).
 - **study_minutes** y **self_study_minutes** ($dy/dx = \sim 0.060$ y 0.0139 respectivamente): Ambos minutos de estudio productivo y autónomo premian la evaluación de forma pura. Una hora extra de estudio (60 mins) propulsa marginalmente la calificación un 3.3%.
 - **burnout_level** ($dy/dx = \sim -0.347$): Por cada punto de burnout extra, se reduce en 0.31 el puntaje total, este cambio es dramático tomando en cuenta que los niveles de burnout varían entre [0-100]. (-0.31 puntos de penalización marginal bruta).
 - **sleep_minutes** ($dy/dx = \sim 0.012$): Confirmado como influyente positivo en el rendimiento de los test, a diferencia de la asistencia al test, por cada hora de sueño extra se aumenta en 0.6 el puntaje.
 - **social_media_minutes** y **gaming_minutes** ($dy/dx = -0.0151$ y -0.0110): detractores principales del rendimiento académico, cada hora en redes sociales al día reduce en un 0.9 puntos la nota del test, mientras que los minutos de juego reducen la nota en 0.66 puntos por hora.
9. Comente los resultados obtenidos en 6, 7 y 8. ¿Cuáles y por qué existen las diferencias entre los resultados?. En su opinión, ¿Cuál sería el más adecuado para responder la pregunta de investigación y por qué? ¿Qué variables resultaron ser robustas a la especificación?

¿Cuáles son las diferencias y por qué existen? Al contrastar analíticamente el Modelo Poisson (Punto 6) frente al Binomial Negativo (Punto 8), observamos fenomenológicamente que los **efectos marginales promedio (dy/dx)** y la **dirección matemática de los parámetros se mantuvieron casi inalterables**. La diferencia yace directamente en los **errores estándar estadísticos de las variables**.

La razón teórica y programática de estas variaciones obedece a que el *modelo Poisson puro asume obligatoriamente que la media y varianza distribucional son idénticas limitándose a λ* . Como logramos certificar empíricamente en el paso (7), esto en la vida real era rotundamente falso (Varianza 128.08 $\gg$ Media 20.60). Forzar un modelo Poisson sobre data sobredispersa produce un subrepticio aplastamiento subestimado de los errores estándar, sesgando los P-valores haciéndolos figurar absurdamente prístinos de forma artificial. Al pasar al **esquema Binomial Negativo**, la inyección del parámetro auxiliar α (≈ 0.04) ensanchó la varianza probabilística reconociendo la heterogeneidad ($v = \mu + \alpha\mu^2$). Esto corrigió las confianzas y nos dio errores estándar y contrastes honestos.

¿Cuál es el más adecuado para responder la pregunta de investigación y por qué? Estadísticamente, el Modelo Binomial Negativo es la opción concluyente y superior. Esto dado que el Binomial Negativo absorbe la heterogeneidad latente, estabilizando y oficializando las predicciones del modelo, en comparación al Poisson.

¿Qué variables resultaron ser verdaderamente robustas a la especificación?

- **Variables positivas Robustas** : La Salud Mental (**mental_health_score**) y las horas de estudio (**study_minutes**)**. Ambas demostraron ser los principales explicadores de la asistencia y rendimiento de los exámenes.

- **Variables negativas Robustas:** El Burnout (`burnout_level`), sumado al tiempo en **Redes Sociales** (`social_media_minutes`) y **Videojuegos** (`gaming_minutes`). Se sostuvieron invariables sin importar los cambios a la función del modelo, solidificando su rol detractor tanto en el rendimiento como en la asistencia al examen. Es importante mencionar que burnout tuvo un efecto mucho más significativo que las horas dedicadas al ocio.