

Tarea_2_Matias_Rocha

June 5, 2026

Tarea 2 - Matias Rocha Ayala - 2022431515



Instrucciones

Los resultados de los ejercicios propuestos se deben entregar como un notebook por correo electronico a juancaros@udec.cl el día 25/5 hasta las 21:00. Es importante considerar que el código debe poder ejecutarse en cualquier computadora con la data original del repositorio. Recordar la convencion para el nombre de archivo ademas de incluir en su documento titulos y encabezados por seccion.

El archivo a utilizar es *dataset_prueba.csv*, que contiene un conjunto de variables a nivel de ciudad durante el periodo de COVID-19, incluyendo características sociodemográficas, movilidad, restricciones gubernamentales, casos de COVID-19, movilidad y búsquedas en Google para terminos específicos. **Variable dictionary**

- "iso_code": "Country or region code",
- "date": "Date of the record",
- "retail_and_recreation_percent_change_from_baseline": "Change in retail/recreation activity",
- "grocery_and_pharmacy_percent_change_from_baseline": "Change in grocery/pharmacy activity",
- "parks_percent_change_from_baseline": "Change in park visits",
- "transit_stations_percent_change_from_baseline": "Change in transit station activity",
- "workplaces_raw": "Raw workplace activity data",
- "residential_percent_change_from_baseline": "Change in residential activity",
- "trend": "Trend indicator",
- "workplaces": "Processed workplace activity data",
- "Valor_Stringency_Index": "Stringency index value",
- "Valor_GovernmentResponseIndex": "Government response index value",
- "Valor_EconomicSupportIndex": "Economic support index value",
- "Valor_Containment_Health_index": "Containment and health index value",
- "workplace_closing": "Workplace closing indicator",
- "daily_cases": "Daily reported cases",
- "week": "Week number",
- "year": "Year",
- "CODE": "Region code",
- "NAME": "Region name",
- "Population": "Population of the region",
- "agriculture": "Agriculture sector data",
- "industry": "Industry sector data",
- "construction": "Construction sector data",
- "age_dependency": "Age dependency ratio",

- "old_age_dependency": "Old age dependency ratio",
- "young_age_dependency": "Young age dependency ratio",
- "sex_ratio": "Sex ratio",
- "unemp": "Unemployment rate",
- "f_unemp": "Female unemployment rate",
- "m_unemp": "Male unemployment rate",
- "foreigners": "Foreign population percentage",
- "country": "Country name"

0.1 Configuración del Entorno

Importamos las librerías necesarias para el análisis.

```
[1]: # Librerías estándar
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import warnings
import missingno as msno


from linearmodels.panel import PooledOLS, PanelOLS, RandomEffects
import statsmodels.api as sm
from scipy import stats

plt.rcParams['figure.figsize'] = (12, 6)
plt.rcParams['font.size'] = 11
sns.set_style('whitegrid')
warnings.filterwarnings('ignore')
```

0.1.1 1. Cargar la base de datos en el ambiente. Identifique los tipos de datos que se encuentran en la base, realice estadísticas descriptivas sobre las variables importantes (Hint: Revisar la distribuciones, datos faltantes, outliers, etc.) y limpie las variables cuando sea necesario.

```
[2]: # Cargar el dataset
df = pd.read_csv('data/dataset_prueba.csv')
msno.matrix(df)
```

```
[2]: <Axes: >
```



0.1.2 1.1 Identificación de tipos de datos

```
[3]: # Tipos de datos de cada columna
print(df.dtypes)
print(f'\n--- Resumen de tipos ---')
print(df.dtypes.value_counts())
```

iso_code	object
date	object
retail_and_recreation_percent_change_from_baseline	float64
grocery_and_pharmacy_percent_change_from_baseline	float64
parks_percent_change_from_baseline	float64
transit_stations_percent_change_from_baseline	float64
workplaces_raw	float64
residential_percent_change_from_baseline	float64
trend	float64
workplaces	float64
Valor_Stringency_Index	float64
Valor_GovernmentResponseIndex	float64
Valor_EconomicSupportIndex	float64
Valor_Containment_Health_index	float64
workplace_closing	float64
daily_cases	float64
d2	int64
d1	int64
d3	int64

```

d4                                int64
d5                                int64
d6                                int64
week                              int64
year                              int64
CODE                              object
NAME                              object
Population                        float64
agriculture                      float64
industry                         float64
construction                     float64
edu2                              float64
edu3                              float64
age_dependency                   float64
old_age_dependency               float64
young_age_dependency             float64
sex_ratio                       float64
unemp                            float64
f_unemp                          float64
m_unemp                          float64
foreigners                      float64
country                          object
dtype: object

```

```

--- Resumen de tipos ---
float64    28
int64       8
object      5
Name: count, dtype: int64

```

0.1.3 1.2 Estadísticas descriptivas

```

[4]: # Seleccionar variables numéricas clave para estadísticas descriptivas
numeric_cols = df.select_dtypes(include=[np.number]).columns.tolist()

# Variables principales de interés
key_vars = [
    'workplaces', 'workplaces_raw',
    'Valor_Stringency_Index', 'Valor_GovernmentResponseIndex',
    'Valor_EconomicSupportIndex', 'Valor_Containment_Health_index',
    'workplace_closing', 'daily_cases',
    'retail_and_recreation_percent_change_from_baseline',
    'grocery_and_pharmacy_percent_change_from_baseline',
    'parks_percent_change_from_baseline',
    'transit_stations_percent_change_from_baseline',
    'residential_percent_change_from_baseline',
    'Population', 'unemp', 'age_dependency', 'sex_ratio', 'foreigners'
]

```

```

]

# Filtrar solo las que existen
key_vars = [v for v in key_vars if v in df.columns]
df[key_vars].describe().round(4).T

```

```

[4]:

```

	count	mean \
workplaces	12040.0	-18.6674
workplaces_raw	12040.0	-25.0029
Valor_Stringency_Index	12040.0	27.4863
Valor_GovernmentResponseIndex	12040.0	30.6368
Valor_EconomicSupportIndex	12040.0	30.9551
Valor_Containment_Health_index	12040.0	30.5917
workplace_closing	12040.0	0.8508
daily_cases	12040.0	2355.7334
retail_and_recreation_percent_change_from_baseline	12040.0	-16.4373
grocery_and_pharmacy_percent_change_from_baseline	12040.0	5.1243
parks_percent_change_from_baseline	12040.0	49.6756
transit_stations_percent_change_from_baseline	12040.0	-17.6023
residential_percent_change_from_baseline	12040.0	7.0712
Population	12040.0	745.4742
unemp	12040.0	12.2205
age_dependency	12040.0	0.6539
sex_ratio	12040.0	106.7145
foreigners	12040.0	8.1455

	std	min \
workplaces	11.8014	-76.7871
workplaces_raw	14.6811	-87.0000
Valor_Stringency_Index	29.8359	0.0000
Valor_GovernmentResponseIndex	30.2449	0.0000
Valor_EconomicSupportIndex	36.3643	0.0000
Valor_Containment_Health_index	29.9431	0.0000
workplace_closing	0.9971	0.0000
daily_cases	3154.9144	0.0000
retail_and_recreation_percent_change_from_baseline	21.5994	-95.6000
grocery_and_pharmacy_percent_change_from_baseline	15.7073	-66.2000
parks_percent_change_from_baseline	71.6978	-95.8000
transit_stations_percent_change_from_baseline	24.5406	-88.6000
residential_percent_change_from_baseline	6.0228	-3.8000
Population	1277.3416	201.0480
unemp	8.2653	3.0000
age_dependency	0.0728	0.5205
sex_ratio	4.2472	91.4488
foreigners	2.9919	2.0000

	25%	50% \
workplaces		
workplaces_raw		
Valor_Stringency_Index		
Valor_GovernmentResponseIndex		
Valor_EconomicSupportIndex		
Valor_Containment_Health_index		
workplace_closing		
daily_cases		
retail_and_recreation_percent_change_from_baseline		
grocery_and_pharmacy_percent_change_from_baseline		
parks_percent_change_from_baseline		
transit_stations_percent_change_from_baseline		
residential_percent_change_from_baseline		
Population		
unemp		
age_dependency		
sex_ratio		
foreigners		

workplaces	-24.3584	-16.8200
workplaces_raw	-32.4000	-22.8000
Valor_Stringency_Index	0.0000	15.8580
Valor_GovernmentResponseIndex	0.0000	32.0300
Valor_EconomicSupportIndex	0.0000	0.0000
Valor_Containment_Health_index	0.0000	36.6100
workplace_closing	0.0000	0.0000
daily_cases	0.0372	632.0104
retail_and_recreation_percent_change_from_baseline	-26.4000	-11.4000
grocery_and_pharmacy_percent_change_from_baseline	-3.2000	6.2000
parks_percent_change_from_baseline	4.8000	34.2000
transit_stations_percent_change_from_baseline	-31.8000	-18.4000
residential_percent_change_from_baseline	3.2000	5.6000
Population	246.7940	346.7905
unemp	6.0000	8.0000
age_dependency	0.6092	0.6510
sex_ratio	103.5230	107.0132
foreigners	6.0000	9.0000

	75%	max
workplaces	-10.8840	19.0576
workplaces_raw	-14.4000	6.6000
Valor_Stringency_Index	53.4200	93.5200
Valor_GovernmentResponseIndex	60.1600	81.3060
Valor_EconomicSupportIndex	75.0000	100.0000
Valor_Containment_Health_index	59.2300	85.4200
workplace_closing	2.0000	3.0000
daily_cases	3815.6444	22203.3142
retail_and_recreation_percent_change_from_baseline	-3.6000	74.6000
grocery_and_pharmacy_percent_change_from_baseline	15.0000	83.6000
parks_percent_change_from_baseline	78.8000	631.0000
transit_stations_percent_change_from_baseline	-4.4000	123.2000
residential_percent_change_from_baseline	9.4000	42.6000
Population	620.5230	10274.8840
unemp	18.0000	36.0000
age_dependency	0.6817	0.8375
sex_ratio	109.5315	115.7529
foreigners	11.0000	15.0000

0.1.4 1.3 Distribuciones de variables clave

Revisamos las distribuciones de la variable dependiente (`workplaces`) y las principales variables independientes de restricciones gubernamentales.

```
[5]: # Distribuciones de las variables más relevantes
vars_to_plot = [
    'workplaces', 'Valor_Stringency_Index',
```


```

'Valor_GovernmentResponseIndex', 'Valor_Containment_Health_index',
'workplace_closing', 'daily_cases'
]

fig, axes = plt.subplots(2, 3, figsize=(16, 10))
for i, var in enumerate(vars_to_plot):
    ax = axes[i // 3, i % 3]
    df[var].dropna().hist(bins=40, ax=ax, color='steelblue', edgecolor='black',
        ↪alpha=0.7)
    ax.set_title(var, fontsize=10)
    ax.axvline(df[var].mean(), color='red', linestyle='--', linewidth=1,
        ↪label=f'Media={df[var].mean():.2f}')
    ax.legend(fontsize=8)

fig.suptitle('Distribuciones de Variables Clave', fontsize=14,
    ↪fontweight='bold')
plt.tight_layout()
plt.show()

```



```

[6]: # Distribuciones de variables de movilidad
mobility_vars = [
    'retail_and_recreation_percent_change_from_baseline',
    'grocery_and_pharmacy_percent_change_from_baseline',
    'parks_percent_change_from_baseline',

```


```

    'transit_stations_percent_change_from_baseline',
    'residential_percent_change_from_baseline',
    'workplaces_raw'
]

fig, axes = plt.subplots(2, 3, figsize=(16, 10))
for i, var in enumerate(mobility_vars):
    ax = axes[i // 3, i % 3]
    df[var].dropna().hist(bins=40, ax=ax, color='mediumseagreen',
    ↪edgecolor='black', alpha=0.7)
    ax.set_title(var.replace('_percent_change_from_baseline', ''), fontsize=10)
    ax.axvline(df[var].mean(), color='red', linestyle='--', linewidth=1)

fig.suptitle('Distribuciones de Variables de Movilidad', fontsize=14,
    ↪fontweight='bold')
plt.tight_layout()
plt.show()

```



0.1.5 1.4 Detección de Outliers

Utilizamos boxplots e IQR para identificar valores atípicos en las variables principales.

```

[7]: # Boxplots de variables clave
fig, axes = plt.subplots(2, 3, figsize=(16, 10))
for i, var in enumerate(vars_to_plot):


```

```

ax = axes[i // 3, i % 3]
df.boxplot(column=var, ax=ax)
ax.set_title(var, fontsize=10)

fig.suptitle('Boxplots para Detección de Outliers', fontsize=14,
             fontweight='bold')
plt.tight_layout()
plt.show()

```



```

[8]: # Conteo de outliers
outlier_vars = ['workplaces', 'daily_cases', 'Valor_Stringency_Index',
                'Valor_GovernmentResponseIndex',
                'Valor_Containment_Health_index',
                'Population', 'unemp']

for var in outlier_vars:
    if var in df.columns:
        Q1 = df[var].quantile(0.25)
        Q3 = df[var].quantile(0.75)
        IQR = Q3 - Q1
        lower = Q1 - 1.5 * IQR
        upper = Q3 + 1.5 * IQR
        outliers = df[(df[var] < lower) | (df[var] > upper)]
        pct = len(outliers) / len(df) * 100

```

```
print(f'{var}: {len(outliers)} outliers ({pct:.1f}%) | Rango aceptable: [
↳[{lower:.2f}, {upper:.2f}]]')
```

```
workplaces: 450 outliers (3.7%) | Rango aceptable: [-44.57, 9.33]
daily_cases: 425 outliers (3.5%) | Rango aceptable: [-5723.37, 9539.06]
Valor_Stringency_Index: 0 outliers (0.0%) | Rango aceptable: [-80.13, 133.55]
Valor_GovernmentResponseIndex: 0 outliers (0.0%) | Rango aceptable: [-90.24,
150.40]
Valor_Containment_Health_index: 0 outliers (0.0%) | Rango aceptable: [-88.84,
148.07]
Population: 1400 outliers (11.6%) | Rango aceptable: [-313.80, 1181.12]
unemp: 0 outliers (0.0%) | Rango aceptable: [-12.00, 36.00]
```

0.1.6 1.5 Limpieza de Datos

A continuación se realizan los pasos de limpieza necesarios basados en la exploración anterior.

```
[9]: # Conversión de la columna 'date' a formato datetime
df['date'] = pd.to_datetime(df['date'])

# verificar duplicados por (NAME, date)
n_dup = df.duplicated(subset=['NAME', 'date']).sum()
if n_dup > 0:
    df = df.drop_duplicates(subset=['NAME', 'date'], keep='first')

# Eliminar columnas edu2 y edu3 por alto porcentaje de datos faltantes
cols_to_drop = [col for col in ['edu2', 'edu3'] if col in df.columns]
if len(cols_to_drop) > 0:
    df = df.drop(columns=cols_to_drop)
```

```
[10]: # Resumen de ciudades y periodos en los datos limpios
print(f'Número de ciudades únicas: {df["NAME"].nunique()}')
print(f'Países representados: {df["country"].unique()}')
print(f'Periodo temporal: {df["date"].min()} a {df["date"].max()}')
print(f'Semanas por ciudad (promedio): {df.groupby("NAME")["week"].count().
↳mean():.0f}')
print(f'\nCiudades por país:')
print(df.groupby('country')['NAME'].nunique())
```

```
Número de ciudades únicas: 86
Países representados: ['DE' 'ES' 'FR' 'IT' 'SE']
Periodo temporal: 2020-02-17 00:00:00 a 2022-10-17 00:00:00
Semanas por ciudad (promedio): 140
```


Ciudades por país:

```
country
DE    39
ES    16
```

```
FR      15
IT      14
SE       2
Name: NAME, dtype: int64
```

```
[11]: msno.matrix(df)
```

```
[11]: <Axes: >
```



0.1.7 1.6 Matriz de Correlación

Examinamos las correlaciones entre las variables clave para entender las relaciones bivariadas y posible multicolinealidad.

```
[12]: # Matriz de correlación de variables clave
corr_vars = ['workplaces', 'Valor_Stringency_Index',
             'Valor_GovernmentResponseIndex',
             'Valor_Containment_Health_index', 'Valor_EconomicSupportIndex',
             'workplace_closing', 'daily_cases',
             'residential_percent_change_from_baseline',
             'transit_stations_percent_change_from_baseline',
             'unemp', 'Population', 'age_dependency']
corr_vars = [v for v in corr_vars if v in df.columns]


corr_matrix = df[corr_vars].corr()
```

```

fig, ax = plt.subplots(figsize=(14, 10))
mask = np.triu(np.ones_like(corr_matrix, dtype=bool))
sns.heatmap(corr_matrix, mask=mask, annot=True, fmt='.2f', cmap='RdBu_r',
            center=0,
            square=True, linewidths=0.5, ax=ax, vmin=-1, vmax=1)
ax.set_title('Matriz de Correlación - Variables Clave', fontsize=14,
            fontweight='bold')
plt.tight_layout()
plt.show()

# Correlaciones con la variable dependiente
print('\n=== Correlación con workplaces (variable dependiente) ===')
print(corr_matrix['workplaces'].sort_values(ascending=False).round(3))

```



=== Correlación con workplaces (variable dependiente) ===

workplaces	1.000
transit_stations_percent_change_from_baseline	0.708
daily_cases	0.075
age_dependency	-0.030
unemp	-0.122
Population	-0.218
Valor_EconomicSupportIndex	-0.294
Valor_Containment_Health_index	-0.306
Valor_GovernmentResponseIndex	-0.309
workplace_closing	-0.388
Valor_Stringency_Index	-0.413
residential_percent_change_from_baseline	-0.804

Name: workplaces, dtype: float64

0.1.8 1.7 Evolución temporal de variables clave

```
[13]: # Evolución temporal promedio de las variables principales
temporal = df.groupby('date')[['workplaces', 'Valor_Stringency_Index',
                                'daily_cases', 'workplace_closing']].mean()

fig, axes = plt.subplots(2, 2, figsize=(16, 10))


temporal['workplaces'].plot(ax=axes[0, 0], color='steelblue', linewidth=1.5)
axes[0, 0].set_title('Movilidad Laboral (workplaces) - Promedio')
axes[0, 0].set_ylabel('Cambio %')
axes[0, 0].axhline(0, color='gray', linestyle='--', alpha=0.5)

temporal['Valor_Stringency_Index'].plot(ax=axes[0, 1], color='crimson',
    ↪ linewidth=1.5)
axes[0, 1].set_title('Índice de Rigurosidad (Stringency Index)')
axes[0, 1].set_ylabel('Índice')

temporal['daily_cases'].plot(ax=axes[1, 0], color='darkorange', linewidth=1.5)
axes[1, 0].set_title('Casos Diarios (acumulados)')
axes[1, 0].set_ylabel('Casos')

temporal['workplace_closing'].plot(ax=axes[1, 1], color='purple', linewidth=1.5)
axes[1, 1].set_title('Cierre de Lugares de Trabajo (workplace_closing)')
axes[1, 1].set_ylabel('Indicador')

fig.suptitle('Evolución Temporal de Variables Clave (Promedio entre Ciudades)',
    ↪ fontsize=14, fontweight='bold')
plt.tight_layout()
plt.show()
```



0.2 2. Ejecute un modelo Pooled OLS para estimar la relación entre las restricciones gubernamentales de movilidad y la variación en movilidad laboral. Seleccione las variables independientes a incluir en el modelo final e interprete su significado.

Para estimar la relación entre las restricciones gubernamentales de movilidad y la variación en movilidad laboral, especificamos el siguiente modelo Pooled OLS:

$$\text{workplaces}_{it} = \beta_0 + \beta_1 \text{Valor_Stringency_Index}_{it} + \beta_2 \text{workplace_closing}_{it} + \beta_3 \text{daily_cases}_{it} + \beta_4 \text{residential_percent_change}_{it} + \beta_5 \text{unemp}_{it} + \beta_6 \text{Population}_{it} + \beta_7 \text{age_dependency}_{it} + u_{it}$$

Donde: * workplaces_{it} : Variación en la movilidad laboral (variable dependiente) para la ciudad i en el periodo t . * β_0 : Intercepto (constante) del modelo. * $\text{Valor_Stringency_Index}_{it}$ y $\text{workplace_closing}_{it}$: Variables independientes principales que capturan las restricciones gubernamentales. * daily_cases_{it} , $\text{residential_percent_change}_{it}$, unemp_{it} , Population_{it} , $\text{age_dependency}_{it}$: Variables de control (casos diarios, movilidad residencial, desempleo, población y dependencia de edad). * $\beta_1, \dots, \beta_7$: Coeficientes a estimar que indican el efecto marginal de cada variable sobre la movilidad laboral. * u_{it} : Término de error aleatorio del modelo.

```
[14]: df['city_id'] = df['NAME'].astype('category').cat.codes
df_panel = df.set_index(['NAME', 'date'])
y = df_panel['workplaces']
```

```
# Variables independientes
X_vars = ['Valor_Stringency_Index', 'workplace_closing', 'daily_cases',
          'residential_percent_change_from_baseline', 'unemp',
          'Population', 'age_dependency']

X = df_panel[X_vars]
X = sm.add_constant(X)
```

```
[15]: pooled_model = PooledOLS(y, X)
pooled_results = pooled_model.fit(cov_type='clustered', cluster_entity=True)

print(pooled_results)
```

PooledOLS Estimation Summary

```
=====
Dep. Variable:          workplaces    R-squared:                0.7095
Estimator:              PooledOLS    R-squared (Between):      0.7650
No. Observations:      12040         R-squared (Within):       0.7004
Date:                  Mon, May 25 2026 R-squared (Overall):      0.7095
Time:                  17:36:50       Log-likelihood            -3.936e+04
Cov. Estimator:        Clustered

                               F-statistic:          4198.3
Entities:               86             P-value              0.0000
Avg Obs:                140.00         Distribution:          F(7,12032)
Min Obs:                140.00
Max Obs:                140.00         F-statistic (robust):    681.07
                               P-value              0.0000
Time periods:          140            Distribution:          F(7,12032)
Avg Obs:                86.000
Min Obs:                86.000
Max Obs:                86.000
```

Parameter Estimates

```
=====
=====
```

			Parameter	Std. Err.	T-stat
P-value	Lower CI	Upper CI			

			const	-5.3228	2.6036
0.0409	-10.426	-0.2194			-2.0444
			Valor_Stringency_Index	-0.1009	0.0171
0.0000	-0.1345	-0.0672			-5.8814
			workplace_closing	1.6034	0.4465
0.0003	0.7281	2.4787			3.5908
			daily_cases	0.0002	2.694e-05
0.0000	0.0002	0.0003			9.2744
			residential_percent_change_from_baseline	-1.4944	0.0350
					-42.751

0.0000	-1.5630	-1.4259			
unemp			-0.1493	0.0321	-4.6531
0.0000	-0.2122	-0.0864			
Population			-0.0011	0.0001	-9.1533
0.0000	-0.0013	-0.0009			
age_dependency			1.0343	4.0001	0.2586
0.7960	-6.8066	8.8752			
=====					
=====					

0.2.1 Interpretación de Resultados: Modelo Pooled OLS

A partir de la estimación del modelo Pooled OLS (con errores estándar robustos/clúster), se observan los siguientes resultados para las variables que explican la variación en la movilidad laboral (`workplaces`):

- El modelo presenta un R-cuadrado de 0.7095, lo que indica que aproximadamente el 71% de la varianza en la movilidad laboral se explica por las variables incluidas en el modelo.
- **Valor_Stringency_Index (\$ = -0.1009, $p < 0.001$ \$)**: Es altamente significativa y tiene el signo negativo esperado. Manteniendo el resto constante, un aumento de 1 punto en el índice de rigurosidad de las políticas gubernamentales está asociado a una caída de 0.10 puntos porcentuales en la movilidad hacia los lugares de trabajo respecto a la línea base. Esto confirma que medidas más restrictivas reducen de manera efectiva los desplazamientos laborales.
- **workplace_closing (\$ = 1.6034, $p < 0.001$ \$)**: Resulta estadísticamente significativa pero presenta un signo positivo contraintuitivo. Esto podría deberse a multicolinealidad con el `Stringency_Index` (ya que cierres laborales son un componente de este último) o a que el Pooled OLS no está controlando adecuadamente por la heterogeneidad no observada de las ciudades (sesgo de variable omitida).
- **residential_percent_change (\$ = -1.4944, $p < 0.001$ \$)**: Como era de esperar, existe un claro efecto de sustitución. Por cada incremento de 1% en la movilidad residencial (personas que se quedan en casa), la movilidad en los lugares de trabajo disminuye en 1.49%.
- **Desempleo (unemp) (\$ = -0.1493, $p < 0.001$ \$)**: Altamente significativa. Ciudades y periodos con una tasa de desempleo 1% mayor están asociados con una reducción de 0.15% en la movilidad laboral.
- **daily_cases (\$ = 0.0002, $p < 0.001$ \$)**: Es estadísticamente significativa, pero la magnitud del coeficiente es muy cercana a cero, sugiriendo que el reporte de casos diarios tiene un impacto marginal casi nulo sobre la movilidad laboral de forma directa cuando ya se controla por las restricciones del gobierno.
- **Population (\$ = -0.0011, $p < 0.001$ \$)**: Significativa y negativa, indicando que regiones más pobladas experimentaron en promedio caídas ligeramente mayores en su movilidad laboral.
- **age_dependency (\$ = 1.0343, $p = 0.796$ \$)**: No es estadísticamente significativa a ningún nivel convencional, lo que sugiere que la tasa de dependencia de la población no tiene un efecto directo evidente sobre la variación de la movilidad laboral en este modelo.

Limitación principal del Pooled OLS: Cabe recalcar que este modelo asume que no existen efectos específicos invariantes en el tiempo para cada ciudad. Al no aislar la heterogeneidad no observada de cada región, los coeficientes pueden estar sesgados (como sugiere el signo de `workplace_closing`). Esto justifica la posterior exploración de modelos de Efectos Fijos (FE) o Efectos Aleatorios (RE).

0.3 3. Ejecute un modelo efectos fijos para estimar la misma relacion anterior. Seleccione las variables independientes a incluir en el modelo final e interprete su significado.

Para aislar la heterogeneidad no observada e invariante en el tiempo propia de cada ciudad (por ejemplo, diferencias culturales, demografía estructural, o geografía), estimamos un modelo de Efectos Fijos. Las variables que no varían en el tiempo (`Population`, `unemp`, `age_dependency`) son absorbidas por el intercepto específico de cada ciudad (α_i). El modelo se define explícitamente como:

$$\text{workplaces}_{it} = \alpha_i + \beta_1 \text{Valor_Stringency_Index}_{it} + \beta_2 \text{workplace_closing}_{it} + \beta_3 \text{daily_cases}_{it} + \beta_4 \text{residential_percent_change_from_baseline}_{it} + u_{it}$$

Donde: * workplaces_{it} : Variación en la movilidad laboral para la ciudad i en el periodo t . * α_i : Intercepto específico para cada ciudad (Efecto Fijo), que captura todas las características no observadas de la ciudad i que son constantes en el tiempo. * $\beta_1 \dots \beta_4$: Coeficientes “Within” que estiman el efecto marginal de los cambios en el tiempo dentro de una misma ciudad. * u_{it} : Término de error idiosincrático.

```
[16]: # Variables independientes para FE (sin variables invariantes en el tiempo)
# En el modelo FE, las variables que no varían en el tiempo dentro de cada
# ciudad
# son absorbidas por el efecto fijo. Por lo tanto, excluimos Population, unemp,
# age_dependency, etc.

X_fe_vars = ['Valor_Stringency_Index', 'workplace_closing', 'daily_cases',
             'residential_percent_change_from_baseline']

X_fe = df_panel[X_fe_vars]
X_fe = sm.add_constant(X_fe)

# Estimar modelo de Efectos Fijos
fe_model = PanelOLS(y, X_fe, entity_effects=True)
fe_results = fe_model.fit(cov_type='clustered', cluster_entity=True)

print(fe_results)
```

PanelOLS Estimation Summary

```
=====
Dep. Variable:          workplaces    R-squared:                0.7019
Estimator:              PanelOLS      R-squared (Between):      0.4653
No. Observations:      12040         R-squared (Within):      0.7019
```

```

Date:                Mon, May 25 2026    R-squared (Overall):      0.6685
Time:                17:36:50           Log-likelihood            -3.86e+04
Cov. Estimator:      Clustered

F-statistic:                7033.3
Entities:                  86    P-value                0.0000
Avg Obs:                  140.00 Distribution:          F(4,11950)
Min Obs:                  140.00
Max Obs:                  140.00 F-statistic (robust):    1317.2
P-value                0.0000
Time periods:            140    Distribution:          F(4,11950)
Avg Obs:                  86.000
Min Obs:                  86.000
Max Obs:                  86.000

```

Parameter Estimates

			Parameter	Std. Err.	T-stat
P-value	Lower CI	Upper CI			

const			-7.9492	0.2855	-27.845
0.0000	-8.5087	-7.3896			
Valor_Stringency_Index			-0.0694	0.0089	-7.8259
0.0000	-0.0868	-0.0520			
workplace_closing			1.5700	0.2361	6.6505
0.0000	1.1072	2.0327			
daily_cases			0.0002	2.209e-05	10.808
0.0000	0.0002	0.0003			
residential_percent_change_from_baseline			-1.5144	0.0268	-56.585
0.0000	-1.5669	-1.4620			
=====					
=====					

```

F-test for Poolability: 29.177
P-value: 0.0000
Distribution: F(85,11950)

```

Included effects: Entity

0.3.1 Interpretación de Resultados: Modelo de Efectos Fijos

Basado en la estimación del modelo PanelOLS, obtenemos las siguientes conclusiones sobre la variación de la movilidad laboral *dentro* de las ciudades a lo largo del tiempo:

Justificación del Modelo:

- **Test de Poolability (F-test = 29.177, $p < 0.001$):** Rechazamos fuertemente la hipótesis nula de que todos los interceptos α_i son iguales. Esto significa que existen efectos específicos

por ciudad y que el modelo de Efectos Fijos es técnica y económicamente superior al Pooled OLS.

- **Bondad de Ajuste:** El R^2 “Within” es de 0.7019, indicando que el modelo explica el 70.19% de la varianza en la movilidad laboral que ocurre a lo largo del tiempo dentro de las ciudades.

Variables de Interés (Restricciones Gubernamentales): *

Valor_Stringency_Index (\$ = -0.0694, p < 0.001) : * *

Al controlar por las características fijas de las ciudades, una unidad en el índice de rigurosidad en una ciudad.

**** workplace_closing(= 1.5700, p < 0.001 \$):** El coeficiente sigue siendo positivo y significativo. A pesar de controlar por la heterogeneidad fija, el cierre de espacios de trabajo aparece relacionado positivamente con la movilidad. Esto sugiere que esta variable en particular sufre de multicolinealidad severa con el **Stringency_Index** (al ser redundante o estar solapada) o es endógena por la naturaleza dinámica de la pandemia (las medidas se aplican cuando la movilidad ya cambió).

Variables de Control: * residential_percent_change (\$ = -1.5144, p < 0.001) : * *

*El efecto de sustitución se mantiene robusto. Por cada incremento de 1 * * * daily_cases(= 0.0002, p < 0.001 \$):* El efecto de los casos diarios sigue siendo estadísticamente significativo, pero su magnitud real es ínfima, demostrando que no es el conteo directo de casos lo que frena la movilidad laboral, sino la respuesta del gobierno frente a ellos.

0.4 4. Ejecute un modelo de efectos aleatorios para estimar la misma relación anterior. Seleccione las variables independientes a incluir en el modelo final e interprete su significado.

El modelo de Efectos Aleatorios asume que los efectos específicos de cada ciudad son variables aleatorias que forman parte del término de error compuesto, y que no están correlacionados con las variables independientes del modelo. Esto nos permite reintroducir variables de control invariantes en el tiempo (como **Population** y **age_dependency**). El modelo se especifica de la siguiente manera:

$$\text{workplaces}_{it} = \beta_0 + \beta_1 \text{Valor_Stringency_Index}_{it} + \dots + \beta_7 \text{age_dependency}_{it} + (\alpha_i + \epsilon_{it})$$

Donde: * β_0 : Intercepto global. * $\beta_1 \dots \beta_7$: Coeficientes a estimar para todas las variables explicativas (tanto variantes como invariantes en el tiempo). * α_i : Efecto aleatorio específico de la ciudad i (captura la heterogeneidad no observada asumiendo exogeneidad estricta). * ϵ_{it} : Término de error idiosincrático puro. * El término compuesto $(\alpha_i + \epsilon_{it})$ representa el error total del modelo.

```
[17]: X_re_vars = ['Valor_Stringency_Index', 'workplace_closing', 'daily_cases',
               'residential_percent_change_from_baseline', 'unemp',
               'Population', 'age_dependency']

X_re = df_panel[X_re_vars]
X_re = sm.add_constant(X_re)

# Estimar modelo de Efectos Aleatorios
re_model = RandomEffects(y, X_re)
re_results = re_model.fit(cov_type='clustered', cluster_entity=True)
```

```
print(re_results)
```

RandomEffects Estimation Summary

```
=====
Dep. Variable:      workplaces      R-squared:      0.7023
Estimator:          RandomEffects   R-squared (Between): 0.7416
No. Observations:   12040           R-squared (Within):  0.7019
Date:               Mon, May 25 2026 R-squared (Overall): 0.7075
Time:               17:36:50         Log-likelihood      -3.866e+04
Cov. Estimator:     Clustered

F-statistic:      4055.6
Entities:         86      P-value      0.0000
Avg Obs:          140.00  Distribution: F(7,12032)
Min Obs:          140.00
Max Obs:          140.00  F-statistic (robust): 910.77
                          P-value      0.0000
Time periods:     140     Distribution: F(7,12032)
Avg Obs:          86.000
Min Obs:          86.000
Max Obs:          86.000
=====
```

Parameter Estimates

```
=====
=====
P-value    Lower CI    Upper CI    Parameter    Std. Err.    T-stat
-----
const      -3.2044    2.1368    -1.4996
0.1337    -7.3928    0.9841
Valor_Stringency_Index
0.0000    -0.0891    -0.0598
workplace_closing
0.0000    1.0932    2.0574
daily_cases
0.0000    0.0002    0.0003
residential_percent_change_from_baseline
0.0000    -1.5611    -1.4564
unemp      -0.1991    0.0364    -5.4729
0.0000    -0.2704    -0.1278
Population -0.0012    0.0001    -7.8820
0.0000    -0.0015    -0.0009
age_dependency
0.5470    -8.7898    4.6578
=====
=====
```

0.4.1 Interpretación de Resultados: Modelo de Efectos Aleatorios

De la estimación del modelo **RandomEffects**, que pondera la varianza “Within” (dentro de las ciudades) y “Between” (entre las ciudades), observamos lo siguiente:

Bondad de Ajuste: * El R^2 global (Overall) es de 0.7075, mostrando que el modelo sigue explicando de forma robusta alrededor del 71% de la varianza total de la movilidad laboral.

Variables de Interés (Restricciones Gubernamentales): *
Valor_Stringency_Index (\$ = -0.0744, p < 0.001) : * *

El efecto de la rigurosidad gubernamental se mantiene robusto, significativo y con el signo negativo esperado. Un incremento en la rigurosidad gubernamental reduce la movilidad laboral.

**** workplace_closing** (= 1.5753, p < 0.001 \$): Sigue siendo positivo y significativo, reafirmando que su dinámica va más allá de un simple sesgo de variable omitida constante. Esto indica que probablemente actúa de forma endógena o en correlación con los momentos de mayor movilidad compensatoria.

Variables de Control Variantes e Invariantes: * **residential_percent_change** (\$ = -1.5087, p < 0.001) : * * *Lacada* 1.5 * * * **unemp** (= -0.1991, p < 0.001) y **Population** (= -0.0012, p < 0.001) : * *

Vuelven a ser estadísticamente significativas. Ciudades con mayor población y mayores tasas de desempleo presentan, en promedio, una menor movilidad laboral.

**** age_dependency** (= -2.0660, p = 0.547 \$): Continúa sin ser estadísticamente significativa. La proporción de población dependiente no es un factor determinante directo de la movilidad hacia el trabajo en esta muestra. Si bien el modelo RE es más eficiente y permite estimar coeficientes para variables fijas, su supuesto de no correlación entre los efectos α_i y los regresores es fuerte.

0.5 5. Comente los resultados obtenidos en 2, 3 y 4. ¿Cuáles y por qué existen las diferencias entre los resultados?. En su opinión, ¿Cuál sería el más adecuado para responder la pregunta de investigación y por qué? ¿Qué variables resultaron ser robustas a la especificación?

La siguiente tabla resume los coeficientes estimados para los tres modelos, donde *** denota significancia al 1%, ** al 5%, y * al 10%.

Variable Independiente	(2) Pooled OLS	(3) Efectos Fijos (FE)	(4) Efectos Aleatorios (RE)
Valor_Stringency_Index	0.1009***	-0.0694***	-0.0744***
workplace_closing	1.6034***	1.5700***	1.5753***
residential_percent_change	-1.5144***	-1.5144***	-1.5087***
daily_cases	0.0002***	0.0002***	0.0002***
unemp	-0.1493***	Absorbida	-0.1991***
Population	-0.0011***	Absorbida	-0.0012***
age_dependency	1.0343	Absorbida	-2.0660
Intercepto (const)	-5.3228**	-7.9492***	-3.2044
R-cuadrado	0.7095	0.7019	0.7075

¿Cuáles y por qué existen las diferencias entre los resultados? Las diferencias en los coeficientes se deben a cómo cada modelo maneja la heterogeneidad no observada de las ciudades:

1. **Pooled OLS:** Asume que todas las ciudades son idénticas en el tiempo y no controla por características propias de la ciudad. Esto causa un sesgo de variable omitida, haciendo que el efecto del `Stringency_Index` esté sobreestimado (-0.1009) porque absorbe el efecto de otras variables no medidas de las ciudades.
2. **Efectos Fijos (FE):** Limpia este sesgo eliminando toda la variación promedio de cada ciudad (absorbiendo variables constantes como población o desempleo estructural). Aquí vemos que el efecto real del `Stringency_Index` cae a -0.0694.
3. **Efectos Aleatorios (RE):** Es un punto intermedio. Permite estimar coeficientes para las variables constantes, pero asume que la heterogeneidad de las ciudades no está correlacionada con las medidas gubernamentales (un supuesto muy fuerte). Su estimador para `Stringency_Index` (-0.0744) es un promedio ponderado de la variación dentro y entre las ciudades.

¿Qué variables resultaron ser robustas a la especificación? Una variable es robusta cuando mantiene la dirección de su efecto (signo) y su significancia estadística sin importar el modelo que se use. En este análisis son robustas:

- * **Valor_Stringency_Index:** Siempre reduce la movilidad laboral (signo negativo).
- * **residential_percent_change:** Muestra consistentemente un fuerte efecto sustitución negativo (~ -1.50).
- * **daily_cases** y **workplace_closing:** Mantienen su significancia y signos positivos a lo largo de todos los modelos.

Realizaremos un test de Hausman para decidir de manera estadística si debemos utilizar un modelo de efectos fijos o un modelo de efectos aleatorios.

0.5.1 Test de Hausman (FE vs RE)

Este test evalúa si existe o no una correlación entre el término de error específico a nivel de ciudad (la heterogeneidad no observada α_i) y las variables explicativas incluidas en el modelo (X_{it}). El estadístico de prueba se calcula a partir de las diferencias entre las estimaciones de ambos modelos, ponderadas por la diferencia en sus matrices de varianzas-covarianzas:

$$H = (\hat{\beta}_{FE} - \hat{\beta}_{RE})' [Var(\hat{\beta}_{FE}) - Var(\hat{\beta}_{RE})]^{-1} (\hat{\beta}_{FE} - \hat{\beta}_{RE}) \sim \chi^2(k)$$

Prueba de Hipótesis:

- * **Hipótesis Nula (H_0):** $Cov(\alpha_i, X_{it}) = 0$. No existe correlación entre los efectos individuales y los regresores. Si esto es cierto, ambos estimadores son consistentes, pero el estimador de Efectos Aleatorios (RE) es más eficiente.
- * **Hipótesis Alternativa (H_1):** $Cov(\alpha_i, X_{it}) \neq 0$. Sí existe correlación entre los efectos individuales y los regresores. Si esto es cierto, el estimador de Efectos Aleatorios es sesgado e inconsistente, por lo que se debe preferir estrictamente el modelo de Efectos Fijos (FE).

```
[18]: # Test de Hausman para comparar FE vs RE
# H0: RE es consistente y eficiente (no hay correlación entre u_i y X_it)
# H1: RE es inconsistente, preferir FE

# Obtener coeficientes comunes
common_vars = [v for v in fe_results.params.index if v in re_results.params.
               ↪index and v != 'const']

# Calcular estadístico de Hausman manualmente
b_fe = fe_results.params[common_vars]
```

```

b_re = re_results.params[common_vars]
diff = b_fe - b_re

# Varianza de la diferencia
var_fe = fe_results.cov[common_vars].loc[common_vars]
var_re = re_results.cov[common_vars].loc[common_vars]
var_diff = var_fe - var_re

try:
    hausman_stat = float(diff.T @ np.linalg.inv(var_diff) @ diff)
    hausman_df = len(common_vars)
    hausman_pval = 1 - stats.chi2.cdf(hausman_stat, hausman_df)

    print(f'\nEstadístico de Hausman: {hausman_stat:.4f}')
    print(f'Grados de libertad: {hausman_df}')
    print(f'P-valor: {hausman_pval:.6f}')
except Exception as e:
    print('Error en cálculo de Hausman:', e)

```

Estadístico de Hausman: 114.4780

Grados de libertad: 4

P-valor: 0.000000



Al ejecutar el test sobre nuestros modelos, obtuvimos un p-valor de **0.0000** ($p < 0.05$). Por lo tanto, **rechazamos fuertemente la hipótesis nula** (H_0).

En su opinión, ¿Cuál sería el más adecuado para responder la pregunta de investigación y por qué? El modelo empíricamente y estadísticamente más adecuado es el de **Efectos Fijos (FE)**, lo cual está sólidamente respaldado por dos pruebas estadísticas clave: 1. **Test de Poolability (F-test = 29.17, $p < 0.001$)**: Rechaza categóricamente al Pooled OLS, confirmando que existen efectos propios de cada ciudad (la heterogeneidad existe y debe ser modelada). 2. **Test de Hausman (p-value < 0.05 / $p = 0.000$)**: El test de Hausman rechaza fuertemente la hipótesis nula de exogeneidad del modelo RE. Esto comprueba empíricamente que las características intrínsecas de las ciudades (efectos individuales) **sí están correlacionadas** con las variables explicativas (como las restricciones de movilidad impuestas). Por lo tanto, los estimadores del modelo RE son **inconsistentes** y sesgados, debiendo elegirse de manera formal el modelo de Efectos Fijos.

0.6 6. Ejecute un modelo de efectos aleatorios correlacionados (CRE) para estimar la misma relacion anterior. Seleccione las variables independientes a incluir en el modelo final e interprete su significado. Es este modelo adecuado, dada la data disponible, para modelar el componente no observado?

El modelo CRE relaja el supuesto tan restrictivo de Efectos Aleatorios (RE). En lugar de asumir que no hay correlación entre la heterogeneidad de cada ciudad (α_i) y las restricciones gubernamentales, modela explícitamente esta correlación. Para hacerlo, introduce como variables adicionales las

medias grupales en el tiempo para cada variable explicativa que varía en el tiempo. El modelo se especifica de la siguiente manera:

$$\text{workplaces}_{it} = \beta_0 + \underbrace{\beta_1 X_{it}}_{\text{Efecto Within}} + \underbrace{\gamma \bar{X}_i}_{\text{Efecto Mundlak}} + \underbrace{\delta Z_i}_{\text{Invariantes}} + (u_i + \epsilon_{it})$$

Donde: * X_{it} : Variables que cambian en el tiempo (ej. `Stringency_Index`, `daily_cases`). Sus coeficientes β miden el efecto “Within”, que son consistentes y casi idénticos a los del modelo FE.
 * $\bar{X}_i$: Medias temporales de cada variable X para cada ciudad. Sus coeficientes γ miden el sesgo potencial. Si algún γ es significativamente distinto de cero, confirma que Efectos Aleatorios simples (RE) estaba sesgado.
 * Z_i : Variables constantes en el tiempo (`Population`, `unemp`). El modelo CRE nos permite estimar su efecto, algo que FE no podía hacer.

```
[19]: # Crear las medias grupales (Mundlak means) para las variables time-varying
cre_time_vars = ['Valor_Stringency_Index', 'workplace_closing', 'daily_cases',
                 'residential_percent_change_from_baseline']

# Calcular medias por ciudad
df_cre = df.copy()
for var in cre_time_vars:
    df_cre[f'{var}_mean'] = df_cre.groupby('NAME')[var].transform('mean')

# Preparar datos de panel para CRE
df_cre_panel = df_cre.set_index(['NAME', 'date'])

y_cre = df_cre_panel['workplaces']

# Variables del modelo CRE: originales + medias grupales + controles invariantes
X_cre_vars = cre_time_vars + [f'{v}_mean' for v in cre_time_vars] + ['unemp',
    'Population', 'age_dependency']

X_cre = df_cre_panel[X_cre_vars]
X_cre = sm.add_constant(X_cre)

[20]: # Estimar modelo CRE usando Random Effects con las medias de Mundlak
cre_model = RandomEffects(y_cre, X_cre)
cre_results = cre_model.fit(cov_type='clustered', cluster_entity=True)

print(cre_results)
```

```

RandomEffects Estimation Summary
=====
Dep. Variable:          workplaces    R-squared:                0.7035
Estimator:              RandomEffects  R-squared (Between):      0.8399
No. Observations:      12040          R-squared (Within):       0.7019
Date:                  Mon, May 25 2026  R-squared (Overall):      0.7214
Time:                  17:36:50          Log-likelihood            -3.864e+04
Cov. Estimator:        Clustered
F-statistic:                2593.9

```

Entities:	86	P-value	0.0000
Avg Obs:	140.00	Distribution:	F(11,12028)
Min Obs:	140.00		
Max Obs:	140.00	F-statistic (robust):	843.16
		P-value	0.0000
Time periods:	140	Distribution:	F(11,12028)
Avg Obs:	86.000		
Min Obs:	86.000		
Max Obs:	86.000		

Parameter Estimates					
=====					
=====					
P-value	Lower CI	Upper CI	Parameter	Std. Err.	T-stat

const			2.6288	3.4637	0.7590
0.4479	-4.1605	9.4182			
Valor_Stringency_Index			-0.0694	0.0089	-7.8204
0.0000	-0.0867	-0.0520			
workplace_closing			1.5698	0.2362	6.6466
0.0000	1.1068	2.0327			
daily_cases			0.0002	2.209e-05	10.810
0.0000	0.0002	0.0003			
residential_percent_change_from_baseline			-1.5144	0.0268	-56.570
0.0000	-1.5669	-1.4619			
Valor_Stringency_Index_mean			0.0939	0.1238	0.7588
0.4480	-0.1487	0.3365			
workplace_closing_mean			-4.4320	3.6157	-1.2258
0.2203	-11.519	2.6554			
daily_cases_mean			0.0017	0.0008	1.9803
0.0477	1.68e-05	0.0033			
residential_percent_change_from_baseline_mean			-1.3881	0.3528	-3.9348
0.0001	-2.0796	-0.6966			
unemp			-0.2313	0.0646	-3.5810
0.0003	-0.3579	-0.1047			
Population			-0.0004	0.0002	-2.2104
0.0271	-0.0007	-4.14e-05			
age_dependency			-0.5669	4.1853	-0.1355
0.8923	-8.7708	7.6369			
=====					
=====					

```
[21]: # Interpretación del modelo CRE
params_cre = cre_results.params
pvalues_cre = cre_results.pvalues
```

```

print('=== COEFICIENTES DEL MODELO CRE ===')
print()
print('--- Variables originales (efecto within, comparable a FE) ---')
for var in cre_time_vars:
    if var in params_cre.index:
        sig = '***' if pvalues_cre[var] < 0.01 else '**' if pvalues_cre[var] <
↪0.05 else '*' if pvalues_cre[var] < 0.1 else ''
        print(f' {var:55s} = {params_cre[var]:10.4f} p = {pvalues_cre[var]:.
↪4f} {sig}')

print()
print('--- Medias grupales (Mundlak terms) ---')
print('(Si significativos, indican correlación entre u_i y X → supuesto RE
↪violado)')
mundlak_significant = False
for var in cre_time_vars:
    mean_var = f'{var}_mean'
    if mean_var in params_cre.index:
        sig = '***' if pvalues_cre[mean_var] < 0.01 else '**' if
↪pvalues_cre[mean_var] < 0.05 else '*' if pvalues_cre[mean_var] < 0.1 else ''
        if pvalues_cre[mean_var] < 0.1:
            mundlak_significant = True
        print(f' {mean_var:55s} = {params_cre[mean_var]:10.4f} p =
↪{pvalues_cre[mean_var]:.4f} {sig}')

print()
print('--- Variables invariantes en el tiempo ---')
for var in ['unemp', 'Population', 'age_dependency', 'const']:
    if var in params_cre.index:
        sig = '***' if pvalues_cre[var] < 0.01 else '**' if pvalues_cre[var] <
↪0.05 else '*' if pvalues_cre[var] < 0.1 else ''
        print(f' {var:55s} = {params_cre[var]:10.4f} p = {pvalues_cre[var]:.
↪4f} {sig}')

print(f'\nR2 (overall) = {cre_results.rsquared_overall:.4f}')
print()
print('--- Evaluación del modelo CRE ---')
if mundlak_significant:
    print(' Al menos un término de Mundlak es significativo.')
    print(' Esto confirma que el supuesto de RE es VIOLADO: existe correlación
↪entre u_i y X_it.')
    print(' El modelo CRE corrige este problema al modelar explícitamente
↪dicha correlación.')
    print(' Los coeficientes de las variables originales en CRE son
↪comparables a los de FE.')

```

```

else:
    print('Los términos de Mundlak no son significativos.')
    print(' Esto sugiere que el supuesto de RE es válido y el modelo RE_
    ↪estándar es adecuado.')

print()
print('--- ¿Es adecuado el CRE para modelar el componente no observado? ---')
print('El modelo CRE es adecuado cuando:')
print(' 1. Existe suficiente variación temporal dentro de cada unidad (ciudad).
    ↪')
print(' 2. Se sospecha correlación entre el efecto no observado y las_
    ↪variables explicativas.')
print(' 3. Se desea estimar simultáneamente efectos within y between.')
print('Con datos de panel COVID-19, donde las restricciones varían_
    ↪significativamente en el tiempo')
print('y las ciudades tienen características estructurales que influyen en las_
    ↪respuestas,')
print('el CRE es un enfoque apropiado para modelar el componente no observado.')

```

=== COEFICIENTES DEL MODELO CRE ===

--- Variables originales (efecto within, comparable a FE) ---

Valor_Stringency_Index	=	-0.0694	p =
0.0000 ***			
workplace_closing	=	1.5698	p =
0.0000 ***			
daily_cases	=	0.0002	p =
0.0000 ***			
residential_percent_change_from_baseline	=	-1.5144	p =
0.0000 ***			

--- Medias grupales (Mundlak terms) ---

(Si significativos, indican correlación entre u_i y $X \rightarrow$ supuesto RE violado)

Valor_Stringency_Index_mean	=	0.0939	p =
0.4480			
workplace_closing_mean	=	-4.4320	p =
0.2203			
daily_cases_mean	=	0.0017	p =
0.0477 **			
residential_percent_change_from_baseline_mean	=	-1.3881	p =
0.0001 ***			

--- Variables invariantes en el tiempo ---

unemp	=	-0.2313	p =
0.0003 ***			
Population	=	-0.0004	p =
0.0271 **			

```

age_dependency          =    -0.5669  p =
0.8923
const                   =     2.6288  p =
0.4479

```

R^2 (overall) = 0.7214

--- Evaluación del modelo CRE ---

Al menos un término de Mundlak es significativo.

Esto confirma que el supuesto de RE es VIOLADO: existe correlación entre u_i y X_{it} .

El modelo CRE corrige este problema al modelar explícitamente dicha correlación.

Los coeficientes de las variables originales en CRE son comparables a los de FE.

--- ¿Es adecuado el CRE para modelar el componente no observado? ---

El modelo CRE es adecuado cuando:

1. Existe suficiente variación temporal dentro de cada unidad (ciudad).
2. Se sospecha correlación entre el efecto no observado y las variables explicativas.
3. Se desea estimar simultáneamente efectos within y between.

Con datos de panel COVID-19, donde las restricciones varían significativamente en el tiempo

y las ciudades tienen características estructurales que influyen en las respuestas,

el CRE es un enfoque apropiado para modelar el componente no observado.

0.6.1 Interpretación de Resultados: Modelo CRE

La estimación del modelo CRE nos arroja conclusiones reveladoras divididas en tres componentes:

1. Efectos Within (Variables Originales - Comparables a FE): Los coeficientes de las variables variantes en el tiempo son casi exactos a los que obtuvimos en el modelo de Efectos Fijos, lo cual demuestra que el modelo CRE logró limpiar el sesgo: * **Valor_Stringency_Index** ($\$ = -0.0694$, $p < 0.001$) : * * *Elefectocausalinternosemantiene.Aumentarunpuntoenlarigurosidadgubernamentalreduceen -0.07puntosporcentualeslamovilidadlaboralrespectoalhístricodeesamismaciudad.* * * * **residential_percent_hange**($= -1.5144$, $p < 0.001$ \$): Muestra el mismo fuerte efecto sustitución idéntico al de Efectos Fijos.

2. Términos de Mundlak (Medias Grupales): Esta sección funciona como un **Test de Hausman integrado**: * Vemos que **daily_cases_mean** ($\$ = 0.0017$, $p < 0.05$) y **residential_percent_hange_mean**($= -1.3881$, $p < 0.001$)sonestadísticamente significativas. * * * *Conclusindeesto* : * * *Alersignificativas,seconfirmaempíricamentequelaheterogeneidadnoobservadadelasciudades(u_i)* si está correlacionada con estas variables. Esto rectifica nuestro hallazgo del Test de Hausman: el supuesto de exogeneidad estricta de RE está violado, y el modelo CRE era necesario para modelar correctamente el componente no observado.

3. Efectos Between (Variables Invariantes en el Tiempo): Gracias a usar CRE, podemos ver el efecto transversal puro (comparando entre ciudades) de características estructurales sin sufrir el sesgo de las variables variantes: * **unemp (\$ = -0.2313, p < 0.001)** : * * *Ciudadescon1* * * * *Population*(= -0.0004, p < 0.05 \$): Muestra un efecto negativo ligero pero significativo, apuntando a que ciudades más pobladas tienen menor movilidad relativa hacia los trabajos.

Dado que nuestra data dispone de variables que varían mucho en el tiempo (restricciones COVID) mezcladas con variables estructurales inamovibles (demografía de las ciudades), el modelo CRE es el más adecuado de todos. Provee coeficientes consistentes (libres de sesgo como FE) y al mismo tiempo nos permite entender el impacto de la macroestructura inamovible de la ciudad (como RE).

0.7 7. Usando sus respuestas anteriores, que modelo prefiere? que se puede inferir en general respecto del efecto de las restricciones gubernamentales sobre la movilidad laboral?

Tomando en cuenta toda la evidencia estadística y econométrica de los modelos anteriores, el modelo preferido es el de Efectos Aleatorios Correlacionados, ya que:

1. **Consistencia:** El Test de Hausman y los términos de Mundlak demostraron empíricamente que la heterogeneidad no observada de las ciudades está correlacionada con las restricciones aplicadas. El modelo CRE corrige este sesgo endógeno (al igual que Efectos Fijos), entregando coeficientes consistentes y confiables para las variables que cambian en el tiempo.
2. **Amplitud Analítica:** A diferencia de Efectos Fijos, CRE nos permite mantener en el análisis variables estructurales fundamentales invariantes en el tiempo (como la población o el desempleo estructural). Es decir, nos entrega estimadores insesgados “Within” (intratemporales) sin sacrificar el análisis “Between” (transversal).

¿Qué se puede inferir en general respecto del efecto de las restricciones gubernamentales sobre la movilidad laboral? A partir del análisis unificado de todas las regresiones, podemos establecer las siguientes inferencias robustas:

1. **Efectividad Real de las Políticas:** Las restricciones gubernamentales (medidas a través del *Valor_Stringency_Index*) tienen un efecto negativo, estadísticamente significativo y robusto sobre la movilidad laboral. Con independencia de la especificación econométrica utilizada, un endurecimiento de las políticas públicas frena directamente el desplazamiento de los ciudadanos hacia sus lugares de trabajo.
2. **El Miedo vs. La Ley:** El coeficiente de los casos diarios (*daily_cases*), aunque es estadísticamente significativo debido al tamaño muestral, tiene una magnitud económica casi nula (0.0002). Esto infiere que la movilidad laboral no se redujo de manera orgánica o voluntaria simplemente porque la población viera subir los contagios (“el miedo al virus”), sino que la caída fuerte en la movilidad fue forzada y canalizada mediante las restricciones formales y mandatos del gobierno.
3. **Efecto Sustitución Fuerte:** La política restrictiva tiene éxito porque genera un cambio de hábito demostrable: por cada 1% que la población decide (o es obligada a) quedarse en zonas residenciales, la movilidad laboral cae en casi 1.5%. El “quedarse en casa” reemplaza casi perfectamente la salida al trabajo, apuntando al impacto masivo que tuvo la adopción del teletrabajo forzado.

4. **Impacto Estructural:** La heterogeneidad importa. Las restricciones gubernamentales pegaron más fuerte o generaron mayores caídas relativas en ciudades con mayor desempleo basal y mayor población. Esto infiere que el impacto de la política pública no es simétrico, sino que el tamaño de la urbe y su mercado laboral previo definen qué tan profundo cae la movilidad cuando el gobierno “apaga” la economía.

0.8 **8. Control Sintetico:** Es posible que sus resultados anteriores tengan sesgo dado que la movilidad laboral y las restricciones son parte de un fenómeno dinámico en el tiempo. Utilice el notebook SynthControl.ipynb para estimar el efecto causal de las restricciones gubernamentales y la movilidad para una ciudad de su elección, usando control sintético (viendo las fechas semanales, deben elegir el periodo de tratamiento e identificar los controles potenciales para la ciudad elegida, que no puede ser Zaragoza). Defina las variables para calcular el control sintético y discuta sus resultados (instalar librería pyncon)

Utilizamos el método de **Control Sintético** para estimar el efecto causal de las restricciones gubernamentales sobre la movilidad laboral para una ciudad específica.

Ciudad tratada: Barcelona.

El método construye un “contrafactual” combinando ponderadamente otras ciudades que no recibieron el mismo nivel de restricciones, para aproximar cómo habría sido la movilidad en la ciudad tratada sin las restricciones. En esta sección usaremos tres enfoques diferentes: PenalizedSynth, Synth clásico y AugSynth.

```
[22]: import matplotlib.pyplot as plt
      from pyncon import Dataprep, Synth, AugSynth, PenalizedSynth
```

```
[23]: # Ciudad tratada y ciudades de control
      treated_city = 'Barcelona'
      all_cities = df['NAME'].unique().tolist()
      control_cities = [c for c in all_cities if c != treated_city and c !=
        ↪ 'Zaragoza']

      # Asegurar que no haya NaN en TODAS las variables predictoras que usó el
        ↪ profesor
      synth_vars = [
        'workplaces', 'Population', 'agriculture', 'industry', 'construction',
        'age_dependency', 'old_age_dependency', 'young_age_dependency',
        'sex_ratio', 'unemp', 'f_unemp', 'daily_cases'
      ]
      df_synth_clean = df.dropna(subset=synth_vars)
      print(f'Ciudades de control potenciales: {len(control_cities)}')
```

Ciudades de control potenciales: 84

```
[24]: treatment_week = 127

# Configurar Dataprep para pysyncon
dataprep = Dataprep(
    foo=df_synth_clean,
    predictors=[
        "Population",
        "agriculture",
        "industry",
        "construction",
        "age_dependency",
        "old_age_dependency",
        "young_age_dependency",
        "sex_ratio",
        "unemp",
        "f_unemp",
    ],
    predictors_op="mean",
    time_predictors_prior=range(40, treatment_week),
    special_predictors=[
        ("daily_cases", range(40, treatment_week), "mean"),
    ],
    dependent="workplaces",
    unit_variable="NAME",
    time_variable="week",
    treatment_identifier=treated_city,
    controls_identifier=control_cities,
    time_optimize_ssr=range(40, treatment_week),
)
```

0.9 Método 1: Penalized Synthetic Control

El método de Control Sintético Penalizado introduce una penalización tipo *Ridge* (L2) a los pesos asignados a las ciudades donantes. A diferencia del método clásico, que a veces sobreajusta la predicción dándole demasiado peso a unas pocas ciudades extremas, este método encoge los pesos para estabilizarlos. Es ideal para evitar el sobreajuste (overfitting) en el periodo pre-tratamiento cuando tenemos muchas ciudades de control.

```
[ ]: pen = PenalizedSynth()
pen.fit(dataprep, lambda_=0.001)

print("\nPesos de las ciudades:")
print(pen.weights())

# Gráficos y resumen
print('\nGRÁFICO: Penalized Synth - Movilidad Barcelona vs Sintética')
pen.path_plot(time_period=range(40, 140), treatment_time=treatment_week)
```

```
pen.summary()
```

Pesos de las ciudades:


Berlin	0.382
Stuttgart	0.000
Freiburg im Breisgau	0.000
Karlsruhe	0.000
Mannheim	0.000

...

Palermo	0.000
Catania	0.000
Messina	0.000
Stockholm	0.092
Malmö	0.000

Name: weights, Length: 84, dtype: float64

GRÁFICO: Penalized Synth - Movilidad Barcelona vs Sintética



[]:	treated	synthetic	sample mean
Population	3722.424	3627.391	710.150
agriculture	0.001	0.002	0.007
industry	0.076	0.079	0.116
construction	0.056	0.055	0.053
age_dependency	0.634	0.636	0.654
old_age_dependency	0.314	0.318	0.321
young_age_dependency	0.320	0.320	0.334
sex_ratio	107.033	106.768	106.678
unemp	15.000	14.670	12.143

f_unemp	0.142	0.143	0.113
special.1.daily_cases	3441.426	3504.099	3683.725

Interpretación de graficos

1. Periodo Pre-Tratamiento (Antes de la línea azul vertical):

- La línea continua representa la movilidad real en Barcelona, mientras que la línea punteada es la Barcelona Sintética (nuestro contrafactual construido a partir de otras ciudades).
- Podemos observar que el modelo sintético logra capturar la tendencia general de la movilidad y los grandes “shocks” o caídas (como las observadas cerca de las semanas 45, 80 y 100).
- Sin embargo, el ajuste no es perfecto. Existen brechas visibles a lo largo de todo el periodo previo (por ejemplo, entre las semanas 50-60 y 70-85), lo que indica que la penalización *Ridge* estabiliza los pesos, pero sacrifica un poco de precisión en el emparejamiento exacto de la serie de tiempo.

2. Periodo Post-Tratamiento (Después de la línea azul vertical):

- La línea azul vertical marca el inicio de la intervención (restricciones).
- Inmediatamente después de la intervención, vemos una caída abrupta en la movilidad real de Barcelona (línea continua cayendo casi hasta -40). En contraste, la Barcelona Sintética (línea punteada) también muestra una caída, pero mucho menos profunda (rondando el -29).
- **Conclusión del efecto causal:** Esta divergencia clara, donde la curva real se sitúa considerablemente por debajo de la curva sintética, sugiere que las restricciones gubernamentales tuvieron un efecto causal negativo y significativo, reduciendo la movilidad laboral en Barcelona mucho más allá de lo que habría caído naturalmente sin la intervención.

0.9.1 Método 2: Control Sintético Clásico

Este es el enfoque original de Control Sintético. Busca crear una “Barcelona artificial” asignando pesos (mayores o iguales a 0, y que sumen 1) a una combinación de otras ciudades donantes. Optimiza estos pesos para que las características y la trayectoria histórica de movilidad de esta ciudad artificial coincidan lo más posible con la Barcelona real en el periodo previo a las restricciones.

```
[26]: synth = Synth()
      synth.fit(dataprep=dataprep, optim_method="Nelder-Mead", optim_initial="ols")

      print("\nPesos de las ciudades:")
      print(synth.weights())

      # Gráficos y resumen
      print('\nGRÁFICO: Synth Clásico - Movilidad Barcelona vs Sintética')
      synth.path_plot(time_period=range(40, 140), treatment_time=treatment_week)

      print('\nGRÁFICO: Synth Clásico - Brecha de Movilidad (Efecto del Tratamiento)')
      synth.gaps_plot(time_period=range(40, 140), treatment_time=treatment_week)
      synth.summary()
```

Pesos de las ciudades:

Berlin	0.202
Stuttgart	0.000
Freiburg im Breisgau	0.000
Karlsruhe	0.002
Mannheim	0.000

...

Palermo	0.000
Catania	0.000
Messina	0.000
Stockholm	0.044
Malmö	0.009

Name: weights, Length: 84, dtype: float64

GRÁFICO: Synth Clásico - Movilidad Barcelona vs Sintética





GRÁFICO: Synth Clásico - Brecha de Movilidad (Efecto del Tratamiento)



[26]:

	V	treated	synthetic	sample mean
Population	0.001	3722.424	3508.102	710.150
agriculture	0.000	0.001	0.005	0.007
industry	0.000	0.076	0.094	0.116
construction	0.000	0.056	0.056	0.053
age_dependency	0.444	0.634	0.633	0.654
old_age_dependency	0.228	0.314	0.314	0.321
young_age_dependency	0.318	0.320	0.320	0.334
sex_ratio	0.000	107.033	107.137	106.678
unemp	0.003	15.000	14.791	12.143
f_unemp	0.004	0.142	0.143	0.113
special.1.daily_cases	0.001	3441.426	3634.631	3683.725

Interpretación de los Gráficos: 1. **Gráfico de Trayectoria (Movilidad Barcelona vs Sintética):** * **Periodo Pre-Tratamiento:** Observamos que la línea punteada (Sintética) sigue la forma general de la línea continua (Barcelona real), pero el ajuste no es perfecto. De hecho, hay fallas notables: por ejemplo, alrededor de la semana 80, la movilidad real de Barcelona se desploma hasta casi -45%, pero la Barcelona Sintética solo logra bajar hasta -35%. Esto indica un “sesgo pre-tratamiento” porque ninguna combinación convexa de las otras ciudades logró replicar una caída tan extrema. * **Periodo Post-Tratamiento:** Después de la línea azul vertical, Barcelona sufre una fuerte caída (llegando a -40% cerca de la semana 132). La ciudad sintética también cae, pero se queda mucho más arriba (cerca de -30%). La separación entre ambas curvas evidencia el impacto restrictivo de las políticas gubernamentales. 2. **Gráfico de Brecha de Movilidad (Gaps Plot):** * Este gráfico aísla el error o “brecha” (Real - Sintético). Idealmente, antes de la línea azul, esta curva debería ser una línea plana pegada al cero. Sin embargo, vemos que oscila fuertemente entre +7.5 y -10 (justamente en el error de la semana 80), confirmando el ruido y el sesgo de emparejamiento previo. * **Efecto Causal:** A pesar del ruido previo, al observar el periodo post-tratamiento, la brecha se desploma drásticamente hasta alcanzar casi un -10%. Esto significa que, atribuible exclusivamente a las restricciones, la movilidad en Barcelona fue hasta 10 puntos

porcentuales menor de lo que habría sido en un escenario normal.

0.9.2 Método 3: Augmented Synthetic Control (AugSynth)

El AugSynth (Control Sintético Aumentado) combina el método clásico con un modelo de regresión tipo Ridge. Si el método clásico deja un “sesgo” o error en el periodo previo al tratamiento (como vimos en el Método 2 alrededor de la semana 80), AugSynth usa la regresión para limpiar esa diferencia matemática, forzando un emparejamiento casi perfecto.

```
[27]: augsynth = AugSynth()
augsynth.fit(dataprep=dataprep)

print("\nPesos de las ciudades:")
print(augsynth.weights())

# Gráficos y resumen
print('\nGRÁFICO: AugSynth - Movilidad Barcelona vs Sintética')
augsynth.path_plot(time_period=range(40, 140), treatment_time=treatment_week)

augsynth.cv_result.plot()

augsynth.summary()
```

Pesos de las ciudades:



Berlin	-0.085
Stuttgart	-0.011
Freiburg im Breisgau	-0.096
Karlsruhe	0.026
Mannheim	-0.063

...

Palermo	0.044
Catania	0.030
Messina	-0.015
Stockholm	0.426
Malmö	-0.323

Name: weights, Length: 84, dtype: float64

GRÁFICO: AugSynth - Movilidad Barcelona vs Sintética



[27]:

	treated	synthetic	sample mean
Population	3722.424	3722.212	710.150
agriculture	0.001	0.001	0.007
industry	0.076	0.076	0.116
construction	0.056	0.056	0.053
age_dependency	0.634	0.634	0.654
old_age_dependency	0.314	0.314	0.321
young_age_dependency	0.320	0.319	0.334

sex_ratio	107.033	107.033	106.678
unemp	15.000	14.999	12.143
f_unemp	0.142	0.142	0.113
special.1.daily_cases	3441.426	3442.613	3683.725

Interpretación de los Gráficos:

1. Gráfico de Trayectoria (Movilidad Barcelona vs Sintética):

- Al mirar el gráfico, la línea sólida (Barcelona real) y la línea punteada (Sintética) **se superponen perfectamente en todo momento**, tanto antes como después de la intervención.
- **Pre-Tratamiento:** El ajuste es perfecto. Ya no existe el error de la semana 80 que teníamos en el método clásico.
- **Post-Tratamiento (Efecto Causal):** Al continuar superpuestas de manera exacta tras la intervención, el modelo nos diría falsamente que “las restricciones no tuvieron efecto” (la brecha es cero).
- **Conclusión Crítica:** Lo que realmente estamos viendo es un claro caso de **Sobreajuste (Overfitting)**. Al tener un λ óptimo cercano a cero (como nos mostró la validación cruzada), el componente de regresión del AugSynth fue tan agresivo que simplemente “memorizó” a Barcelona usando las demás ciudades, destruyendo la validez del contrafactual en el periodo post-tratamiento.

2. Gráfico de Validación Cruzada (Cross-Validation Result):

- Este gráfico es clave para entender qué pasó. Muestra el error de predicción en el eje Y para distintos niveles de penalización λ (Lambda) en el eje X.
- Podemos observar que la curva es estrictamente ascendente: **el menor error se encuentra en el extremo izquierdo**, donde λ es prácticamente cero (10^{-1} o menor).
- Al elegir un λ tan pequeño, el modelo de regresión casi no tiene penalización, comportándose como un Mínimos Cuadrados Ordinarios (OLS) tradicional que simplemente memoriza los datos.

Conclusión Final sobre Control Sintético: Considerando el sobreajuste masivo de AugSynth (Método 3) y el sesgo pre-tratamiento del Synth Clásico (Método 2), **el método de Penalized Synth (Método 1) resulta ser el más robusto y confiable** para este caso. Logra estabilizar los pesos, evita el overfitting extremo del AugSynth y nos permite observar de forma fidedigna la caída causal de la movilidad en Barcelona debido a las restricciones gubernamentales.