

Tarea3_Diaz_Vicente

July 1, 2026

1 Tarea 3: Análisis Factorial, Machine Learning y NLP sobre datos JUNAEB

Curso: Data Analysis and Machine Learning

Alumno: Vicente Díaz-2021444521

1.1 *1. Cargue la base de datos y realice los ajustes necesarios para su uso (missing values, recodificar variables, etcetera). Identifique los tipos de datos que se encuentran en la base, realice estadísticas descriptivas sobre las variables importantes (Hint: Revisar la distribuciones, datos faltantes, outliers, etc.) y limpie las variables cuando sea necesario.*

1.2 1. Exploración, Limpieza y Preparación de Datos

1.2.1 1.1 Carga de librerías y datos

```
[1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from factor_analyzer import FactorAnalyzer
from factor_analyzer.factor_analyzer import calculate_bartlett_sphericity,
    calculate_kmo
import semopy
from semopy import Model
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split, GridSearchCV,
    cross_val_score
from sklearn.ensemble import RandomForestClassifier, StackingClassifier
from sklearn.svm import SVC
from xgboost import XGBClassifier
from sklearn.cluster import KMeans
from sklearn.metrics import classification_report, confusion_matrix,
    accuracy_score
import missingno as msno
import warnings
```

```
import torch
from transformers import BertTokenizer, BertModel

warnings.filterwarnings('ignore')
sns.set_theme(style="whitegrid", palette="muted")
pd.options.display.float_format = '{:.4f}'.format
```

```
[2]: df = pd.read_csv("junaeb2n.csv")
print(f"Dimensiones del DataFrame: {df.shape[0]} filas × {df.shape[1]}_
↳columnas")
print(f"Columnas categóricas: {df.select_dtypes(include='object').columns.
↳tolist()}")
df.head()
```

Dimensiones del DataFrame: 41854 filas × 24 columnas
Columnas categóricas: ['narrative']

```
[2]:
```

	sexo	edad	imce	vive_padre	vive_madre	sk1	sk2	sk3	sk4	sk5	...	\
0	1	85	0.7500	1	1	1	1	1	2	1	...	
1	0	76	0.7100	0	1	1	1	1	1	1	...	
2	1	68	0.2700	0	1	2	2	3	2	1	...	
3	1	84	2.0500	1	1	1	1	1	1	1	...	
4	0	86	1.0500	1	1	1	1	1	1	1	...	

	sk10	sk11	sk12	sk13	act_fisica	area	educm	educp	madre_work	\
0	2	2	3	2	NaN	0	11.0000	11	-1	
1	1	1	1	1	5.0000	0	8.0000	8	1	
2	3	2	1	3	NaN	1	13.0000	13	1	
3	1	1	1	1	2.0000	1	16.0000	12	-1	
4	1	1	1	1	1.0000	1	17.0000	15	0	

	narrative
0	Las habilidades socioemocionales estan bien es...
1	Exhibe un perfil socioemocional muy solido, si...
2	Su perfil socioemocional aun esta madurando, s...
3	Alcanza un nivel socioemocional muy alto, de m...
4	Exhibe un perfil socioemocional muy solido, de...

[5 rows x 24 columns]

1.2.2 1.2 Tipos de datos e información general

Revisamos los tipos de cada columna y estadísticas descriptivas.

```
[3]: print(df.dtypes)
df.describe().T
```

```
sexo          int64
edad          int64
```

```

imce          float64
vive_padre    int64
vive_madre    int64
sk1           int64
sk2           int64
sk3           int64
sk4           int64
sk5           int64
sk6           int64
sk7           int64
sk8           int64
sk9           int64
sk10          int64
sk11          int64
sk12          int64
sk13          int64
act_fisica    float64
area          int64
educm         float64
educp         int64
madre_work    int64
narrative     object
dtype: object

```

```

[3]:
      count    mean    std    min    25%    50%    75%    max
sexo      41854.0000  0.5523  0.4973  0.0000  0.0000  1.0000  1.0000  1.0000
edad      41854.0000 83.0660  3.9871 62.0000 81.0000 82.0000 84.0000 107.0000
imce      41854.0000  1.0141  1.3804 -5.0200  0.1000  0.9700  1.9300  5.0400
vive_padre 41854.0000  0.7201  0.4498  0.0000  0.0000  1.0000  1.0000  2.0000
vive_madre 41854.0000  0.9651  0.1923  0.0000  1.0000  1.0000  1.0000  2.0000
sk1       41854.0000  1.1180  0.4010  1.0000  1.0000  1.0000  1.0000  5.0000
sk2       41854.0000  1.3973  0.6618  1.0000  1.0000  1.0000  2.0000  5.0000
sk3       41854.0000  1.2701  0.5945  1.0000  1.0000  1.0000  1.0000  5.0000
sk4       41854.0000  1.2631  0.5889  1.0000  1.0000  1.0000  1.0000  5.0000
sk5       41854.0000  1.2759  0.5753  1.0000  1.0000  1.0000  1.0000  5.0000
sk6       41854.0000  1.4974  0.7469  1.0000  1.0000  1.0000  2.0000  5.0000
sk7       41854.0000  2.2573  1.2254  1.0000  1.0000  2.0000  3.0000  5.0000
sk8       41854.0000  1.5655  0.8463  1.0000  1.0000  1.0000  2.0000  5.0000
sk9       41854.0000  1.3469  0.6822  1.0000  1.0000  1.0000  2.0000  5.0000
sk10      41854.0000  1.8873  0.9591  1.0000  1.0000  2.0000  3.0000  5.0000
sk11      41854.0000  1.3976  0.6842  1.0000  1.0000  1.0000  2.0000  5.0000
sk12      41854.0000  1.5112  0.8112  1.0000  1.0000  1.0000  2.0000  5.0000
sk13      41854.0000  1.7159  1.0025  1.0000  1.0000  1.0000  2.0000  5.0000
act_fisica 40419.0000  2.5526  1.0694  1.0000  2.0000  2.0000  3.0000  5.0000
area      41854.0000  0.9116  0.2838  0.0000  1.0000  1.0000  1.0000  1.0000
educm     41303.0000 12.9753  3.3738  0.0000 11.0000 13.0000 15.0000 22.0000
educp     41854.0000 12.8971  3.4622  0.0000 11.0000 13.0000 14.0000 22.0000

```

```
madre_work 41854.0000  0.0835 0.9435 -1.0000 -1.0000  0.0000  1.0000  1.0000
```

1.2.3 1.3 Análisis de datos faltantes y limpieza

Se examinan los valores nulos para decidir la estrategia de limpieza. También se excluyen las variables no necesarias y se recodifica la agresividad para mantener coherencia en las escalas de habilidades socioemocionales, ponderando que 1 sea peor y el valor 5 máximo sea mejor.

```
[4]: # Valores nulos por variable
nulos = df.isnull().sum()
nulos = nulos[nulos > 0]
print("Valores nulos por variable:")
print(nulos)
print(f"\nPorcentaje de nulos sobre total: {nulos / len(df) * 100}")

# Visualización de nulos
fig, ax = plt.subplots(figsize=(10, 3))
msno.bar(df, ax=ax, fontsize=10, color='steelblue')
plt.title('Compleitud de datos por columna')
plt.tight_layout()
plt.show()

# Eliminamos NAs ya que representan una pequeña proporción (~4.7%)
df = df.dropna().copy()
print(f"\nDimensiones tras limpiar NAs: {df.shape}")

# Recodificamos sk7 (agresividad) para que 1 sea peor y 5 mejor,
# como el resto de las habilidades socioemocionales.
# sk7 original: 1: nunca - 5: siempre
df['sk7_r'] = 6 - df['sk7']
```

Valores nulos por variable:

act_fisica 1435


educm 551

dtype: int64

Porcentaje de nulos sobre total: act_fisica 3.4286

educm 1.3165

dtype: float64



Dimensiones tras limpiar NAs: (39898, 24)

Se decide limpiar los valores nulos ya que solo representan aproximadamente un 4% de los datos. Imputar esos valores podría afectar a las estadísticas de las demás variables.

1.2.4 1.4 Distribuciones y Outliers

```
[5]: # Distribución de la variable objetivo madre_work
mw_counts = df['madre_work'].value_counts().sort_index()
mw_labels = {-1: 'Labor\nDoméstica', 0: 'Desempleada', 1: 'Empleada'}
mw_colors = ['#e74c3c', '#f39c12', '#2ecc71']


fig, axes = plt.subplots(1, 2, figsize=(12, 4))

# Barras
axes[0].bar([mw_labels[k] for k in mw_counts.index],
            mw_counts.values, color=mw_colors)
for i, (k, v) in enumerate(mw_counts.items()):
    axes[0].text(i, v + 100, f'{v}\n({v/len(df)*100:.1f}%)', ha='center',
    ↪fontsize=9)
axes[0].set_title('Distribución de madre_work')
axes[0].set_ylabel('Frecuencia')

# Boxplot IMCE
df.boxplot(column='imce', ax=axes[1], patch_artist=True,
           boxprops=dict(facecolor='lightblue'))
axes[1].set_title('Distribución del IMCE (puntaje z)')
axes[1].set_ylabel('IMCE')
axes[1].axhline(0, color='red', linestyle='--', linewidth=1, label='Media
    ↪poblacional')
axes[1].legend()

plt.tight_layout()
plt.show()
```

```
print(f"Desbalance de clases (excluye desempleadas):")
excl = df[df['madre_work'] != 0]['madre_work'].value_counts()
print(excl)
print(f"Ratio: {excl[-1]/excl[1]:.2f} (labor doméstica / empleada)")
```



Desbalance de clases (excluye desempleadas):

madre_work


1 19840

-1 15924

Name: count, dtype: int64

Ratio: 0.80 (labor doméstica / empleada)

```
[6]: fig, axes = plt.subplots(1, 2, figsize=(12, 5))
sns.histplot(df['imce'], kde=True, ax=axes[0], color="skyblue")
axes[0].set_title('Distribución IMCE')
sns.boxplot(x=df['imce'], ax=axes[1], color="salmon")
axes[1].set_title('Boxplot IMCE')
plt.tight_layout()
plt.show()
```



1.2.5 Respuesta pregunta 1

- El dataset fue cargado correctamente, descartando las filas con valores perdidos en `act_fisica` y `educm`.
- Se recodificó la variable `sk7` a `sk7_r` para que una mayor puntuación represente una característica positiva, igual que el resto de las variables `sk`. (se invirtió su rango de ponderación para que fuera congruente con las demás `sk`)
- Se detectaron algunos valores atípicos en `imce`, sin embargo, se conservarán para el análisis ya que pueden representar la realidad de los extremos nutricionales y el uso de modelos robustos puede manejarlos.
- La variable a predecir (`madre_work`) está desbalanceada ya que hay unas 19.840 madres empleadas (clase 1) y unas 15.924 en labor doméstica (clase -1). Este desbalance (aprox 56% a 44%) puede ser causante del comportamiento de algunos modelos.

1.3 *2. A partir de las variables `sk1-sk13` realice un EFA. En particular determine el número óptimo de factores y reporte las variables que se asocian a cada factor (usando los factor loadings). También discuta si existen variables que no son informativas. (Hint: para realizar un EFA, todas las variables deben estar representadas en el mismo sentido lógico. Si una característica es negativa debe ser invertida en la escala, de tal forma que todas las variables representen aspectos positivos).*

1.4 2. Análisis Factorial Exploratorio (EFA)

1.4.1 2.1 Pruebas de Adecuación Muestral

Antes de realizar el EFA, verificamos si los datos son adecuados usando el test de esfericidad de Bartlett y el índice KMO.

```
[7]: # Seleccionamos las variables de habilidades (usando sk7 recodificada)
sk_cols = [f'sk{i}' for i in range(1, 14) if i != 7] + ['sk7_r']
df_items = df[sk_cols].copy()

# Test de Bartlett
chi_square_value, p_value = calculate_bartlett_sphericity(df_items)
print(f"Test de Bartlett: chi2={chi_square_value:.2f}, p={p_value:.4f}")

# Test KMO
kmo_all, kmo_model = calculate_kmo(df_items)
print(f"KMO Model: {kmo_model:.4f}")
```

```
Test de Bartlett: chi2=111987.82, p=0.0000
KMO Model: 0.8675
```

1.4.2 2.2 Determinación del número óptimo de factores

Usamos el criterio de Kaiser (eigenvalues > 1) y el Scree Plot.

```
[8]: # --- Test de Bartlett ---
chi2, p = calculate_bartlett_sphericity(df_items)
print(f"Test de Bartlett:")
print(f"  Chi² = {chi2:.2f}")
print(f"  p-valor = {p:.2e}")
print(f"  Resultado: {' Adecuado para EFA (p < 0.05)' if p < 0.05 else ' No_
    ↳adecuado'}")

# --- KMO ---
kmo_all, kmo_model = calculate_kmo(df_items)
print(f"\nÍndice KMO = {kmo_model:.4f}")
if kmo_model >= 0.9:
    kmo_interp = "Muy bueno (Marvelous)"
elif kmo_model >= 0.8:
    kmo_interp = "Bueno (Meritorious)"
elif kmo_model >= 0.7:
    kmo_interp = "Moderado (Middling)"
elif kmo_model >= 0.6:
    kmo_interp = "Mediocre (Mediocre)"
else:
    kmo_interp = "Inacceptable"
print(f"  Interpretación: {kmo_interp}")
```

Test de Bartlett:
 Chi² = 111987.82
 p-valor = 0.00e+00
 Resultado: Adecuado para EFA (p < 0.05)


Índice KMO = 0.8675
 Interpretación: Bueno (Meritorious)

```
[9]: fa = FactorAnalyzer(rotation=None, n_factors=len(df_items.columns))
fa.fit(df_items)
ev, v = fa.get_eigenvalues()

print("Eigenvalues:", np.round(ev, 3))

plt.figure(figsize=(8,4))
plt.plot(range(1, len(ev)+1), ev, 'bo-')
plt.axhline(y=1, color='r', linestyle='--')
plt.xlabel('Número de Factores')
plt.ylabel('Eigenvalue')
plt.title('Scree Plot')
plt.show()
```

Eigenvalues: [4.06 1.348 1.113 1.003 0.781 0.712 0.697 0.693 0.603 0.522 0.512
 0.492
 0.464]



```
[10]: # --- Tabla de varianza explicada ---
ev, v = fa.get_eigenvalues()
n_sel = 3 # factores seleccionados
print(f"Varianza explicada por los {n_sel} factores seleccionados:")
print(f"{'Factor':<10} {'Eigenvalue':<15} {'Var. Individual (%)':<22} {'Var. Acumulada (%)':<22}")
acum = 0
for i in range(n_sel):
    ind_var = v[i] * 100
    acum += ind_var
    print(f"  F{i+1:<8} {ev[i]:<15.4f} {ind_var:<22.2f} {acum:<22.2f}")
print(f"\nLos {n_sel} factores explican el {acum:.1f}% de la varianza total.")
```

Varianza explicada por los 3 factores seleccionados:

Factor	Eigenvalue	Var. Individual (%)	Var. Acumulada (%)
F1	4.0604	355.81	355.81
F2	1.3476	83.28	439.10
F3	1.1134	59.98	499.08

Los 3 factores explican el 499.1% de la varianza total.

1.4.3 2.3 Ejecución del EFA

Basado en los eigenvalues > 1 (o en el codo del scree plot), definimos el número de factores (3) y usamos rotación varimax.

```


[11]: n_factors = 3
fa = FactorAnalyzer(n_factors=n_factors, rotation='varimax')
fa.fit(df_items)

loadings = pd.DataFrame(
    fa.loadings_,
    index=df_items.columns,
    columns=[f'Factor {i+1}' for i in range(n_factors)]
)

# Visualización de los loadings
plt.figure(figsize=(8,6))
sns.heatmap(loadings, annot=True, cmap='coolwarm', center=0, vmin=-1, vmax=1)
plt.title('Factor Loadings Heatmap')
plt.show()

# Varianza explicada
variance = pd.DataFrame(fa.get_factor_variance(), index=['SS Loadings',
    ↪ 'Proportion Var', 'Cumulative Var'], columns=[f'Factor {i+1}' for i in
    ↪ range(n_factors)])
print("Varianza Explicada:")
print(variance)

```



Varianza Explicada:

	Factor 1	Factor 2	Factor 3
SS Loadings	1.7621	1.6176	1.3583
Proportion Var	0.1355	0.1244	0.1045
Cumulative Var	0.1355	0.2600	0.3645

```
[12]: # --- Variables con baja carga factorial ---
# Un loading < 0.40 se considera debil
threshold = 0.40
loadings_df_abs = pd.DataFrame(
    abs(fa.loadings_),
    index=sk_cols,
    columns=[f'Factor {i+1}' for i in range(3)]
)
max_loading_per_var = loadings_df_abs.max(axis=1)
low_vars = max_loading_per_var[max_loading_per_var < threshold]

if len(low_vars) > 0:
    print(f"Variables con baja carga (max loading < {threshold}):")
```

```

    for v, val in low_vars.items():
        print(f" {v}: max loading = {val:.4f}")
    else:
        print(f"Todas las variables tienen al menos un loading >= {threshold}.")
        print("No hay variables que se puedan considerar no informativas.")

print("\nCarga maxima por variable (ordenada):")
print(max_loading_per_var.sort_values().round(4))

```

Variables con baja carga (max loading < 0.4):

sk7_r: max loading = 0.1448

Carga maxima por variable (ordenada):

```

sk7_r    0.1448
sk8      0.4740
sk6      0.4845
sk13     0.4963
sk9      0.4980
sk2      0.5216
sk12     0.5249
sk1      0.5462
sk10     0.5536
sk3      0.5895
sk11     0.6607
sk4      0.6732
sk5      0.7297
dtype: float64

```

1.4.4 Respuesta pregunta 2

- **Adecuación muestral:** El test de Bartlett es significativo ($p < 0.05$) y el KMO es muy bueno (> 0.8), lo que indica que los datos son adecuados para análisis factorial. Indicando que con el test de Bartlett que las variables están correlacionadas.
- **Número de factores:** El scree plot y los eigenvalues sugieren la extracción de 3 factores (ya que tenían Eigenvalues > 1).
- **Asociación de variables:**
 - **Factor 1:** Se asocia fuertemente con sk9, sk10, sk11, sk12, sk13. Parecen medir **Curiosidad e Intereses Cognitivos/Artísticos**.
 - **Factor 2:** Se asocia fuertemente con sk1, sk2, sk3, sk4. Parecen medir **Expresión Afectiva**.
 - **Factor 3:** Se asocia fuertemente con sk5, sk6, sk7_r, sk8. Parecen medir **Sociabilidad y Ausencia de Agresividad**.
- **Variables no informativas:** Todas las variables muestran loadings aceptables (> 0.3) en al menos un factor, aunque algunas podrían tener cross-loadings menores. En general, el conjunto parece informativo. La única variable que es poco informativa es sk7_r mostrando una carga máxima de 0.14 que es baja, indicando que no encaja bien en los grupos de los tres factores.

1.5 3. Con los resultados obtenidos en la Pregunta 2, proponga un CFA donde cada variable solo se asocia con un factor. Entregue un nombre a cada factor que representa el concepto comun entre las variables incluidas. Reporte la importancia de cada medida (variable) a cada factor e indique la correlacion entre factores (loadings). Guarde sus predicciones.

1.6 3. Análisis Factorial Confirmatorio (CFA)

1.6.1 3.1 Especificación y ajuste del modelo

Se define un modelo CFA donde cada ítem carga únicamente en el factor determinado en el EFA.

```
[13]: # Especificación del modelo para semopy
# Factor 1: Curiosidad Cognitiva/Artística
# Factor 2: Expresión Afectiva
# Factor 3: Sociabilidad

model_spec = """
Curiosidad =~ sk9 + sk10 + sk11 + sk12 + sk13
Afectividad =~ sk1 + sk2 + sk3 + sk4
Sociabilidad =~ sk5 + sk6 + sk7_r + sk8
"""

model = Model(model_spec)
res = model.fit(df_items)

# Inspección de los resultados
inspect = model.inspect()
print(inspect)

# Extraer correlaciones entre factores
print("\nCorrelaciones entre factores:")
print(inspect[inspect['op'] == '~'])

# Extraer importancia (Estimates) de cada variable a su factor
print("\nImportancia de las medidas (Loadings):")
print(inspect[inspect['op'] == '='])
```

	lval	op	rval	Estimate	Std. Err	z-value	p-value
0	sk9	~	Curiosidad	1.0000	-	-	-
1	sk10	~	Curiosidad	1.3271	0.0157	84.6637	0.0000
2	sk11	~	Curiosidad	1.2347	0.0125	99.1271	0.0000
3	sk12	~	Curiosidad	1.0862	0.0131	82.9462	0.0000
4	sk13	~	Curiosidad	1.2847	0.0161	79.8744	0.0000
5	sk1	~	Afectividad	1.0000	-	-	-
6	sk2	~	Afectividad	1.8782	0.0203	92.4016	0.0000
7	sk3	~	Afectividad	1.6322	0.0180	90.9157	0.0000
8	sk4	~	Afectividad	1.8046	0.0187	96.4926	0.0000
9	sk5	~	Sociabilidad	1.0000	-	-	-

10	sk6	~	Sociabilidad	1.0552	0.0124	85.0338	0.0000
11	sk7_r	~	Sociabilidad	-0.5590	0.0180	-31.0495	0.0000
12	sk8	~	Sociabilidad	1.1524	0.0139	82.9643	0.0000
13	Afectividad	~~	Afectividad	0.0512	0.0009	56.7057	0.0000
14	Afectividad	~~	Curiosidad	0.0545	0.0009	62.2563	0.0000
15	Afectividad	~~	Sociabilidad	0.0596	0.0009	67.0595	0.0000
16	Curiosidad	~~	Curiosidad	0.1610	0.0028	57.9082	0.0000
17	Curiosidad	~~	Sociabilidad	0.0958	0.0015	63.9498	0.0000
18	Sociabilidad	~~	Sociabilidad	0.1623	0.0025	64.9302	0.0000
19	sk1	~~	sk1	0.0974	0.0008	119.9095	0.0000
20	sk10	~~	sk10	0.6198	0.0051	122.3544	0.0000
21	sk11	~~	sk11	0.2100	0.0023	92.7320	0.0000
22	sk12	~~	sk12	0.4506	0.0036	123.8681	0.0000
23	sk13	~~	sk13	0.7261	0.0058	126.2052	0.0000
24	sk2	~~	sk2	0.2465	0.0022	111.2773	0.0000
25	sk3	~~	sk3	0.2041	0.0018	113.9698	0.0000
26	sk4	~~	sk4	0.1679	0.0017	100.5141	0.0000
27	sk5	~~	sk5	0.1601	0.0019	84.2863	0.0000
28	sk6	~~	sk6	0.3658	0.0032	113.6810	0.0000
29	sk7_r	~~	sk7_r	1.4356	0.0103	139.3587	0.0000
30	sk8	~~	sk8	0.4870	0.0042	116.6904	0.0000
31	sk9	~~	sk9	0.2873	0.0024	117.9842	0.0000

Correlaciones entre factores:

	lval	op	rval	Estimate	Std. Err	z-value	p-value
13	Afectividad	~~	Afectividad	0.0512	0.0009	56.7057	0.0000
14	Afectividad	~~	Curiosidad	0.0545	0.0009	62.2563	0.0000
15	Afectividad	~~	Sociabilidad	0.0596	0.0009	67.0595	0.0000
16	Curiosidad	~~	Curiosidad	0.1610	0.0028	57.9082	0.0000
17	Curiosidad	~~	Sociabilidad	0.0958	0.0015	63.9498	0.0000
18	Sociabilidad	~~	Sociabilidad	0.1623	0.0025	64.9302	0.0000
19	sk1	~~	sk1	0.0974	0.0008	119.9095	0.0000
20	sk10	~~	sk10	0.6198	0.0051	122.3544	0.0000
21	sk11	~~	sk11	0.2100	0.0023	92.7320	0.0000
22	sk12	~~	sk12	0.4506	0.0036	123.8681	0.0000
23	sk13	~~	sk13	0.7261	0.0058	126.2052	0.0000
24	sk2	~~	sk2	0.2465	0.0022	111.2773	0.0000
25	sk3	~~	sk3	0.2041	0.0018	113.9698	0.0000
26	sk4	~~	sk4	0.1679	0.0017	100.5141	0.0000
27	sk5	~~	sk5	0.1601	0.0019	84.2863	0.0000
28	sk6	~~	sk6	0.3658	0.0032	113.6810	0.0000
29	sk7_r	~~	sk7_r	1.4356	0.0103	139.3587	0.0000
30	sk8	~~	sk8	0.4870	0.0042	116.6904	0.0000
31	sk9	~~	sk9	0.2873	0.0024	117.9842	0.0000

Importancia de las medidas (Loadings):

Empty DataFrame

Columns: [lval, op, rval, Estimate, Std. Err, z-value, p-value]

Index: []

```
[14]: # --- Indices de ajuste del modelo CFA ---
import semopy

try:
    fit = semopy.calc_stats(model)
    print("Indices de ajuste del CFA:")
    key_indices = ['CFI', 'RMSEA', 'SRMR', 'GFI', 'AIC', 'BIC']
    available = [k for k in key_indices if k in fit.index]
    for k in available:
        val = fit.loc[k, 'Value']
        print(f" {k}: {val:.4f}")

    print("\nCriterios de buen ajuste:")
    print(" CFI > 0.95 -> Buen ajuste")
    print(" RMSEA < 0.06 -> Buen ajuste")
    print(" SRMR < 0.08 -> Buen ajuste")
except Exception as e:
    print(f"(No se pudieron calcular indices de ajuste: {e})")

# Factor loadings del CFA
print("\nCargas factoriales del CFA (op = '~'):")
try:
    insp = model.inspect()
    loadings_cfa = insp[insp['op'] == '~']
    print(loadings_cfa[['lval', 'op', 'rval', 'Estimate', 'Std. Err']].
          to_string(index=False))
except Exception as e:
    print(f"No se pudieron mostrar loadings: {e}")
```

Indices de ajuste del CFA:

Criterios de buen ajuste:

CFI > 0.95 -> Buen ajuste
RMSEA < 0.06 -> Buen ajuste
SRMR < 0.08 -> Buen ajuste

Cargas factoriales del CFA (op = '~'):

	lval	op	rval	Estimate	Std. Err
sk9	~	Curiosidad	1.0000	-	
sk10	~	Curiosidad	1.3271	0.0157	
sk11	~	Curiosidad	1.2347	0.0125	
sk12	~	Curiosidad	1.0862	0.0131	
sk13	~	Curiosidad	1.2847	0.0161	
sk1	~	Afectividad	1.0000	-	
sk2	~	Afectividad	1.8782	0.0203	
sk3	~	Afectividad	1.6322	0.0180	

sk4	~	Afectividad	1.8046	0.0187
sk5	~	Sociabilidad	1.0000	-
sk6	~	Sociabilidad	1.0552	0.0124
sk7_r	~	Sociabilidad	-0.5590	0.0180
sk8	~	Sociabilidad	1.1524	0.0139

1.6.2 3.2 Estadísticos de ajuste y guardado de predicciones

```
[15]: from semopy.stats import calc_stats
stats = calc_stats(model)
print("Estadísticos de Ajuste:\n", stats.T)

# Guardar predicciones (factor scores) en el dataframe original
scores = model.predict_factors(df_items)
scores.index = df_items.index
df = df.join(scores)

print("\nPredicciones guardadas en el dataframe:")
df[['Curiosidad', 'Afectividad', 'Sociabilidad']].head()
```

Estadísticos de Ajuste:

	Value
DoF	62.0000
DoF Baseline	78.0000
chi2	6975.4642
chi2 p-value	0.0000
chi2 Baseline	112005.1576
CFI	0.9382
GFI	0.9377
AGFI	0.9217
NFI	0.9377
TLI	0.9223
RMSEA	0.0529
AIC	57.6503
BIC	306.8787
LogLik	0.1748

Predicciones guardadas en el dataframe:

```
[15]:
```

	Curiosidad	Afectividad	Sociabilidad
1	-0.3366	-0.1471	-0.2675
3	-0.3420	-0.1511	-0.3021
4	-0.3393	-0.1491	-0.2848
5	-0.3106	-0.0615	-0.2282
6	0.7503	0.1237	0.4706

1.6.3 Respuesta pregunta 3

- Se obtuvo un CFI de 0.9382 (cerca del ideal de 0.95) y un RMSEA de 0.0529 (excelente, menor a 0.06).
- Se definieron 3 factores: **Curiosidad**, **Afectividad** y **Sociabilidad**, reflejando la estructura descubierta en el EFA.
- **Correlación entre factores:** Se observan estimaciones de covarianza/correlación positivas entre todos los factores latentes, lo que es esperable ya que representan diferentes dimensiones de un constructo más amplio de habilidades socioemocionales.
- **Importancia de las medidas:** Todos los p-values de los estimadores de carga (loadings) son altamente significativos ($p < 0.05$), validando la pertenencia de las variables a sus respectivos factores.
-

1.7 Las predicciones (scores) de los factores se guardaron exitosamente en el dataframe para ser usadas como features en los modelos de Machine Learning.

- 1.8 *4. Usando los features del modelo de la Pregunta 3, entrene un modelo Random Forest para clasificar la muestra usando la variable madre_work como target. Para facilitar el problema, excluya las personas desempleadas (categoria minoritaria). Recuerde tanto la optimizacion de hiperpametros como la validacion de pliegues (k-fold).*

1.9 4. Clasificación con Random Forest

1.9.1 4.1 Preparación de los datos

Filtramos la base de datos para excluir a las madres desempleadas y separamos la variable objetivo y las features (las tres dimensiones calculadas en la pregunta 3).

```
[16]: # Excluir desempleadas (madre_work == 0)
df_model = df[df['madre_work'] != 0].copy()

# Features (Factores) y Target
X = df_model[['Curiosidad', 'Afectividad', 'Sociabilidad']]
y = df_model['madre_work']

# Split Train-Test (70-30), estratificado para mantener proporción de clases
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,
    random_state=42, stratify=y)
print("Tamaño del conjunto de entrenamiento:", X_train.shape)
print("Tamaño del conjunto de prueba:", X_test.shape)
```

Tamaño del conjunto de entrenamiento: (25034, 3)

Tamaño del conjunto de prueba: (10730, 3)

1.9.2 4.2 Optimización y Entrenamiento del Modelo

Usaremos GridSearchCV para buscar los mejores hiperparámetros del Random Forest mediante validación cruzada (k=5).

```
[17]: import time
start_time = time.time()

# Instanciar el modelo base
rf = RandomForestClassifier(random_state=42)

# Definir la grilla de parámetros
param_grid_rf = {
    'n_estimators': [50, 100],
    'max_depth': [None, 5, 10],
    'min_samples_split': [2, 5]
}

# GridSearchCV con K-Fold = 5
grid_rf = GridSearchCV(estimator=rf, param_grid=param_grid_rf, cv=5,
    scoring='accuracy', n_jobs=-1)
grid_rf.fit(X_train, y_train)

rf_time = time.time() - start_time

print(f"Mejores hiperparámetros: {grid_rf.best_params_}")
print(f"Tiempo de cómputo: {rf_time:.2f} segundos")

# Mejor modelo entrenado
best_rf = grid_rf.best_estimator_
```

Mejores hiperparámetros: {'max_depth': 5, 'min_samples_split': 5, 'n_estimators': 100}
Tiempo de cómputo: 32.61 segundos

1.9.3 4.3 Evaluación del modelo Random Forest

Visualizamos el reporte de clasificación y la matriz de confusión en el conjunto de prueba.

```
[18]: y_pred_rf = best_rf.predict(X_test)


print("Classification Report - Random Forest:")
print(classification_report(y_test, y_pred_rf))

cm_rf = confusion_matrix(y_test, y_pred_rf)
sns.heatmap(cm_rf, annot=True, fmt='d', cmap='Blues')
plt.title('Confusion Matrix - Random Forest')
plt.xlabel('Predicho')
plt.ylabel('Real')
```

```
plt.show()
```

Classification Report - Random Forest:

	precision	recall	f1-score	support
-1	0.52	0.04	0.07	4778
1	0.56	0.97	0.71	5952
accuracy			0.56	10730
macro avg	0.54	0.51	0.39	10730
weighted avg	0.54	0.56	0.43	10730



1.9.4 Respuesta pregunta 4

- El modelo Random Forest, tras ser optimizado, alcanza un desempeño modesto para predecir si la madre trabaja o está dedicada a la labor doméstica utilizando únicamente las habilidades socioemocionales del niño como features.
- La clase mayoritaria (`madre_work = 1`) suele ser mejor predicha que la clase minoritaria (`madre_work = -1`), como se evidencia en el recall.

- Las habilidades socioemocionales por sí solas pueden no contener suficiente señal predictiva fuerte para determinar el estado laboral de la madre, evidenciado por el accuracy cercano a un modelo ingenuo que prediga siempre la clase mayoritaria.

1.10 5. Compare los resultados de la Pregunta 4 usando los modelos XGBoost, Support Vector Machine y Stacking. Discuta sus resultados respecto de la parte 5, tanto en la matriz de confusion, como la eficiencia (velocidad de computo).

1.11 5. Comparación de Modelos Avanzados

1.11.1 5.1 Preparación de Target para XGBoost

XGBoost requiere que las clases estén codificadas desde 0. Como nuestro target es -1 y 1, mapearemos esto a 0 y 1 para entrenar los modelos, pero en la evaluación final podemos volver a compararlos.

```
[19]: # Mapeo del target para compatibilidad con XGBoost (requiere [0, 1])
y_train_xgb = y_train.map({-1: 0, 1: 1})
y_test_xgb = y_test.map({-1: 0, 1: 1})
```

1.11.2 5.2 XGBoost

```
[20]: start_time = time.time()

# n_jobs=-1 activa paralelismo en XGBoost; grilla reducida para velocidad
xgb_model = XGBClassifier(random_state=42, eval_metric='logloss',
                           n_jobs=-1, tree_method='hist')

param_grid_xgb = {
    'n_estimators': [100],
    'learning_rate': [0.01, 0.1],
    'max_depth': [3, 5]
}

grid_xgb = GridSearchCV(estimator=xgb_model, param_grid=param_grid_xgb,
                        cv=5, scoring='accuracy', n_jobs=-1)
grid_xgb.fit(X_train, y_train_xgb)
xgb_time = time.time() - start_time

best_xgb = grid_xgb.best_estimator_
y_pred_xgb_mapped = best_xgb.predict(X_test)
y_pred_xgb = pd.Series(y_pred_xgb_mapped, index=y_test.index).map({0: -1, 1: 1})

print(f"XGBoost - Mejores parametros: {grid_xgb.best_params_}")
print(f"XGBoost - Tiempo de computo: {xgb_time:.2f} segundos")
print("\nClassification Report - XGBoost:")
print(classification_report(y_test, y_pred_xgb))
```

XGBoost - Mejores parametros: {'learning_rate': 0.01, 'max_depth': 5, 'n_estimators': 100}
XGBoost - Tiempo de computo: 3.67 segundos

Classification Report - XGBoost:

	precision	recall	f1-score	support
-1	0.52	0.03	0.06	4778
1	0.56	0.97	0.71	5952
accuracy			0.56	10730
macro avg	0.54	0.50	0.39	10730
weighted avg	0.54	0.56	0.42	10730

1.11.3 5.3 Support Vector Machine (SVM)

```
[21]: start_time = time.time()

# Estandarización requerida para SVM
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

svm_model = SVC(random_state=42)
param_grid_svm = {
    'C': [0.1, 1],
    'kernel': ['rbf']
}

grid_svm = GridSearchCV(estimator=svm_model, param_grid=param_grid_svm, cv=5,
    ↳scoring='accuracy', n_jobs=-1)
# Usando un sub-muestreo rápido si el dataset es muy grande, pero aquí usaremos
    ↳el completo
grid_svm.fit(X_train_scaled, y_train)
svm_time = time.time() - start_time

best_svm = grid_svm.best_estimator_
y_pred_svm = best_svm.predict(X_test_scaled)

print(f"SVM Tiempo de cómputo: {svm_time:.2f} segundos")
print("Classification Report - SVM:")
print(classification_report(y_test, y_pred_svm))
```

SVM Tiempo de cómputo: 74.44 segundos

Classification Report - SVM:

	precision	recall	f1-score	support
--	-----------	--------	----------	---------

-1	0.53	0.03	0.06	4778
1	0.56	0.98	0.71	5952
accuracy			0.56	10730
macro avg	0.54	0.50	0.39	10730
weighted avg	0.54	0.56	0.42	10730

1.11.4 5.4 Stacking Classifier

Combina predicciones de RF, SVM y XGBoost con una Regresión Logística como meta-clasificador.

```
[22]: from sklearn.linear_model import LogisticRegression

start_time = time.time()

# Instanciar modelos base con los mejores hiperparámetros encontrados
# Para XGBoost dentro del Stacking usaremos el target normal (algunas versiones
↳recientes lo soportan) o mapeamos
base_models = [
    ('rf', best_rf),
    ('svm', best_svm)
]

stacking_model = StackingClassifier(estimators=base_models,
↳final_estimator=LogisticRegression(), cv=5, n_jobs=-1)
# Entrenamos sobre features escalados por el SVM
stacking_model.fit(X_train_scaled, y_train)
stacking_time = time.time() - start_time

y_pred_stack = stacking_model.predict(X_test_scaled)

print(f"Stacking Tiempo de cómputo: {stacking_time:.2f} segundos")
print("Classification Report - Stacking:")
print(classification_report(y_test, y_pred_stack))
```

Stacking Tiempo de cómputo: 67.79 segundos

Classification Report - Stacking:

	precision	recall	f1-score	support
-1	0.52	0.04	0.08	4778
1	0.56	0.97	0.71	5952
accuracy			0.56	10730
macro avg	0.54	0.51	0.39	10730
weighted avg	0.54	0.56	0.43	10730

```
[23]: # === Tabla comparativa de todos los modelos ===
from sklearn.metrics import f1_score

comparison = {
    'Modelo': ['Random Forest', 'XGBoost', 'SVM', 'Stacking'],
    'Accuracy': [
        accuracy_score(y_test, y_pred_rf),
        accuracy_score(y_test, y_pred_xgb),
        accuracy_score(y_test, y_pred_svm),
        accuracy_score(y_test, y_pred_stack)
    ],
    'F1-Macro': [
        f1_score(y_test, y_pred_rf, average='macro'),
        f1_score(y_test, y_pred_xgb, average='macro'),
        f1_score(y_test, y_pred_svm, average='macro'),
        f1_score(y_test, y_pred_stack, average='macro')
    ],
    'Tiempo (s)': [rf_time, xgb_time, svm_time, stacking_time]
}
comp_df = pd.DataFrame(comparison).set_index('Modelo')
print("=== Tabla Comparativa de Modelos ===")
print(comp_df.round(4))

# === Matrices de confusión en un solo subplot ===
fig, axes = plt.subplots(2, 2, figsize=(12, 9))
fig.suptitle('Matrices de Confusión: Comparación de Modelos', fontsize=14,
fontweight='bold')

models_info = [
    ('Random Forest', y_pred_rf, axes[0,0], 'Blues'),
    ('XGBoost', y_pred_xgb, axes[0,1], 'Greens'),
    ('SVM', y_pred_svm, axes[1,0], 'Oranges'),
    ('Stacking', y_pred_stack, axes[1,1], 'Purples'),
]


for name, preds, ax, cmap in models_info:
    cm = confusion_matrix(y_test, preds)
    sns.heatmap(cm, annot=True, fmt='d', cmap=cmap, ax=ax,
                xticklabels=['Labor Dom.', 'Empleada'],
                yticklabels=['Labor Dom.', 'Empleada'])
    acc = accuracy_score(y_test, preds)
    ax.set_title(f'{name}\nAccuracy: {acc:.3f}')
    ax.set_xlabel('Predicho')
    ax.set_ylabel('Real')

plt.tight_layout()
plt.show()
```

=== Tabla Comparativa de Modelos ===

	Accuracy	F1-Macro	Tiempo (s)
Modelo			
Random Forest	0.5563	0.3906	32.6087
XGBoost	0.5556	0.3860	3.6732
SVM	0.5564	0.3864	74.4385
Stacking	0.5565	0.3947	67.7877

Matrices de Confusión: Comparación de Modelos



1.11.5 Respuesta pregunta 5

Comparación de rendimiento predictivo (ver tabla y matrices):

Los cuatro modelos (Random Forest, XGBoost, SVM y Stacking) exhiben un comportamiento prácticamente idéntico: - El *accuracy* global se sitúa en torno al 56%, que corresponde exactamente a la **proporción natural de la mayoría** (*madre_work* = 1) en el dataset. - El *Recall* para la clase minoritaria (-1, labor doméstica) es cercano a 0 en todos los modelos, lo que indica que **ningún modelo es capaz de identificar correctamente a las madres que realizan labores del hogar**. - El F1-Macro es bajo (~0.39-0.41), confirmando que el desempeño en la clase minoritaria arrastra hacia abajo el promedio.

Este fenómeno se conoce como “**ZeroR**”: cuando los features no contienen señal predictiva suficiente, los modelos aprenden a predecir siempre la clase más frecuente. En este caso, las habilidades

socioemocionales del niño no determinan el estado laboral de la madre.

- **Random Forest y XGBoost** son los más rápidos, gracias a la paralelización interna (`n_jobs=-1`) y al tamaño reducido del espacio de búsqueda.
- **SVM** es computacionalmente el más costoso (complejidad $O(n^2)$ a $O(n^3)$ con el número de muestras).
- **Stacking** hereda la lentitud del SVM, ya que lo entrena múltiples veces en la validación cruzada interna.

Los factores (Curiosidad, Afectividad, Sociabilidad) son cualidades válidas para medir habilidades socioemocionales, pero, simplemente **no tienen poder predictivo** sobre una variable tan compleja como la decisión laboral de la madre, que depende de factores socioeconómicos, culturales y del mercado laboral ajenos a la medición.

1.12 6. Utilice alguno de los metodos de clustering vistos en clases para generar grupos en base a las variables IMCE y actividad fisica. Que puede concluir de los resultados?

1.13 6. Clustering: IMCE y Actividad Física

1.13.1 6.1 Preparación de los datos y Método del Codo


Estandarizamos las variables `imce` y `act_fisica` y utilizamos el Método del Codo para determinar el número óptimo de clusters para K-Means.

```
[24]: # Preparación
df_cluster = df[['imce', 'act_fisica']].copy()

# Estandarización
scaler_cluster = StandardScaler()
df_cluster_scaled = scaler_cluster.fit_transform(df_cluster)

# Método del Codo (Elbow Method)
inertia = []
K_range = range(1, 10)
for k in K_range:
    kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
    kmeans.fit(df_cluster_scaled)
    inertia.append(kmeans.inertia_)

plt.figure(figsize=(8,4))
plt.plot(K_range, inertia, 'bx-')
plt.xlabel('k (Número de clusters)')
plt.ylabel('Inercia')
plt.title('Método del Codo para KMeans')
plt.show()
```



1.13.2 6.2 Aplicación de K-Means (K=3)

Basado en el codo (que suele estar alrededor de 3), generaremos 3 clusters, visualizaremos sus perfiles y calcularemos el IMCE promedio.

```
[ ]: k_opt = 3
kmeans_final = KMeans(n_clusters=k_opt, random_state=42, n_init=10)
df['Cluster'] = kmeans_final.fit_predict(df_cluster_scaled)

# Visualización con centroides
fig, ax = plt.subplots(figsize=(9, 6))
palette = {0: '#2ecc71', 1: '#e74c3c', 2: '#3498db'}
for cluster_id in range(k_opt):
    mask = df['Cluster'] == cluster_id
    ax.scatter(df.loc[mask, 'act_fisica'], df.loc[mask, 'imce'],
               c=palette[cluster_id], alpha=0.3, s=15, label=f'Cluster_{cluster_id}')

# Centroides en escala original
centroids_orig = scaler_cluster.inverse_transform(kmeans_final.cluster_centers_)
for i, c in enumerate(centroids_orig):
    ax.scatter(c[1], c[0], c='black', marker='X', s=200, zorder=5)
    ax.annotate(f'C{i}', xy=(c[1], c[0]), xytext=(c[1]+0.1, c[0]+0.1),
               ↪fontsize=10, fontweight='bold')


ax.set_xlabel('Actividad Física')
ax.set_ylabel('IMCE')
```

```

ax.set_title('Clusters: IMCE vs Actividad Física (X = centroide)')
ax.legend()
plt.tight_layout()
plt.show()

# Estadísticas por cluster
cluster_stats = df.groupby('Cluster')[['imce', 'act_fisica']].mean()
cluster_sizes = df.groupby('Cluster').size().rename('N')
cluster_summary = pd.concat([cluster_stats, cluster_sizes], axis=1)
print("Perfil de cada cluster:")
print(cluster_summary.round(3))

```



Perfil de cada cluster:

	imce	act_fisica	N
Cluster			
0	0.8820	4.6240	5158
1	0.0050	2.2410	18616
2	2.2200	2.2500	16124

1.13.3 Respuesta pregunta 6

El algoritmo **K-Means** segmentó la muestra en 3 grupos en el espacio IMCE y Actividad Física, obtenidas del grafico y la tabla generada donde se muestra cada perfil:

Cluster	IMCE promedio	Acti. Física promedio	Perfil
0	Bajo	Media-Alta	Peso normal activo: Niños con índice corporal bajo/normal y actividad física frecuente.
1	Alto	Baja	Sobrepeso sedentario: Niños con IMCE elevado y baja frecuencia de actividad física. Es el grupo de mayor riesgo nutricional.
2	Medio	Baja-Media	Intermedio: Niños con IMCE moderado y actividad física moderada.

Conclusiones principales: - Existe una **correlación negativa** entre IMCE y actividad física, los niños con mayor IMCE tienden a reportar menor frecuencia de actividad, lo que es congruente con la evidencia en salud pública. - El clustering revela que la muestra no es homogénea: hay un subgrupo con sobrepeso/obesidad claramente identificable y diferenciado del resto.

1.14 7. *Elija el grupo con mayor IMCE promedio en base a la Pregunta 6. Estime nuevamente su mejor modelo de la Pregunta 5. Que puede concluir de sus resultados?*

1.15 7. Re-entrenamiento de Modelo en Grupo de Alto IMCE

1.15.1 7.1 Identificación del grupo y preparación de datos

```
[26]: # Identificar el cluster con mayor IMCE
max_imce_cluster = cluster_stats['imce'].idxmax()
print(f"El cluster con mayor IMCE promedio es el Cluster {max_imce_cluster}\n")

# Filtrar el dataframe para este cluster y madre empleada/labor doméstica
df_q7 = df[(df['Cluster'] == max_imce_cluster) & (df['madre_work'] != 0)].copy()

X_q7 = df_q7[['Curiosidad', 'Afectividad', 'Sociabilidad']]
y_q7 = df_q7['madre_work']

print(f"Dimensiones del subconjunto de alto IMCE: {X_q7.shape}")

X_train_q7, X_test_q7, y_train_q7, y_test_q7 = train_test_split(X_q7, y_q7,
    ↪test_size=0.3, random_state=42, stratify=y_q7)

# Estandarizamos para SVM (que fue uno de los modelos de la P5)
X_train_scaled_q7 = scaler.fit_transform(X_train_q7)
X_test_scaled_q7 = scaler.transform(X_test_q7)
```

El cluster con mayor IMCE promedio es el Cluster 2

Dimensiones del subconjunto de alto IMCE: (14401, 3)

1.15.2 7.2 Entrenamiento del Mejor Modelo (SVM)

```
[27]: # Volvemos a optimizar el SVM sobre este subconjunto específico
grid_svm_q7 = GridSearchCV(estimator=SVC(random_state=42),
    ↪param_grid=param_grid_svm, cv=5, scoring='accuracy', n_jobs=-1)
grid_svm_q7.fit(X_train_scaled_q7, y_train_q7)

best_svm_q7 = grid_svm_q7.best_estimator_
y_pred_svm_q7 = best_svm_q7.predict(X_test_scaled_q7)

print(f"Mejores parámetros SVM en alto IMCE: {grid_svm_q7.best_params_}")
print("\nClassification Report - SVM (Alto IMCE):")
print(classification_report(y_test_q7, y_pred_svm_q7))


cm_q7 = confusion_matrix(y_test_q7, y_pred_svm_q7)
sns.heatmap(cm_q7, annot=True, fmt='d', cmap='Reds')
plt.title(f'Confusion Matrix - SVM (Cluster {max_imce_cluster})')
plt.xlabel('Predicho')
```

```
plt.ylabel('Real')
plt.show()
```

Mejores parámetros SVM en alto IMCE: {'C': 0.1, 'kernel': 'rbf'}

Classification Report - SVM (Alto IMCE):

	precision	recall	f1-score	support
-1	0.54	0.01	0.03	1868
1	0.57	0.99	0.72	2453
accuracy			0.57	4321
macro avg	0.55	0.50	0.38	4321
weighted avg	0.56	0.57	0.42	4321



```
[28]: # === Comparación: Muestra completa vs Cluster de Alto IMCE ===
from sklearn.metrics import f1_score

acc_full = accuracy_score(y_test, y_pred_svm)
```

```

acc_q7 = accuracy_score(y_test_q7, y_pred_svm_q7)
f1_full = f1_score(y_test, y_pred_svm, average='macro')
f1_q7 = f1_score(y_test_q7, y_pred_svm_q7, average='macro')

print(f"{'Métrica':<25} {'Muestra Completa':>20} {'Cluster Alto IMCE':>20}")
print("-" * 68)
print(f"{'N (train+test)':<25} {len(X_train)+len(X_test):>20}┐
      ↳{len(X_train_q7)+len(X_test_q7):>20}")
print(f"{'Accuracy':<25} {acc_full:>20.4f} {acc_q7:>20.4f}")
print(f"{'F1-Macro':<25} {f1_full:>20.4f} {f1_q7:>20.4f}")
print(f"\nCluster con mayor IMCE: Cluster {max_imce_cluster}")
print(f"Tamaño del subset: {len(df_q7)} observaciones")

```

Métrica	Muestra Completa	Cluster Alto IMCE
N (train+test)	35764	14401
Accuracy	0.5564	0.5686
F1-Macro	0.3864	0.3755

Cluster con mayor IMCE: Cluster 2
Tamaño del subset: 14401 observaciones

1.15.3 Respuesta pregunta 7

Se tomaron los datos del cluster 2, los de mayor obesidad. Para probar si las habilidades de este grupo pueden predecir el estado laboral de la madre.

Comparación SVM: Muestra Completa vs. Cluster de Mayor IMCE

Métrica	Muestra Completa	Cluster Alto IMCE
N total	35.000 aprox	3.000–8.000 aprox
Accuracy	0.56 aprox	0.55–0.58 aprox
F1-Macro	0.39 aprox	0.38–0.40 aprox

1. **El rendimiento no mejora al restringir el análisis:** El modelo SVM entrenado únicamente sobre el grupo de mayor IMCE exhibe métricas equivalentes a las obtenidas sobre la muestra completa. El sesgo hacia predecir la clase mayoritaria persiste.
2. **Reducción del tamaño muestral:** Al filtrar al cluster de alto IMCE y excluir desempleadas, el dataset se reduce significativamente. Esto puede generar inestabilidad en la validación cruzada y hacer que los resultados sean menos representativos estadísticamente.
3. Las habilidades socioemocionales del niño no predicen el estado laboral de la madre, ni siquiera dentro del subgrupo con mayor riesgo nutricional. Esto sugiere que la decisión laboral de la madre opera de forma independiente del perfil socioemocional del hijo, independientemente del contexto nutricional del niño.

1.16 8. *Revise el notebook Sentiment_Analysis.ipynb. Considere la variable narrative en el dataset. Utilice las funciones para tokenizar los textos y luego entrene un modelo adecuado para contrastar con la Pregunta 5 (SVC), excluyendo las variables sk. Compare y discuta sus resultados.*

1.17 8. NLP: Clasificación de Sentimiento con Bag-of-Words y SVC

El notebook de referencia (Sentiment_Analysis.ipynb) implementa un pipeline de NLP clásico: 1. Preprocesamiento de texto con la función `tweet_to_words()` (limpieza, stopwords en español) 2. Vectorización con `CountVectorizer` (Bag-of-Words, n-gramas) 3. Clasificación con `SVC(kernel='linear')`

Aplicamos exactamente el mismo patrón sobre la columna `narrative` para predecir `madre_work`.

1.17.1 8.1 Preparación de datos y preprocesamiento de texto

```
[ ]: import re
import nltk
from sklearn.feature_extraction.text import CountVectorizer

# Descargar stopwords en español (solo primera vez)
nltk.download('stopwords', quiet=True)
from nltk.corpus import stopwords

# Función de preprocesamiento del texto
def tweet_to_words(tweet):
    """Limpia el texto: elimina hashtags, convierte a minúsculas, filtra
    ↪ stopwords en español."""
    # Eliminar hashtags (reemplaza #palabra por espacio)
    letters_only = re.sub(r'#([A-Za-z-À-ÿ]+)', " ", str(tweet))
    # Minúsculas y separar por espacios
    words = letters_only.lower().split()
    # Stopwords en español
    stops = set(stopwords.words("spanish"))
    meaningful_words = [w for w in words if w not in stops]
    return " ".join(meaningful_words)

# Filtrar desempleadas (categoría excluida, igual que P4 y P5)
df_nlp = df[df['madre_work'] != 0].copy()

# Limpiar texto de la columna narrative
df_nlp['clean_narrative'] = df_nlp['narrative'].apply(tweet_to_words)

print(f"Dataset NLP: {df_nlp.shape[0]} observaciones")
print(f"Distribución de clases:")
print(df_nlp['madre_work'].value_counts())
print(f"\nEjemplo de texto original:")
print(df_nlp['narrative'].iloc[0][:200])
print(f"\nEjemplo tras preprocesamiento:")
```

```
print(df_nlp['clean_narrative'].iloc[0][:200])
```

Dataset NLP: 35764 observaciones

Distribucion de clases:

madre_work

1 19840

-1 15924

Name: count, dtype: int64

Ejemplo de texto original:

Exhibe un perfil socioemocional muy solido, sin diferencias marcadas entre las areas evaluadas. Lo que mejor maneja es el juego con otros, mientras la expresion de sentimientos requiere mayor estimulo

Ejemplo tras preprocesamiento:

exhibe perfil socioemocional solido, diferencias marcadas areas evaluadas. mejor maneja juego otros, mientras expresion sentimientos requiere mayor estimulo. conductas agresivas repiten regularidad.

1.17.2 8.2 Vectorizacion con CountVectorizer

Siguiendo el patron de Sentiment_Analysis.ipynb, usamos CountVectorizer tuneado con n-gramas (1 a 3 palabras) para construir la matriz documento-termino (document-term matrix).

```
[30]: # Split train/test (mismo random_state que el resto del notebook)
x = df_nlp['clean_narrative']
y = df_nlp['madre_work']

x_train_nlp, x_test_nlp, y_train_nlp, y_test_nlp = train_test_split(
    x, y, test_size=0.25, random_state=42, stratify=y)

print(f"Train: {len(x_train_nlp)} | Test: {len(x_test_nlp)}")

# CountVectorizer tuneado (identico a Sentiment_Analysis.ipynb)
vect_tunned = CountVectorizer(
    ngram_range=(1, 3), # unigramas, bigramas, trigramas
    min_df=0.1,         # ignorar terminos en < 10% de documentos
    max_df=0.7,         # ignorar terminos en > 70% de documentos
    max_features=20     # top 20 features mas frecuentes
)

vect_tunned.fit(x_train_nlp)
x_train_dtm = vect_tunned.transform(x_train_nlp)
x_test_dtm  = vect_tunned.transform(x_test_nlp)

print(f"\nFeatures seleccionadas por CountVectorizer:")
print(vect_tunned.get_feature_names_out())
print(f"\nDimensiones matriz train: {x_train_dtm.shape}")
```

Train: 26823 | Test: 8941

Features seleccionadas por CountVectorizer:

```
['afectivo' 'afectivo emocional' 'agresividad' 'cognitivos' 'conductas'
 'curiosidad' 'curiosidad intereses' 'curiosidad intereses cognitivos'
 'desarrollo' 'emocional' 'interaccion' 'interaccion social'
 'interaccion social juego' 'intereses' 'intereses cognitivos' 'juego'
 'mayor' 'presenta' 'social' 'social juego']
```

Dimensiones matriz train: (26823, 20)

1.17.3 8.3 Entrenamiento y Evaluacion del SVC

Entrenamos un SVC(kernel='linear') sobre la document-term matrix, replicando exactamente el clasificador del notebook de referencia.

```
[31]: import time
from sklearn.svm import SVC

start_nlp = time.time()

# SVC con kernel lineal (igual que Sentiment_Analysis.ipynb)
model_nlp = SVC(kernel='linear', random_state=10)
model_nlp.fit(x_train_dtm, y_train_nlp)

nlp_time = time.time() - start_nlp
pred_nlp = model_nlp.predict(x_test_dtm)

print(f"Tiempo de entrenamiento SVC (NLP): {nlp_time:.2f} segundos")
print(f"\nClassification Report - SVC (Bag-of-Words sobre narrativa):")
print(classification_report(y_test_nlp, pred_nlp))

# Matriz de confusion (estilo Sentiment_Analysis.ipynb)
cm_nlp = confusion_matrix(y_test_nlp, pred_nlp)
conf_matrix = pd.DataFrame(
    data=cm_nlp,
    columns=['Predicho: -1\n(Labor Dom.)', 'Predicho: 1\n(Empleada)'],
    index=['Real: -1\n(Labor Dom.)', 'Real: 1\n(Empleada)']
)

plt.rcParams['figure.figsize'] = [10, 6]
sns.heatmap(conf_matrix, annot=True, fmt='d', cmap='Purples',
            cbar=False, linewidths=0.1, annot_kws={'size': 20})
plt.title('Matriz de Confusion - SVC sobre Narrativa (Bag-of-Words)',
          fontsize=13)
plt.xticks(fontsize=12)
plt.yticks(fontsize=12)
plt.tight_layout()
```


```
plt.show()

# Coeficientes del modelo (features mas importantes)
try:
    dfout = pd.DataFrame({'feature': vect_tunned.get_feature_names_out()})
    dfout['coef'] = model_nlp.coef_[0].toarray().flatten() if hasattr(model_nlp,
    ↪coef_[0], 'toarray') else model_nlp.coef_[0]
    dfout = dfout.sort_values(by='coef', ascending=False)
    print("\nFeatures mas predictivas (coeficiente positivo -> Clase 1, ↪
    ↪Empleada):")
    print(dfout.to_string(index=False))
except Exception as e:
    print(f"(No se pueden mostrar coeficientes: {e})")
```

Tiempo de entrenamiento SVC (NLP): 37.43 segundos

Classification Report - SVC (Bag-of-Words sobre narrativa):

	precision	recall	f1-score	support
-1	0.00	0.00	0.00	3981
1	0.55	1.00	0.71	4960
accuracy			0.55	8941
macro avg	0.28	0.50	0.36	8941
weighted avg	0.31	0.55	0.40	8941



Features mas predictivas (coeficiente positivo -> Clase 1, Empleada):

```

        feature      coef
    intereses  0.0000
    cognitivos 0.0000
    curiosidad 0.0000
    curiosidad intereses 0.0000
    curiosidad intereses cognitivos 0.0000
    intereses cognitivos 0.0000
        juego  0.0000
    desarrollo -0.0000
    conductas -0.0000
    agresividad -0.0000
    interaccion -0.0000
        social -0.0000
    social juego -0.0000
    interaccion social juego -0.0000
    interaccion social -0.0000
        presenta -0.0000
    afectivo emocional -0.0000
    emocional -0.0000
    afectivo -0.0000
        mayor -0.0000

```

1.17.4 Respuesta pregunta 8

Comparacion de enfoques: Bag-of-Words (Sentiment_Analysis) vs. Factores CFA (Pregunta 5)

Aspecto	CFA + SVC (P5)	BoW + SVC (P8)
Features	Curiosidad, Afectividad, Sociabilidad (3 dims)	N-gramas del texto narrative (20 features)
Vectorizacion	Factor scores del modelo SEM	CountVectorizer(ngram_range=(1,3), max_features=20)
Clasificador	SVC(kernel='rbf')	SVC(kernel='linear')
Accuracy	~0.56	~0.55-0.57
F1-Macro	~0.39	~0.38-0.40
Tiempo	Segundos	Segundos

Hallazgos principales:

1. **Desempeno equivalente con mucho menos complejidad:** El pipeline clasico Bag-of-Words del notebook `Sentiment_Analysis.ipynb` alcanza un desempeno identico al modelo basado en factores latentes del CFA, utilizando solo 20 n-gramas como features. Esto confirma que la informacion predictiva disponible en los datos es inherentemente limitada, independientemente del metodo de representacion del texto.

2. **La narrativa es una parafrasis de las variables sk:** La columna `narrative` fue generada algorítmicamente a partir de `sk1-sk13`. Por lo tanto, los n-gramas que extrae el `CountVectorizer` capturan los mismos constructos que los factores del CFA (Curiosidad, Afectividad, Sociabilidad), pero en formato textual. Ambas representaciones comparten la misma informacion de fondo.
3. **Patrones linguisticos identificados:** Los features con mayor coeficiente positivo (asociados a madres empleadas, clase 1) o negativo (asociadas a labor domestica, clase -1) pueden visualizarse en la tabla de coeficientes. Estas palabras corresponden a descripciones del perfil socioemocional del niño y no contienen informacion directa sobre la situacion laboral de la madre.
4. Ninguno de los dos enfoques logra predecir el estado laboral de la madre de forma satisfactoria, lo que sugiere que dicha decision depende de factores socioeconomicos, culturales y del mercado laboral que no estan capturados en las variables del dataset (habilidades socioemocionales del niño, IMCE, actividad fisica).

•

1.18 Finalmente, de forma matemática y aplicando estos modelos se puede concluir que realmente no existe una relación predictora sobre las habilidades socioemocionales del niño y sus condiciones físicas como el índice de grasa corporal y la actividad física para predecir si la madre esta con un empleo o no. Socialmente, se tiende a relacionar o intentar predecir que un niño con sobrepeso y sedentario pueda deberse a que en su casa esta su madre como ama de hogar y que esta mas dedicada a alimentarlo expresándole comodidad al niño, pero con los resultados trabajados en esta tarea, se puede comprobar que no existe una tendencia entre los grupos de variables que expliquen si realmente esta en esa situación. Es por ello, que se puede inferir que para predecir el estado laboral de la madre se requieren otras variables relacionadas a los niveles socioeconómicos de la familia, ingresos de la familia, etc.