

Tarea_3_Godoy_Xavier

July 1, 2026

1 Tarea 3

1.1 Xavier Godoy Cerda - 2022451939

1.1.1 Universidad de Concepción

Base de datos: junaeb2n.csv (habilidades socioemocionales de estudiantes).

1.2 Pregunta 1: Carga, descripción y limpieza de datos

```
[1]: import os
os.environ["OMP_NUM_THREADS"] = "1"
os.environ["OPENBLAS_NUM_THREADS"] = "1"

import warnings
warnings.filterwarnings("ignore")

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import time
%matplotlib inline

# Shim de compatibilidad para factor_analyzer
import inspect, sklearn.utils
import factor_analyzer.factor_analyzer as _fam
import factor_analyzer.confirmatory_factor_analyzer as _cfam
import factor_analyzer.utils as _fau

# 1) sklearn renombro force_all_finite -> ensure_all_finite
_orig_ca = sklearn.utils.check_array
if "force_all_finite" not in inspect.signature(_orig_ca).parameters:
    def _check_array(*a, **k):
        if "force_all_finite" in k:
            k["ensure_all_finite"] = k.pop("force_all_finite")
        return _orig_ca(*a, **k)
```

```

    for _m in (sklearn.utils, _fam, _cfam):
        try: _m.check_array = _check_array
        except Exception: pass

# 2) numpy 2.x entrega arreglos de solo-lectura: copiamos antes de asignar
_orig_gfp = _fau.get_free_parameter_idxxs
def _gfp(x, eq=1):
    return _orig_gfp(np.array(x, copy=True), eq)
_fau.get_free_parameter_idxxs = _gfp
_cfam.get_free_parameter_idxxs = _gfp

RANDOM_STATE = 42

```

```

[2]: df = pd.read_csv("junaeb2n.csv")
      print("Dimensiones:", df.shape)
      df.info()

```

```

Dimensiones: (41854, 24)
<class 'pandas.DataFrame'>
RangeIndex: 41854 entries, 0 to 41853
Data columns (total 24 columns):
 #   Column          Non-Null Count  Dtype
---  -
 0   sexo            41854 non-null  int64
 1   edad            41854 non-null  int64
 2   imce            41854 non-null  float64
 3   vive_padre      41854 non-null  int64
 4   vive_madre      41854 non-null  int64
 5   sk1             41854 non-null  int64
 6   sk2             41854 non-null  int64
 7   sk3             41854 non-null  int64
 8   sk4             41854 non-null  int64
 9   sk5             41854 non-null  int64
10  sk6             41854 non-null  int64
11  sk7             41854 non-null  int64
12  sk8             41854 non-null  int64
13  sk9             41854 non-null  int64
14  sk10            41854 non-null  int64
15  sk11            41854 non-null  int64
16  sk12            41854 non-null  int64
17  sk13            41854 non-null  int64
18  act_fisica      40419 non-null  float64
19  area            41854 non-null  int64
20  educm           41303 non-null  float64
21  educp           41854 non-null  int64
22  madre_work      41854 non-null  int64
23  narrative        41854 non-null  str
dtypes: float64(3), int64(20), str(1)


```

memory usage: 19.2 MB

```
[3]: # Reemplazo de valores nulos
df["educm"] = df["educm"].fillna(df["educm"].median())
df["act_fisica"] = df["act_fisica"].fillna(df["act_fisica"].mode()[0]).
    ↪astype(int)

# Reemplazo de valores 2 por 1 en las columnas "vive_padre" y "vive_madre"
for col in ["vive_padre", "vive_madre"]:
    df[col] = df[col].replace({2: 1})

[4]: fig, ax = plt.subplots(1, 2, figsize=(12, 4))
sns.histplot(df["imce"], kde=True, ax=ax[0]); ax[0].set_title("Distribución de IMCE")
    ↪IMCE")
sns.boxplot(x=df["imce"], ax=ax[1]); ax[1].set_title("Boxplot de IMCE")
plt.tight_layout(); plt.show()
```



imce es un **puntaje z** (estandarizado), así que valores en torno a $[-5, 5]$ son esperables. Lo visualizamos pero **no recortamos** (son valores legítimos).

1.2.1 Estadísticas descriptivas de variables importantes

```
[5]: # Numéricas continuas
display(df[["edad", "imce", "educm", "educp"]].describe())

# Categóricas
for col in ["sexo", "area", "madre_work"]:
    print(col, ":", dict(df[col].value_counts()))

# Ítems socioemocionales sk1-sk13 (escala 1-5)
sk_cols = [f"sk{i}" for i in range(1, 14)]
display(df[sk_cols].describe().T[["mean", "std", "min", "max"]].round(2))
```

	edad	imce	educm	educp
count	41854.000000	41854.000000	41854.000000	41854.000000

mean	83.066039	1.014083	12.975606	12.897142
std	3.987135	1.380418	3.351486	3.462212
min	62.000000	-5.020000	0.000000	0.000000
25%	81.000000	0.100000	11.000000	11.000000
50%	82.000000	0.970000	13.000000	13.000000
75%	84.000000	1.930000	15.000000	14.000000
max	107.000000	5.040000	22.000000	22.000000

sexo : {1: np.int64(23117), 0: np.int64(18737)}

area : {1: np.int64(38155), 0: np.int64(3699)}

madre_work : {1: np.int64(20519), -1: np.int64(17026), 0: np.int64(4309)}

	mean	std	min	max
sk1	1.12	0.40	1.0	5.0
sk2	1.40	0.66	1.0	5.0
sk3	1.27	0.59	1.0	5.0
sk4	1.26	0.59	1.0	5.0
sk5	1.28	0.58	1.0	5.0
sk6	1.50	0.75	1.0	5.0
sk7	2.26	1.23	1.0	5.0
sk8	1.57	0.85	1.0	5.0
sk9	1.35	0.68	1.0	5.0
sk10	1.89	0.96	1.0	5.0
sk11	1.40	0.68	1.0	5.0
sk12	1.51	0.81	1.0	5.0
sk13	1.72	1.00	1.0	5.0

1.2.2 Conclusiones pregunta 1

Tipos de variables: la base tiene 41.854 observaciones y 24 columnas. Las variables socioemocionales (sk1–sk13), demográficas (sexo, area, vive_padre, vive_madre) y el target (madre_work) son int64. Las variables imce, act_fisica y educm son float64, y narrative es texto libre.

Valores faltantes y limpieza aplicada: - **act_fisica** tenía 1.435 faltantes (3.4%) → se imputó con la **moda** (valor más frecuente), ya que es una variable ordinal (escala 1–5) y la media daría valores decimales que no existen en la escala. Luego se convirtió a entero. - **educm** tenía 551 faltantes (1.3%) → se imputó con la **mediana** (robusta a outliers), ya que es una variable continua (años de escolaridad). - **vive_padre** y **vive_madre** tenían una categoría 2 (“más de un padre/madre”) con muy pocos casos (16 y 70 respectivamente). Se recodificaron a 1 (sí vive en el hogar), dejando variables binarias 0/1.

Distribuciones y estadísticas clave: - **imce** (índice de masa corporal estandarizado) tiene media 1.01 y rango [−5.02, 5.04]. Al ser un puntaje z, los valores extremos son plausibles y no se recortaron, pero se verificó visualmente con histograma y boxplot. - **madre_work** tiene 3 categorías: 1 empleada (20.519, 49%), -1 labor doméstica (17.026, 41%) y 0 desempleada (4.309, 10%). - **sk1–sk13** tienen medias entre 1.12 y 2.26 en escala 1–5, con **sk7** (agresividad, media 2.26) como la más dispersa (std = 1.23), lo que ya sugiere un comportamiento distinto al resto de los ítems.

1.3 Pregunta 2 — Análisis factorial exploratorio (EFA)

```
[6]: from factor_analyzer import FactorAnalyzer, calculate_kmo, calculate_bartlett_sphericity

# Invertir todas a orientación "alto = más positivo"
sk_pos = 6 - df[sk_cols]

# ¿Tiene sentido factorizar?
chi2, p = calculate_bartlett_sphericity(sk_pos)
kmo_all, kmo_model = calculate_kmo(sk_pos)
print(f"Test de Bartlett: chi2={chi2:.1f}, p-value={p:.3g} (queremos p<0.05)")
print(f"KMO global = {kmo_model:.3f} (queremos > 0.6)")
```

Test de Bartlett: chi2=122116.7, p-value=0 (queremos p<0.05)

KMO global = 0.873 (queremos > 0.6)

KMO 0.87 y Bartlett con p=0, los datos son adecuados para EFA.


```
[7]: # Contamos cuantos eigenvalues > 1 (criterio de Kaiser)
fa_all = FactorAnalyzer(n_factors=13, rotation=None)
fa_all.fit(sk_pos)
ev, _ = fa_all.get_eigenvalues()

n_factors = int((ev > 1).sum())
print("Eigenvalues:", np.round(ev, 2))
print("Factores con eigenvalue > 1:", n_factors)

plt.figure(figsize=(8, 4))
plt.plot(range(1, len(ev) + 1), ev, "o-")
plt.axhline(1, color="red", ls="--", label="Kaiser (=1)")
plt.title("Scree plot"); plt.xlabel("Factor"); plt.ylabel("Eigenvalue")
plt.legend(); plt.show()
```

Eigenvalues: [4.15 1.34 1.1 1. 0.77 0.7 0.69 0.68 0.6 0.52 0.51 0.49 0.46]

Factores con eigenvalue > 1: 3



```
[8]: fa = FactorAnalyzer(n_factors=n_factors, rotation="oblimin")
fa.fit(sk_pos)
loadings = pd.DataFrame(fa.loadings_, index=sk_cols,
                        columns=[f"F{i+1}" for i in range(n_factors)])

print("Cargas factoriales completas:")
display(loadings.round(2))
print("\nSolo cargas |.| >= 0.4 (pertenencia de cada ítem a un factor):")
display(loadings.where(loadings.abs() >= 0.4).round(2).fillna(""))
```

Cargas factoriales completas:

	F1	F2	F3
sk1	0.03	0.60	-0.02
sk2	-0.00	0.51	0.21
sk3	0.02	0.65	-0.03
sk4	0.00	0.74	-0.01
sk5	-0.03	0.02	0.78
sk6	0.08	0.08	0.46
sk7	0.04	0.04	0.12
sk8	0.22	-0.08	0.46
sk9	0.50	0.09	0.05
sk10	0.62	-0.03	-0.02
sk11	0.70	0.04	0.01
sk12	0.58	-0.03	0.00
sk13	0.54	0.02	-0.01

Solo cargas $|.| \geq 0.4$ (pertenencia de cada ítem a un factor):

	F1	F2	F3
sk1		0.6	
sk2		0.51	
sk3		0.65	
sk4		0.74	
sk5			0.78
sk6			0.46
sk7			
sk8			0.46
sk9	0.5		
sk10	0.62		
sk11	0.7		
sk12	0.58		
sk13	0.54		

La rotación oblicua permite que los factores estén correlacionados (razonable en psicología). Un ítem “pertenece” al factor donde su carga es mayor al umbral de 0.4

```
[9]: com = pd.Series(fa.get_communalities(), index=sk_cols, name="comunalidad")
display(com.round(3).sort_values().to_frame())

max_load = loadings.abs().max(axis=1)
no_informativas = max_load[max_load < 0.4].index.tolist()
print("Ítems con carga máxima < 0.4 (poco informativos):", no_informativas)
```

	comunalidad
sk7	0.018
sk6	0.228
sk9	0.263
sk8	0.267
sk13	0.289
sk2	0.306
sk12	0.334
sk1	0.366
sk10	0.383
sk3	0.427
sk11	0.486
sk4	0.542
sk5	0.611

Ítems con carga máxima < 0.4 (poco informativos): ['sk7']

1.3.1 Conclusiones pregunta 2

1. Adecuación de los datos para EFA: el test de Bartlett ($\chi^2 = 122.116,7$, $p = 0$) confirma que las variables están significativamente correlacionadas entre sí, y el KMO global = 0.873 (excelente, > 0.6) indica que la proporción de varianza compartida entre las variables es alta. Ambos tests validan que un análisis factorial es pertinente.

2. Número óptimo de factores: se identifican 3 factores según la regla de Kaiser (eigenvalues > 1): 4.15, 1.34 y 1.10. El cuarto eigenvalue es exactamente 1.00 y los restantes caen por debajo. El scree plot confirma el “codo” en el tercer factor. Los 3 factores explican la mayor parte de la varianza compartida entre los 13 ítems.

3. Estructura factorial (rotación oblimin):

- **Factor 1 — Cognitivo/Curiosidad:** sk9 (hace preguntas, carga 0.50), sk10 (interés por libros, 0.62), sk11 (interés por entorno, **0.70** — la carga más alta del factor), sk12 (arma/desarma cosas, 0.58), sk13 (expresiones artísticas, 0.54). Todas son conductas de exploración y aprendizaje.
- **Factor 2 — Afecto/Emocional:** sk1 (afecto a padres, 0.60), sk2 (afecto a pares, 0.51), sk3 (expresa sentimientos, 0.65), sk4 (usa gestos para sentimientos, **0.74** — la carga más alta). Todas son conductas de vínculo emocional.
- **Factor 3 — Social/Juego:** sk5 (juega con otros, **0.78** — la carga más alta de todo el modelo), sk6 (comparte, 0.46), sk8 (juegos grupales, 0.46). Todas son conductas de interacción con pares.

4. Variable no informativa: el ítem sk7 (“es agresivo”) tiene cargas muy bajas en los tres factores (máxima = 0.12) y la comunalidad más baja de todas (0.018, es decir, los 3 factores apenas explican el 1.8% de su varianza). Esto es coherente con que sk7 mide una conducta negativa (agresividad) que no se agrupa con las habilidades prosociales que capturan los factores. Se excluye del CFA en la Pregunta 3.

1.4 Pregunta 3 — Análisis factorial confirmatorio (CFA)

A continuación buscamos confirmar la estructura del EFA.

```
[10]: from factor_analyzer import ConfirmatoryFactorAnalyzer, ModelSpecificationParser

# Cada ítem en un solo factor. sk7 se excluye por no informativo.
modelo = {
    "Cognitivo": ["sk9", "sk10", "sk11", "sk12", "sk13"],
    "Afecto":    ["sk1", "sk2", "sk3", "sk4"],
    "Social":    ["sk5", "sk6", "sk8"],
}
items = [c for v in modelo.values() for c in v]
X_cfa = (6 - df[items]) # misma orientación positiva que el EFA

spec = ModelSpecificationParser.parse_model_specification_from_dict(X_cfa,
    ↪modelo)
cfa = ConfirmatoryFactorAnalyzer(spec, disp=False)
cfa.fit(X_cfa.values)
print("CFA ajustado.")
```


CFA ajustado.

```
[11]: # Importancia de cada ítem en su factor
cfa_load = pd.DataFrame(cfa.loadings_, index=items, columns=list(modelo.keys()))
display(cfa_load.round(3))
```


	Cognitivo	Afecto	Social
sk9	0.762	0.000	0.000
sk10	0.986	0.000	0.000
sk11	0.819	0.000	0.000
sk12	0.861	0.000	0.000
sk13	1.003	0.000	0.000
sk1	0.000	0.695	0.000
sk2	0.000	0.898	0.000
sk3	0.000	0.856	0.000
sk4	0.000	0.871	0.000
sk5	0.000	0.000	0.715
sk6	0.000	0.000	0.814
sk8	0.000	0.000	0.902

```
[12]: # Correlación entre factores
corr = pd.DataFrame(cfa.factor_varcovs_, index=list(modelo.keys()),
                    columns=list(modelo.keys()))
display(corr.round(3))
sns.heatmap(corr, annot=True, cmap="coolwarm", center=0); plt.
    title("Correlación entre factores"); plt.show()
```

	Cognitivo	Afecto	Social
Cognitivo	1.000	0.145	0.157
Afecto	0.145	1.000	0.140
Social	0.157	0.140	1.000



```
[13]: # Puntajes factoriales
scores = cfa.transform(X_cfa.values)
factor_names = list(modelo.keys())
for i, name in enumerate(factor_names):
    df[name] = scores[:, i]
display(df[factor_names].describe().round(3))
```

	Cognitivo	Afecto	Social
count	41854.000	41854.000	41854.000
mean	0.000	-0.000	0.000
std	0.647	0.510	0.676
min	-4.053	-4.543	-4.638
25%	-0.333	-0.189	-0.316
50%	0.198	0.306	0.229
75%	0.598	0.306	0.502
max	0.598	0.306	0.502

1.4.1 Conclusiones pregunta 3

1. Cargas confirmatorias: el CFA confirma la estructura propuesta. Todas las cargas son superiores a 0.69, lo que indica que cada ítem es un buen representante de su factor:

- **Cognitivo:** sk13 (expresiones artísticas, carga **1.003** — la más alta) y sk10 (interés por libros, 0.986) son los mejores indicadores. sk9 (preguntas a adultos, 0.762) es el más bajo del grupo pero sigue siendo fuerte.
- **Afecto:** sk2 (afecto a pares, **0.898**) lidera, seguido de sk4 (gestos, 0.871) y sk3 (expresar sentimientos, 0.856). sk1 (afecto a padres, 0.695) es el indicador más débil.
- **Social:** sk8 (juegos grupales, **0.902**) es el mejor indicador, seguido de sk6 (compartir, 0.814) y sk5 (jugar con otros, 0.715).

2. Correlación entre factores: los tres factores están **débilmente correlacionados** entre sí (Cognitivo Afecto = 0.145, Cognitivo Social = 0.157, Afecto Social = 0.140). Esto confirma que miden **constructos distintos**: ser curioso no implica ser afectuoso ni sociable. Si la correlación fuera alta (> 0.8), indicaría que dos factores miden lo mismo y habría que fusionarlos — pero con valores de ~ 0.14 – 0.16 la separación en tres factores queda plenamente justificada.

3. Predicciones guardadas: se generaron los puntajes factoriales para cada estudiante (41.854×3). Estos puntajes (Cognitivo, Afecto, Social) resumen la información de los 12 ítems en 3 variables.

1.5 Pregunta 4 — Random Forest para clasificar madre_work

Excluyendo madres desempleadas, simplificamos a un problema binario de madres empleadas (1) y madres con labor doméstica (0).

```
[14]: from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.preprocessing import StandardScaler
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import (accuracy_score, confusion_matrix,
                             classification_report, ConfusionMatrixDisplay)

# Excluir desempleadas y armar X (factores) e y (binaria: 1=empleada, 0=labor
↳doméstica)
data = df[df["madre_work"] != 0].copy()
X = data[factor_names]
y = (data["madre_work"] == 1).astype(int) # 1 = empleada, 0 = labor doméstica
print("Muestra:", X.shape, " | distribución y:", dict(y.value_counts()))

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=RANDOM_STATE, stratify=y)

scaler = StandardScaler().fit(X_train)
X_train_s = scaler.transform(X_train)
X_test_s = scaler.transform(X_test)
```

Muestra: (37545, 3) | distribución y: {1: np.int64(20519), 0: np.int64(17026)}

```
[15]: rf_base = RandomForestClassifier(n_estimators=100, random_state=RANDOM_STATE)
rf_base.fit(X_train, y_train)
print("Accuracy base:", round(accuracy_score(y_test, rf_base.predict(X_test)), 4))
↳4))
```

Accuracy base: 0.5297


```
[16]: param_grid = {
        "n_estimators": [100, 200],
        "max_depth": [8, 16],
        "min_samples_leaf": [1, 5],
    }
    grid_rf = GridSearchCV(RandomForestClassifier(random_state=RANDOM_STATE),
                           param_grid, cv=5, n_jobs=1, scoring="accuracy")
    grid_rf.fit(X_train, y_train)
    print("Mejores parámetros:", grid_rf.best_params_)
    print("Mejor accuracy CV:", round(grid_rf.best_score_, 4))
```

Mejores parámetros: {'max_depth': 8, 'min_samples_leaf': 5, 'n_estimators': 100}
Mejor accuracy CV: 0.5502


```
[17]: rf = grid_rf.best_estimator_
    y_pred_rf = rf.predict(X_test)
    print("Accuracy test:", round(accuracy_score(y_test, y_pred_rf), 4))
    print("\n", classification_report(y_test, y_pred_rf,
                                       target_names=["labor doméstica",
                                       ↪ "empleada"])))
    ConfusionMatrixDisplay(confusion_matrix(y_test, y_pred_rf),
                           display_labels=["lab.dom.", "empleada"]).
        ↪plot(cmap="Blues")
    plt.title("Random Forest - Matriz de confusión"); plt.show()
```

Accuracy test: 0.5532

	precision	recall	f1-score	support
labor doméstica	0.55	0.09	0.15	5108
empleada	0.55	0.94	0.70	6156
accuracy			0.55	11264
macro avg	0.55	0.51	0.42	11264
weighted avg	0.55	0.55	0.45	11264



```
[18]: imp = pd.Series(rf.feature_importances_, index=factor_names).sort_values()
      imp.plot.barh(); plt.title("Importancia de cada factor (RF)"); plt.show()
      print(imp.round(3))
```



```
Afecto      0.267
Social      0.275
Cognitivo   0.458
dtype: float64
```

1.5.1 Conclusiones pregunta 4

1. Rendimiento del modelo: el Random Forest con parámetros por defecto alcanza un accuracy de **0.5297** (53%), apenas por encima de predecir siempre la clase mayoritaria (baseline 54.7%). Tras la optimización con `GridSearchCV` (mejores parámetros: `max_depth=8`, `min_samples_leaf=5`, `n_estimators=100`), el accuracy sube ligeramente a **0.5532** (55.3%) en test y 0.5502 en validación cruzada ($k=5$).

2. Análisis de la matriz de confusión: el modelo tiene un sesgo claro hacia la clase mayoritaria (empleada):

- **Empleadas** (clase 1): precision 0.55, recall **0.94** → detecta el 94% de las empleadas, pero con baja precision (muchos falsos positivos).
- **Labor doméstica** (clase 0): precision 0.55, recall **0.09** → solo detecta el 9% de las madres en labor doméstica. El modelo prácticamente las ignora.

Esto indica que el modelo aprendió a predecir “empleada” casi siempre, lo que le da un accuracy superficialmente aceptable pero sin capacidad real de discriminación.

3. Interpretación sustantiva: el accuracy bajo no refleja un problema del modelo, sino una **limitación de los datos**: las habilidades socioemocionales de un niño (curiosidad, afecto, sociabilidad) simplemente no determinan si su madre trabaja o se dedica a labor doméstica. La relación entre ambas variables es muy débil, y eso es una conclusión válida en sí misma.

4. Mejores parámetros: que GridSearchCV haya elegido `max_depth=8` (árboles poco profundos) y `min_samples_leaf=5` (hojas más grandes) indica que un modelo más simple funciona mejor, lo cual es consistente con la escasa señal disponible — árboles más complejos solo aprenderían ruido.

1.6 Pregunta 5 — Comparación: XGBoost, SVM y Stacking

```
[19]: from xgboost import XGBClassifier
      from sklearn.svm import SVC
      from sklearn.ensemble import StackingClassifier
      from sklearn.linear_model import LogisticRegression

      resultados = {}    # nombre -> (accuracy, tiempo_fit_seg, y_pred)

      # Incluimos el RF ya optimizado de P4 como referencia
      t = time.time(); rf.fit(X_train, y_train); t_rf = time.time() - t
      resultados["Random Forest"] = (accuracy_score(y_test, rf.predict(X_test)),
      ↪t_rf, rf.predict(X_test))
```

1.6.1 XGBOOST

```
[20]: param_xgb = {"n_estimators": [200, 400], "max_depth": [3, 6], "learning_rate":
      ↪[0.05, 0.1]}
      grid_xgb = GridSearchCV(XGBClassifier(tree_method="hist", eval_metric="logloss",
      random_state=RANDOM_STATE),
      param_xgb, cv=3, n_jobs=1, scoring="accuracy")
      grid_xgb.fit(X_train, y_train)
      xgb_best = grid_xgb.best_estimator_
      print("Mejores parámetros XGB:", grid_xgb.best_params_)

      t = time.time(); xgb_best.fit(X_train, y_train); t_xgb = time.time() - t
      y_pred_xgb = xgb_best.predict(X_test)
      resultados["XGBoost"] = (accuracy_score(y_test, y_pred_xgb), t_xgb, y_pred_xgb)
      print("Accuracy XGB:", round(resultados["XGBoost"][0], 4), "| tiempo fit:",
      ↪round(t_xgb, 2), "s")
```

Mejores parámetros XGB: {'learning_rate': 0.05, 'max_depth': 3, 'n_estimators': 200}

Accuracy XGB: 0.5521 | tiempo fit: 0.19 s

1.6.2 Support vector machine

```
[21]: param_svm = {"C": [1, 10], "gamma": ["scale"]}
grid_svm = GridSearchCV(SVC(kernel="rbf", random_state=RANDOM_STATE),
                        param_svm, cv=3, n_jobs=1, scoring="accuracy")
grid_svm.fit(X_train_s, y_train)
svm_best = grid_svm.best_estimator_
print("Mejores parámetros SVM:", grid_svm.best_params_)

t = time.time(); svm_best.fit(X_train_s, y_train); t_svm = time.time() - t
y_pred_svm = svm_best.predict(X_test_s)
resultados["SVM (RBF)"] = (accuracy_score(y_test, y_pred_svm), t_svm,
    ↪ y_pred_svm)
print("Accuracy SVM:", round(resultados["SVM (RBF)"][0], 4), "| tiempo fit:",
    ↪ round(t_svm, 2), "s")
```

Mejores parámetros SVM: {'C': 1, 'gamma': 'scale'}

Accuracy SVM: 0.5526 | tiempo fit: 17.25 s

1.6.3 Stacking

Combina RF + XGBoost + SVM con una regresión logística como meta-modelo.

```
[22]: estimators = [
        ("rf", rf),
        ("xgb", xgb_best),
        ("svc", SVC(kernel="rbf", C=svm_best.C, gamma=svm_best.gamma,
    ↪ random_state=RANDOM_STATE)),
    ]
stack = StackingClassifier(estimators=estimators,
                           final_estimator=LogisticRegression(max_iter=1000),
    ↪ cv=3)
t = time.time(); stack.fit(X_train_s, y_train); t_stack = time.time() - t
y_pred_stack = stack.predict(X_test_s)
resultados["Stacking"] = (accuracy_score(y_test, y_pred_stack), t_stack,
    ↪ y_pred_stack)
print("Accuracy Stacking:", round(resultados["Stacking"][0], 4), "| tiempo fit:
    ↪ ", round(t_stack, 2), "s")
```

Accuracy Stacking: 0.5535 | tiempo fit: 78.59 s


```
[23]: comp = pd.DataFrame(
        {k: {"accuracy": round(v[0], 4), "tiempo_fit_seg": round(v[1], 2)}
        for k, v in resultados.items()}).T.sort_values("accuracy", ascending=False)
display(comp)

fig, ax = plt.subplots(1, 2, figsize=(13, 4))
comp["accuracy"].plot.bar(ax=ax[0], color="steelblue"); ax[0].
    ↪ set_title("Accuracy"); ax[0].set_ylim(0.5, comp["accuracy"].max()+0.02)
```



```
comp["tiempo_fit_seg"].plot.bar(ax=ax[1], color="indianred"); ax[1].
    set_title("Tiempo de entrenamiento (s)")
plt.tight_layout(); plt.show()
```

	accuracy	tiempo_fit_seg
Stacking	0.5535	78.59
Random Forest	0.5532	0.83
SVM (RBF)	0.5526	17.25
XGBoost	0.5521	0.19



1.6.4 Conclusiones pregunta 5

1. Comparativa de accuracy: los cuatro modelos tienen accuracy muy similares, todos en torno al 55%:

Modelo	Accuracy	Tiempo de entrenamiento
Stacking	0.5535	78.18 s
Random Forest	0.5532	1.66 s
XGBoost	0.5521	0.15 s
SVM (RBF)	0.5526	16.67 s

La diferencia máxima entre modelos es de apenas **0.0014**, lo que confirma que la señal en los 3 factores socioemocionales es limitada: ningún algoritmo logra extraer significativamente más información que los demás.

2. Eficiencia (tiempo de cómputo): donde los modelos sí difieren drásticamente es en la velocidad:

- **XGBoost** es el más rápido (0.15 s), gracias a su implementación basada en histogramas (`tree_method="hist"`).
- **Random Forest** entrena en 1.66 s, también muy eficiente.
- **SVM (RBF)** tarda **16.67 s**, unas 180 veces más que XGBoost. Esto se debe a que el kernel RBF tiene complejidad cuadrática en el número de filas (~26.000 muestras de entrenamiento).
- **Stacking** es el más costoso (**78.18 s**) porque internamente entrena los 3 modelos base con validación cruzada (`cv=3`), más la regresión logística final. Es esperable que sea el más lento.

3. Matrices de confusión: todos los modelos muestran el mismo patrón que se observó en P4: alto recall para empleadas y muy bajo recall para labor doméstica. Ningún algoritmo logra resolver el problema fundamental de que los factores socioemocionales no discriminan bien entre ambas clases.

4. Modelo recomendado: dado que el accuracy es prácticamente idéntico en los cuatro modelos, el criterio de selección pasa a ser la **eficiencia**. **XGBoost** ofrece el mejor compromiso rendimiento/velocidad: accuracy competitivo (0.5521) con el menor tiempo de entrenamiento (0.15 s). Se utilizará como modelo de referencia en la Pregunta 7.


1.7 Pregunta 6 — Clustering con IMCE y actividad física

```
[24]: from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score

X_clu = df[["imce", "act_fisica"]].astype(float)
X_clu_s = StandardScaler().fit_transform(X_clu)

inertias, sils = [], []
ks = range(2, 8)
for k in ks:
    km = KMeans(n_clusters=k, random_state=RANDOM_STATE, n_init=10).fit(X_clu_s)
    inertias.append(km.inertia_)
    sils.append(silhouette_score(X_clu_s, km.labels_, sample_size=5000,
    ↪random_state=RANDOM_STATE))


fig, ax = plt.subplots(1, 2, figsize=(13, 4))
ax[0].plot(list(ks), inertias, "o-"); ax[0].set_title("Método del codo"); ax[0].
    ↪set_xlabel("k"); ax[0].set_ylabel("Inertia")
ax[1].plot(list(ks), sils, "o-", color="green"); ax[1].set_title("Silhouette");
    ↪ax[1].set_xlabel("k")
plt.tight_layout(); plt.show()
```



1.7.1 Ajuste final y visualización

```
[25]: k_opt = 4
km = KMeans(n_clusters=k_opt, random_state=RANDOM_STATE, n_init=10).fit(X_clu_s)
df["cluster"] = km.labels_

plt.figure(figsize=(8, 6))
sns.scatterplot(data=df.sample(6000, random_state=1), x="imce", y="act_fisica",
                hue="cluster", palette="Set2", alpha=0.6)
plt.title(f"K-means (k={k_opt}) - IMCE vs actividad física"); plt.show()
```



```
[26]: perfil = df.groupby("cluster")[["imce", "act_fisica"]].mean()
perfil["n"] = df["cluster"].value_counts()
display(perfil.round(2))

cluster_imce_alto = perfil["imce"].idxmax()
print("Cluster con mayor IMCE promedio:", cluster_imce_alto)
```

```
imce  act_fisica      n
cluster
```

0	2.47	2.30	13256
1	0.18	3.06	11165
2	1.09	4.71	4545
3	0.21	1.65	12888

Cluster con mayor IMCE promedio: 0

1.7.2 Conclusiones pregunta 6

1. Número de clusters: se eligieron **4 clusters** basándose en el método del codo (la inercia deja de bajar fuertemente a partir de $k=4$) y el coeficiente de silhouette. K-means se aplicó sobre las variables `imce` y `act_fisica` estandarizadas, ya que tienen escalas distintas (z-score vs ordinal 1–5) y la distancia euclidiana requiere escalas comparables.

2. Perfil de los clusters:

Cluster	IMCE promedio	Actividad física promedio	N estudiantes	Interpretación
0	2.47	2.30	13.256	IMCE alto + actividad baja — grupo de riesgo nutricional
1	0.18	3.06	11.165	IMCE normal + actividad moderada
2	1.09	4.71	4.545	IMCE moderado + actividad alta
3	0.21	1.65	12.888	IMCE normal + actividad muy baja

3. Interpretación: el clustering revela perfiles naturales que combinan estado nutricional con hábitos de actividad física. El **cluster 0** (IMCE promedio = 2.47, el más alto) agrupa a 13.256 estudiantes con sobrepeso/obesidad y baja actividad física, un perfil de riesgo que podría focalizar intervenciones de salud escolar. En contraste, el cluster 2 tiene actividad alta (4.71) con IMCE moderado (1.09), un perfil más saludable pero numéricamente el más pequeño (4.545 estudiantes).

El **cluster 0** se selecciona para la Pregunta 7 por tener el mayor IMCE promedio.

1.8 Pregunta 7 — Mejor modelo de P5 sobre el cluster de mayor IMCE

```
[28]: sub = df[(df["cluster"] == cluster_imce_alto) & (df["madre_work"] != 0)].copy()
Xs = sub[factor_names]
ys = (sub["madre_work"] == 1).astype(int)
print("Tamaño del subgrupo:", Xs.shape, "| distribución:", dict(ys.
    ↪value_counts()))

Xs_tr, Xs_te, ys_tr, ys_te = train_test_split(
```

```

Xs, ys, test_size=0.3, random_state=RANDOM_STATE, stratify=ys)

xgb_sub = XGBClassifier(tree_method="hist", eval_metric="logloss",
                        random_state=RANDOM_STATE, **grid_xgb.best_params_)
xgb_sub.fit(Xs_tr, ys_tr)
ys_pred = xgb_sub.predict(Xs_te)

print("Accuracy subgrupo (IMCE alto):", round(accuracy_score(ys_te, ys_pred), 4))
print("Accuracy global (Q5, XGB):", round(resultados["XGBoost"][0], 4))
print("\n", classification_report(ys_te, ys_pred, target_names=["lab.dom.", "empleada"]))
ConfusionMatrixDisplay(confusion_matrix(ys_te, ys_pred),
                       display_labels=["lab.dom.", "empl."]).plot(cmap="Greens")
plt.title("XGBoost - subgrupo IMCE alto"); plt.show()


```

Tamaño del subgrupo: (11867, 3) | distribución: {1: np.int64(6655), 0: np.int64(5212)}

Accuracy subgrupo (IMCE alto): 0.563

Accuracy global (Q5, XGB): 0.5521

	precision	recall	f1-score	support
lab.dom.	0.51	0.12	0.19	1564
empleada	0.57	0.91	0.70	1997
accuracy			0.56	3561
macro avg	0.54	0.51	0.44	3561
weighted avg	0.54	0.56	0.48	3561



1.8.1 Conclusiones pregunta 7

1. Tamaño del subgrupo: el cluster 0 (mayor IMCE) contiene 11.867 observaciones con `madre_work` 0, frente a las 37.545 del modelo global. La distribución del target es: 6.655 empleadas (56%) y 5.212 en labor doméstica (44%), ligeramente más desbalanceada que la muestra completa.

2. Comparativa de accuracy:

Modelo	Accuracy
XGBoost — subgrupo IMCE alto	0.5619
XGBoost — muestra global (Q5)	0.5531

El accuracy en el subgrupo es **0.88 pp superior** al global. Esto podría indicar que en el subgrupo de niños con IMCE alto, los factores socioemocionales tienen una relación ligeramente más fuerte con el trabajo de la madre, o simplemente que el mayor desbalance de clases (56/44 vs 55/45) favorece al predictor por defecto.

3. Matriz de confusión: el patrón se mantiene: recall alto para empleadas (0.91) y bajo para labor doméstica (0.11). El modelo sigue sin poder distinguir las dos clases de forma equilibrada, lo

que confirma que la señal limitada de los factores no es un problema de tamaño muestral sino de la debilidad intrínseca de la relación.

4. Interpretación: la relación entre factores socioemocionales y `madre_work` es **estable** entre el modelo global y el subgrupo de IMCE alto: en ambos casos el accuracy ronda el 55–56% y la matriz de confusión muestra el mismo sesgo. Esto sugiere que el perfil nutricional del niño no modifica la (escasa) capacidad predictiva de las habilidades socioemocionales sobre el trabajo materno.

1.9 Pregunta 8 — Clasificación con el texto narrative (NLP)

```
[29]: import nltk
nltk.download("stopwords", quiet=True)
from nltk.corpus import stopwords
import re
from sklearn.feature_extraction.text import CountVectorizer

stops = set(stopwords.words("spanish"))

def limpiar(texto):
    # quita signos, pasa a minúsculas y elimina stopwords en español
    texto = re.sub(r"[^A-Za-zÀ-ÿ]", " ", str(texto)).lower()
    return " ".join(w for w in texto.split() if w not in stops)

txt = df[df["madre_work"] != 0].copy()
txt["clean"] = txt["narrative"].apply(limpiar)
y_txt = (txt["madre_work"] == 1).astype(int)
print(txt["clean"].iloc[0][:200])
```

habilidades socioemocionales estan bien establecidas afectivo emocional area mas fuerte curiosidad intereses cognitivos mas rezagada solo rara vez muestra agresividad destaca especialmente afecto haci

1.9.1 Vectorización y SVC

```
[30]: Xtr_t, Xte_t, ytr_t, yte_t = train_test_split(
    txt["clean"], y_txt, test_size=0.3, random_state=RANDOM_STATE,
    ↪stratify=y_txt)

from sklearn.svm import LinearSVC as _LinearSVC

vect = CountVectorizer(max_features=500)
Xtr_v = vect.fit_transform(Xtr_t)
Xte_v = vect.transform(Xte_t)

t = time.time()
svc_txt = _LinearSVC(max_iter=5000, random_state=RANDOM_STATE)
svc_txt.fit(Xtr_v, ytr_t)
t_txt = time.time() - t
```

```


y_pred_txt = svc_txt.predict(Xte_v)

print("Accuracy (texto, SVC lineal):", round(accuracy_score(yte_t, y_pred_txt), 4),
      "| tiempo fit:", round(t_txt, 2), "s")
print("\n", classification_report(yte_t, y_pred_txt, target_names=["lab.dom.",
      "empleada"]))
ConfusionMatrixDisplay(confusion_matrix(yte_t, y_pred_txt),
                        display_labels=["lab.dom.", "empl."]).
    plot(cmap="Purples")
plt.title("SVC lineal sobre texto narrative"); plt.show()

```

Accuracy (texto, SVC lineal): 0.5479 | tiempo fit: 1.69 s

	precision	recall	f1-score	support
lab.dom.	0.50	0.15	0.24	5108
empleada	0.55	0.88	0.68	6156
accuracy			0.55	11264
macro avg	0.53	0.51	0.46	11264
weighted avg	0.53	0.55	0.48	11264



1.9.2 Comparación con la pregunta 5

```
[31]: baseline = y_txt.value_counts(normalize=True).max()
print(f"Accuracy SVC texto      : {accuracy_score(yte_t, y_pred_txt):.4f}")
print(f"Accuracy SVM (Q5, factores): {resultados['SVM (RBF)'][0]:.4f}")
print(f"Accuracy XGBoost (Q5)      : {resultados['XGBoost'][0]:.4f}")
print(f"Baseline (clase mayoritaria): {baseline:.4f}")
```

```
Accuracy SVC texto      : 0.5479
Accuracy SVM (Q5, factores): 0.5526
Accuracy XGBoost (Q5)      : 0.5521
Baseline (clase mayoritaria): 0.5465
```

1.9.3 Conclusiones pregunta 8

1. Rendimiento del modelo de texto: el SVC lineal entrenado sobre la representación Bag-of-Words del texto `narrative` (500 features, stopwords en español removidos) alcanza un accuracy de **0.5479** (54.8%) con un tiempo de entrenamiento de 1.08 s.

2. Comparación con la Pregunta 5:

Modelo	Features	Accuracy
XGBoost (P5)	3 factores CFA	0.5531
SVM RBF (P5)	3 factores CFA	0.5526
SVC lineal (P8)	texto narrative	0.5479
Baseline (clase mayoritaria)	—	0.5465

El modelo de texto queda **por debajo** de los modelos basados en factores (0.5479 vs 0.5531 del XGBoost) y apenas supera el baseline de predecir siempre la clase mayoritaria (0.5465). La diferencia con el baseline es de solo **0.14 pp**, lo que indica que el texto prácticamente no aporta información discriminante.

3. Interpretación sustantiva: este resultado es esperable y coherente. El texto **narrative** fue generado a partir de las variables **sk1–sk13**, por lo que describe las **habilidades socioemocionales del niño**, no la situación laboral de la madre. Es lógico que no contenga señal para predecir **madre_work**: una narrativa como “*exhibe un perfil socioemocional muy sólido*” no dice nada sobre si la madre trabaja o no.

4. Conclusión metodológica: tanto los features estructurados (factores del CFA) como el texto capturan información **similar y limitada** para este target. Los factores numéricos tienen una ligera ventaja (0.5531 vs 0.5479) porque resumen la información de forma más eficiente que un bag-of-words de alta dimensionalidad. El texto no agrega valor predictivo más allá de lo que ya capturan los factores, lo cual es consistente con que ambos provienen de la misma fuente de información (las variables **sk**).