

Tarea_3_Sepulveda_Patricio

July 1, 2026

1 Tarea 3 — Patricio Sepúlveda Ewert

1.1 Pregunta 1 — Carga, exploración y limpieza

41.854 observaciones $\times$ 24 variables. 13 ítems Likert **sk1–sk13** (1–5), variables demográficas/familiares y una narrativa textual generada a partir de los ítems.

Faltantes: solo **act_fisica** (1.435 3.4 %) y **educm** (551 1.3 %); se imputan por **mediana** (robusta a la asimetría de variables ordinales). **Recodificaciones:** **vive_padre/vive_madre** colapsan el valor marginal 2 a 1 (presencia en hogar); los ítems de conducta **deseable** (**sk1–sk6**, **sk8–sk13**) se reexpresan en sentido **positivo** ($6 - x$) para que un valor alto signifique siempre conducta más deseable —requisito del EFA—. **sk7** (agresividad) tiene polaridad opuesta en el diccionario (1: nunca $\rightarrow$ 5: siempre, conducta no deseable), por lo que se deja **sin invertir**: si se invirtiera quedaría apuntando en sentido contrario al resto. Esta es la única variable de polaridad negativa, y como resulta no informativa (ver P2) la decisión no altera la estructura factorial. **Outliers:** **imce** se mueve en un rango plausible de puntajes z y se conserva.

1.2 Pregunta 2 — EFA

KMO = **0.873** (meritorio) y Bartlett significativo ($\chi^2 \approx 122.117$, $p < 10^{-300}$): matriz factorizable. Kaiser y scree coinciden en **3 factores** (autovalores 4.15, 1.34, 1.10; el cuarto cae a 0.999). Rotación oblicua **promax** (factores teóricamente correlacionados).

Factor	Ítems	Concepto
F1	sk9, sk10, sk11, sk12, sk13	Curiosidad / interés cognitivo
F2	sk1, sk2, sk3, sk4	Afecto y expresión emocional
F3	sk5, sk6, sk8	Sociabilidad y juego compartido

Variable no informativa: **sk7** (agresividad), comunalidad 0.02 y cargas 0.14: no comparte varianza con el constructo. Se descarta para el CFA.

1.3 Pregunta 3 — CFA

Estructura simple (cada ítem en un solo factor) sobre los 12 ítems informativos, con **semopy**. Ajuste **bueno**: CFI = 0.949, TLI = 0.934, RMSEA = 0.053. Factores nombrados **Afectivo** (sk1–sk4), **Social** (sk5, sk6, sk8) y **Cognitivo** (sk9–sk13). Correlaciones entre factores: Afectivo–Social 0.66, Cognitivo–Afectivo 0.61, Cognitivo–Social 0.60 (relacionados pero discriminables). Se guardan las **puntuaciones factoriales** como features.

1.4 Pregunta 4 — Random Forest (target madre_work, binario)

Siguiendo el enunciado, se **excluye la categoría minoritaria** 0 (desempleada), dejando un problema **binario**: labor doméstica (−1) vs empleada (1), con 37.545 observaciones (baseline de clase mayoritaria 0.547). Features: los 3 scores del CFA. Optimización de hiperparámetros con GridSearchCV y validación StratifiedKFold(5), dentro de Pipeline.

Resultado: Random Forest da accuracy 0.520 y macro-F1 0.512, cerca del baseline (0.547). El macro-F1 es alto respecto a un planteamiento de 3 clases porque, al ser binario y más balanceado, reparte las predicciones entre ambas clases. Aun así, los 3 factores socioemocionales aportan **señal predictiva limitada** sobre el empleo materno.

1.5 Pregunta 5 — XGBoost vs SVM vs Stacking

Los tres modelos sobre el mismo target binario, con optimización de hiperparámetros y CV, comparados contra el RF de la P4. Se reportan matriz de confusión y **tiempo de cómputo**.

Desempeño: todos próximos al baseline (0.547): accuracy 0.520–0.539. Mejor por macro-F1 el **Stacking (0.515)**; por accuracy el SVM-RBF (0.539). **Eficiencia**: XGBoost es el más rápido por un margen amplio (1–2 s), seguido del SVM-RBF y el RandomForest (1–2.5 min cada uno); el Stacking es el más costoso (8 min), al reentrenar los tres modelos base más el meta-modelo. Los segundos exactos dependen del equipo, pero el orden relativo es estable. **Conclusión**: ningún modelo supera el baseline; con los tres scores factoriales el problema tiene poca señal, el modelo no es el factor limitante.

1.6 Pregunta 6 — Clustering (imce × act_fisica)

K-Means sobre las dos variables estandarizadas; el silhouette se aplana entre $k = 3$ y $k = 4$ (0.376 vs 0.379), se elige $k = 3$ por parsimonia. Los tres grupos son:

Cluster	IMCE medio	Act. física media	n
0	0.00 (normal)	2.23 (baja)	19.595
1	2.22 (alto)	2.24 (baja)	17.026
2	0.89 (moderado)	4.62 (alta)	5.233

El **cluster 1** concentra el IMCE más alto con actividad física baja (perfil de riesgo); el **cluster 2** agrupa a los estudiantes muy activos, con IMCE moderado; el **cluster 0** reúne IMCE normal y

actividad baja. La separación la dominan los niveles de IMCE, con la actividad física distinguiendo al grupo activo. El gradiente IMCE actividad es coherente con la evidencia en salud.

1.7 Pregunta 7 — Mejor modelo de P5 sobre el grupo de mayor IMCE

Se selecciona el cluster de mayor IMCE (15.225 obs.) y se reestima el **mejor modelo de la P5** (Stacking) sobre ese subgrupo. Da accuracy 0.537 y macro-F1 0.514, bajo el baseline del subgrupo (0.558). **Conclusión:** restringir al subgrupo de riesgo no mejora la predicción, lo que confirma que la débil relación entre habilidades socioemocionales y empleo materno es **robusta**.

1.8 Pregunta 8 — Clasificación de texto (SVC) siguiendo `Sentiment_Analysis.ipynb`

Siguiendo el notebook de referencia, se procesa la narrativa con una **función de tokenización** (limpieza con regex + stopwords en español vía NLTK), se vectoriza con **CountVectorizer** (300 términos, para un clasificador adecuado) y se entrena un **SVM lineal** (LinearSVC) sobre el target binario, **excluyendo las variables sk**, para **contrastar con la P5**. Resultado: accuracy 0.541, macro-F1 0.54 — el modelo discrimina ambas clases (no colapsa) pero queda en el baseline, igual que en la P5.

Discusión. La narrativa es una paráfrasis determinista de los mismos ítems `sk1–sk13`; por ello el SVC de texto **no aporta señal nueva** sobre `madre_work` y su desempeño queda en torno al baseline, en línea con lo observado en la P5. El ejercicio demuestra el pipeline completo de NLP (tokenización, vectorización, clasificación e interpretación de coeficientes) más que una mejora predictiva.

1.9 Importación de Librerías

```
[1]: import warnings
warnings.filterwarnings('ignore')
import time, re
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

from factor_analyzer import FactorAnalyzer
from factor_analyzer.factor_analyzer import calculate_kmo, calculate_bartlett_sphericity
import semopy

import nltk
nltk.download('stopwords')
from nltk.corpus import stopwords
```

```

from sklearn.model_selection import (StratifiedKFold, GridSearchCV,
                                     cross_validate, cross_val_predict,
                                     train_test_split)
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.ensemble import RandomForestClassifier, StackingClassifier
from sklearn.svm import SVC
from sklearn.linear_model import LogisticRegression
from sklearn.cluster import KMeans
from sklearn.metrics import (confusion_matrix, classification_report,
                             silhouette_score, accuracy_score)
from sklearn.feature_extraction.text import CountVectorizer
from xgboost import XGBClassifier

RANDOM_STATE = 42
plt.rcParams['figure.figsize'] = (12, 4)
sns.set_theme(style='whitegrid', palette='muted')
pd.set_option('display.max_columns', None)
pd.set_option('display.float_format', '{:.4f}'.format)

```

```

[nltk_data] Downloading package stopwords to
[nltk_data] C:\Users\Patricio\AppData\Roaming\nltk_data...
[nltk_data] Package stopwords is already up-to-date!

```

1.10 Pregunta 1 — Carga, Exploración y Limpieza

1.10.1 1.A Carga y exploración inicial

```

[2]: df = pd.read_csv('junaeb2n.csv')
TEXT_COL = 'narrative' if 'narrative' in df.columns else 'resumen_sk'
sk_cols = [f'sk{i}' for i in range(1, 14)]

print(f'Dimensiones: {df.shape[0]:,} filas x {df.shape[1]} columnas')
print(f'Columna de texto detectada: "{TEXT_COL}"\n')
df.head(3)

```

```

Dimensiones: 41,854 filas x 24 columnas
Columna de texto detectada: "resumen_sk"

```

```

[2]:
  sexo  edad  imce  vive_padre  vive_madre  sk1  sk2  sk3  sk4  sk5  sk6  \
0     1    85  0.7500           1           1     1     1     1     2     1     2
1     0    76  0.7100           0           1     1     1     1     1     1     1
2     1    68  0.2700           0           1     2     2     3     2     1     2

  sk7  sk8  sk9  sk10  sk11  sk12  sk13  act_fisica  area  educm  educp  \

```

0	2	1	2	2	2	3	2	NaN	0	11.0000	11
1	4	1	1	1	1	1	1	5.0000	0	8.0000	8
2	3	2	2	3	2	1	3	NaN	1	13.0000	13

	madre_work	resumen_sk
0	-1	En el plano afectivo y emocional, la dimension...
1	1	En el plano afectivo y emocional, la dimension...
2	1	En el plano afectivo y emocional, la dimension...

```
[3]: print('Tipos de datos:')
print(df.dtypes.value_counts(), '\n')
print('Items Likert sk1-sk13 (1-5); continuas: imce, act_fisica, educm, educp;')
print('categoricas/binarias: sexo, area, vive_padre, vive_madre, madre_work.')
```

Tipos de datos:

```
int64      20
float64     3
object      1
Name: count, dtype: int64
```

```
Items Likert sk1-sk13 (1-5); continuas: imce, act_fisica, educm, educp;
categoricas/binarias: sexo, area, vive_padre, vive_madre, madre_work.
```

1.10.2 1.B Datos faltantes, descriptivas y outliers

```
[4]: na = df.isna().sum(); na = na[na > 0]
print('Valores faltantes:')
print(pd.DataFrame({'n_NA': na, 'pct': (100*na/len(df)).round(2)}).to_string(),
      '\n')
print(df[['edad', 'imce', 'act_fisica', 'educm', 'educp']].describe().round(2))
```

Valores faltantes:

	n_NA	pct
act_fisica	1435	3.4300
educm	551	1.3200

	edad	imce	act_fisica	educm	educp
count	41854.0000	41854.0000	40419.0000	41303.0000	41854.0000
mean	83.0700	1.0100	2.5500	12.9800	12.9000
std	3.9900	1.3800	1.0700	3.3700	3.4600
min	62.0000	-5.0200	1.0000	0.0000	0.0000
25%	81.0000	0.1000	2.0000	11.0000	11.0000
50%	82.0000	0.9700	2.0000	13.0000	13.0000
75%	84.0000	1.9300	3.0000	15.0000	14.0000
max	107.0000	5.0400	5.0000	22.0000	22.0000

```
[5]: fig, ax = plt.subplots(1, 3, figsize=(14, 3.5))
df['imce'].hist(bins=50, ax=ax[0]); ax[0].set_title('IMCE (z-score)')
```

```
df['act_fisica'].value_counts().sort_index().plot.bar(ax=ax[1]); ax[1].
    ↪set_title('Actividad fisica')
df['madre_work'].value_counts().sort_index().plot.bar(ax=ax[2]); ax[2].
    ↪set_title('madre_work')
plt.tight_layout(); plt.show()

# Outliers de IMCE (|z|>3)
out = (df['imce'].abs() > 3).sum()
print(f'IMCE fuera de |z|>3: {out} ({100*out/len(df):.2f}%) - puntajes z_
    ↪clínicamente válidos, se conservan.')
```



IMCE fuera de $|z|>3$: 3356 (8.02%) - puntajes z clínicamente válidos, se conservan.

1.10.3 1.C Limpieza y recodificación

```
[6]: df_clean = df.copy()

# 1. Imputacion por mediana
for col in ['act_fisica', 'educm']:
    df_clean[col] = df_clean[col].fillna(df_clean[col].median())

# 2. Colapsar codigo 2 ("mas de un padre/madre") a presencia = 1
for col in ['vive_padre', 'vive_madre']:
    df_clean[col] = df_clean[col].replace({2: 1})

# 3. Reexpresion en sentido POSITIVO (mayor = conducta mas deseable).
# sk1-sk6, sk8-sk13 estan codificadas 1:siempre -> 5:nunca para conductas
# DESEABLES, por lo que se invierten con (6 - x) para que alto = mejor.
# sk7 (agresivo) esta en sentido inverso (1:nunca -> 5:siempre) para una
# conducta NO deseable; ahi alto valor crudo ya = mas agresion = peor, por
# lo que NO se invierte: se deja crudo para que alto siga significando
# "mas agresivo". Asi las 13 variables quedan en escala homogenea solo si se
# interpreta sk7 como el unico item de polaridad negativa. Como sk7 resulta
# no informativo (ver P2), esta distincion no afecta el EFA/CFA, pero se deja
# explicita por correccion metodologica.
```

```

items_deseables = [c for c in sk_cols if c != 'sk7']
sk_pos = df_clean[sk_cols].astype(float).copy()
sk_pos[items_deseables] = 6 - sk_pos[items_deseables]
# sk7 se mantiene crudo (alto = mas agresivo). Queda como item de polaridad
# opuesta; el EFA lo identificara como no informativo.

print('NA tras imputacion:', int(df_clean[['act_fisica', 'educm']].isna().sum().
    ↳sum()))
print('vive_padre:', df_clean['vive_padre'].value_counts().to_dict())
sk_pos.head(3)

```

NA tras imputacion: 0
vive_padre: {1: 30121, 0: 11733}

```

[6]:      sk1    sk2    sk3    sk4    sk5    sk6    sk7    sk8    sk9    sk10  \
0  5.0000  5.0000  5.0000  4.0000  5.0000  4.0000  2.0000  5.0000  4.0000  4.0000
1  5.0000  5.0000  5.0000  5.0000  5.0000  5.0000  4.0000  5.0000  5.0000  5.0000
2  4.0000  4.0000  3.0000  4.0000  5.0000  4.0000  3.0000  4.0000  4.0000  3.0000

      sk11    sk12    sk13
0  4.0000  3.0000  4.0000
1  5.0000  5.0000  5.0000
2  4.0000  5.0000  3.0000

```

1.11 Pregunta 2 — Análisis Factorial Exploratorio (EFA)

1.11.1 2.A Adecuación: KMO y Bartlett

```

[7]: kmo_all, kmo_model = calculate_kmo(sk_pos)
chi2_b, p_b = calculate_bartlett_sphericity(sk_pos)
print(f'KMO global = {kmo_model:.3f} (>0.8 = meritorio)')
print(f'Bartlett: chi2 = {chi2_b:,.1f}, p = {p_b:.2e}')

```

KMO global = 0.873 (>0.8 = meritorio)
Bartlett: chi2 = 122,116.7, p = 0.00e+00

1.11.2 2.B Número óptimo de factores (Kaiser + scree)

```


[8]: fa_full = FactorAnalyzer(rotation=None, n_factors=len(sk_cols))
fa_full.fit(sk_pos)
ev, _ = fa_full.get_eigenvalues()
n_factors = int((ev > 1).sum())
print('Autovalores:', np.round(ev, 3))
print(f'Factores con autovalor > 1 (Kaiser): {n_factors}')

plt.figure(figsize=(8, 3.5))
plt.plot(range(1, len(ev)+1), ev, 'o-')

```

```
plt.axhline(1, color='r', ls='--', label='Kaiser')
plt.xlabel('Factor'); plt.ylabel('Autovalor'); plt.title('Scree plot'); plt.
    legend()
plt.tight_layout(); plt.show()
```

Autovalores: [4.154 1.337 1.099 0.999 0.772 0.701 0.692 0.684 0.597 0.516 0.506
0.487
0.456]
Factores con autovalor > 1 (Kaiser): 3



1.11.3 2.C Loadings rotados (promax) y variable no informativa

```
[9]: fa = FactorAnalyzer(rotation='promax', n_factors=n_factors)
fa.fit(sk_pos)
loadings = pd.DataFrame(fa.loadings_, index=sk_cols,
                        columns=[f'F{i+1}' for i in range(n_factors)])
comm = pd.Series(fa.get_communalities(), index=sk_cols, name='comunalidad')
print('Factor loadings (promax):'); print(loadings.round(2), '\n')
print('Comunalidades:'); print(comm.round(3).to_string())
print(f'\n>>> Variable NO informativa: sk7 (comunalidad={comm["sk7"]:.3f}, '
      f'cargas <= {loadings.loc["sk7"].abs().max():.2f})')
```

Factor loadings (promax):

	F1	F2	F3
sk1	0.0200	0.6200	-0.0400
sk2	-0.0400	0.5100	0.2300
sk3	0.0200	0.6700	-0.0500
sk4	-0.0000	0.7500	-0.0300
sk5	-0.1600	-0.0200	0.8800
sk6	0.0100	0.0500	0.5200
sk7	-0.0200	-0.0300	-0.1400


```

sk8    0.1500 -0.1100  0.5200
sk9    0.5000  0.0900  0.0600
sk10   0.6200 -0.0300 -0.0300
sk11   0.7000  0.0400  0.0100
sk12   0.5800 -0.0300 -0.0000
sk13   0.5400  0.0200 -0.0200

```

Comunalidades:

```

sk1     0.3820
sk2     0.3110
sk3     0.4460
sk4     0.5640
sk5     0.7970
sk6     0.2730
sk7     0.0200
sk8     0.3030
sk9     0.2560
sk10    0.3920
sk11    0.4870
sk12    0.3370
sk13    0.2940

```

```
>>> Variable NO informativa: sk7 (comunalidad=0.020, cargas <= 0.14)
```

```
[10]: print('Asignacion de items por carga dominante (|loading|>0.4):\n')
      for f in loadings.columns:
          print(f'  {f}: {loadings.index[(loadings[f].abs() > 0.4)].tolist()}')
```

Asignacion de items por carga dominante (|loading|>0.4):

```

F1: ['sk9', 'sk10', 'sk11', 'sk12', 'sk13']
F2: ['sk1', 'sk2', 'sk3', 'sk4']
F3: ['sk5', 'sk6', 'sk8']

```

1.12 Pregunta 3 — Análisis Factorial Confirmatorio (CFA)

Estructura simple sobre los 12 ítems informativos. Se excluye sk7 por su comunalidad nula en el EFA (no comparte varianza con ningún factor).

```
[11]: model_desc = '''
      Afectivo  =~ sk1 + sk2 + sk3 + sk4
      Social    =~ sk5 + sk6 + sk8
      Cognitivo =~ sk9 + sk10 + sk11 + sk12 + sk13
      '''
      cfa = semopy.Model(model_desc)
      cfa.fit(sk_pos)
      stats = semopy.calc_stats(cfa)
```

```
print('Indices de ajuste:')
print(stats[['chi2', 'DoF', 'CFI', 'TLI', 'RMSEA']].round(3).
↳to_string(index=False))
```

Indices de ajuste:

	chi2	DoF	CFI	TLI	RMSEA
	6148.0960	51	0.9490	0.9340	0.0530

1.12.1 3.A Importancia de cada medida (cargas estandarizadas)

```
[12]: fac = ['Afectivo', 'Social', 'Cognitivo']
ins = cfa.inspect(std_est=True)
# En esta version de semopy las cargas factoriales usan el operador '~'
# (item ~ factor), con el factor latente en la columna rval.
loads = ins[(ins['op'] == '~') & (ins['rval'].isin(fac))][['rval', 'lval', 'Est.
↳ Std', 'p-value']]
loads.columns = ['Factor', 'Item', 'Carga_std', 'p_value']
loads['Carga_std'] = loads['Carga_std'].astype(float).round(3)
print('Importancia de cada item a su factor (cargas estandarizadas):\n')
print(loads.sort_values(['Factor', 'Carga_std'], ascending=[True, False]).
↳to_string(index=False))
```

Importancia de cada item a su factor (cargas estandarizadas):

	Factor	Item	Carga_std	p_value
	Afectivo	sk4	0.7150	0.0000
	Afectivo	sk2	0.6520	0.0000
	Afectivo	sk3	0.6460	0.0000
	Afectivo	sk1	0.6000	-
	Cognitivo	sk11	0.7360	0.0000
	Cognitivo	sk9	0.6080	-
	Cognitivo	sk10	0.5650	0.0000
	Cognitivo	sk12	0.5510	0.0000
	Cognitivo	sk13	0.5230	0.0000
	Social	sk5	0.7230	-
	Social	sk6	0.5720	0.0000
	Social	sk8	0.5590	0.0000

1.12.2 3.B Correlación entre factores

```
[13]: fac = ['Afectivo', 'Social', 'Cognitivo']
covs = ins[(ins['op'] == '~') & (ins['lval'] != ins['rval'])]
covs = covs[covs['lval'].isin(fac) & covs['rval'].isin(fac)]
print(covs[['lval', 'rval', 'Est. Std']].round(3).to_string(index=False))
```

	lval	rval	Est. Std
Cognitivo	Afectivo		0.6120
	Social	Afectivo	0.6580
	Social	Cognitivo	0.5960

1.12.3 3.C Predicciones (scores factoriales) — se guardan para P4–P7

```
[14]: factor_scores = cfa.predict_factors(sk_pos)[fac]
factor_scores.columns = ['Afectivo', 'Social', 'Cognitivo']
factor_scores.to_csv('cfa_factor_scores.csv', index=False)
print('Scores guardados en cfa_factor_scores.csv')
print(factor_scores.describe().round(3))
```

Scores guardados en cfa_factor_scores.csv

	Afectivo	Social	Cognitivo
count	41854.0000	41854.0000	41854.0000
mean	-0.0000	-0.0000	-0.0000
std	0.2140	0.3560	0.3670
min	-2.0200	-3.0010	-2.7670
25%	-0.0660	-0.1510	-0.1790
50%	0.0840	0.1260	0.1120
75%	0.1450	0.2690	0.2750
max	0.1600	0.3080	0.3530

1.13 Pregunta 4 — Random Forest (target madre_work binario)

Siguiendo el enunciado, se excluye la categoría minoritaria 0 (desempleada), dejando un problema binario: labor doméstica (-1) vs empleada (1).

```
[15]: # Excluir desempleadas (clase 0) -> problema binario
keep = df_clean['madre_work'] != 0
X = factor_scores.loc[keep, ['Afectivo', 'Social', 'Cognitivo']].values
y = (df_clean.loc[keep, 'madre_work'] == 1).astype(int).values # 1=empleada, 0=labor domestica

cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=RANDOM_STATE)
print(f'Observaciones tras excluir desempleadas: {len(y):,}')
print('Distribucion del target binario:', {'-1 (dom.)': int((y==0).sum()), '1 (empleada)': int((y==1).sum())})
print(f'Baseline mayoritario: {pd.Series(y).value_counts(normalize=True).max():.4f}')
```

Observaciones tras excluir desempleadas: 37,545

Distribucion del target binario: {'-1 (dom.)': 17026, '1 (empleada)': 20519}

Baseline mayoritario: 0.5465

```
[16]: rf_pipe = Pipeline([('rf', RandomForestClassifier(random_state=RANDOM_STATE,
    n_jobs=-1,
    class_weight='balanced'))])

rf_grid = {
    'rf__n_estimators': [200, 400],
    'rf__max_depth': [None, 6, 10],
```

```

    'rf__min_samples_leaf': [1, 5, 20],
}
rf_search = GridSearchCV(rf_pipe, rf_grid, cv=cv, scoring='f1_macro', n_jobs=-1)
t0 = time.time(); rf_search.fit(X, y); t_rf = time.time() - t0
print(f'Mejores hiperparametros: {rf_search.best_params_}')
print(f'Mejor macro-F1 (CV): {rf_search.best_score_:.4f} | tiempo: {t_rf:.4f}s')

```

Mejores hiperparametros: {'rf__max_depth': None, 'rf__min_samples_leaf': 20, 'rf__n_estimators': 200}
Mejor macro-F1 (CV): 0.5120 | tiempo: 143.8s

```

[17]: best_rf = rf_search.best_estimator_
res = cross_validate(best_rf, X, y, cv=cv, scoring=['accuracy', 'f1_macro'], n_jobs=-1)
acc_rf, f1_rf = res['test_accuracy'].mean(), res['test_f1_macro'].mean()
print(f'Random Forest -> accuracy={acc_rf:.4f} macro-F1={f1_rf:.4f}')
print(f'Baseline: {pd.Series(y).value_counts(normalize=True).max():.4f}\n')

y_pred = cross_val_predict(best_rf, X, y, cv=cv, n_jobs=-1)
print('Matriz de confusion (0=dom., 1=empleada):')
print(pd.DataFrame(confusion_matrix(y, y_pred),
                    index=['real_dom', 'real_emp'], columns=['pred_dom', 'pred_emp']))

```

Random Forest -> accuracy=0.5200 macro-F1=0.5120
Baseline: 0.5465

Matriz de confusion (0=dom., 1=empleada):

	pred_dom	pred_emp
real_dom	7607	9419
real_emp	8602	11917

1.14 Pregunta 5 — XGBoost vs SVM vs Stacking

Mismo target binario y protocolo de CV. Se comparan los tres modelos contra el RF de la P4, con matriz de confusión y **tiempo de cómputo**.

```

[18]: def evaluate(name, estimator, X, y, cv):
    t0 = time.time()
    r = cross_validate(estimator, X, y, cv=cv, scoring=['accuracy', 'f1_macro'], n_jobs=-1)
    return {'modelo': name, 'accuracy': r['test_accuracy'].mean(),
            'macro_F1': r['test_f1_macro'].mean(), 'tiempo_s': time.time() - t0}

```

1.14.1 5.A XGBoost — optimización de hiperparámetros

```
[19]: xgb_search = GridSearchCV(
        XGBClassifier(tree_method='hist', random_state=RANDOM_STATE, verbosity=0,
        ↪eval_metric='logloss'),
        {'n_estimators': [200, 400], 'max_depth': [3, 5, 7], 'learning_rate': [0.
        ↪05, 0.1, 0.2]},
        cv=cv, scoring='f1_macro', n_jobs=-1)
t0 = time.time(); xgb_search.fit(X, y); t_xgb = time.time() - t0
xgb = xgb_search.best_estimator_
print(f'XGBoost - mejores: {xgb_search.best_params_}')
print(f'macro-F1 CV: {xgb_search.best_score_:.4f} | tiempo: {t_xgb:.1f}s')
```

XGBoost - mejores: {'learning_rate': 0.2, 'max_depth': 7, 'n_estimators': 400}
macro-F1 CV: 0.4891 | tiempo: 15.2s

1.14.2 5.B SVM (RBF) — optimización de hiperparámetros

```
[20]: svm_search = GridSearchCV(
        Pipeline([('sc', StandardScaler()),
        ('svc', SVC(kernel='rbf', class_weight='balanced',
        ↪cache_size=1000))]),
        {'svc__C': [0.1, 1.0, 10.0], 'svc__gamma': ['scale', 0.1]},
        cv=cv, scoring='f1_macro', n_jobs=-1)
t0 = time.time(); svm_search.fit(X, y); t_svm = time.time() - t0
svm = svm_search.best_estimator_
print(f'SVM - mejores: {svm_search.best_params_}')
print(f'macro-F1 CV: {svm_search.best_score_:.4f} | tiempo: {t_svm:.1f}s')
```

SVM - mejores: {'svc__C': 1.0, 'svc__gamma': 0.1}
macro-F1 CV: 0.4978 | tiempo: 675.8s

1.14.3 5.C Stacking (RF + XGBoost + SVM → meta-modelo logístico)

```
[21]: stack = StackingClassifier(
        estimators=[('rf', best_rf.named_steps['rf']), ('xgb', xgb), ('svm', svm)],
        final_estimator=LogisticRegression(max_iter=1000, class_weight='balanced'),
        cv=cv, n_jobs=-1)
```

1.14.4 5.D Comparación: desempeño y eficiencia

```
[22]: rows = [{'modelo': 'RandomForest', 'accuracy': acc_rf, 'macro_F1': f1_rf,
        ↪'tiempo_s': t_rf}]
for name, est in [('XGBoost', xgb), ('SVM (RBF)', svm), ('Stacking', stack)]:
    rows.append(evaluate(name, est, X, y, cv))
comp = pd.DataFrame(rows).set_index('modelo')
print(comp.round(4).to_string())
```

	accuracy	macro_F1	tiempo_s
modelo			
RandomForest	0.5200	0.5120	143.8224
XGBoost	0.5328	0.4891	1.4242
SVM (RBF)	0.5390	0.4978	105.2792
Stacking	0.5281	0.5146	476.1763

1.14.5 5.E Matrices de confusión

```
[23]: def matriz_conf(est, X, y, titulo):
    pred = cross_val_predict(est, X, y, cv=cv, n_jobs=-1)
    print(f'\n=== {titulo} ===')
    print(pd.DataFrame(confusion_matrix(y, pred),
                        index=['real_dom', 'real_emp'], columns=['pred_dom',
                        ↪ 'pred_emp']))
    print(classification_report(y, pred, target_names=['dom.(-1)',
    ↪ 'empleada(1)']))

matriz_conf(xgb, X, y, 'XGBoost')
matriz_conf(svm, X, y, 'SVM (RBF)')
matriz_conf(stack, X, y, 'Stacking')
```

=== XGBoost ===

	pred_dom	pred_emp			
real_dom	4516	12510			
real_emp	5031	15488			
	precision	recall	f1-score	support	
dom.(-1)	0.47	0.27	0.34	17026	
empleada(1)	0.55	0.75	0.64	20519	
accuracy			0.53	37545	
macro avg	0.51	0.51	0.49	37545	
weighted avg	0.52	0.53	0.50	37545	

=== SVM (RBF) ===

	pred_dom	pred_emp			
real_dom	4751	12275			
real_emp	5032	15487			
	precision	recall	f1-score	support	
dom.(-1)	0.49	0.28	0.35	17026	
empleada(1)	0.56	0.75	0.64	20519	
accuracy			0.54	37545	
macro avg	0.52	0.52	0.50	37545	

weighted avg	0.53	0.54	0.51	37545
--------------	------	------	------	-------

=== Stacking ===

	pred_dom	pred_emp		
real_dom	6784	10242		
real_emp	7476	13043		
	precision	recall	f1-score	support
dom.(-1)	0.48	0.40	0.43	17026
empleada(1)	0.56	0.64	0.60	20519
accuracy			0.53	37545
macro avg	0.52	0.52	0.51	37545
weighted avg	0.52	0.53	0.52	37545

Discusión. Con el target binario los modelos quedan próximos al baseline (~0.55 de accuracy) y un macro-F1 más alto que en un planteamiento de 3 clases (al estar más balanceado). En eficiencia, XGBoost es el más rápido; el SVM-RBF y el Stacking son sustancialmente más costosos (el SVM escala $\sim O(n^2)$). La señal de los tres scores factoriales sobre el empleo materno sigue siendo limitada: el cuello de botella es la información disponible, no el algoritmo.

1.15 Pregunta 6 — Clustering (imce $\times$ act_fisica)

```
[24]: clu_data = df_clean[['imce', 'act_fisica']].copy()
      clu_scaled = StandardScaler().fit_transform(clu_data)
      sample_idx = np.random.RandomState(RANDOM_STATE).choice(len(clu_scaled),
                                                                min(5000,
                                                                len(clu_scaled)), replace=False)
      print('Silhouette por numero de clusters:')
      for kk in [2, 3, 4, 5]:
          km = KMeans(n_clusters=kk, random_state=RANDOM_STATE, n_init=10).
          fit(clu_scaled)
          print(f' k={kk}: {silhouette_score(clu_scaled[sample_idx], km.
          labels_[sample_idx]):.3f}')
```

Silhouette por numero de clusters:

```
k=2: 0.344
k=3: 0.376
k=4: 0.379
k=5: 0.370
```

```
[25]: k_opt = 3
      km = KMeans(n_clusters=k_opt, random_state=RANDOM_STATE, n_init=10).
          fit(clu_scaled)
      df_clean['cluster'] = km.labels_
```


```

resumen = df_clean.groupby('cluster')[['imce', 'act_fisica']].mean()
resumen['n'] = df_clean['cluster'].value_counts().sort_index()
print(resumen.round(3).to_string())

plt.figure(figsize=(7, 5))
sns.scatterplot(x=df_clean['imce'], y=df_clean['act_fisica'],
                hue=df_clean['cluster'], palette='Set1', s=10, alpha=0.4)
plt.title('Clusters K-Means (IMCE vs actividad fisica)')
plt.tight_layout(); plt.show()

```

	imce	act_fisica	n
cluster			
0	0.0030	2.2320	19595
1	2.2170	2.2390	17026
2	0.8860	4.6240	5233



Conclusión. El silhouette es máximo en $k = 4$ (0.379) pero apenas supera a $k = 3$ (0.376), por lo que se opta por **3 clusters** (más parsimonioso e interpretable). Los grupos se separan principalmente por **IMCE**, con la **actividad física** aislando al grupo activo:

- **Cluster 0** ($n = 19.595$): IMCE normal (0.00) y actividad baja (2.2). Grupo modal.
- **Cluster 1** ($n = 17.026$): **IMCE alto** (2.22) y actividad baja (2.2). Perfil de **riesgo** (sobrepeso con poca actividad).

- **Cluster 2** (n = 5.233): IMCE moderado (0.89) y **actividad alta** (4.6). Estudiantes activos.

El patrón es coherente con la evidencia en salud: el subgrupo con mayor IMCE coincide con baja actividad física, mientras que los más activos no alcanzan los IMCE extremos. La actividad física, aunque secundaria en la partición, es lo que diferencia al cluster 2 del resto a IMCE comparable.

1.16 Pregunta 7 — Mejor modelo de P5 sobre el grupo de mayor IMCE

Se elige el cluster de mayor IMCE promedio y se reestima el **mejor modelo de la P5** (por macro-F1) sobre ese subgrupo, con el mismo target binario.

```
[26]: high_imce_cluster = resumen['imce'].idxmax()
print(f'Cluster de mayor IMCE: {high_imce_cluster} (IMCE={resumen.
      ↪loc[high_imce_cluster,"imce"]:.3f})')

# Subgrupo, manteniendo la exclusion de desempleadas (target binario)
mask_sub = (df_clean['cluster'] == high_imce_cluster) & (df_clean['madre_work']_
      ↪!= 0)
X_sub = factor_scores.loc[mask_sub, ['Afectivo', 'Social', 'Cognitivo']].values
y_sub = (df_clean.loc[mask_sub, 'madre_work'] == 1).astype(int).values
print(f'Tamano del subgrupo: {mask_sub.sum():,}')
print('Distribucion:', {'-1': int((y_sub==0).sum()), '1': int((y_sub==1).
      ↪sum())})

best_p5_name = comp.loc[['XGBoost', 'SVM (RBF)', 'Stacking']]['macro_F1'].
      ↪idxmax()
print(f'Mejor modelo de la P5 (por macro-F1): {best_p5_name}')
```

Cluster de mayor IMCE: 1 (IMCE=2.217)

Tamano del subgrupo: 15,225

Distribucion: {'-1': 6725, '1': 8500}

Mejor modelo de la P5 (por macro-F1): Stacking

```
[27]: cv_sub = StratifiedKFold(n_splits=5, shuffle=True, random_state=RANDOM_STATE)
if best_p5_name == 'XGBoost':
    best_model = GridSearchCV(
        XGBClassifier(tree_method='hist', random_state=RANDOM_STATE,
      ↪verbosity=0, eval_metric='logloss'),
        {'n_estimators': [200, 400], 'max_depth': [3, 5, 7], 'learning_rate':_
      ↪[0.05, 0.1, 0.2]},
        cv=cv_sub, scoring='f1_macro', n_jobs=-1)
elif best_p5_name == 'SVM (RBF)':
    best_model = GridSearchCV(
        Pipeline([('sc', StandardScaler()),
      ↪('svc', SVC(kernel='rbf', class_weight='balanced',
      ↪cache_size=1000))]),
```

```

        {'svc__C': [0.1, 1.0, 10.0], 'svc__gamma': ['scale', 0.1]},
        cv=cv_sub, scoring='f1_macro', n_jobs=-1)
else:
    best_model = stack

res_sub = cross_validate(best_model, X_sub, y_sub, cv=cv_sub,
                        scoring=['accuracy', 'f1_macro'], n_jobs=-1)
print(f'{best_p5_name} sobre cluster de mayor IMCE:')
print(f'  accuracy = {res_sub["test_accuracy"].mean():.4f}')
print(f'  macro-F1 = {res_sub["test_f1_macro"].mean():.4f}')
print(f'  baseline = {pd.Series(y_sub).value_counts(normalize=True).max():.4f}')

```

Stacking sobre cluster de mayor IMCE:

```

accuracy = 0.5373
macro-F1 = 0.5137
baseline = 0.5583

```

Conclusión. Sobre el cluster de mayor IMCE (15.225 obs.), el mejor modelo de la P5 (**Stacking**) da accuracy 0.537 y macro-F1 0.514, por debajo del baseline del subgrupo (0.558) y en línea con la muestra completa. Restringir al subgrupo de riesgo **no** revela una relación latente: la débil asociación entre habilidades socioemocionales y empleo materno es **robusta** y no un artefacto de mezclar subpoblaciones con distinto IMC.

1.17 Pregunta 8 — Clasificación de texto (SVC) siguiendo Sentiment_Analysis.ipynb

Se replica el flujo del notebook de referencia: **función de tokenización** (regex + stopwords español de NLTK), **CountVectorizer** y un **SVC**, sobre el target binario y **excluyendo las variables sk**, para contrastar con la P5.

1.17.1 8.A Función de tokenización (adaptada del notebook de referencia)

```

[28]: stops_es = set(stopwords.words('spanish'))

def text_to_words(texto):
    '''Limpieza + tokenización al estilo de Sentiment_Analysis.ipynb.'''
    letters_only = re.sub(r'#[A-Za-z-À-ÿ]+', ' ', str(texto))
    words = letters_only.lower().split()
    meaningful = [w for w in words if w not in stops_es]
    return ' '.join(meaningful)

# Se trabaja con las mismas observaciones del problema binario (excluye_
↳ desempleadas)
data_txt = df_clean.loc[keep].copy()
data_txt['clean_text'] = data_txt[TEXT_COL].apply(text_to_words)
y_txt = (data_txt['madre_work'] == 1).astype(int).values
print('Ejemplo de texto tokenizado:')

```

```
print(data_txt['clean_text'].iloc[0][:200])
```

Ejemplo de texto tokenizado:

plano afectivo emocional, dimension encuentra desarrollada, manifestandose manera constante: muestra afecto hacia padres siempre, hacia pares siempre, expresa sentimientos siempre recurre casi siempre

1.17.2 8.B Vectorización (CountVectorizer) y split 80/20

```
[29]: x_train, x_test, y_train, y_test = train_test_split(
        data_txt['clean_text'], y_txt, test_size=0.2, random_state=RANDOM_STATE,
        ↪stratify=y_txt)

# Funcion de tokenizacion del notebook de referencia + vocabulario ampliado
# para obtener un clasificador adecuado (el enunciado pide "un modelo
  ↪adecuado").
vect = CountVectorizer(ngram_range=(1, 2), min_df=5, max_features=300)
vect.fit(x_train)
x_train_dtm = vect.transform(x_train)
x_test_dtm = vect.transform(x_test)
print(f'Vocabulario: {len(vect.get_feature_names_out())} features')
print(f'Train: {x_train_dtm.shape} Test: {x_test_dtm.shape}')
```

Vocabulario: 300 features

Train: (30036, 300) Test: (7509, 300)

1.17.3 8.C Modelo SVM lineal (LinearSVC) y evaluación


```
[30]: from sklearn.svm import LinearSVC
model = LinearSVC(random_state=10, class_weight='balanced', max_iter=5000)
t0 = time.time(); model.fit(x_train_dtm, y_train); t_txt = time.time() - t0
pred = model.predict(x_test_dtm)

acc_txt = accuracy_score(y_test, pred)
print(f'SVC (texto) - accuracy = {acc_txt:.4f} | tiempo: {t_txt:.1f}s')
print(f'Baseline: {pd.Series(y_test).value_counts(normalize=True).max():.4f}\n')

cm = confusion_matrix(y_test, pred)
plt.figure(figsize=(6, 4))
sns.heatmap(pd.DataFrame(cm, index=['Actual:dom', 'Actual:emp'],
                          columns=['Pred:dom', 'Pred:emp']),
            annot=True, fmt='d', cmap='Blues', cbar=False)
plt.title('SVC sobre texto - matriz de confusion'); plt.tight_layout(); plt.
  ↪show()

print(classification_report(y_test, pred, target_names=['dom.(-1)',
  ↪empleada(1)]))
```

SVC (texto) - accuracy = 0.5415 | tiempo: 7.2s
 Baseline: 0.5465



	precision	recall	f1-score	support
dom.(-1)	0.49	0.53	0.51	3405
empleada(1)	0.59	0.55	0.57	4104
accuracy			0.54	7509
macro avg	0.54	0.54	0.54	7509
weighted avg	0.54	0.54	0.54	7509

1.17.4 8.D Coeficientes del SVC lineal (palabras más informativas)

```
[31]: dfout = pd.DataFrame(vect.get_feature_names_out(), columns=['feature'])
dfout['coef'] = model.coef_[0] # LinearSVC: coef_ ya es denso
dfout = dfout.sort_values('coef', ascending=False)
print('Tokens con mayor peso hacia "empleada" (coef alto) y "dom." (coef bajo):
      ↪')
print(pd.concat([dfout.head(8), dfout.tail(8)]).to_string(index=False))
```

Tokens con mayor peso hacia "empleada" (coef alto) y "dom." (coef bajo):

feature	coef
---------	------

```

    constante hace 0.1795
    ambito desarrollada 0.1795
    ambito bien 0.1744
    frecuente hace 0.1744
    pares aspecto 0.1475
    vez juega 0.1369
    entorno rara 0.1369
    ambito proceso 0.1254
    frecuentes muestra -0.1484
    encuentra incipiente -0.1484
    encuentra proceso -0.2154
    intermitente muestra -0.2154
    encuentra desarrollada -0.2807
    constante muestra -0.2807
    frecuente muestra -0.2854
    encuentra bien -0.2854

```

1.17.5 8.E Contraste con la Pregunta 5

```

[32]: print('Contraste P8 (texto, SVC) vs P5 (scores CFA):')
print(f' SVC sobre TEXT0 (P8): accuracy = {acc_txt:.4f}')
print(f' SVM (RBF) sobre scores (P5): accuracy = {comp.loc["SVM_
↳(RBF)","accuracy"]:.4f} '
      f'macro-F1 = {comp.loc["SVM (RBF)","macro_F1"]:.4f}')
print(f' Mejor modelo P5 ({best_p5_name}): accuracy = {comp.
↳loc[best_p5_name,"accuracy"]:.4f}')
print(f' Baseline: {pd.Series(y_txt).value_counts(normalize=True).max():.4f}')

```

```

Contraste P8 (texto, SVC) vs P5 (scores CFA):
SVC sobre TEXT0 (P8): accuracy = 0.5415
SVM (RBF) sobre scores (P5): accuracy = 0.5390 macro-F1 = 0.4978
Mejor modelo P5 (Stacking): accuracy = 0.5281
Baseline: 0.5465

```

Discusión. El SVM lineal sobre la narrativa tokenizada da accuracy 0.541, casi igual al baseline (0.547) y al mejor modelo de la P5 (SVM-RBF 0.539, Stacking 0.528). Con 300 términos el modelo **sí discrimina** (precision/recall equilibrados, macro-F1 0.54) y permite interpretar coeficientes: bigramas como “constante hace” o “ambito desarrollada” empujan hacia *empleada*, mientras que “frecuente muestra” o “encuentra bien” empujan hacia *labor doméstica*. Aun así, el desempeño confirma el hallazgo de la P5: la narrativa es una **paráfrasis determinista** de los ítems sk1–sk13 y no añade señal nueva sobre *madre_work*. El valor es metodológico: implementa el flujo de NLP de referencia (tokenización, CountVectorizer, SVM lineal, matriz de confusión, coeficientes) y lo contrasta con los modelos tabulares de la P5.